可靠性评估方法课程讲义

1 初识可靠性评估

首先，我们再来回顾一下可靠性的定义。可靠性是指产品在规定的时间和规定的条件下完成规定的功能的能力[1]。既然可靠性是一种能力，那我们如何描述能力的高低呢？

在这里，我们拿百米短跑来举一例。苏炳添是我国著名的短跑运动员。在描述他的短跑能力时，我们可以有以下两种表述：

(1) 苏炳百米跑得特别快；

(2) 苏炳添百米最好成绩是9"83。

通过分析这两种表述，我们可以得出第一种表述是一种定性评价，而第二种表述则是一种定量评估。在第二种表述中，通过“百米最好成绩”这一指标给出了苏炳添百米竞速能力的量化评估是9"83。我们要想对可靠性这一能力进行定量评估，也需要有合适的量化指标。那评估可靠性水平高低的指标有哪些呢？在目前的可靠性工程实践中，形成了以可靠度为核心的指标体系。

1.1 以可靠度为核心的指标体系

1.1.1 可靠度

从概念上看，可靠度是裕量大于 0 的机会。

可靠度函数的表达式为：

$$R\left(\boldsymbol{X},\boldsymbol{Y},t,\vec{t},P_{\mathrm{th}}\right)=\mathrm{Ch}\left\{\tilde{M}\left(\boldsymbol{X},\boldsymbol{Y},t,\vec{t},P_{\mathrm{th}}\right)>0\right\}$$

式中，R 表示可靠度，$\boldsymbol{X}$ 表示内因变量，$\boldsymbol{Y}$ 表示外因变量，t 表示牛顿时间、$\vec{t}$ 表示退化时间，P_{th} 表示性能阈值，Ch 表示机会测度，$\tilde{M}$ 表示裕量。

根据所含要素的不同，可靠度函数可以分为：单要素可靠度、多要素可靠度和全要素可靠度三类。下面以一个单要素可靠度函数为例，说明可靠性评估就是确定可靠度函数的值的过程。

在上面这个案例中，我们要想凭借以退化时间为变量的单要素可靠度函数进行可靠性评估，实际上只需要确定该可靠度函数中各参数的取值（如该例中的$\lambda=1.9\times10^{-5}$/天），然后将变量$\vec{t}=90$带入可靠度函数，即可得到可靠度函数的值

案例．可靠度计算

设有单要素可靠度函数$R(\vec{t}) = \exp(-\lambda\vec{t})$. 若已知$\lambda = 1.9 \times 10^{-5}$/天，试求$\vec{t}$=90 天时，可靠度为多少？

$$R(90) = \exp(-1.9 \times 10^{-5} \times 90) = 0.9982.$$

0.9982。其可靠性评估的结论为：该产品在 90 天时可靠度为 0.9982。

1.1.2 可靠寿命

单要素可靠度函数$R(\vec{t})$描述了产品在$\vec{t}$时刻裕量仍大于 0 的机会是多少。那相应地，为了描述在产品裕量大于 0 的机会在α以上，产品可以工作多长时间，我们引入了可靠寿命的概念。

定义（可靠寿命）：设系统寿命为T，系统的可靠度函数为$R(\vec{t})$，令α为一个(0,1)区间内的实数，则系统的可靠寿命为:

$$T(\alpha) = \sup\{\vec{t} | R(\vec{t}) \geq \alpha\}.$$

案例．可靠寿命$B10$

系统的$B10$寿命定义为：

$$t_{B10} = T(0.9) = \sup\{\vec{t} | R(\vec{t}) \geq 0.9\}.$$

它意味着系统有 0.9 的可能性工作到t_{B10}这个时间。

1.1.3 平均故障前时间

平均故障前时间（Mean Time to Failure，MTTF）是不可修产品的可靠性指标。其定义如下：

设系统寿命为T，系统的可靠度函数为$R(\vec{t})$，则系统的 MTTF 为：

$$\mathrm{MTTF} = E[T] = \int_0^{+\infty} R(\vec{t})\mathrm{d}\vec{t}.$$

对于像灯泡、晶体管等这类的不可修产品，MTTF 即为其平均寿命。

1.1.4 平均故障间隔时间

平均故障间隔时间（Mean Time between Failure，MTBF）是可修产品的可靠性指标。其基本定义如下：

一个可修产品在使用中发生了N_0次故障，每次故障修复后又重新投入使用，测得其每次工作持续时间为$t_1, t_2, \cdots, t_{N_0}$. 则平均故障间隔时间为

$$\mathrm{MTBF} = \frac{1}{N_0}\sum_{i=1}^{N_0} t_i$$

对于完全修复的产品，因其修复的状态和新产品一样，一个产品发生了N_0次故障等同于N_0个新产品工作到首次故障，此时：

$$\mathrm{MTBF} = \mathrm{MTTF} = \int_0^{+\infty} R(\vec{t})\,\mathrm{d}\vec{t}\,.$$

1.1.5 指标间的转化关系

可靠度函数、可靠寿命和平均故障前时间三个指标间的转换关系如下图所示。

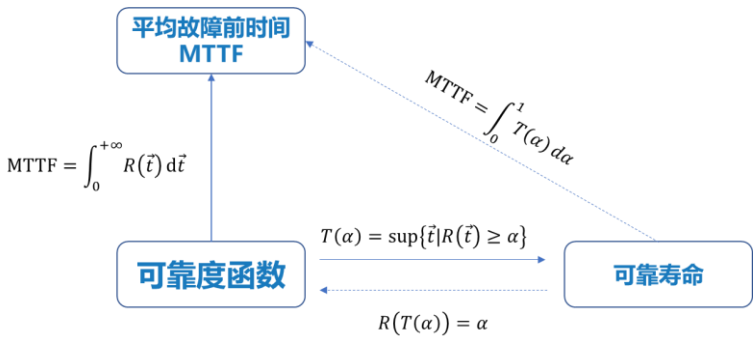

图 1　以可靠度为核心的指标体系

作业：

试推导图 1 中概率测度与不确定测度下可靠寿命到可靠度函数之间的转换关系（即$R(T(\alpha))=\alpha$），及可靠寿命与 MTTF 之间的转换关系（即$\mathrm{MTTF} = \int_0^1 T(\alpha)\,d\alpha$）

1.1.6 拓展与思考

【生活小常识】

在乘用车领域，通常用 PP100 来表征汽车可靠性水平的高低。PP100 是指消费者在购买汽车后前 90 天内每 100 辆车遇到的问题数。PP100 越低，说明该品牌汽车在前 90 天内的故障数越少，可靠度水平越高。该指数是由美国公司 JD Power 提出，并由每年发布相应排名。JD Power 发布的 2022 中国新车质量研究结果如下图所示。

图 2　JD Power 2022 中国新车质量报告

2022 中国新车质量报告显示，中国新车的 PP100 平均值为 213 个。其中，问题增长点主要来自于设计缺陷类问题，如驾驶体验、动力总成和车身外观。

各位同学将来买车时，不妨参考一下该项报告哦~

【思考】

那 PP100 和可靠度有没有关系呢？

- “暴力”估算

设该型汽车有可靠度函数$R(\vec{t}) = \exp(-\lambda\vec{t})$. 若 PP100=219, 问 1 年后，该型汽车可靠度是多少？

$$\lambda = \frac{219}{90 \times 100} = 0.0243/\text{天}$$

$$R(365) = \exp(-0.0243 \times 365) = 0.0001$$

- “暴力”推论：

  一年以后，没出过故障的车“万里挑一”。

- “冷静”思考：

可靠度函数服从指数分布嘛？上述故障数据的统计范围是什么？

1.2 可靠性评估的基本流程

结合前面的思考，我们可以发现，可靠性评估的基本流程共分三步：第一步，收集可靠性数据；第二步，对可靠性数据进行不确定性量化；第三步，带入可靠度函数，计算可靠度。

图 3　可靠性评估的基本流程

由于第三步中的可靠度函数主要在可靠性建模中进行，因此，本节所讲可靠性评估的重点主要围绕可靠性数据收集及其不确定性量化方法展开。

2　可靠性数据及其分类

2.1 可靠性数据的定义及内涵

可靠性评估始于可靠性数据的收集。那可靠性数据是什么呢？可靠性数据是指在产品寿命周期各阶段的可靠性工作及活动中所产生的能够反应产品可靠性水平及状况的数据[2]。

通俗来讲，可靠性数据就是可靠度函数中所涉及的参数的数据。例如，如果建立的可靠度函数为单要素可靠度函数$R(\vec{t})$，那么此时所要收集的可靠性数据就是与退化时间$\vec{t}$相关的数据，即故障时间数据。类似地，如果建立可靠度函数为全要素可靠度函数$R(\boldsymbol{X},\boldsymbol{Y},t,\vec{t},P_{\mathrm{th}})$，那么相应需要收集的可靠性数据则包括了内因参数的数据、外因参数的数据、牛顿时间的数据、退化时间的数据以及性能阈值的数据等。

那收集到的可靠性数据（如故障时间数据）就可以直接用于不确定性量化及

可靠性评估吗？答案是还需要明确可靠性数据的类别，从而选择合适的不确定性量化方法并完成可靠性评估。

2.2 可靠性数据的分类

2.2.1 根据物理属性分类

如前所述，当我们需要依据多要素可靠度函数或全要素可靠度函数进行可靠性评估时，那我们收集到的可靠性数据自然而然地就可以依据其物理含义划分成不同类别，如电压、电流、温度、湿度等等。但同一物理属性的可靠性数据就适合一起用于可靠性评估吗？答案是否定的，我们还需要根据其过程属性对其进一步分类。

案例．手机电池电量数据

假设我的手机剩余电量 20%，问在不额外充电的情况下，我的手机能再使用 6 个小时的可能性是多少？

课堂上的我们手里都有手机，大家的手机型号一定不完全相同。我们每个人都能收集到我们各自手机耗电量的数据。那这些从物理属性上看来都是“耗电量”的数据，可以用于回答前面的问题吗？

2.2.2 根据过程属性分类

我们将获得可靠性数据的过程称为观测过程，即每得到一个可靠性数据称为一次观测。对可靠性数据按照过程属性进行分类，就需要知道“观测”这一过程的定义与内涵。

2.2.2.1 观测的基本概念

在定义观测前，需要明确并界定以下概念。

定义.（对象与对象空间）对象是指所关注的事物，记作O。对象的集合构成对象空间，记作Ω。

在可靠性工程中，对象随着人们关注的内容而变化，复杂至武器装备系统、复杂网络，简单至电阻、电压、电感等元器件。而对象空间，作为对象的集合，圈定了研究的具体范围。例如，在研究某型号电路系统的可靠性时，对象空间就是所有该型号的电路系统，可靠性设计、分析、验证工作均围绕此电路系统展开，可靠性评估结果也对此电路系统有意义。

定义.(状态与状态空间)状态是指对象在某个时刻某种条件下表现出来的形态，记作z。对象所有可能状态的集合构成状态空间，记作$\mathcal{Z}$。若$\mathcal{F}$为$\mathcal{Z}$的σ-代数，那么二元函数$(\mathcal{Z},\mathcal{F})$构成一个可测状态空间。

可靠性是指产品在规定的时间和规定的条件下完成规定的功能的能力。因此，在可靠性工程中，常常通过产品在对规定的时间和规定的条件的状态来判断产品能否完成规定的功能。例如，某电路系统的功能指标是在25℃输出电压大于12V。那么，对于该电路系统而言，就需要关注其在25℃的输出电压这个状态。该型电路系统在25℃条件下所有可能的输出电压构成了状态空间。

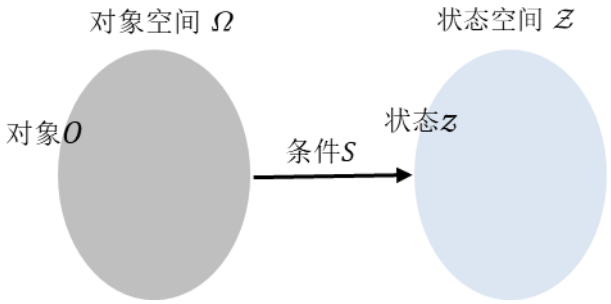

图 4　对象、对象空间、状态及状态空间

定义.（状态变量）状态变量是指从可测状态空间到实数集$\Re$的一个可测函数，记作ξ。

状态变量ξ是对状态的量化表征。由定义可知，$\forall z\in\mathcal{Z}$，均有$\xi(z)$是一个实数。根据不同的可靠性工作需求，可以构造不同的状态变量ξ对系统进行分析与表征。例如，对于电路系统的输出电压来说，可以令$\xi(z)=z$，即映射为输出电压值本身；若状态为{“工作”、“待机”、“宕机”}这样的文字表征，则状态变量ξ可以写作：

$$\xi(z)=\begin{cases}1,\ \text{if } z=\text{‘工作’},\\ 0,\ \text{if } z=\text{‘待机’},\\ -1,\ \text{if } z=\text{‘宕机’}.\end{cases}$$

此时，映射为从文字表征到实数，从而完成了从状态空间到实数集的映射。

定义.（状态域）状态域是指可测状态空间中的所有元素经状态变量ξ映射后构成的取值范围的集合，记作Ξ_z。

以上文所述电路系统为例，当$\xi(z)=z$时，该型号电路系统在25℃时所有可能的输出电流压值构成了状态域。

从图 5 中可以看出，对象空间Ω和条件$\boldsymbol{S}$决定了状态本身，即“状态是什么”；状态变量决定了状态的值，即“状态是多少”。因此，状态域是由对象空间Ω、条件$\boldsymbol{S}$和状态变量ξ三个要素共同决定的。我们将对象空间Ω、条件$\boldsymbol{S}$和状态变量ξ称为状态域三要素，记作$(\Omega,\boldsymbol{S},\xi)$。

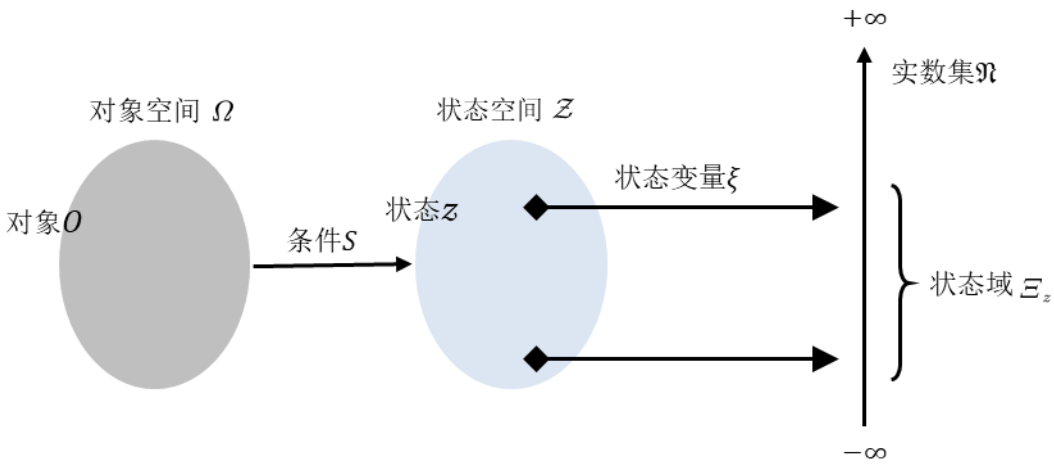

图 5　状态变量与状态域

数学上，常常使用分布来描述变量的不确定性。如图 6 所示，分布表征了变量落在给定值x左侧的可能性α随x变化的情况。显然，随着给定值x的自左向右移动，分布函数的值$\Phi(x)$也随之增大。

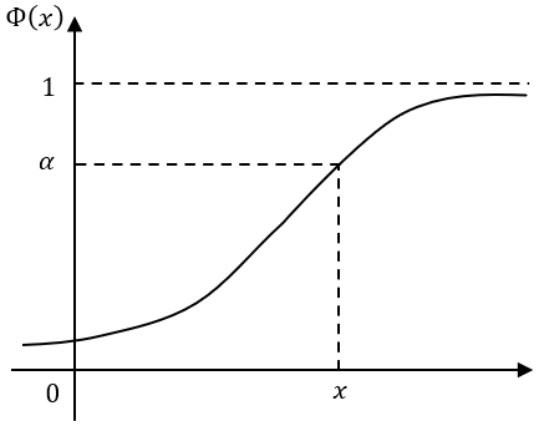

图 6　分布示意图

理想状态下，如果我们能对状态域进行完全统计，我们可以得到状态变量所有可能的取值及其可能性，继而得到状态变量的分布。这也是概率统计得到概率

分布的基本思想。然而，在实际中，无法对状态域认知完全，通常只能通过有限的活动对状态域进行观察测量，进而确定状态可能的量值。为此，我们将对状态域的进行观察测量以确定状态变量取值的活动称为观测。

与状态域三元素$(\Omega,\boldsymbol{S},\xi)$相对应，一次观测的完成离不开观测三元素，即观测对象O_{G}、观测条件$\boldsymbol{S}_{\mathrm{G}}$和观测方式$f_{\mathrm{G}}$。

定义.（观测对象和观测对象集）观测对象是指进行观测时从对象空间选取的对象，记作O_{G}。观测对象所组成的集合称为观测对象集，记作Ω_{G}。

在进行观测时，通常选取一个或多个对象进行观察测量，那么，选取的这一个或多个观测对象就构成了一个集合，即观测对象集Ω_{G}。因此，观测对象集是对象空间的子集，即$\Omega_{\mathrm{G}}\subset\Omega$。

定义.（观测条件）观测条件是指进行观测时的条件，记作$\boldsymbol{S}_{\mathrm{G}}$。

更为具体地，观测条件可分为工作条件、环境条件、使用维护条件等。例如，在一次观测中“电路板在25℃时的输出电流为2.5mA”，25℃就是观测条件。

定义.（观测方式）观测方式是指观测时所进行的活动，记作f_{G}。

在可靠性工程中，观测方式包括试验、仿真、实际使用等。例如，“在一次仿真试验中，电路板在25℃时的输出电流为2.5mA”，仿真试验就是观测方式。

观测三元素指出了完成一次观测必不可少的三项工作：第一，选择合适的观测对象即明确状态的所属；第二，选择合适的观测条件，即确定所关注的状态；第三，选择合适的观测方式，即明确观测活动的具体形式。通过以上三项工作，我们可以得到状态变量可能的取值，即观测数据。

定义.（观测数据）观测数据是指观测对象在一定的观测条件下经一定的观测方式得到的数据。

更为通俗地来讲，观测数据就是在观测中所获得状态变量的可能的取值。例如，对某型电路系统的输出电压进行测试，测得电流值分别为 12.1V，12.2V，12.3V。那么，观测数据就是12.1，12.2，12.3这三个数值。

2.2.2.2 观测数据的分类

由观测数据的定义可知，观测数据由观测对象、观测条件和观测方式三个因素共同决定。根据观测对象、观测条件和观测方式这三元素的异同，观测数据可被划分为以下八类：

1. 同一观测对象，同一观测条件，同一观测方式；

2. 同一观测对象，同一观测条件，不同观测方式；

3. 同一观测对象，不同观测条件，同一观测方式；

4. 同一观测对象，不同观测条件，不同观测方式；

5. 不同观测对象，同一观测条件，同一观测方式；

6. 不同观测对象，同一观测条件，不同观测方式；

7. 不同观测对象，不同观测条件，同一观测方式；

8. 不同观测对象，不同观测条件，不同观测方式。

基于上述分类，本文定义了同源观测数据和多源观测数据。

定义.（同源观测数据）同源观测数据是指来自同一观测对象、经同一观测条件下使用同一观测方式得到的观测数据。

定义.（多源观测数据）多源观测数据是观测三元素不同的观测数据。

多源观测数据对应上述第 2 类至第 8 类观测数据，它们或属于不同观测对象、或经历不同观测条件、或使用不同观测方式。

可靠性数据是一类特殊的观测数据。因此，上文所述观测数据的分类同样适用于可靠性数据的分类。需要指出的是，由于可靠性数据在工程活动中往往呈现出“稀疏”的特征，因此，本节主要介绍针对稀疏可靠性数据的不确定性量化方法。

稀疏可靠性数据按照同源和多源共分为两大类、八小类，具体内涵如图 7 所示。本节课所讲内容主要针对其中的：

1. 同源稀疏可靠性数据；

2. 同一观测方式下来自相同观测对象不同观测条件的多源稀疏可靠性数据；

3. 不同观测方式下来自相同观测对象相同观测条件的多源稀疏可靠性数据；

4. 同一观测方式下来自相似观测对象相同观测条件的多源稀疏可靠性数据；

共四类，介绍其不确定性量化方法及其相应的可靠性评估案例。

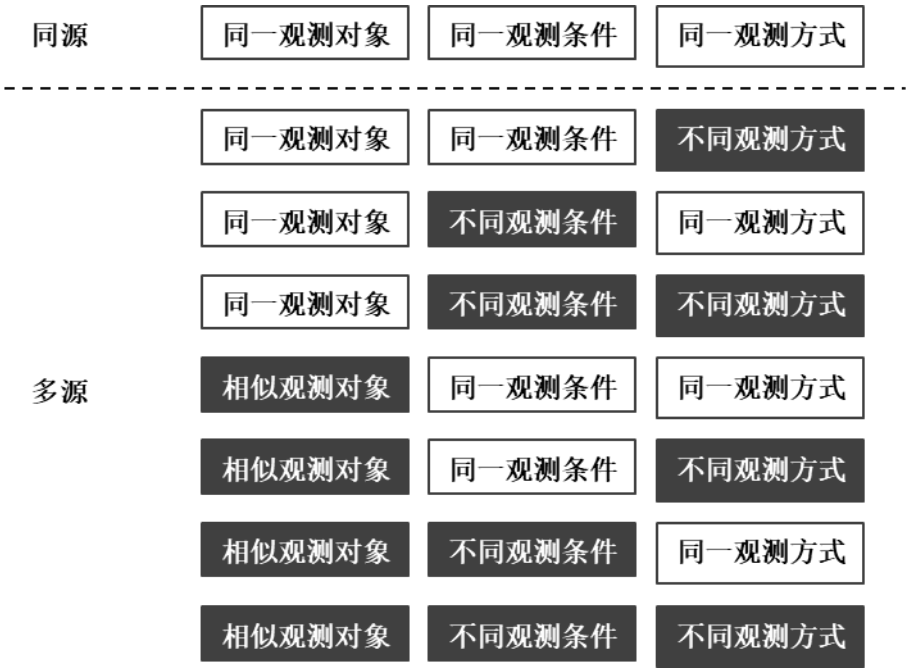

图 7　同源稀疏可靠性数据与多源稀疏可靠性数据

3　同源稀疏可靠性数据的不确定性量化方法

3.1 熵与最大熵原理

3.1.1 熵

在不确定理论中，熵的定义如下。

定义.（熵[3]）设ξ是一个不确定变量，其不确定分布为Φ。那么它的熵$H[\xi]$被定义为：

$$H[\xi]=\int_{-\infty}^{+\infty} S(\Phi(x))\mathrm{d}x, \tag{1}$$

其中，$S=-t\ln t-(1-t)\ln(1-t)$.

熵是不确定测度下准确预测不确定变量的实现（realization）的难度的一种表征。熵越大，该不确定变量的不确定性就越大，因此准确预测不确定变量实现的难度就越大。

需要指出的是，当不确定变量ξ是一个常数a时，其熵等于0。根据熵的定义可以计算：

$$H[\xi]=-\int_{-\infty}^{a}(0\ln 0+1\ln 1)\mathrm{d}x-\int_{a}^{+\infty}(1\ln 1+0\ln 0)\mathrm{d}x=0.$$

这是因为当不确定变量ξ是一个常数时，它就只是这一个确定的数，没有其他可

能的实现，此时准确不确定变量的实现的难度最低。

3.1.2 最大熵原理

在实际应用中，常常会面临变量的分布选择问题：虽然已知变量的一些特征或者要求，但是通常会有多种分布形式都满足变量的这些已知特征或要求，需要从满足特征或要求的多个分布中选择一个合适的分布，以便进行后续的分析研究。例如，如果已知一个变量的期望为 2，方差为 3，那么正态不确定分布$\mathcal{N}\left(2,\sqrt{3}\right)$和线性不确定分布$\mathcal{L}(-1,5)$都满足要求。这时，应该选择哪个分布来表征这个变量？

为解决给定条件下的分布选择问题，刘宝碇教授提出了最大熵原理[3]。

【最大熵原理】: 在满足要求的前提下选择熵最大的分布。

最大熵原理意味着在满足要求的前提下，选择包含最多信息的分布来表征变量。此时，认为这个变量处于一种不确定性最大的“最坏情况”状态，以保证后续分析都是保守的。

根据公式(1)，可以计算得到正态不确定分布$\mathcal{N}\left(2,\sqrt{3}\right)$的熵为$\pi$，线性不确定分布$\mathcal{L}(-1,5)$的熵为 3。显然，正态不确定分布$\mathcal{N}\left(2,\sqrt{3}\right)$的熵大于线性不确定分布的熵。因此，根据最大熵原理，在已知期望为 2，方差为 3 的前提下，应该选择正态不确定分布来表征这个变量进行后续的分析研究。

陈孝伟和戴韡证明了在已知期望和方差的条件下，正态不确定分布是最大熵分布，并将此定理命名为最大熵定理。

定理.（最大熵定理[4]**）** 设ξ是一个不确定变量，它的期望值是e，方差是σ^2. 那么，不确定变量ξ的熵有

$$H[\xi]\leqslant\frac{\pi\sigma}{\sqrt{3}},\tag{2}$$

当且仅当是不确定变量ξ是期望值为e，方差为σ^2的正态不确定变量$\mathcal{N}(e,\sigma)$时等号成立。

根据最大熵定理，可以获取以下两种情况下的不确定分布：

(1)如果已知一个变量的期望和方差，应直接选择正态不确定分布作为该变量的分布；

(2)如果可以利用观测数据合理地估计变量的期望和方差，那么，也应选择正

态不确定分布作为该变量的分布。

针对第二种情况，本论文提出了修匀公式，以利用稀疏观测数据合理估计变量的期望和方差，进而获取参数化的不确定分布。

如果已知信息不仅仅一个变量的期望和方差，还包含了其他数值特征，那么，最大熵定理已不再适用，不能假设再变量服从正态不确定分布，应认为该变量的分布形式不定。因此，本论文还将从变量的矩特征出发，基于最大熵原理分别提出了 k 阶原点矩和 k 阶中心矩等两种用于获取非参数不确定分布的方法。

3.2 修匀公式

3.2.1 修匀公式的定义

修匀公式的基本思想是观测数据对应的信度与由其决定的经验期望和其经验方差所确定的正态不确定分布所计算出的信度相等。

首先，介绍不确定理论中 k 阶经验矩的定义。

定义.（k 阶经验矩[5]） 设(x_i,α_i),$(i=1,2,...,n)$是不确定变量ξ的一组经验数据且满足

$$x_1<x_2<\cdots<x_n, 0\leqslant\alpha_1\leqslant\alpha_2\leqslant\cdots\leqslant\alpha_n\leqslant 1.$$

那么，对于任意的正整数k，不确定变量ξ的 k 阶经验矩$\overline{\xi^k}$为：

$$\overline{\xi^k}=\alpha_1 x_1^k+\frac{1}{k+1}\sum_{i=1}^{n-1}\sum_{j=0}^{k}(\alpha_{i+1}-\alpha_i)x_i^j x_{i+1}^{k-j}+(1-\alpha_n)x_n^k. \tag{3}$$

其次，根据经验矩的定义，可以推导出经验期望和经验方差的表达式。经验期望$\overline{e}$可以写作：

$$\overline{e}=\frac{\alpha_1+\alpha_2}{2}x_1+\sum_{i=2}^{n-1}\frac{\alpha_{i+1}-\alpha_{i-1}}{2}x_i+\left(1-\frac{\alpha_{n-1}+\alpha_n}{2}\right)x_n.$$

经验方差$\overline{\sigma^2}$可以写作：

$$\overline{\sigma^2}=\alpha_1(x_1-e)^2+\frac{1}{3}\sum_{i=1}^{n-1}\sum_{j=0}^{2}(\alpha_{i+1}-\alpha_i)(x_i-e)^j(x_{i+1}-e)^{2-j}+(1-\alpha_n)(x_n-e)^2.$$

对于一组观测数据而言，如果它服从正态不确定分布，那么，观测数据对应的信度就可以由正态不确定分布$\mathcal{N}(e,\sigma)$推导出；继而，根据推导出的信度，可

利用经验期望公式和经验方差公式确定经验期望$\bar{e}$和经验方差$\overline{\sigma^2}$，又可确定另一正态不确定分布$\mathcal{N}(\bar{e},\bar{\sigma})$。对于同一组观测数据而言，我们希望确定一个唯一的正态不确定分布，即希望$\mathcal{N}(e,\sigma)=\mathcal{N}(\bar{e},\bar{\sigma})$。根据上述思想，修匀公式的定义如下。

定义.（修匀公式[6]）设ξ是一个不确定变量，其观测数据$x_1,x_2,...,x_n$均为正数且在重新排序后满足$x_1<x_2<\cdots<x_n$。则观测数据x_i对应的信度α_i满足：

$$\alpha_i=\left(1+\exp\left(\frac{\pi(e-x_i)}{\sqrt{3}\sigma}\right)\right)^{-1},\ i=1,2,...,n, \tag{4}$$

其中，$e=\dfrac{\alpha_1+\alpha_2}{2}x_1+\sum\limits_{i=2}^{n-1}\dfrac{\alpha_{i+1}-\alpha_{i-1}}{2}x_i+\left(1-\dfrac{\alpha_{n-1}+\alpha_n}{2}\right)x_n$，且

$$\sigma=\sqrt{\alpha_1(x_1-e)^2+\frac{1}{3}\sum_{i=1}^{n-1}\sum_{j=0}^{2}(\alpha_{i+1}-\alpha_i)(x_i-e)^j(x_{i+1}-e)^{2-j}+(1-\alpha_n)(x_n-e)^2}.$$

3.2.2 案例应用

失效时间数据是一类常见的观测数据，它是失效时间这一状态变量的观测值。随着产品可靠性水平的提高，产品寿命越来越长，受时间成本和经济成本等条件的限制，无论是试验观测还是实际观测，失效时间数据也都越来越难以获得，呈现出稀疏的特征。本节以一组失效时间数据为例，展示提出的修匀公式。

例. 某系统的失效时间观测数据为 444h，538h，790h，1006h。为确定系统失效时间的不确定分布，可根据修匀公式列出如下方程组：

$$\begin{cases}\alpha_1 &=\left(1+\exp\left(\dfrac{\pi(e-444)}{\sqrt{3}\sigma}\right)\right)^{-1},\\ \alpha_2 &=\left(1+\exp\left(\dfrac{\pi(e-538)}{\sqrt{3}\sigma}\right)\right)^{-1},\\ \alpha_3 &=\left(1+\exp\left(\dfrac{\pi(e-790)}{\sqrt{3}\sigma}\right)\right)^{-1},\\ \alpha_4 &=\left(1+\exp\left(\dfrac{\pi(e-1006)}{\sqrt{3}\sigma}\right)\right)^{-1}.\end{cases}$$

其中，$e=\dfrac{\alpha_1+\alpha_2}{2}x_1+\sum\limits_{i=2}^{3}\dfrac{\alpha_{i+1}-\alpha_{i-1}}{2}x_i+\left(1-\dfrac{\alpha_3+\alpha_4}{2}\right)x_4$且

$$\sigma=\sqrt{\alpha_1(x_1-e)^2+\frac{1}{3}\sum_{i=1}^{3}\sum_{j=0}^{2}(\alpha_{i+1}-\alpha_i)(x_i-e)^j(x_{i+1}-e)^{2-j}+(1-\alpha_4)(x_4-e)^2}.$$

根据修匀公式的近似求解算法，可以解得

$$\begin{cases}\alpha_1=0.0429,\\ \alpha_2=0.1082,\\ \alpha_3=0.7309,\\ \alpha_4=0.9724.\end{cases}$$

该系统失效时间的不确定分布为：

$$\Phi(x)=\left(1+\exp\left(\frac{\pi(705.7671-x)}{\sqrt{3}\times152.9962}\right)\right)^{-1}.$$

其图像如图 8 所示。

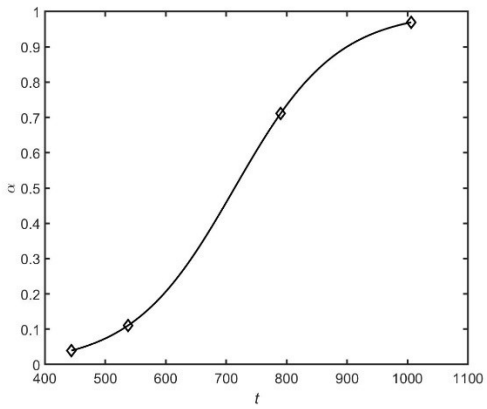

图 8　失效时间的不确定分布图像

3.3 k 阶原点矩方法

参数不确定分布，如线性不确定分布、正态不确定分布等，使用时表征容易，可以通过定义的参数来清晰的表征不确定分布的形式、量值等信息。然而，有限的参数不确定分布并不能覆盖所有的需求。因此，研究非参数不确定分布获取方法是十分必要的。对此，本节提出了一种基于 k 阶原点矩模型获取非参数不确定分布获取的方法。

3.3.1 k 阶原点矩模型

首先，介绍不确定理论中 k 阶原点矩的定义。

定义.（k 阶原点矩[2]） 设 ξ 是一个不确定变量且 k 是一个正整数，那么，不确定变量 ξ 的 k 阶原点矩 $E[\xi^k]$ 定义为：

$$E[\xi^k]=\int_0^{+\infty}\mathcal{M}\{\xi^k\geqslant x\}\mathrm{d}x-\int_{-\infty}^0\mathcal{M}\{\xi^k\leqslant x\}\mathrm{d}x. \tag{5}$$

Sheng 和 Kar 二人提出了通过逆不确定分布计算k阶原点矩的方法。

定理[7]**.** 设ξ是一个不确定变量，有正则不确定分布Φ，且k是一个正整数，那么，k阶原点矩$E[\xi^k]$可以写作：

$$E[\xi^k]=\int_0^1(\Phi^{-1}(\alpha))^k\mathrm{d}\alpha. \tag{6}$$

上述定理将k阶原点矩与逆分布连接起来。根据逆不确定分布与不确定分布的运算关系，显然可以将k阶原点矩与不确定分布连接起来。

令$\alpha=\Phi(x)$，$x=\Phi^{-1}(\alpha)$，则公式(6)可写作：

$$E[\xi^k]=\int_0^1 x^k\mathrm{d}\Phi(x). \tag{7}$$

可以看到，公式(7)建立了k阶原点矩与不确定分布计算之间的关系，为本论文建立k阶原点矩模型奠定了基础。

k阶原点矩模型的定义如下：

模型.（k阶原点矩模型）设不确定变量ξ的不确定分布为$\Phi(x)$，其k阶原点矩为μ_k，则k阶原点矩模型为：

$$\begin{cases}\max\ H[\xi]\ =\ \displaystyle\int_{-\infty}^{+\infty}-\Phi(x)\ln\Phi(x)-(1-\Phi(x))\ln(1-\Phi(x))\mathrm{d}x\\ s.t.\\ \displaystyle\int_0^1 x^k\mathrm{d}\Phi(x)=\mu_k,\ k\ =1,2,3,\cdots\end{cases} \tag{8}$$

k阶原点矩模型的决策变量是某不确定变量的不确定分布，约束条件是给定的该不确定变量的前k阶原点矩，目标是使不确定变量具备最大的熵。k阶原点矩描述了不确定变量相对于原点的离散性，熵描述了不确定变量的信息量。因此，k阶原点矩模型旨在找到给定范围内包含信息量最大的不确定分布，以保证后续分析不会过度乐观。

3.3.2 k阶原点矩近似等价模型

k阶原点矩模型只是一种理想模型，在不确定分布不定的情况下，是无解的。

因此，本论文基于线性假设，提出了 k 阶原点矩近似等价模型。

线性假设 1（分布线性假设）：不确定分布为线性分段函数，其形式为：

$$\Phi(x)=\begin{cases}0, & 若x<x_1,\\ \alpha_i+\dfrac{(\alpha_{i+1}-\alpha_i)(x-x_i)}{x_{i+1}-x_i}, & 若x_i\leqslant x<x_{i+1},\\ 1, & 若x\geqslant x_N.\end{cases} \tag{9}$$

线性假设 2（信度线性假设）：插值点x_i对应的信度α_i由其次序决定，且

$$\alpha_i = \frac{2i-1}{2N}. \tag{10}$$

分布线性假设赋予未知的不确定分布以具体而灵活的表达。一方面，将不确定分布假定为线性分段函数，可使未知的不确定分布拥有了具体表达式，保证了后续分析具体可操作性；另一方面，线性分段函数可随着插值变化，不会限制不确定分布的形式可能性。信度线性假设可使不确定分布是正则的，保证后续分析的理论规范性。

根据分布线性假设，公式(7)中的 k 阶原点矩可以写作：

$$E[\xi^k]=\sum_{i=1}^{N-1}\frac{(\alpha_{i+1}-\alpha_i)(x_{i+1}^{k+1}-x_i^{k+1})}{(k+1)(x_{i+1}-x_i)},\ k=1,2,.... \tag{11}$$

根据分布线性假设和信度线性假设，模型(8)中的熵$H[\xi]$可以写作：

$$H=N\times\sum_{i=1}^{N-1}p(i)\times(x_{i+1}-x_i), \tag{12}$$

其中，$p(i)$可由下式计算得到。

$$\begin{aligned}p(i)=&-0.5(\alpha_{i+1}^2\ln\alpha_{i+1}-\alpha_i^2\ln\alpha_i)+0.25(\alpha_{i+1}^2-\alpha_i^2)\\&-0.5((1-\alpha_i)^2\ln(1-\alpha_i)-(1-\alpha_{i+1})^2\ln(1-\alpha_{i+1}))\\&+0.25((1-\alpha_i)^2-(1-\alpha_{i+1})^2).\end{aligned}$$

根据线性假设及变换，可以得到 k 阶原点矩近似等价模型。

模型.（k 阶原点矩近似等价模型）

$$
\begin{cases}
\max\ H[\xi]=N\times\sum_{i=1}^{N-1}p(i)\times(x_{i+1}-x_i) \\
s.t. \\
\sum_{i=1}^{N-1}\frac{(\alpha_{i+1}-\alpha_i)(x_{i+1}^{k+1}-x_i^{k+1})}{(k+1)(x_{i+1}-x_i)}-\mu_k=0,\ k=1,2,... \\
x_1<x_2<\cdots<x_N
\end{cases}
\tag{13}
$$

其中，$p(i)$可由下式计算得到。

$$
\begin{aligned}
p(i)=&-0.5(\alpha_{i+1}^2\ln\alpha_{i+1}-\alpha_i^2\ln\alpha_i)+0.25(\alpha_{i+1}^2-\alpha_i^2) \\
&-0.5((1-\alpha_i)^2\ln(1-\alpha_i)-(1-\alpha_{i+1})^2\ln(1-\alpha_{i+1})) \\
&+0.25((1-\alpha_i)^2-(1-\alpha_{i+1})^2).
\end{aligned}
$$

k阶原点矩近似等价模型是一个典型的非线性规划模型，可以通过遗传算法来进行求解。

3.3.3 模型验证

本节基于最大熵定理验证提出的k阶原点矩近似等价模型的正确性。

最大熵定理指明在已知期望和方差的条件下，变量服从正态不确定分布时其熵最大。期望就是一阶原点矩，方差是二阶原点矩与期望的平方之差。因此，最大熵定理可外推得到下述定理。

定理.设ξ是一个不确定变量，它的一阶原点矩是μ_1，二阶原点矩是μ_2. 那么，不确定变量ξ的熵有

$$
H[\xi]\leqslant\frac{\pi\sqrt{\mu_2-\mu_1^2}}{\sqrt{3}},
\tag{14}
$$

当且仅当不确定变量ξ是期望值为μ_1，方差为$(\mu_2-\mu_1^2)$的正态不确定变量$\mathcal{N}\left(\mu_1,\sqrt{\mu_2-\mu_1^2}\right)$时等号成立。

证明：

由期望与k阶原点矩的定义可知，期望e等于一阶原点矩，即$e=\mu_1$；由参考文献[7]中的定理可知，方差σ^2是二阶原点矩与期望的平方之差，即$\sigma^2=\mu_2-\mu_1^2$。

根据最大熵定理，不确定变量ξ的熵H满足：

$$H[\xi] \leqslant \frac{\pi\sqrt{\mu_2-\mu_1^2}}{\sqrt{3}},$$

当且仅当是不确定变量ξ是服从期望值为μ_1，方差为$(\mu_2-\mu_1^2)$的正态不确定分布$\mathcal{N}\left(\mu_1,\sqrt{\mu_2-\mu_1^2}\right)$时等号成立。

定理得证。

根据上述定理，本节设计了数值试验，验证所提近似等价模型的正确性。

数值试验的参数选取如表 1 所示。

表 1　k阶原点矩近似等价模型的模型验证试验参数

序号	名称	符号	数值
1	一阶原点矩	μ_1	5
2	二阶原点矩	μ_2	50
3	方差	σ^2	25
4	插值点数	N	500

图 9 中红色的线表示标定不确定分布曲线，该曲线展示了正态不确定分布$\mathcal{N}(5,5)$的图像，蓝色的线表示近似等价模型曲线。可以看出，红色的线和蓝色的线几乎是重合的，这说明了近似等价模型及其解法是有效的。

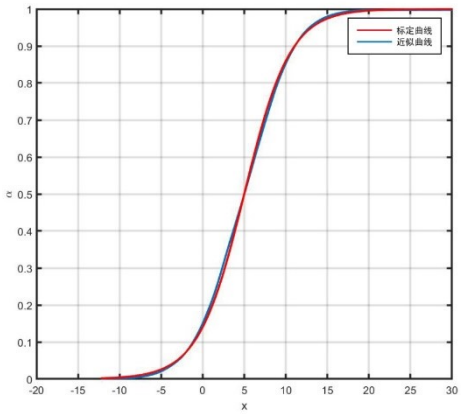

（注：标定曲线为标定不确定分布曲线的简称，近似曲线为近似等价模型曲线的简称）

图 9　近似等价模型曲线和标定不确定分布曲线

近似等价模型曲线和标定不确定分布曲线之间的误差如图 10 所示。图 10 中，近似等价模型曲线和标定不确定分布曲线二者之间的误差不超过 0.025，进

一步说明了近似等价模型可以有效地对不确定分布进行估计。

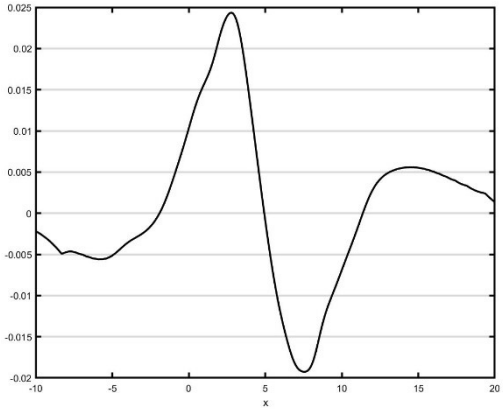

图 10　近似等价模型曲线和标定不确定分布曲线之间的误差

3.3.4 敏感性分析

由公式（2）可知：熵的大小与方差的正方根（即标准偏差）的大小是正相关的。因此，本节首先对方差进行敏感性分析。

方差敏感性分析的参数选取如表 2 所示。

表 2　方差敏感性分析的试验参数

类别	序号	名称	符号	数值
通用参数	1	一阶原点矩	μ_1	5
	2	插值点数	μ_2	50
敏感性参数	1	方差	σ^2	1
	2			9
	3			49
	4			81

方差敏感性分析的试验结果如图 11 所示。图 11 展示了一阶原点矩$\mu_1=5$，插值点数$N=100$时，k 阶原点矩近似等价模型与标定不确定分布之间的绝对误差随方差变化的趋势。从图 11 中可以清楚地看出：随着方差地增加，k 阶原点矩近似等价模型与标定不确定分布之间的绝对误差的峰值也在逐渐增加。因此，在相同的一阶原点矩与插值点数下，k 阶原点矩近似等价模型得出的结果的精确性会随着方差的增大而减小。这是因为方差是数据离散程度的一种表征，方差越

大，数据的离散程度越大，那么在相同的条件下，得出的分析结果的不确定性也相应增加，其精确性降低。

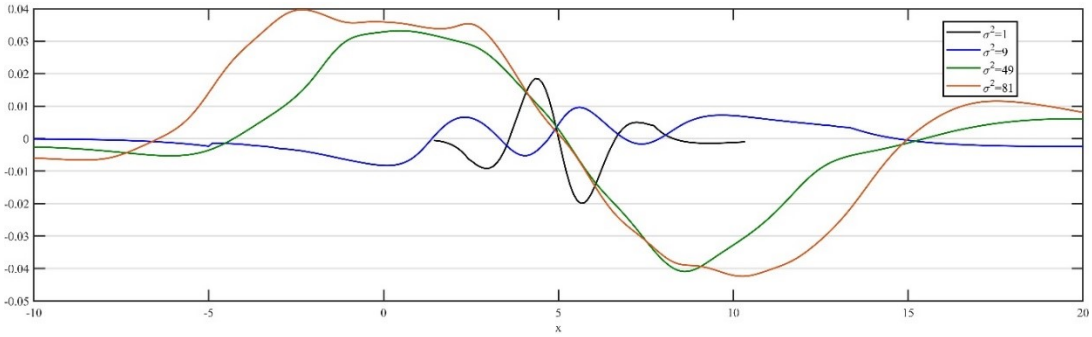

图 11　方差的敏感性分析的试验结果

此外，根据公式(13)可以 k 阶原点矩近似等价模型中的不确定熵H的计算与插值点数N密切相关。因此，本节对插值点数N进行了敏感性分析。插值点数敏感性分析的通用参数选取如表 3 所示。敏感性参数——插值点数的选取为{5, 10, 15, 20, 25, 30, 35, 40, 45, 50, 55, 60, 65, 70, 75, 80, 85, 90, 95, 100}。

表 3　插值点数敏感性分析的试验参数

类别	序号	名称	符号	数值
通用参数	1	一阶原点矩	μ_1	5
	2	二阶原点矩	μ_2	50

图 12 和图 13 展示了插值点数敏感性分析的试验结果。其中，图 12 展示了插值点数从 5 开始，步长为 5，增加至 50 时，k 阶原点矩近似等价模型曲线与标定不确定分布曲线之间差距的变化趋势；图 13 展示了从 55 开始，步长为 5，增加至 100 时，k 阶原点矩近似等价模型曲线与标定不确定分布曲线之间差距的变化趋势。

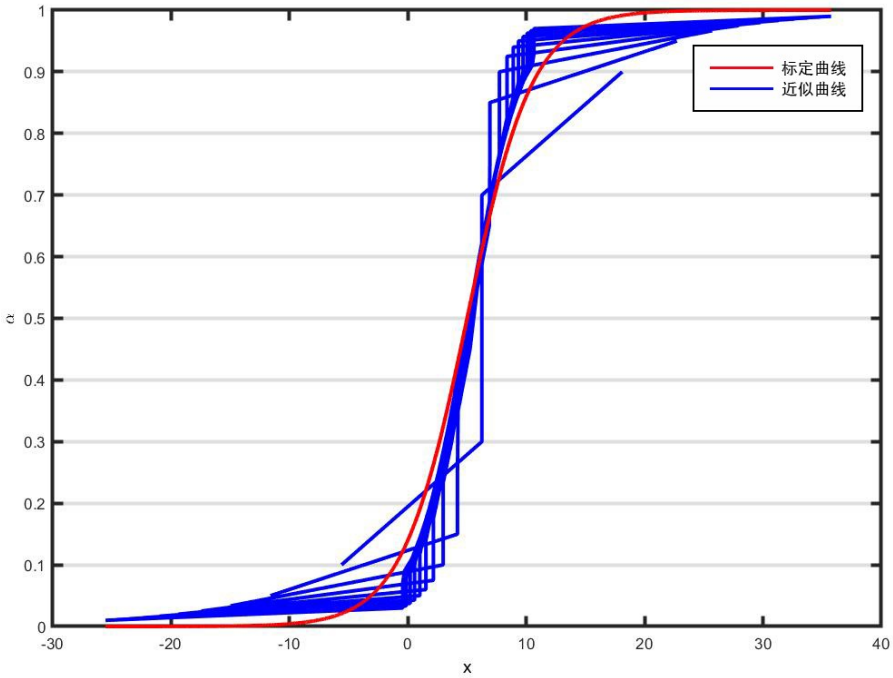

（注：标定曲线为标定不确定分布曲线的简称，近似曲线为近似等价模型曲线的简称）

图 12　插值点数敏感性分析的试验结果（*N*=5:5:50）

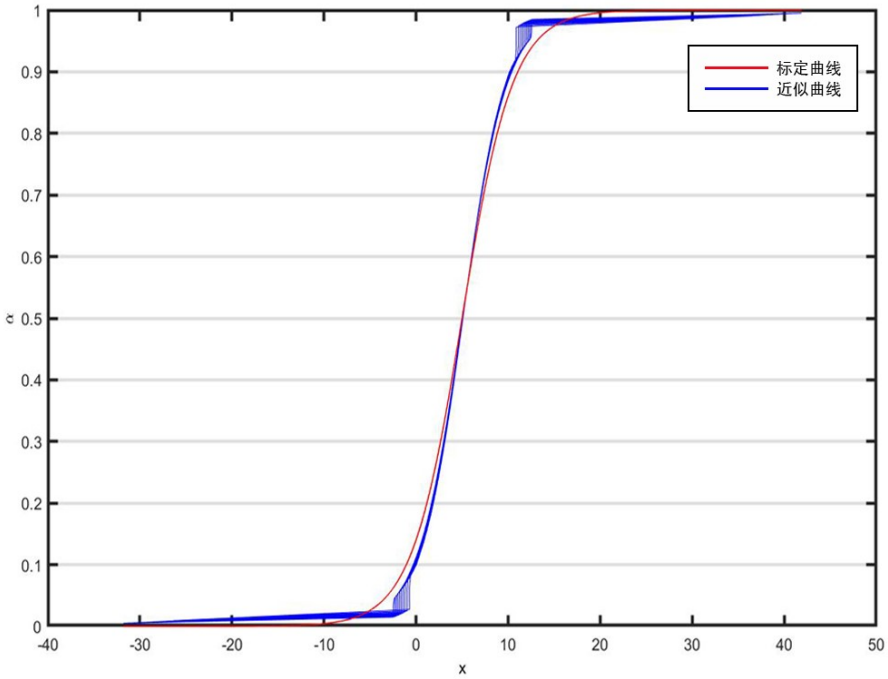

（注：标定曲线为标定不确定分布曲线的简称，近似曲线为近似等价模型曲线的简称）

图 13　插值点数敏感性分析的试验结果（*N*=55:5:100）

从图 12 中可以看出，在插值点数较少时，k 阶原点矩近似等价模型曲线与标定不确定分布曲线的线性部分（信度 0.5 附近）比较接近，而在曲线部分（信度接近 0 和接近 1 的部分）差距较大。从图 13 中可以看出，随着插值点数的逐渐增多，k 阶原点矩近似等价模型曲线与标定不确定分布曲线的曲线部分的差距逐渐缩小，估计精度逐步提高。结合图 12 和图 13 可以做出这样的推断：在线性部分进行估计时，可以采用较少的插值点数来提高k阶原点矩近似等价模型的估计效率；在对 0 和 1 附近的曲线部分进行估计时，需要采用较多的插值点数来提高k阶原点矩近似等价模型的估计精度。

3.4 k 阶中心矩方法

中心矩刻画了不确定变量偏离其‘中心’的程度。较之原点矩，更为直接地描述了不确定变量围绕其期望的离散程度。因此，在 k 阶原点矩模型的基础上，提出了 k 阶中心矩模型，作为一种不确定分布的统计方法。

3.4.1 k 阶中心矩模型

首先，介绍不确定理论中 k 阶中心矩的定义。

定义.（k 阶中心矩）设不确定变量ξ的期望$E[\xi]$存在且有限，k是一个正整数。如果$E[(\xi-E[\xi])^k]$存在且有限，那么$E[(\xi-E[\xi])^k]$就叫做不确定变量ξ的k阶中心矩。

k 阶中心矩刻画了不确定变量偏离其期望的离散程度。与 k 阶原点矩模型类似，下面直接写出 k 阶中心矩模型。

模型.（k 阶中心矩模型）设不确定变量ξ的不确定分布为$\Phi(x)$，μ_k^c为不确定变量的k阶中心矩，则k阶中心矩模型为：

$$\begin{cases} \max\ H[\xi] = \displaystyle\int_{-\infty}^{+\infty} -\Phi(x)\ln\Phi(x) - (1-\Phi(x))\ln(1-\Phi(x))\mathrm{d}x \\ s.t. \\ \displaystyle\int_0^1 x\mathrm{d}\Phi(x) = \mu_1^c, \\ \displaystyle\int_0^1 (x-\mu_1^c)^k\mathrm{d}\Phi(x) = \mu_k^c,\ k = 2,3,\cdots \end{cases} \tag{15}$$

3.4.2 k 阶中心矩的近似求解方法

可以看到，k 阶中心矩模型与 k 阶原点矩模型一样，都只是一种理想模型，在不确定分布不定的情况下，是无解的。前述提到，k 阶原点矩是描述的是变量围绕原点的离散程度,k 阶中心矩描述的是变量围绕其均值的离散程度。换言之，如果将坐标系做适当地平移，使得中心由变量的期望变成“原点”，那么，k 阶中心矩模型就可以转化为“一阶原点矩为 0”的 k 阶原点矩模型，也就可以按照 3.3.2 节中提出的近似等价模型进行相应地求解。

首先，进行坐标系平移：令 $x'=x-\mu_1^c$，则 k 阶中心矩模型可以转化为一阶原点矩为 0 的 k 阶原点矩模型，即

$$\begin{cases} \max\ H[\xi] = \int_{-\infty}^{+\infty} -\Phi(x')\ln\Phi(x') - (1-\Phi(x'))\ln(1-\Phi(x'))\mathrm{d}x' \\ s.t. \\ \int_0^1 x'\mathrm{d}\Phi(x') = 0, \\ \int_0^1 (x')^k \mathrm{d}\Phi(x') = \mu_k^c,\ k=2,3,... \end{cases} \tag{16}$$

其次，根据线性分布假设（见公式(9)）和线性信度假设（见公式(10)），可以将模型(16)转化为非线性规划模型，即可利用遗传算法进行求解，设求解结果为 x'^*。

最后，再次进行坐标变换 $x^*=x'^*+\mu_1^c$，即可得到 k 阶中心矩近似等价模型的解 x^*。

3.4.3 应用示例

本节以某吊桥的南侧桥墩的性能裕量方程为例，说明本节所提出的 k 阶中心矩模型在实际中的应用。吊桥的形貌如图 14 所示。

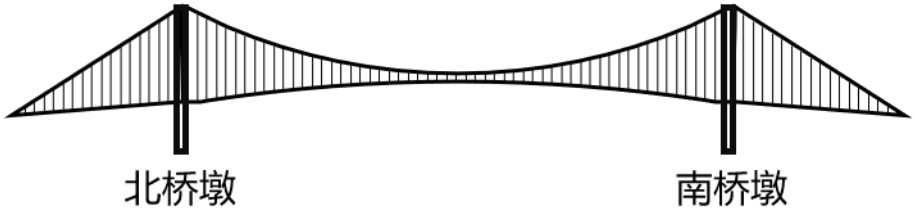

图 14　吊桥

据 Wang 等[8]的研究结果，可写出吊桥南侧桥墩的性能裕量方程为：

$$m_P = 85.36 - 0.19\omega\theta - 0.61\omega - 5.01\theta - 4.99V_T - 1.77V_{\min}, \tag{17}$$

式中，ω表示水流速度（m/s），θ表示冲击角度（°），V_T表示典型冲击速度（m/s），$V_{\min}$表示最小设计冲击速度（m/s）。

性能裕量方程(17)中各参数的矩约束条件表 4 所示。

表 4 性能裕量方程中参数的矩约束条件表

参数名称	符号	期望	方差	三阶中心矩	四阶中心矩
水流速度	ω	1.32	0.070	--	--
冲击角度	θ	10	16	72.96	132.84
典型冲击速度	V_T	3	0.36	--	--
最小设计冲击速度	$V_{\min}$	1	0.04	--	--

根据最大熵定理，可以直接写出变量ω、V_T和$V_{\min}$的不确定分布，依次为：

$$\Phi_\omega = \left(1 + \exp\left(\frac{\pi(1.32 - x)}{\sqrt{3} \times 0.264}\right)\right)^{-1},$$

$$\Phi_{V_T} = \left(1 + \exp\left(\frac{\pi(3 - x)}{\sqrt{3} \times 0.6}\right)\right)^{-1},$$

$$\Phi_{V_{min}} = \left(1 + \exp\left(\frac{\pi(1 - x)}{\sqrt{3} \times 0.2}\right)\right)^{-1}.$$

根据提出的 k 阶中心矩模型和表 4 中所列信息，可以写出用以求解变量冲击角度θ的不确定分布的 k 阶中心矩模型：

$$
\begin{cases}
\max H_\theta = -\int_{-\infty}^{+\infty} -\Phi(x_1)\ln\Phi(x_1) - (1-\Phi(x_1))\ln(1-\Phi(x_1))\mathrm{d}x_1 \\
s.t. \\
\int_0^1 x_1 \mathrm{d}\Phi(x_1) = 10, \\
\int_0^1 (x_1-10)^2 \mathrm{d}\Phi(x_1) = 16, \\
\int_0^1 (x_1-10)^3 \mathrm{d}\Phi(x_1) = 72.96, \\
\int_0^1 (x_1-10)^4 \mathrm{d}\Phi(x_1) = 1382.4.
\end{cases}
\tag{18}
$$

首先，进行坐标系平移，令$x_1{}' = x_1 - 10$，将模型(18)转化为四阶原点矩模型，即

$$
\begin{cases}
\max H_\theta = -\int_{-\infty}^{+\infty} -\Phi(x_1{}')\ln\Phi(x_1{}') - (1-\Phi(x_1{}'))\ln(1-\Phi(x_1{}'))\mathrm{d}x_1{}' \\
s.t. \\
\int_0^1 x_1{}' \mathrm{d}\Phi(x_1{}') = 0, \\
\int_0^1 (x_1{}')^2 \mathrm{d}\Phi(x_1{}') = 16, \\
\int_0^1 (x_1{}')^3 \mathrm{d}\Phi(x_1{}') = 72.96, \\
\int_0^1 (x_1{}')^4 \mathrm{d}\Phi(x_1{}') = 1382.4.
\end{cases}
\tag{19}
$$

其次，依据k阶原点矩近似等价模型中所提方法，利用线性分布假设和线性信度假设，可将模型(19)转化为非线性规划模型，即：

$$
\begin{cases}
\text{may } H[\xi]=N\times\sum_{i=1}^{N-1}p(i)\times(y'_{i+1}-y'_i) \\
s.t. \\
\sum_{i=1}^{N-1}\frac{(\alpha_{i+1}-\alpha_i)((y'_{i+1})^2-(y'_i)^2)}{2(y'_{i+1}-y'_i)}=0, \\
\sum_{i=1}^{N-1}\frac{(\alpha_{i+1}-\alpha_i)((y'_{i+1})^3-(y'_i)^3)}{3(y'_{i+1}-y'_i)}-16=0, \\
\sum_{i=1}^{N-1}\frac{(\alpha_{i+1}-\alpha_i)((y'_{i+1})^4-(y'_i)^4)}{4(y'_{i+1}-y'_i)}-72.96=0, \\
\sum_{i=1}^{N-1}\frac{(\alpha_{i+1}-\alpha_i)((y'_{i+1})^5-(y'_i)^5)}{5(y'_{i+1}-y'_i)}-1382.4=0, \\
y'_1<y'_2<\cdots<y'_N
\end{cases}
\tag{20}
$$

式中，$p(i)$可由下式计算得到。

$$
\begin{aligned}
p(i)=&-0.5(\alpha_{i+1}^2\ln\alpha_{i+1}-\alpha_i^2\ln\alpha_i)+0.25(\alpha_{i+1}^2-\alpha_i^2) \\
&-0.5((1-\alpha_i)^2\ln(1-\alpha_i)-(1-\alpha_{i+1})^2\ln(1-\alpha_{i+1})) \\
&+0.25((1-\alpha_i)^2-(1-\alpha_{i+1})^2).
\end{aligned}
$$

模型(20)利用遗传算法进行求解后，可得冲击角度θ的不确定分布图像如图15所示。

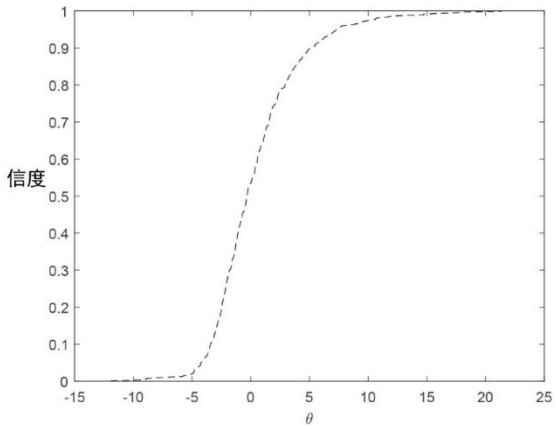

图 15　θ的不确定分布图像

至此，我们得到了裕量方程(17)中所有参数的不确定分布。接下来，我们可以利用根据定理，计算性能裕量的逆不确定分布$\Psi^{-1}(\alpha)$：

$$
\begin{aligned}
\Psi^{-1}(\alpha)=&85.36-0.19\Phi_\omega^{-1}(1-\alpha)\Phi_\theta^{-1}(1-\alpha)-0.61\Phi_\omega^{-1}(1-\alpha) \\
&-5.01\Phi_\theta^{-1}(1-\alpha)-4.99\Phi_{V_T}^{-1}(1-\alpha)-1.77\Phi_{V_{min}}^{-1}(1-\alpha).
\end{aligned}
$$

最后，根据确信可靠度的定义，我们可以计算吊桥南侧桥墩的可靠度：

$$R_B = \mathcal{M}\{m_P > 0\} = 1 - \mathcal{M}\{m_P \leqslant 0\} = 1 - \Psi(0) = 0.981, \quad (21)$$

其中，$\Psi(0)$可由$\Psi^{-1}(\alpha) = 0$确定。

参考文献

[1] 杨为民等. 可靠性维修性保障性导论[M]. 北京：国防工业出版社, 1995.

[2] 赵宇，杨军，马小兵 编著. 可靠性数据分析教程[M]. 北京：北京航空航天大学出版社，2009.

[3] LIU B D. Uncertainty Theory[M]. 5th. Beijing：Uncertainty Theory Laboratory, 2020 (Online).

[4] CHEN X W, DAI W. Maximum entropy principle for uncertain variables[J]. International Journal of Fuzzy Systems, 2011, 13(3): 232-236.

[5] WANG X S, PENG Z X. Method of moments for estimating uncertainty distributions[J]. Journal of Uncertainty Analysis and Applications, 2014, 2: Article 5.

[6] Tianpei Zu, Rui Kang, Meilin Wen. Graduation Formula: a new method to construct belief reliability distribution under epistemic uncertainty, Journal of Systems Engineering and Electronics, 2020, 31(3): 626-633.

[7] SHENG Y H, KAR S. Some results of moments of uncertain variable through incerse uncertainty distribution[J]. Fuzzy Optimization and Decision Making, 2015, 14: 57-76.

[8] WANG J J, FU T, BAO Y F. Vessel-bridge collision risk analysis based on structural reliability theory[J]. Journal of Asian Architecture and Building Engineering, 2009, 8(2): 539-545.