机器学习
Machine Learning

北京航空航天大学计算机学院
School of Computer Science and Engineering, Beihang University
黄 迪　张永飞

2020年秋季学期
Fall 2020

部分内容来源于C. Bishop和A. NG等人的课程以及互联网资源

第三章：线性模型

Chapter 3: Linear Models

机器学习算法

机器学习主要问题

	Supervised Learning	Unsupervised Learning
Discrete	Classification or Categorization	Clustering
Continuous	Regression	Dimensionality Reduction

“回归”起源

- **Francis Galton**

  英国生物学家

  研究父母身高与子女身高之间关系

  若父母身高高于平均身高，则其子女身高倾向于倒退生长，即会比其父母身高矮一些而更接近于大众平均身高.

  若父母身高小于平均身高，则其子女身高倾向于向上生长，即会更接近于大众平均身高.

  此现象被Galton称之为回归现象，即Regression.

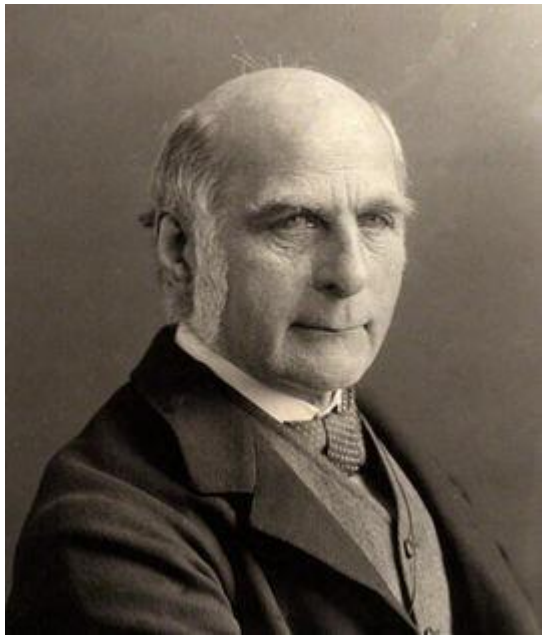

Francis Galton
1822.2.16-1911.1.17

“回归”起源

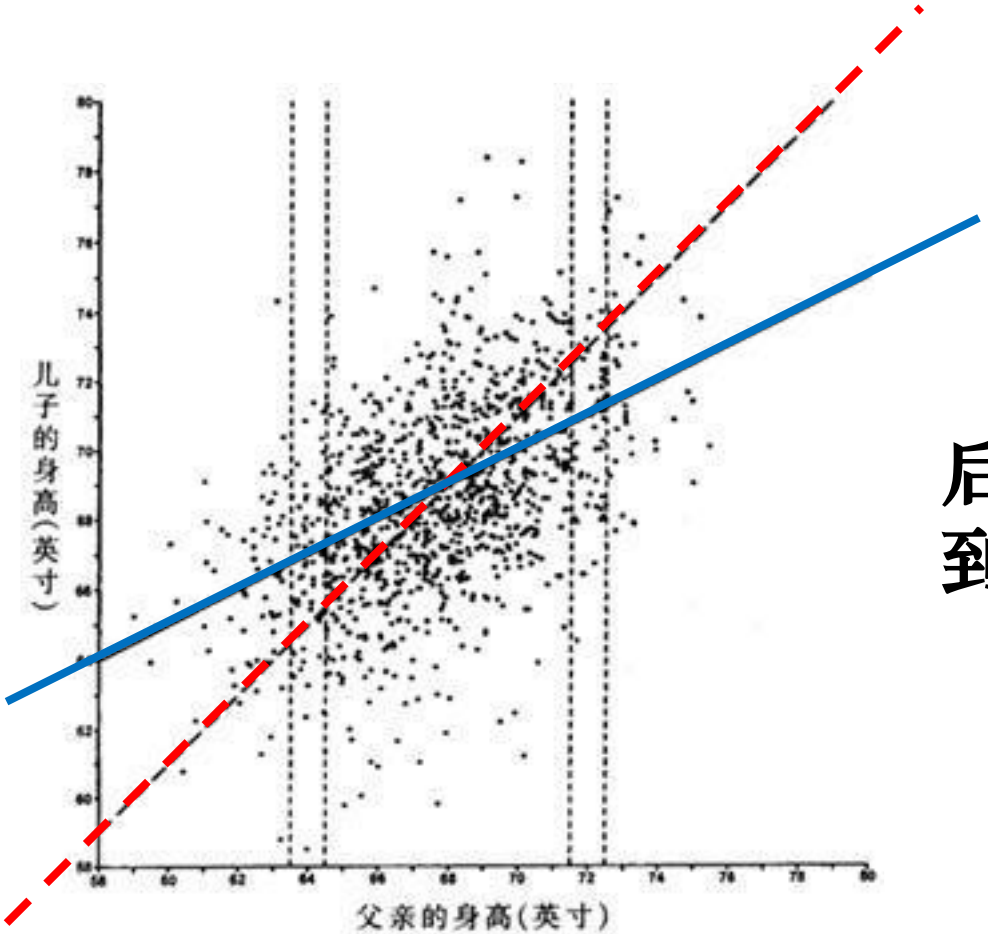

后代的身高倾向于“回归”到一个**平均值**.

回归问题举例

- 例：房价估计

Size (feet²)	Number of bedrooms	Number of floors	Age of home (years)	Price ($1000)
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
…	…	…	…	…

Size (feet²)	Number of bedrooms	Number of floors	Age of home (years)	Price ($1000)
1500	3	2	30	?

测试样本

回归问题举例

- 例：房价估计

训练样本

Size (feet²) x_1	Number of bedrooms x_2	Number of floors x_3	Age of home (years) x_4	Price ($1000) y
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
…	…	…	…	…

N

监督学习

N: 训练样本个数
x: 输入变量/“特征”
y: 输出变量/目标变量

回归模型

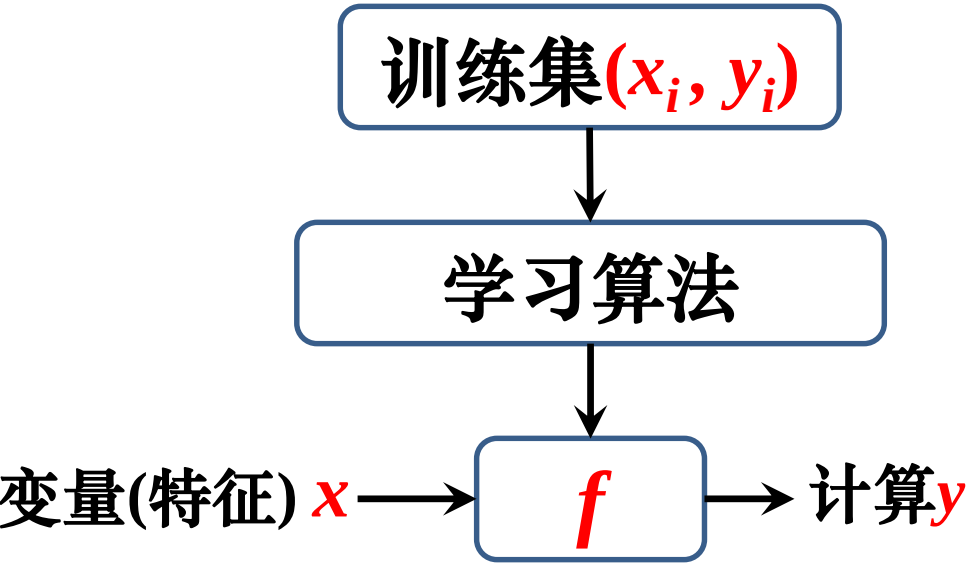

$$f(\mathbf{x}) = w_0 + w_1 x_1 + \ldots + w_m x_m$$
$$= w_0 + \sum_{i=1}^{m} w_i x_i$$
$$= \sum_{i=0}^{m} w_i x_i \qquad \boxed{x_0 = 1}$$

如何表示 f？

线性回归：
假设函数 f 为输入x的线性函数

$$f(\mathbf{x}) = w_0 + w_1 x_1 + \ldots + w_m x_m$$
$$= w_0 + \sum_{j=1}^{m} w_i x_i$$

写成向量形式：
增加一维 x_0=1，表示截距项

$$f(\mathbf{x}) = \boxed{\mathbf{w}^T}\mathbf{x}$$

回归模型

基函数

$$y(\mathbf{x}, \mathbf{w}) = \sum_{j=0}^{M-1} w_j \boxed{\phi_j(\mathbf{x})} = \mathbf{w}^{\mathrm{T}} \boldsymbol{\phi}(\mathbf{x})$$

最简单的情况下： $\phi_j(x) = x_j$

- **多项式基函数**

$$\phi_j(x) = x^j$$

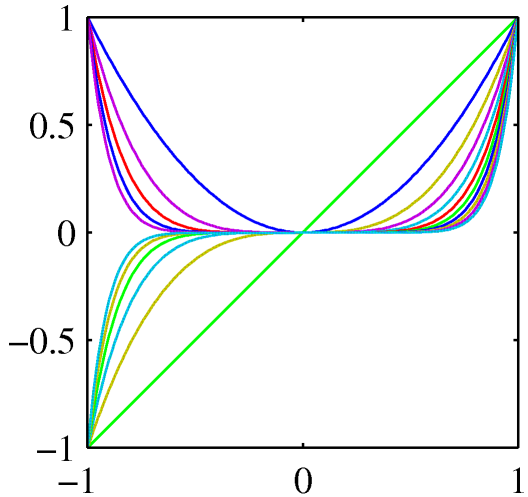

- **高斯基函数**

$$\phi_j(x) = \exp\left\{-\frac{(x-\mu_j)^2}{2s^2}\right\}$$

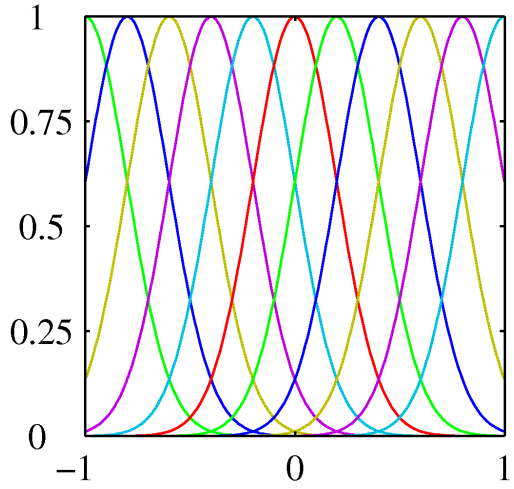

- **Sigmoid基函数**

$$\phi_j(x) = \sigma\left(\frac{x-\mu_j}{s}\right) \quad \sigma(a) = \frac{1}{1+\exp(-a)}.$$

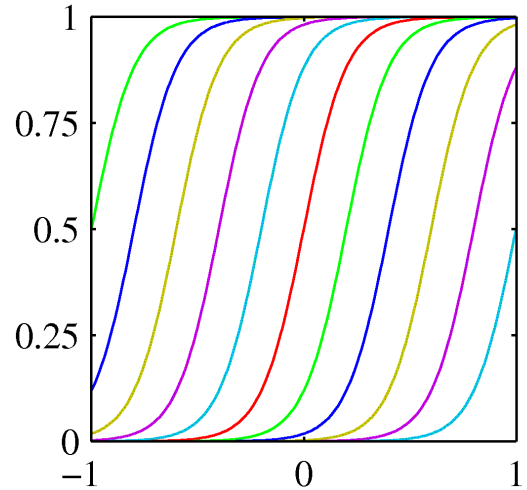

问题求解

- 问题本质：确定模型中的参数$\mathbf{w}^T$
- 基本思想：基于训练集最小化预测值f与真实输出值 y的差异
- 定义目标函数(又叫代价函数Cost Function)：

$$J(\mathbf{w}) = \frac{1}{2}\sum_{i=1}^{N}(f(\mathbf{x}_i) - y_i)^2$$

- 进一步：

$$\hat{\mathbf{w}} = \arg\min_{\mathbf{w}} J(\mathbf{w}) = \arg\min_{\mathbf{w}} \left[\frac{1}{2}\sum_{i=1}^{N}(f(\mathbf{x}_i) - y_i)^2\right]$$

梯度下降(Gradient Descent)

- **损失函数** $J(w)$

$$\min_{w} J(w)$$

- **一般流程**

  (1)首先对*w*赋值，这个值可以是随机的，也可以是一个全零的向量。

  (2)改变*w*的值，使得*J(w)*按梯度下降的方向进行减少，直到收敛。

梯度下降(Gradient Descent)

- 梯度下降

梯度下降法是一个最优化算法，是求解无约束优化问题最简单和最基础的方法之一.

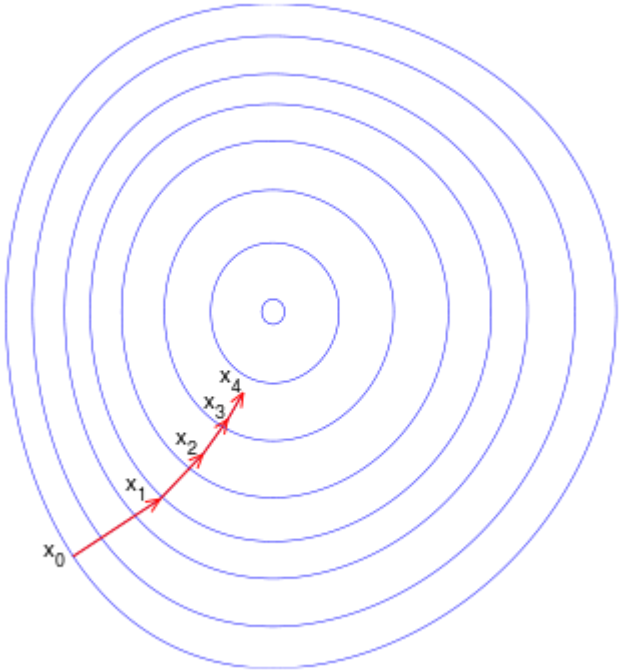

以负梯度方向为搜索方向

越接近目标值，步长越小，前进越慢.

梯度下降(Gradient Descent)

- 梯度下降：

  -给定初始值w^0

  -更新w使得J(w)越来越小

$$w_j^t = w_j^{t-1} - \alpha \frac{\partial}{\partial w_j} J(\mathbf{w})$$

$$\frac{\partial}{\partial w_j} J(\mathbf{w}) = \sum_{i=1}^{N} (f(\mathbf{x}_i) - y_i) \cdot \mathbf{x}_{i,j}$$

  -同时更新w的各维 $f(\mathbf{x}_i) = [\mathbf{w}^{t-1}]^T \mathbf{x}_i$

  α为学习率(Learning Rate)或更新步长

批处理梯度下降
(Batch Gradient Descent)

- 在梯度下降方法中，每次更新都利用所有数据，即：

$$w_j^t = w_j^{t-1} - \alpha \boxed{\sum_{i=1}^{N}} (f(\mathbf{x}_i) - y_i) \cdot x_j$$

在大样本条件下，批处理梯度下降的迭代速度很慢

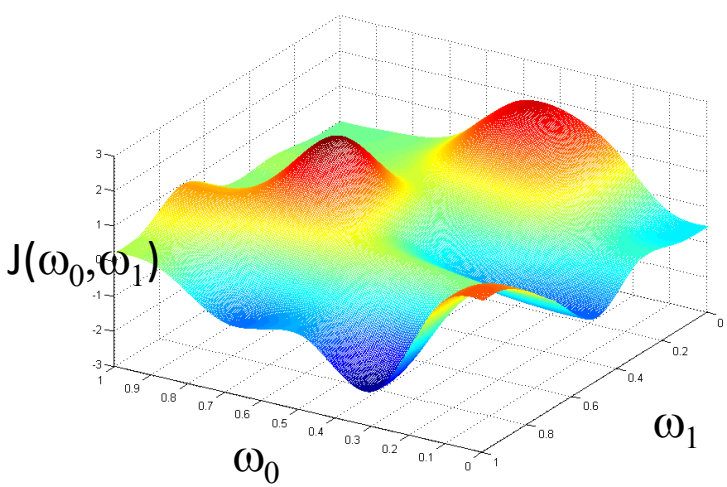

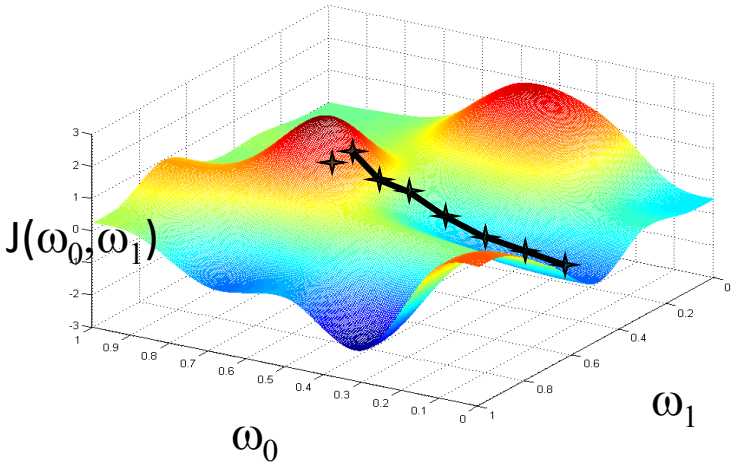

随机梯度下降
（Stochastic Gradient Descent）

- 基本思想：如果条件对所有样本都成立，则对任一样本也成立

  每次只用一个样本 $(\mathbf{x}_r, y_r)$

$$w_j^t = w_j^{t-1} - \alpha\left(f(\mathbf{x}_r) - y_r\right) \cdot \mathbf{x}_{r,j}$$

  -收敛速度较快
  -不太容易陷入局部极值
  -对大样本数据较有效

  又称在线学习(Online Learning)

- 变化形式

  可离线学习，每次“看”一个样本，对所有样本循环使用多次(一次循环称为一个Epoch)

  每次可以看一些样本(Mini-Batch)

$$f_w(x)$$

(for fixed w_0, w_1, this is a function of x)

$$J(w)$$

(function of the parameters w_0, w_1)

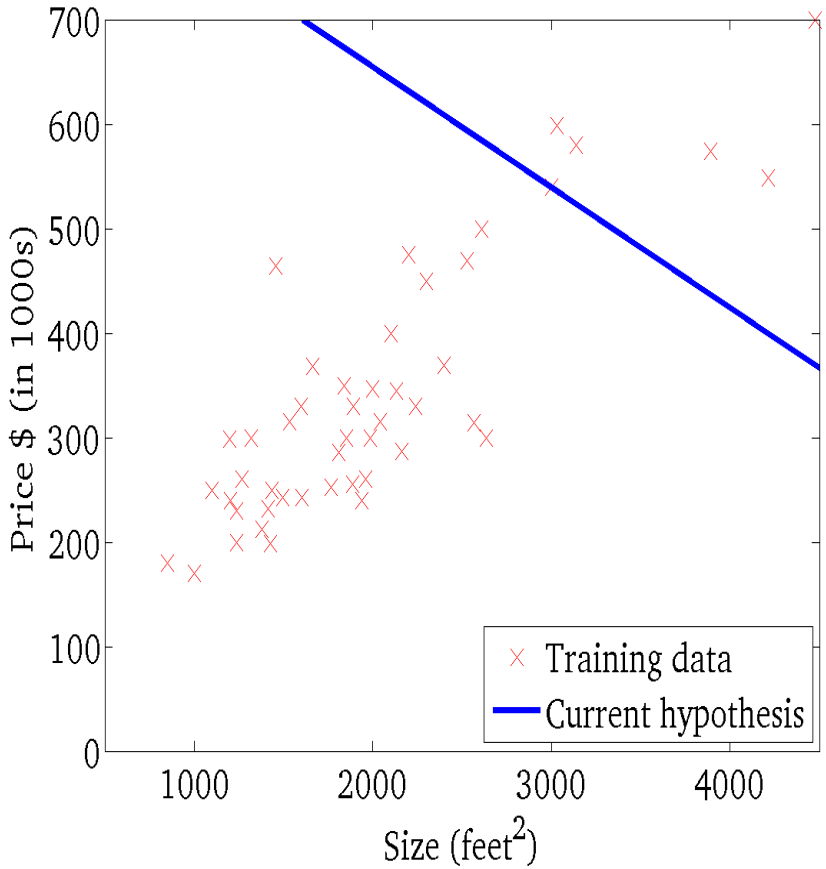

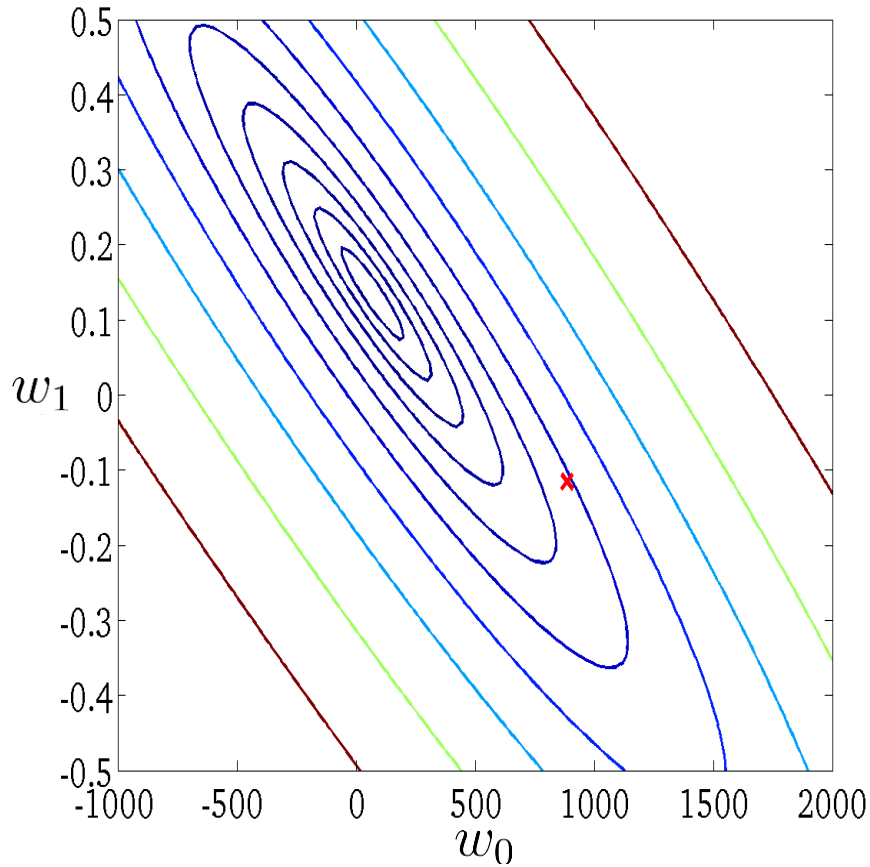

$$f_w(x)$$

(for fixed w_0, w_1, this is a function of x)

$$J(w)$$

(function of the parameters w_0, w_1)

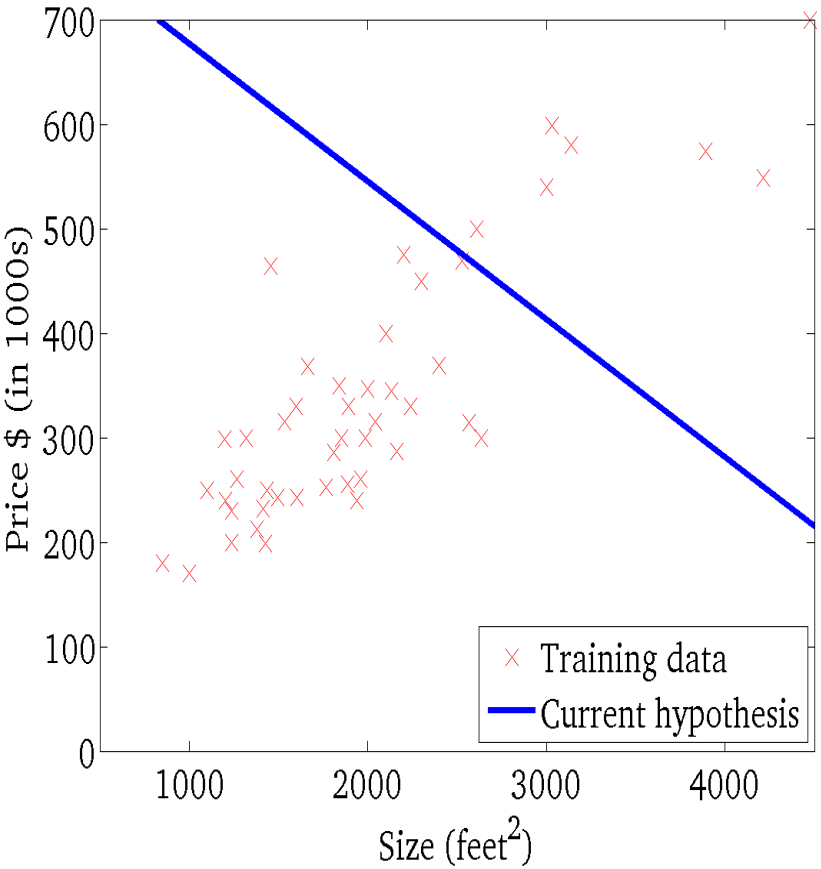

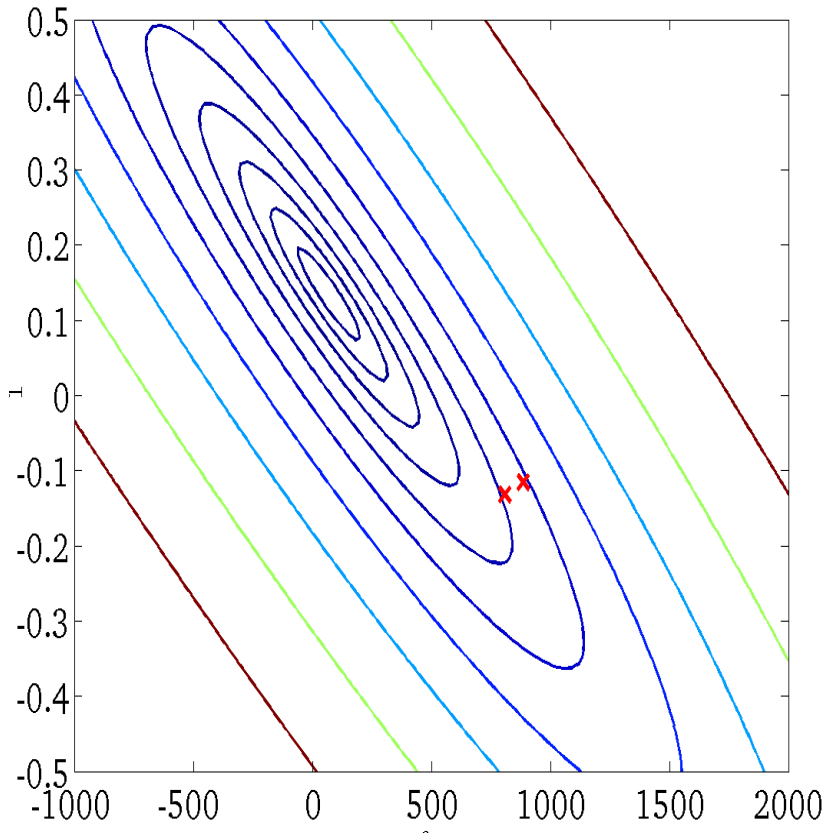

$$f_w(x)$$

(for fixed w_0, w_1, this is a function of x)

$$J(w)$$

(function of the parameters w_0, w_1)

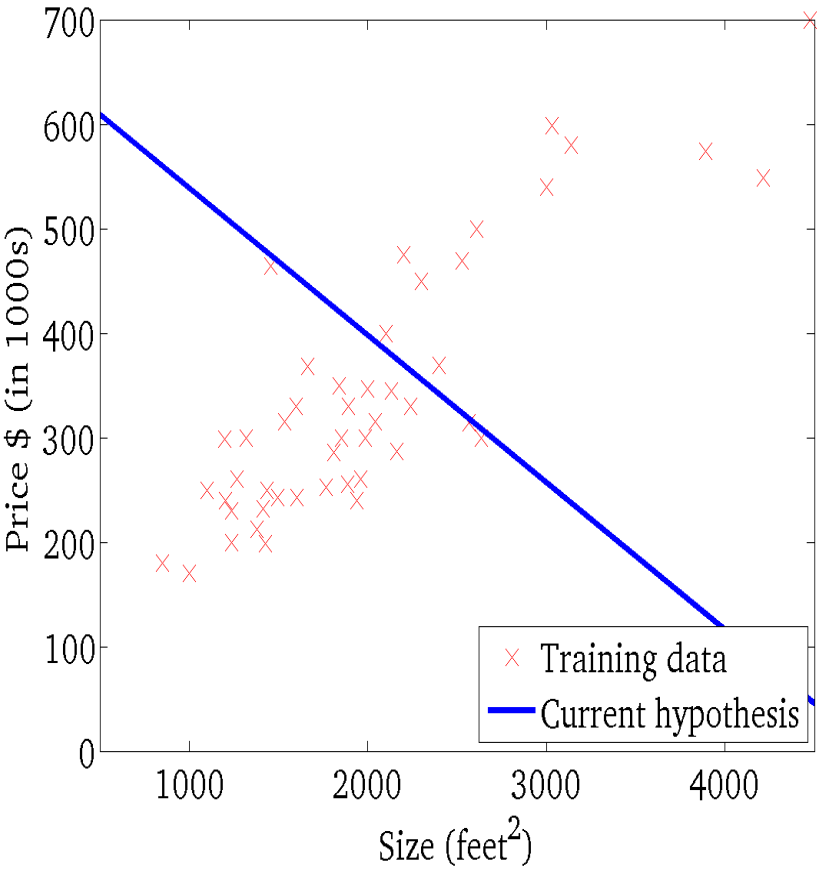

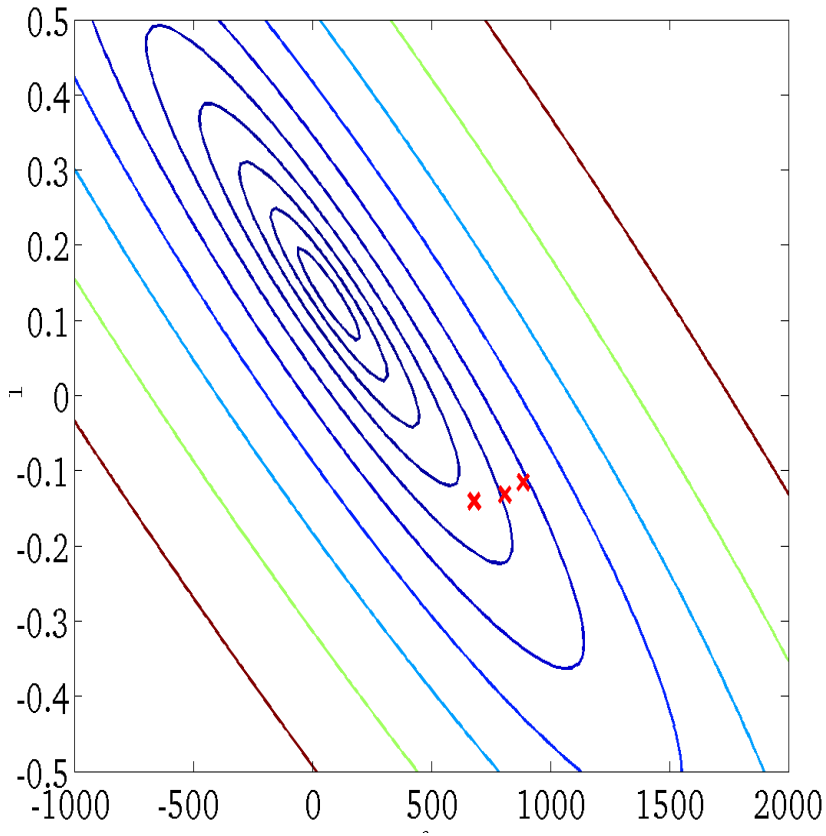

$$f_w(x)$$

(for fixed w_0, w_1, this is a function of x)

$$J(w)$$

(function of the parameters w_0, w_1)

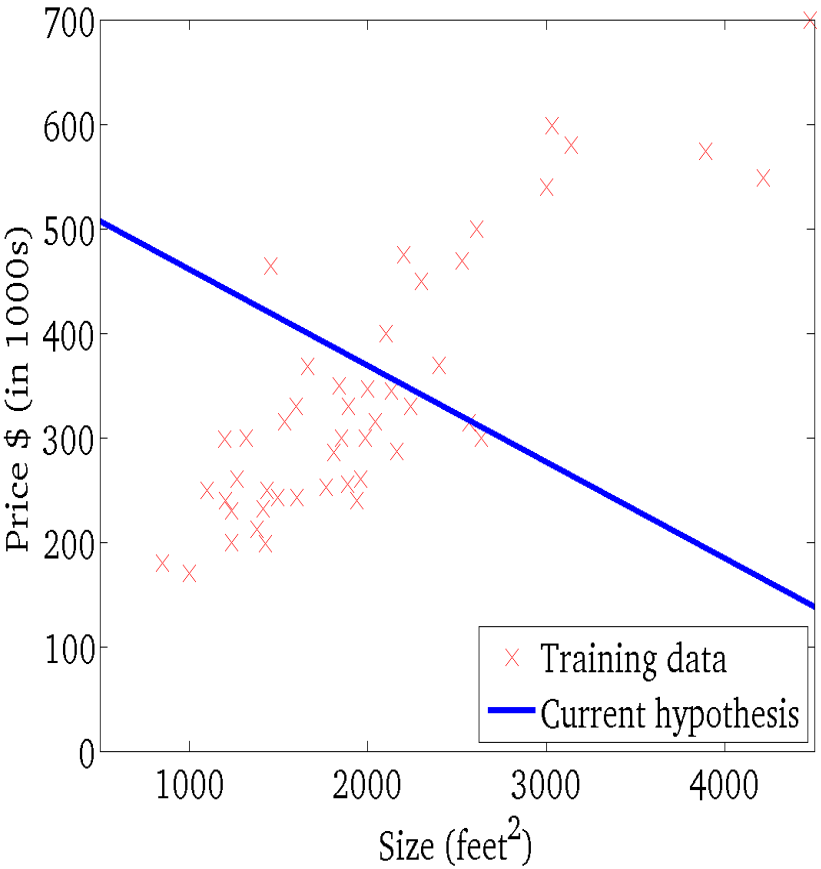

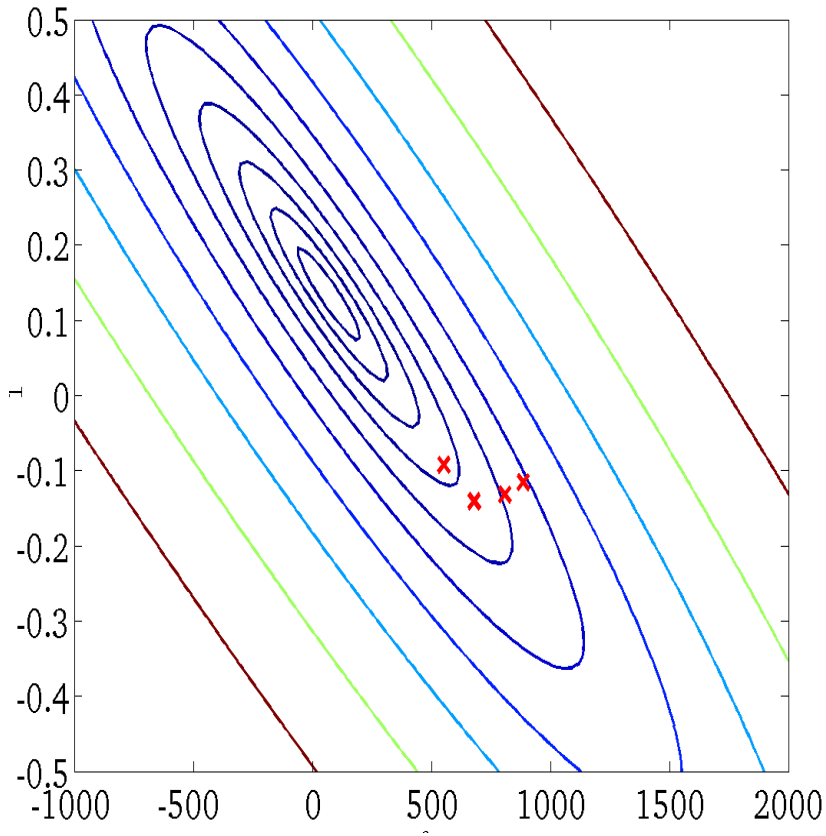

$$f_w(x)$$

(for fixed w_0, w_1, this is a function of x)

$$J(w)$$

(function of the parameters w_0, w_1)

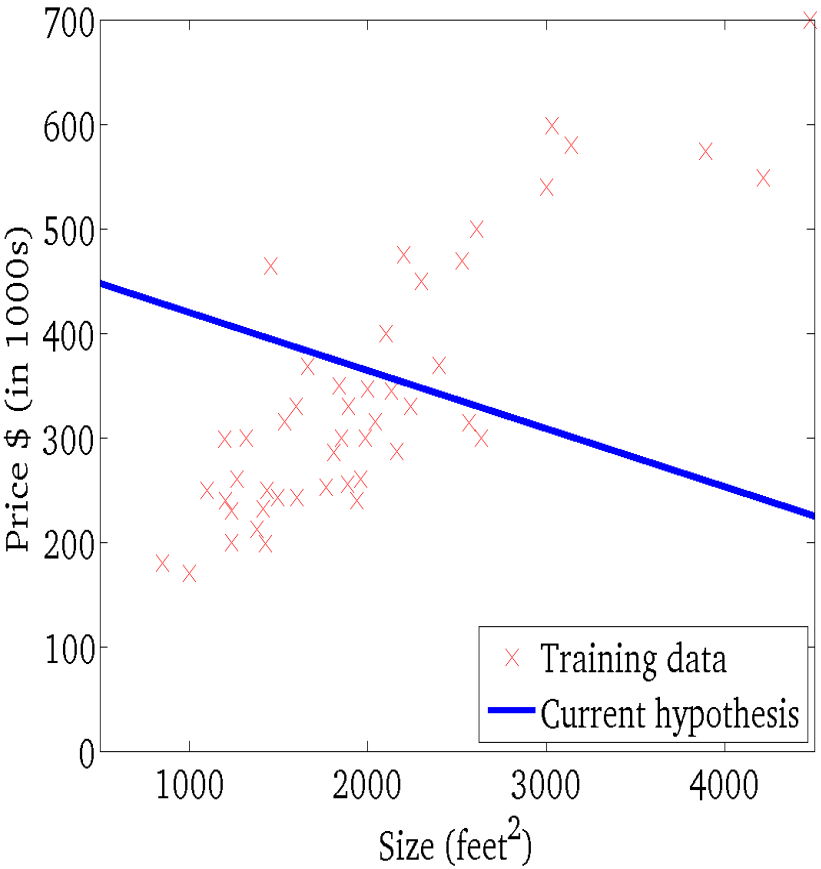

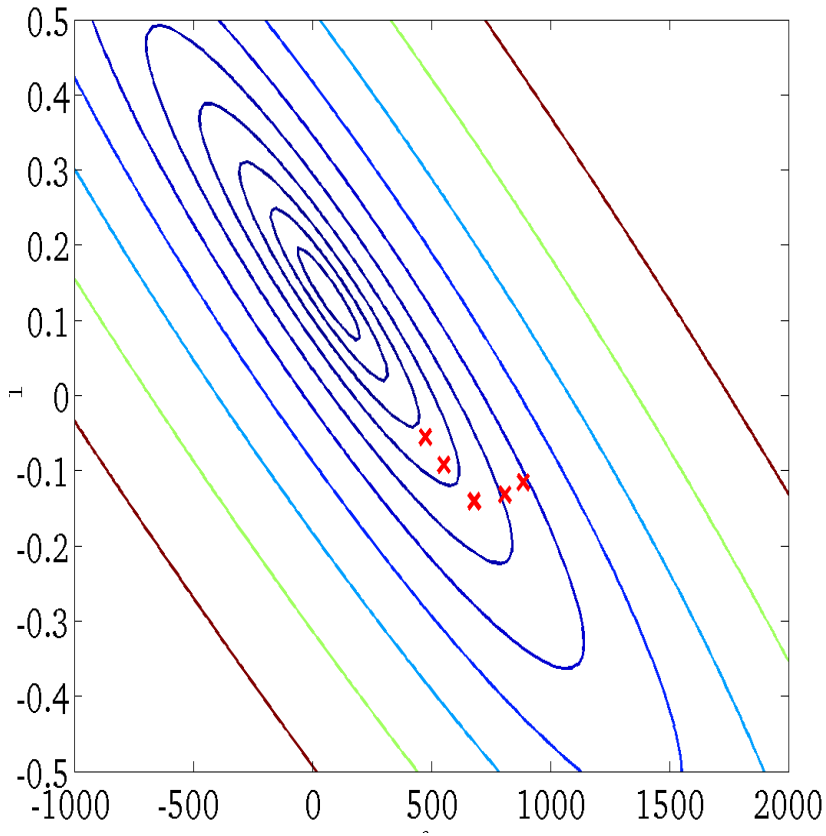

$$f_w(x)$$

(for fixed w_0, w_1, this is a function of x)

$$J(w)$$

(function of the parameters w_0, w_1)

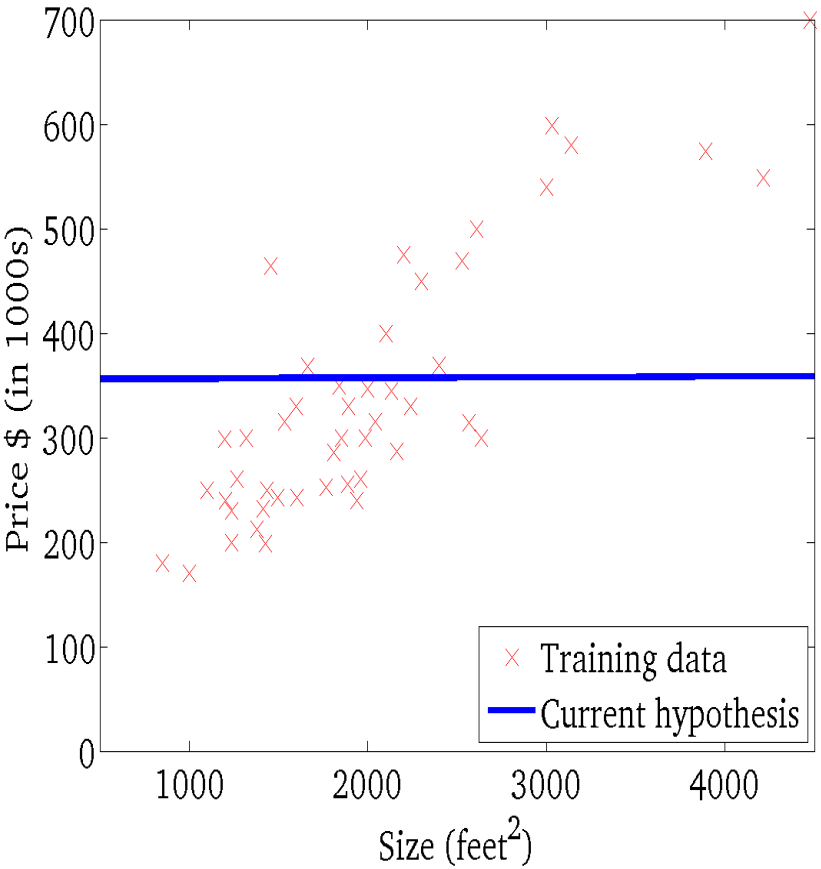

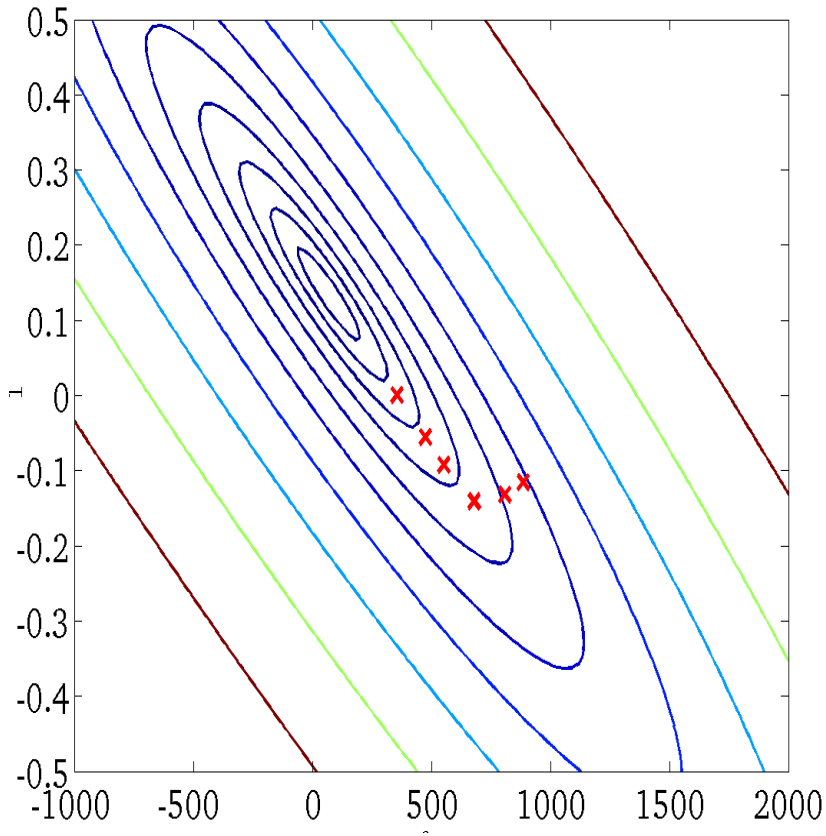

$$f_w(x)$$

(for fixed w_0, w_1, this is a function of x)

$$J(w)$$

(function of the parameters w_0, w_1)

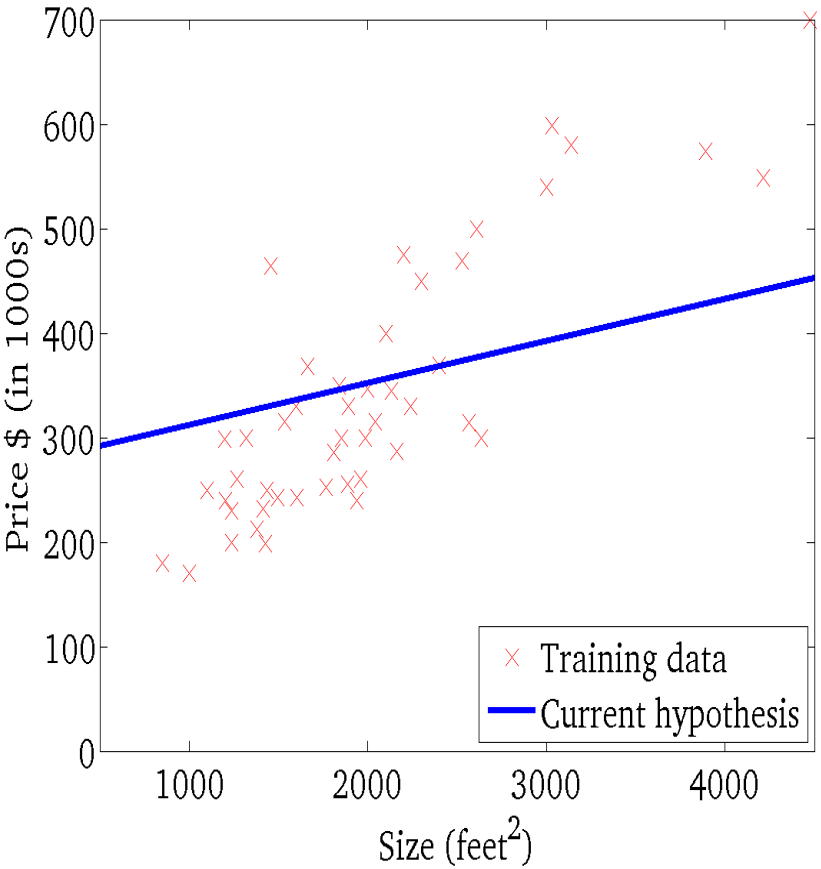

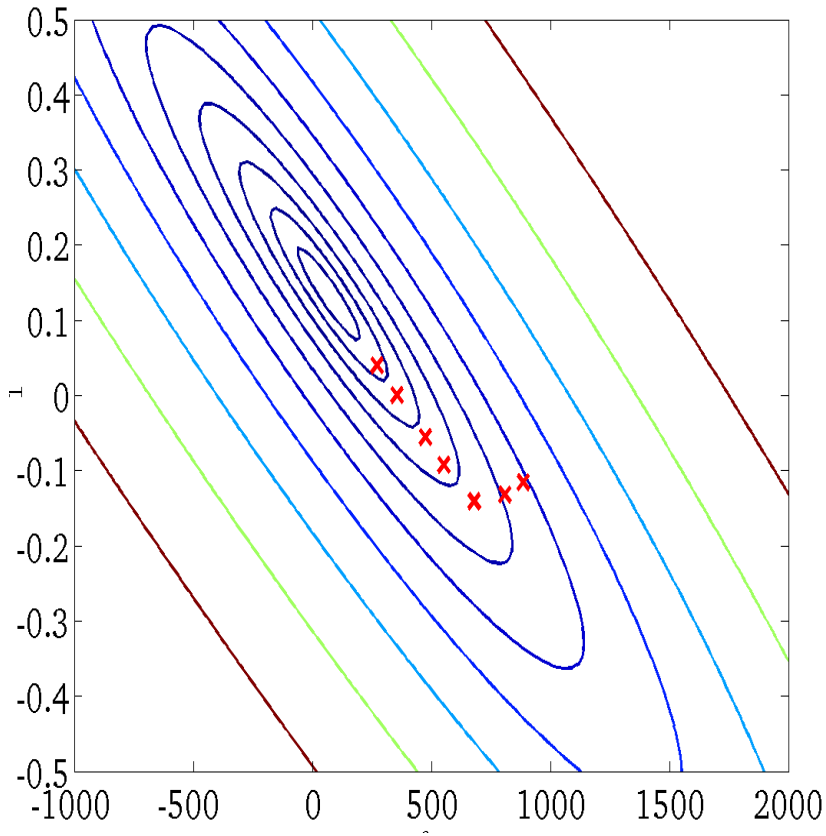

$$f_w(x)$$

(for fixed w_0, w_1, this is a function of x)

$$J(w)$$

(function of the parameters w_0, w_1)

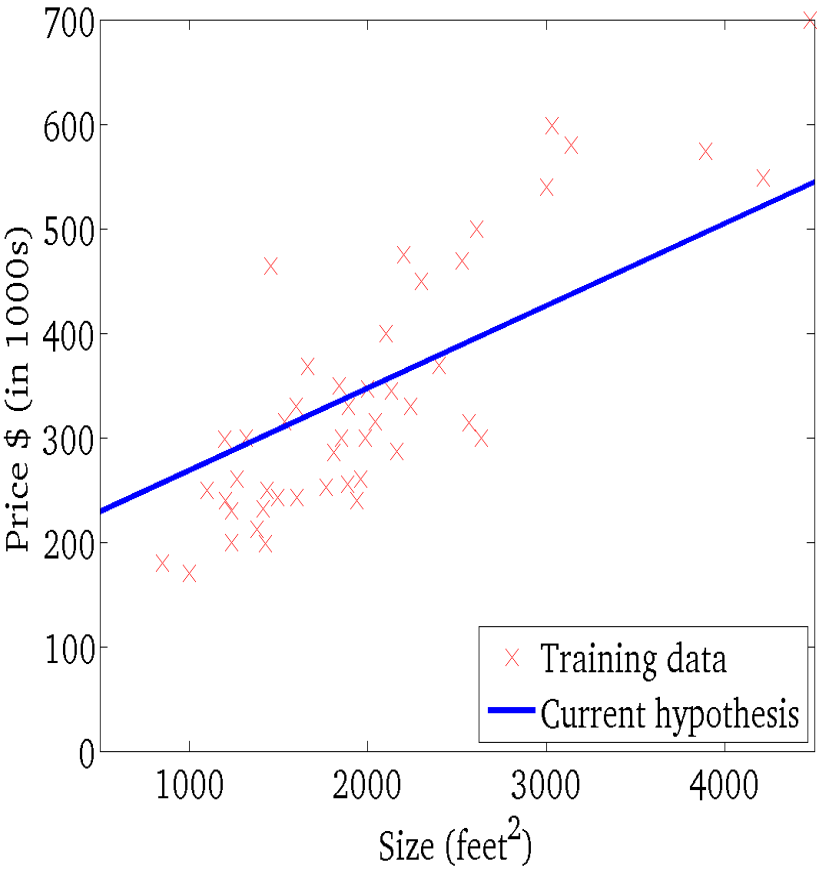

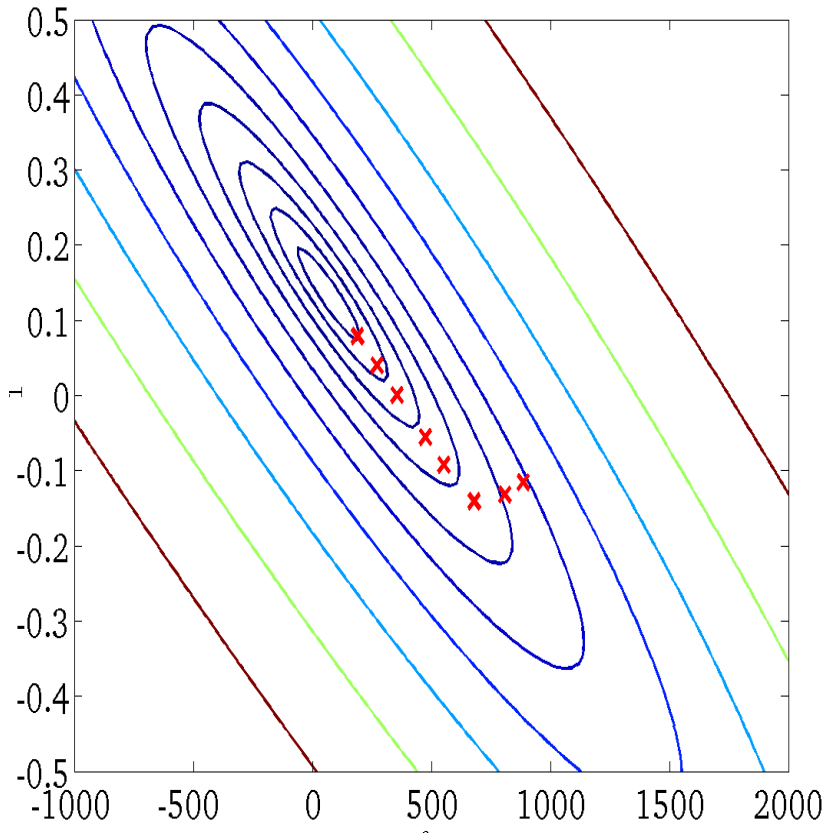

$$f_w(x)$$

(for fixed w_0, w_1, this is a function of x)

$$J(w)$$

(function of the parameters w_0, w_1)

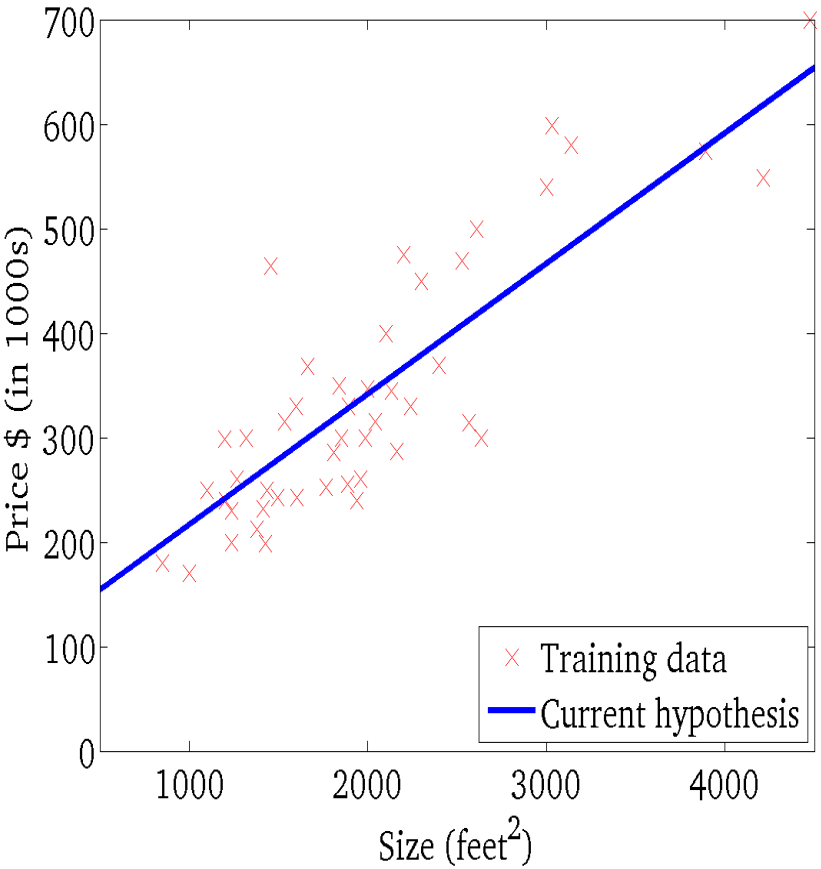

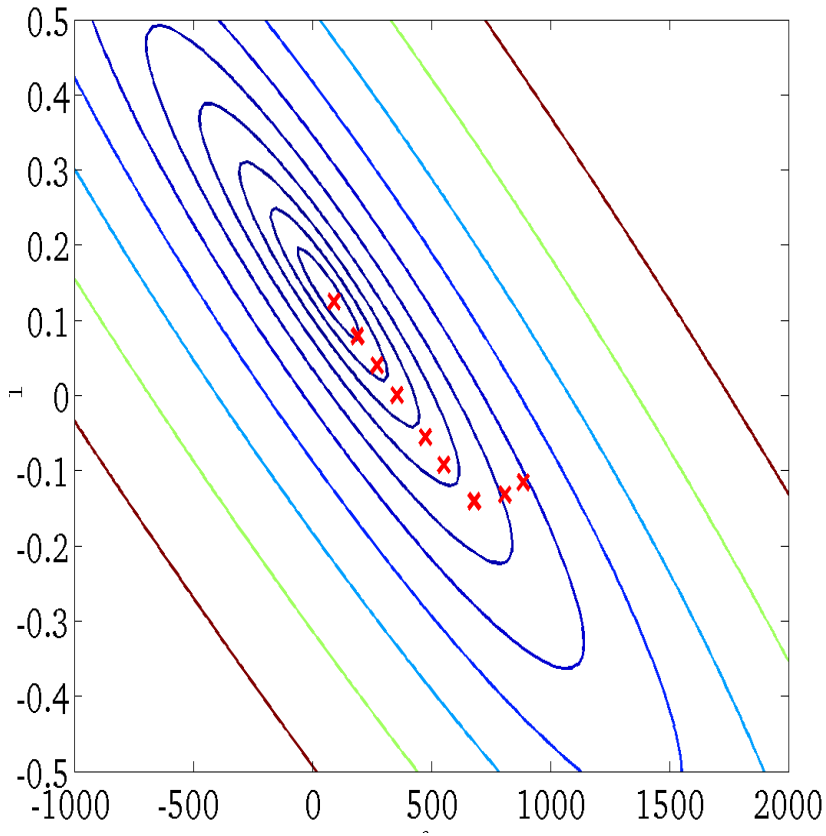

标准方程组
(Normal Equations)

- **目标函数:**

$$J(\mathbf{w}) = \sum_{i=1}^{N} (f(\mathbf{x}_i) - y_i)^2$$
$$= \sum_{i=1}^{N} (\mathbf{w}^T \mathbf{x}_i - y_i)^2$$

- **直接求导，并令其等于0，求得极值**

标准方程组
(Normal Equations)

- 将目标函数写成矩阵形式:

$$
\begin{aligned}
J(\mathbf{w}) &= \sum_{i=1}^{N} (\mathbf{w}^T \mathbf{x}_i - y_i)^2 \\
&= (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y})
\end{aligned}
$$

- 其中

$$
X = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \dots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_{11}, x_{12}, \cdots, x_{1m} \\ x_{21}, x_{22}, \cdots, x_{2m} \\ \vdots \qquad \ddots \\ x_{N1}, x_{N2}, \cdots, x_{Nm} \end{pmatrix} \qquad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}^T
$$

标准方程组
(Normal Equations)

- **求导:**

$$\frac{\partial}{\partial \mathbf{w}} J(\mathbf{w}) = \frac{\partial}{\partial \mathbf{w}} (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y})$$
$$= 2X^T(X\mathbf{w} - \mathbf{y}) = 0$$

$$\Rightarrow X^T X \mathbf{w} = X^T \mathbf{y}$$

- **得到模型的参数:**

$$\hat{\mathbf{w}} = (X^T X)^{-1} X^T \mathbf{y}$$

梯度下降 *vs* 标准方程组

- **梯度下降法：**
  - -需要选择 α
  - -需要迭代多次
  - -需要数据归一化
  - -样本量非常大时也适用

- **标准方程组：**
  - -不需要选择 α
  - -不需要迭代多次
  - -无需数据归一化
  - -样本量大时不适用
    (需要计算 $(X^TX)^{-1}$)

样本量较小时选用标准方程组求解
样本量较大时选用梯度下降法求解

再看曲线拟合

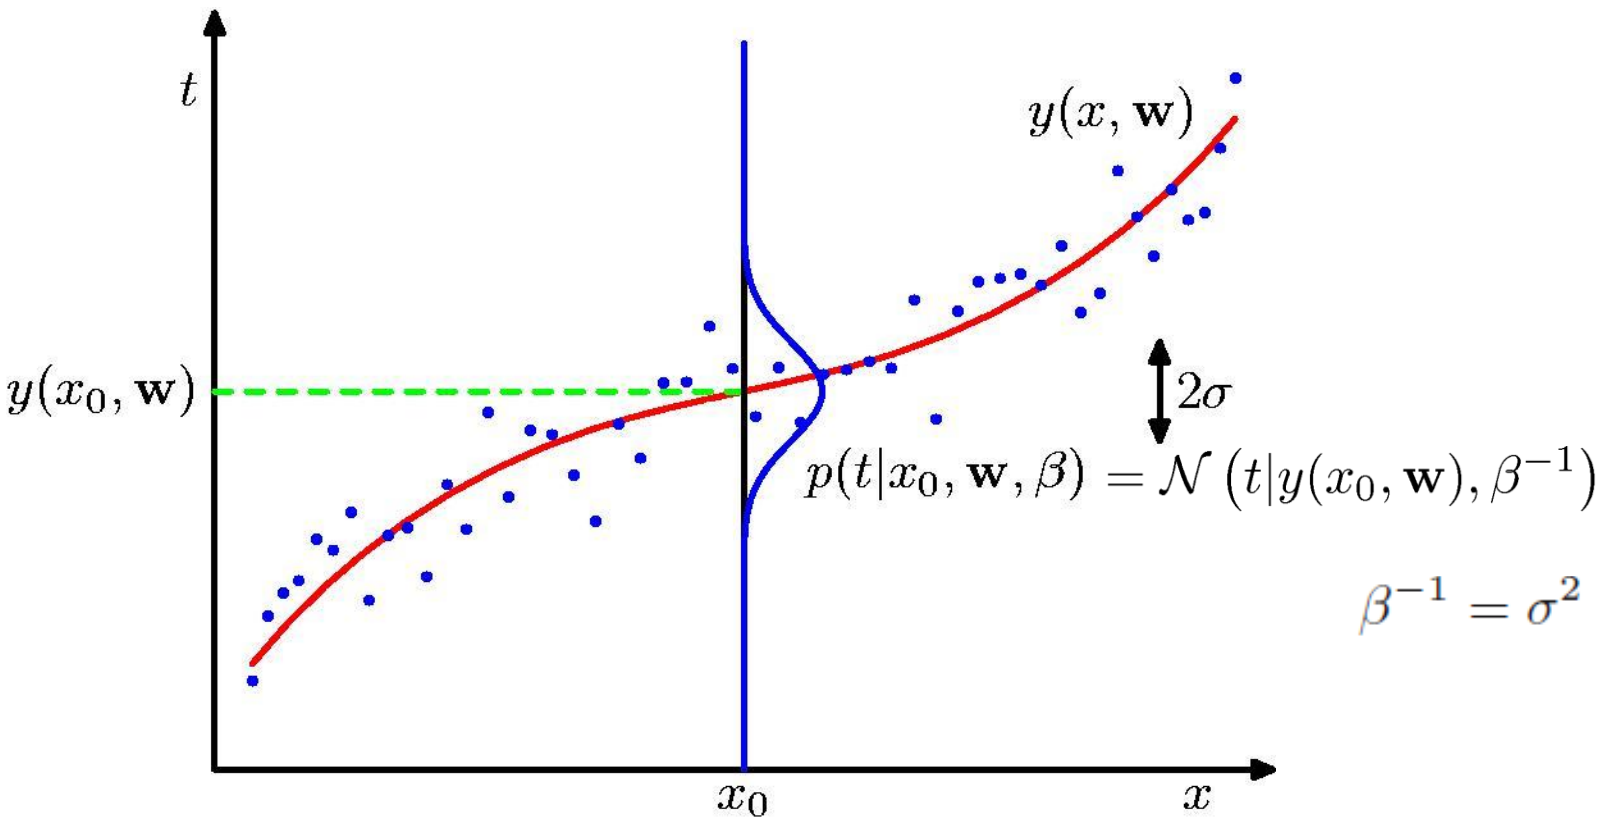
t
$y(x, \mathbf{w})$
$y(x_0, \mathbf{w})$
2σ
$p(t|x_0, \mathbf{w}, \beta) = \mathcal{N}\left(t|y(x_0, \mathbf{w}), \beta^{-1}\right)$
$\beta^{-1} = \sigma^2$
x_0
x

最大似然估计与贝叶斯估计

假定观测数据由确定的函数加高斯噪声组成

$$t = y(\mathbf{x}, \mathbf{w}) + \epsilon \qquad p(\epsilon|\beta) = \mathcal{N}(\epsilon|0, \beta^{-1})$$

- **最大似然估计**：

  把待估计的参数看做是确定的量，只是其取值未知。最佳估计就是使得产生以观测到的样本的概率最大的那个值。

- **贝叶斯估计**：

  把待估计的参数看做是符合某种先验概率分布的随机变量。对样本进行观测的过程，就是把先验概率密度转化为后验概率密度，从而利用样本信息修正了对参数的初始估计值。

模型求解

- **最大似然估计(*w*是确定量)**

$$p(\mathbf{t}|\mathbf{x},\mathbf{w},\beta)=\prod_{n=1}^{N}\mathcal{N}\left(t_n|y(x_n,\mathbf{w}),\beta^{-1}\right)$$

$$\frac{1}{\beta_{\mathrm{ML}}}=\frac{1}{N}\sum_{n=1}^{N}\{y(x_n,\mathbf{w}_{\mathrm{ML}})-t_n\}^2$$

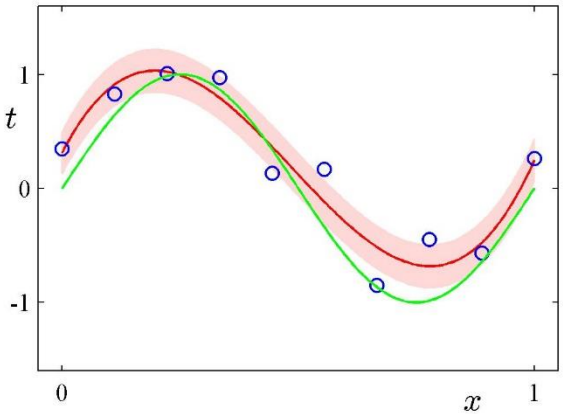

- **贝叶斯估计(*w*是随机量)**

$$p(t|x,\mathbf{x},\mathbf{t})=\int p(t|x,\mathbf{w})p(\mathbf{w}|\mathbf{x},\mathbf{t})\,\mathrm{d}\mathbf{w}=\mathcal{N}\left(t|m(x),s^2(x)\right)$$

$$m(x)=\beta\boldsymbol{\phi}(x)^{\mathrm{T}}\mathbf{S}\sum_{n=1}^{N}\boldsymbol{\phi}(x_n)t_n$$

$$s^2(x)=\beta^{-1}+\boldsymbol{\phi}(x)^{\mathrm{T}}\mathbf{S}\boldsymbol{\phi}(x)$$

$$\mathbf{S}^{-1}=\alpha\mathbf{I}+\beta\sum_{n=1}^{N}\boldsymbol{\phi}(x_n)\boldsymbol{\phi}(x_n)^{\mathrm{T}}\quad\boldsymbol{\phi}(x_n)=\left(x_n^0,\ldots,x_n^M\right)^{\mathrm{T}}$$

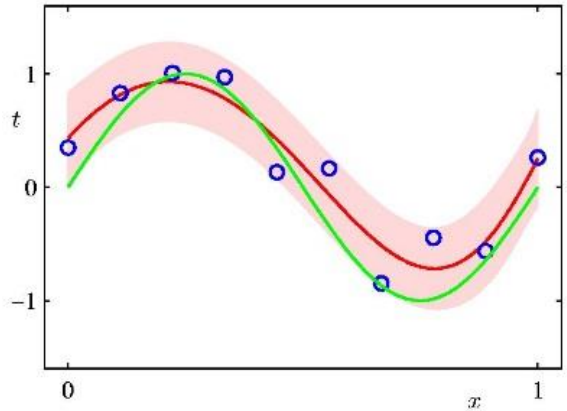

机器学习算法

机器学习主要问题

	Supervised Learning	Unsupervised Learning
Discrete	Classification or Categorization	Clustering
Continuous	Regression	Dimensionality Reduction

从贝叶斯分类说起

- **样本(Sample)** $\mathbf{x} \in R^d$
- **状态(State) 第一类:** $w = w_1$ **第二类:** $w = w_2$
- **先验概率(A Priori Probability or Prior)** $P(w_1)$ $P(w_2)$
- **样本分布密度(Sample Distribution Density)** $p(\mathbf{x})$
- **类条件概率密度(Class-Conditional Probability Density)**

$$p(\mathbf{x}|w_1) \qquad p(\mathbf{x}|w_2)$$

从贝叶斯分类说起

- **后验概率(A Posteriori Probability or Posterior)**

$$P(w_1|\mathbf{x}), P(w_2|\mathbf{x})$$

- **错误概率(Probability of Error)**

$$P(e|\mathbf{x}) \begin{cases} P(w_2|\mathbf{x}) \text{ if } \mathbf{x} \text{ is assigned to } w_1 \\ P(w_1|\mathbf{x}) \text{ if } \mathbf{x} \text{ is assigned to } w_2 \end{cases}$$

- **平均错误率(Average Probability of Error)**

$$P(e) = \int P(e|\mathbf{x})p(\mathbf{x})d\mathbf{x}$$

- **正确率(Probability of Correctness)** $P(c)$

基于最小错误率的决策

$$\min \quad P(e) = \int P(e|x)p(x)dx$$

因为 $P(e|\mathbf{x}) \geq 0,\ p(x) \geq 0$

$$\longrightarrow \quad \min P(e|\mathbf{x}) \text{ for all } x$$

而 $$P(e|\mathbf{x}) \begin{cases} P(w_2|\mathbf{x}), & \text{if } P(w_1|\mathbf{x}) > P(w_2|\mathbf{x}) \\ P(w_1|\mathbf{x}), & \text{if } P(w_2|\mathbf{x}) > P(w_1|\mathbf{x}) \end{cases}$$

$$\text{if } P(w_1|\mathbf{x}) \begin{matrix} > \\ < \end{matrix} P(w_2|\mathbf{x}) \text{ assign } \begin{matrix} x \in w_1 \\ x \in w_2 \end{matrix}$$

$$P(w|\mathbf{x}) = \max_{j=1,\ldots,c} P(w_j|\mathbf{x})$$

基于最小风险的决策

条件期望损失：对于特定的*x*采取决策 α_i 的期望损失：

$$R(\alpha_i|x) = E[\lambda(\alpha_i, w_j)|x] = \sum_{j=1}^{c} \lambda(\alpha_i, w_j) P(w_j|x), \ i = 1, 2, ..., k$$

期望风险：对所有可能的*x*采取决策 $\alpha(x)$ 所造成的期望损失之和

$$R(\alpha) = \int R(\alpha(x)|x) p(x) dx$$

也称平均风险($R(\alpha)$**表示*R*依赖于决策规则**$\alpha(\cdot)$**)**

对所有*x*，使 $R(\alpha(x)|x)$ 最小，则可以使 $R(\alpha)$ 最小

最小风险贝叶斯决策规则：

$$\text{if } R(\alpha_t|x) = \min_{j=1...k} R(\alpha_j|x), \text{then } \alpha = \alpha_t$$

示例-基于最小错误率

- 假设在某个局部区域细胞中正常(w_1)和异常(w_2)两类的先验概率分别为：正常状态 $P(w_1)=0.9$, 异常状态 $P(w_2)=0.1$。现有一待识别细胞，其观察值为x，从类条件概率密度曲线上查得 $p(x|w_1)=0.2$，$p(x|w_2)=0.4$。试对该细胞x进行分类。

解：利用贝叶斯公式计算w_1和w_2的后验概率

$$P(w_1|x)=\frac{p(x|w_1)P(w_1)}{\sum_{j=1}^{2}p(x|w_j)P(w_j)}=\frac{0.2\times0.9}{0.2\times0.9+0.4\times0.1}=0.818$$

$$P(w_2|x)=1-P(w_1|x)=0.182$$

根据贝叶斯决策规则有

$$P(w_1|x)=0.818>P(w_2|x)=0.182$$

把x归类于正常细胞。

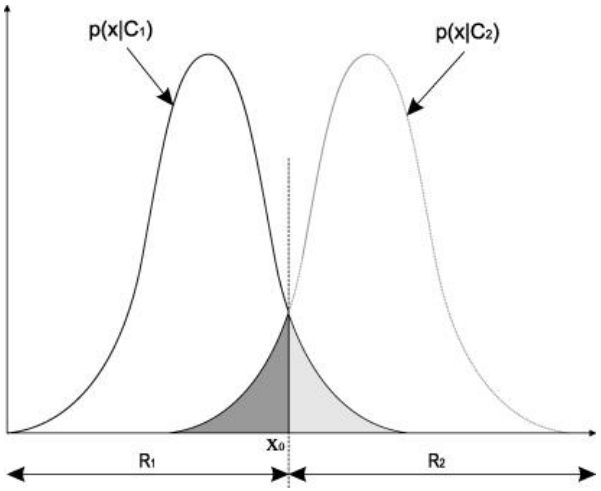

示例-基于最小风险

- **决策表**

决策 \ 损失 \ 状态	w_1	w_2
α_1	0	6
α_2	1	0

解： $\lambda_{11}=0, \lambda_{12}=6, \lambda_{21}=1, \lambda_{22}=0$ $P(w_1|x)=0.818$ $P(w_2|x)=0.182$

计算条件风险 $R(\alpha_1|x)=\sum_{j=1}^{2}\lambda_{1j}P(w_j|x)=\lambda_{12}P(w_2|x)=1.092$

$$R(\alpha_2|x)=\lambda_{21}P(w_1|x)=0.818$$

由于 $R(\alpha_1|x)>R(\alpha_2|x)$

把*x*归类于异常细胞。

小结

- 已知类条件概率密度 $p(\mathbf{x}|w_i)$ 和先验概率 $P(w_i)$，计算后验概率 $P(w_i|\mathbf{x})$ 进行决策

若类条件概率密度参数未知?

- 已知类条件概率密度 $p(\mathbf{x}|w_i)$ 的参数表达式，利用样本估计 $p(\mathbf{x}|w_i)$ 的未知参数，再利用贝叶斯定理将其转化成后验概率 $P(w_i|\mathbf{x})$ 进行决策

若类条件概率密度形式难以确定?

- 非参数方法估计

需要大量样本…

线性判别函数

- 利用样本集直接设计分类器

线性回归： $y(x) = w^T x + w_0$

利用样本估计*w*，对于给定*x*，计算*y*。

$$y(x) = f(w^T x + w_0) \quad f(a) = \begin{cases} +1, & a \geqslant 0 \\ -1, & a < 0 \end{cases}$$

$$w^T x + w_0 \geq 0 \Rightarrow C_1$$

$$w^T x + w_0 \leq 0 \Rightarrow C_2$$

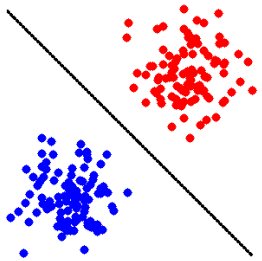

将分类器设计问题转化为求准则函数极值的问题

准则函数：分类器设计的某些要求的函数形式

线性判别函数

- **两类情况下线性判别函数** $g(x) = w^T x + w_0$

$x=\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$ **特征向量/样本向量；** $w=\begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix}$ **权向量；** $\boldsymbol{w_0}$**阈值权 (常数)**

令 $g(x) = g_1(x) - g_2(x)$

如果 $\begin{cases} \boldsymbol{g(x) > 0, x \in w_1} \\ \boldsymbol{g(x) < 0, x \in w_2} \\ \boldsymbol{g(x) = 0}, \text{可将}\boldsymbol{x}\text{分到任意一类或拒绝} \end{cases}$

***g*(*x*)=0定义了一个决策面，当*g*(*x*)为线性函数时，决策面就是超平面。**

线性判别函数

如果x_1和x_2都在决策面H上，则有

$$w^T x_1 + w_0 = w^T x_2 + w_0$$

即

$$w^T(x_1 - x_2) = 0$$

说明w和超平面H上任一向量正交，即w是H的法向量。

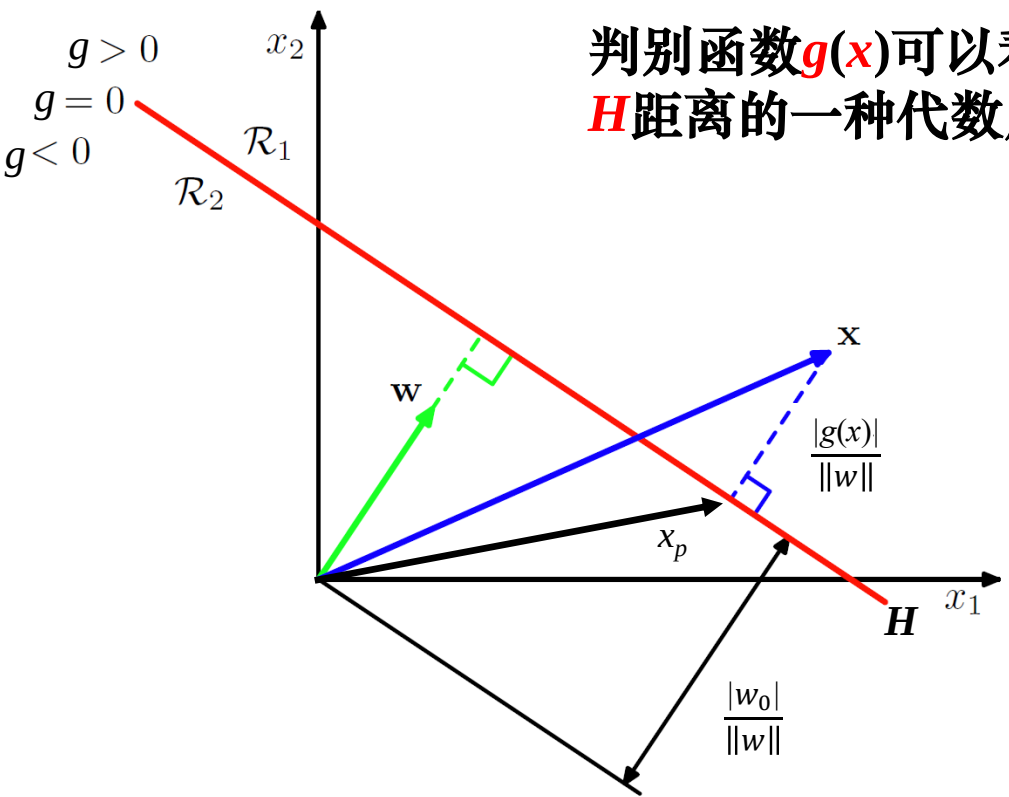

判别函数$g(x)$可以看成是特征空间中某点x到超平面H距离的一种代数度量

$$x = x_p + r\frac{w}{\|w\|}$$

x_p： x在H上的投影向量

r： x到H上的垂直距离

$\frac{w}{\|w\|}$：是w方向上的单位向量

$$g(x) = w^T\left(x_p + r\frac{w}{\|w\|}\right) + w_0$$

$$= w^T x_p + r\frac{w^T w}{\|w\|} + w_0 = r\|w\|$$

$$r = \frac{g(x)}{\|w\|}$$

线性判别函数

若x为原点，则 $g(x) = w_0$

从原点到超平面H的距离 $r_0 = \frac{w_0}{\|w\|}$

如果 $w_0 > 0$, 则原点在H的正侧

如果 $w_0 < 0$, 则原点在H的负侧

如果 $w_0 = 0$, 则$g(x)$具有齐次形式，超平面H通过原点

超平面H的方向由**权向量w**决定；其位置由**阈值权w_0**确定。

判别函数**$g(x)$**正比于 x 点到超平面的代数距离

当x在H的正侧时，$g(x) > 0$

当x在H的负侧时，$g(x) < 0$

广义线性判别函数

- 两类问题, X是一维样本空间

不适用于非凸和多连通区域划分

若 $x < a$ 或 $x > b$, $x \in w_1$

若 $a < x < b$, $x \in w_2$

如果建立 $g(x) = (x-a)(x-b)$

决策规则 $\begin{cases} \boldsymbol{g(x) > 0, x \in w_1} \\ \boldsymbol{g(x) < 0, x \in w_2} \end{cases}$

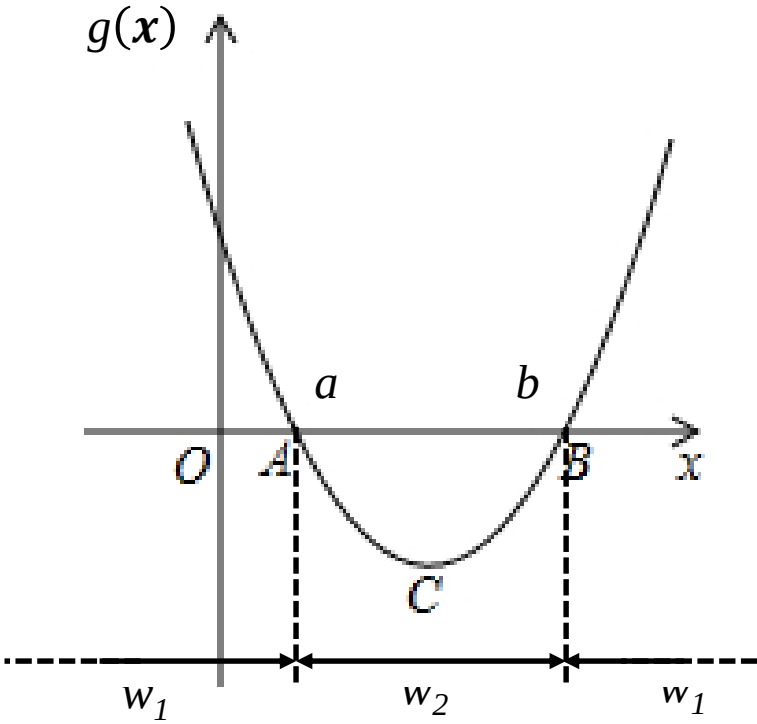

一般形式 $g(x) = c_0 + c_1 x + c_2 x^2$

可转化为 $g(x) = a^T y = \sum_{i=1}^{3} a_i y_i$

$$y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} 1 \\ x \\ x^2 \end{bmatrix} \qquad a = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix}$$

称 $g(x) = a^T y$ 广义线性判别函数

a 广义权向量

利用线性函数的简单性解决复杂问题

维数大大增加→“维数灾难”

线性判别函数齐次化

- **线性判别函数** $g(x) = w^T x + w_0$

  改写成 $g(x) = w_0 + \sum_{i=1}^{d} w_i x_i = \sum_{i=1}^{d} a_i y_i = a^T y$

  称为线性判别函数的齐次简化

  $y = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} = \begin{bmatrix} 1 \\ x \end{bmatrix}$**增广样本向量；** $a = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix} = \begin{bmatrix} w_0 \\ w \end{bmatrix}$**增广权向量**

  $\hat{d} = d + 1$; ***y*比*x*增加一维，保持样本空间欧式距离不变，变换后的样本仍全部位于*d*维子空间(原*X*空间)中。**

  方程 $a^T y = 0$ **在*Y*空间确定了一个通过原点的超平面$\hat{H}$, 它对*d*维子空间的划分与原决策面**$w^T x + w_0 = 0$ **对原*X*空间的划分完全相同。*Y*空间中任意一点*y*到$\hat{H}$的距离:**

  $$r = \frac{g(x)}{\|a\|} = \frac{a^T y}{\|a\|}$$

线性分类器设计

- 利用训练样本建立线性判别函数

$$g(x) = \boxed{w^T} x + \boxed{w_0}$$

$$g(x) = w_0 + \sum_{i=1}^{d} w_i x_i = \sum_{i=1}^{d} a_i y_i = \boxed{a^T} y$$

最好的结果一般出现在准则函数的极值点上，所以**将分类器设计问题转化为求准则函数极值** w^*, w_0^* **或** a^* **的问题。**

步骤1： 具有类别标志的样本集$\mathcal{X} = \{x_1, x_2, \dots x_N\}$或其增广样本集$\mathcal{Y}$。

步骤2： 确定准则函数$\mathcal{J}$，满足①$\mathcal{J}$是样本集和w, w_0或a的函数；②$\mathcal{J}$的值反应分类器的性能，其极值对应“最好”的决策。

步骤3： 优化求解准则函数极值w^*, w_0^* 或a^* 。

最终得到线性判别函数：$g(x) = w^{*T} x + w_0^*$ 或 $g(x) = a^{*T} y$ ，对于未知类别样本x_k，计算$g(x_k)$并通过决策规则判断其类别。

准则函数

- Fisher准则
- 感知机准则
- 最小平方误差准则
- 最小错分样本数准则
- …

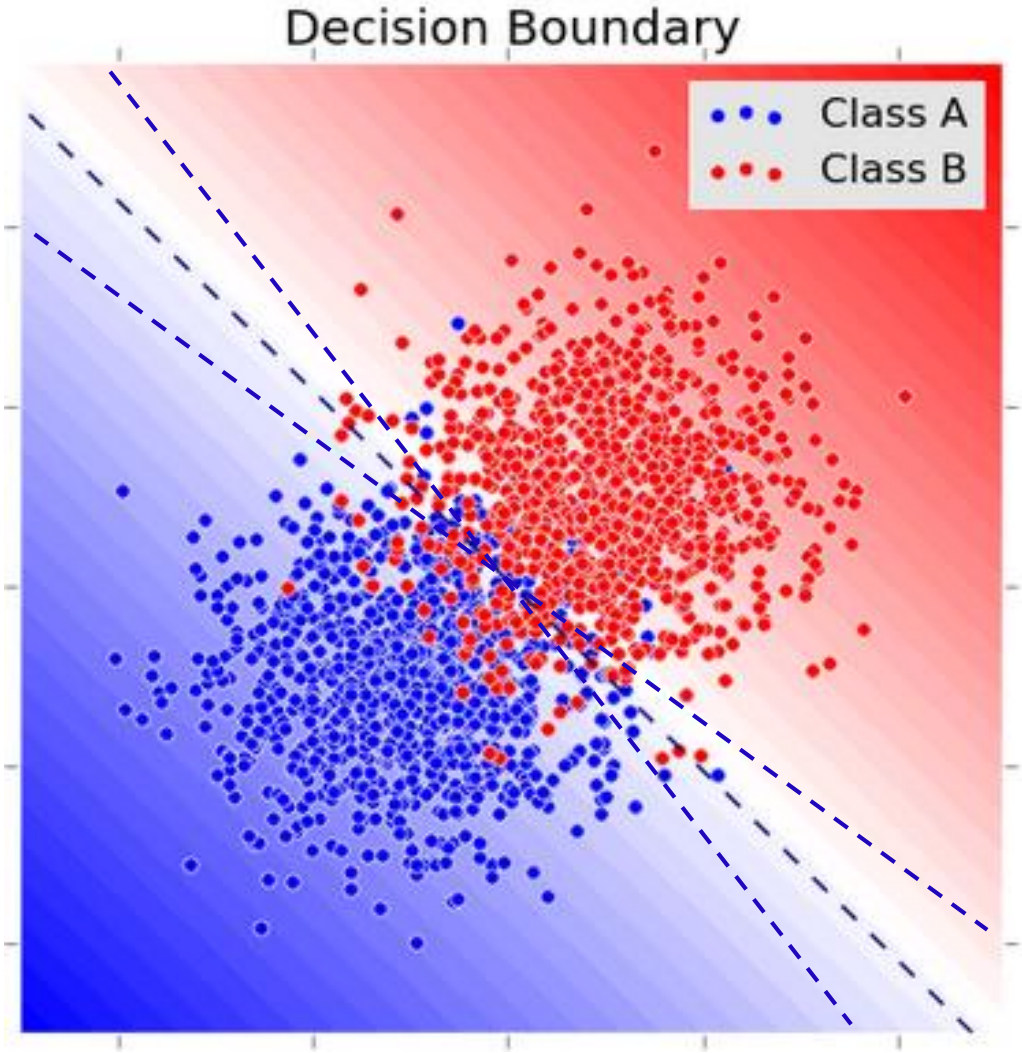

Fisher准则

- **R. A. Fisher (1936年论文)**

考虑把 *d* 维空间的样本投影到一条直线上形成一维空间。在一般情况下总可以找到某个方向，使样本在这个方向的直线上的投影分开得最好。

Fisher准则就是要解决
如何根据实际情况找到这条最好的、最易于分类的投影线的问题

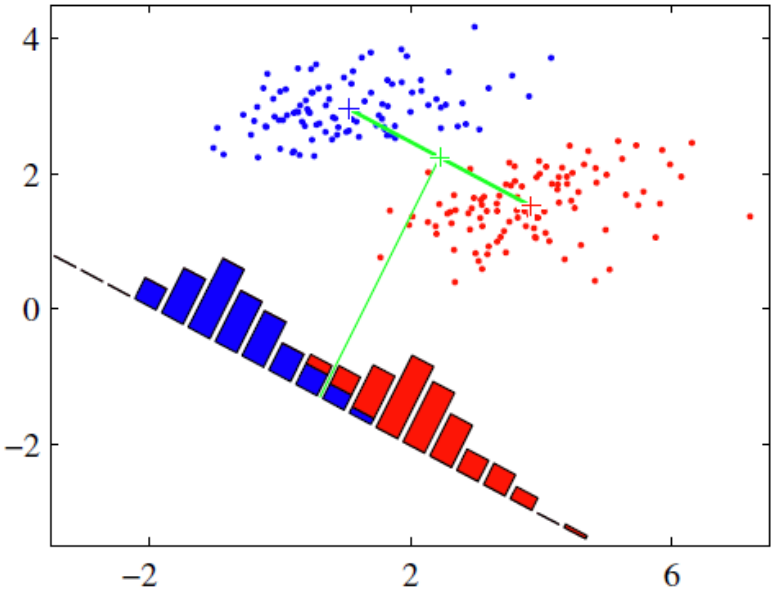

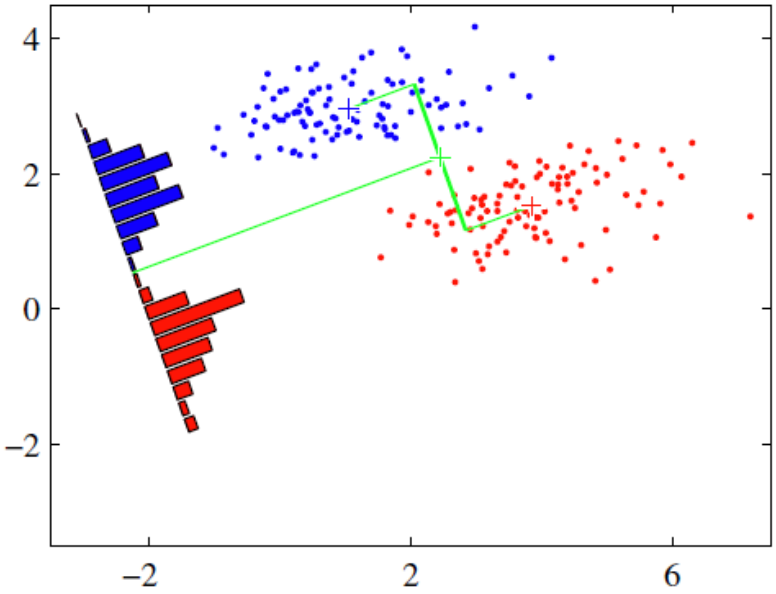

Fisher准则

- **寻找最好投影方向** w^*

以二分类问题为例，*d*维样本$x_1, x_2, \ldots x_N$, 其中N_1个属于w_1类记为子集X_1, N_2个属于w_2类记为子集X_2。

在*d*维*X*空间

(1)各类样本的均值向量m_i $m_i = \frac{1}{N_i} \sum_{x \in \chi_i} x, i = 1, 2$

(2)样本类内离散度矩阵S_i和总类内离散度矩阵S_w

$$S_i = \sum_{x \in \chi_i} (x - m_i)(x - m_i)^T, i = 1, 2$$

$$S_w = S_1 + S_2$$

$$S_w = P(w_1)S_1 + P(w_1)S_2$$

(3)样本类间离散度矩阵S_b

$$S_b = (m_1 - m_2)(m_1 - m_2)^T$$

$$S_b = P(w_1)P(w_2)(m_1 - m_2)(m_1 - m_2)^T$$

Fisher准则

- **寻找最好投影方向** w^*

以二分类问题为例，*d*维样本$x_1, x_2, \ldots x_N$, 其中N_1个属于w_1类记为子集X_1, N_2个属于w_2类记为子集X_2。

在一维*Y*空间

$$y_n = w^T x_n$$

(1)各类样本均值$\widetilde{m}_i$

$$\tilde{m}_i = \frac{1}{N_i} \sum_{y \in \eta_i} y, i = 1, 2$$

(2)样本类内离散度$\widetilde{S}_i^2$和总类内离散度$\widetilde{S}_w$

$$\tilde{S}_i^2 = \sum_{y \in \eta_i} (y - \tilde{m}_i)^2, i = 1, 2$$

$$\tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2$$

Fisher准则

- 希望投影后在一维Y空间中各类样本尽可能分开，即两类均值之差$(\tilde{m}_1-\tilde{m}_2)$越大越好；同时希望各类样本内部尽量密集，即类内离散度越小越好。

Fisher准则函数：$J_F(w)=\frac{(\tilde{m}_1-\tilde{m}_2)^2}{\tilde{S}_1^2+\tilde{S}_2^2}$

Fisher准则

- 求$J_F(w)$取得最大值的w $J_F(w)=\frac{(\tilde{m}_1-\tilde{m}_2)^2}{\tilde{S}_1^2+\tilde{S}_2^2}$

$$\tilde{m}_i=\frac{1}{N_i}\sum_{y\in\eta_i}y=\frac{1}{N_i}\sum_{x\in\chi_i}w^Tx=w^T(\frac{1}{N_i}\sum_{x\in\chi_i}x)=w^Tm_i$$

$$(\tilde{m}_1-\tilde{m}_2)^2=(w^Tm_1-w^Tm_2)^2=w^T(m_1-m_2)(m_1-m_2)^Tw=w^TS_bw$$

$$\tilde{S}_i^2=\sum_{y\in\eta_i}(y-\tilde{m}_i)^2=\sum_{x\in\chi_i}(w^Tx-w^Tm_i)^2=w^T[\sum_{x\in\chi_i}(x-m_i)(x-m_i)^T]w=w^TS_iw$$

$$\tilde{S}_1^2+\tilde{S}_2^2=w^T(S_1+S_2)w=w^TS_ww \Rightarrow J_F(w)=\frac{w^TS_bw}{w^TS_ww}$$

Lagrange乘子法求解：

$$w^*=S_w^{-1}(m_1-m_2)$$

分类时确定分界阈值y_0，与 $y=w^{*T}x$ 比较进行决策。

感知机准则

- F. Rosenblatt(1950-1960年提出)

感知准则是一种自学习判别函数生成方法，由于Rosenblatt试图将其用于脑模型感知器，因此得名。该方法对随意给定的判别函数初始值，通过样本分类训练过程逐步对其修正直至最终确定。

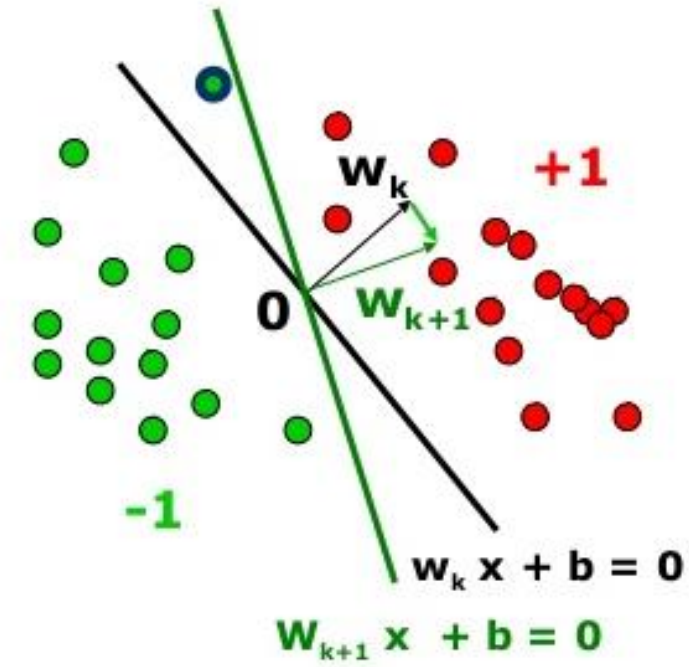

几个基本概念

- **线性可分性**

一组容量为N的样本集$y_1, y_2, \ldots y_N$, 其中y_n为$\hat{d}$维增广样本向量, 分别来自w_1类和w_2类, 如果存在权向量a, 使得对于任何$y \in w_1$, 都有$a^T y > 0$, 而对于任何$y \in w_2$, 都有$a^T y < 0$, 则称这组样本为线性可分的, 反之亦然成立。

- **样本的规范化**

$$\begin{cases} a^T y_i > 0, y_i \in w_1 \\ a^T y_j < 0, y_j \in w_2 \end{cases}$$

$$y_n' = \begin{cases} y_i > 0, y_i \in w_1 \\ -y_j < 0, y_j \in w_2 \end{cases}$$

规范化增广样本向量

$$a^T y_n' > 0, n = 1, 2, \ldots, N$$

几个基本概念

- 解向量和解区

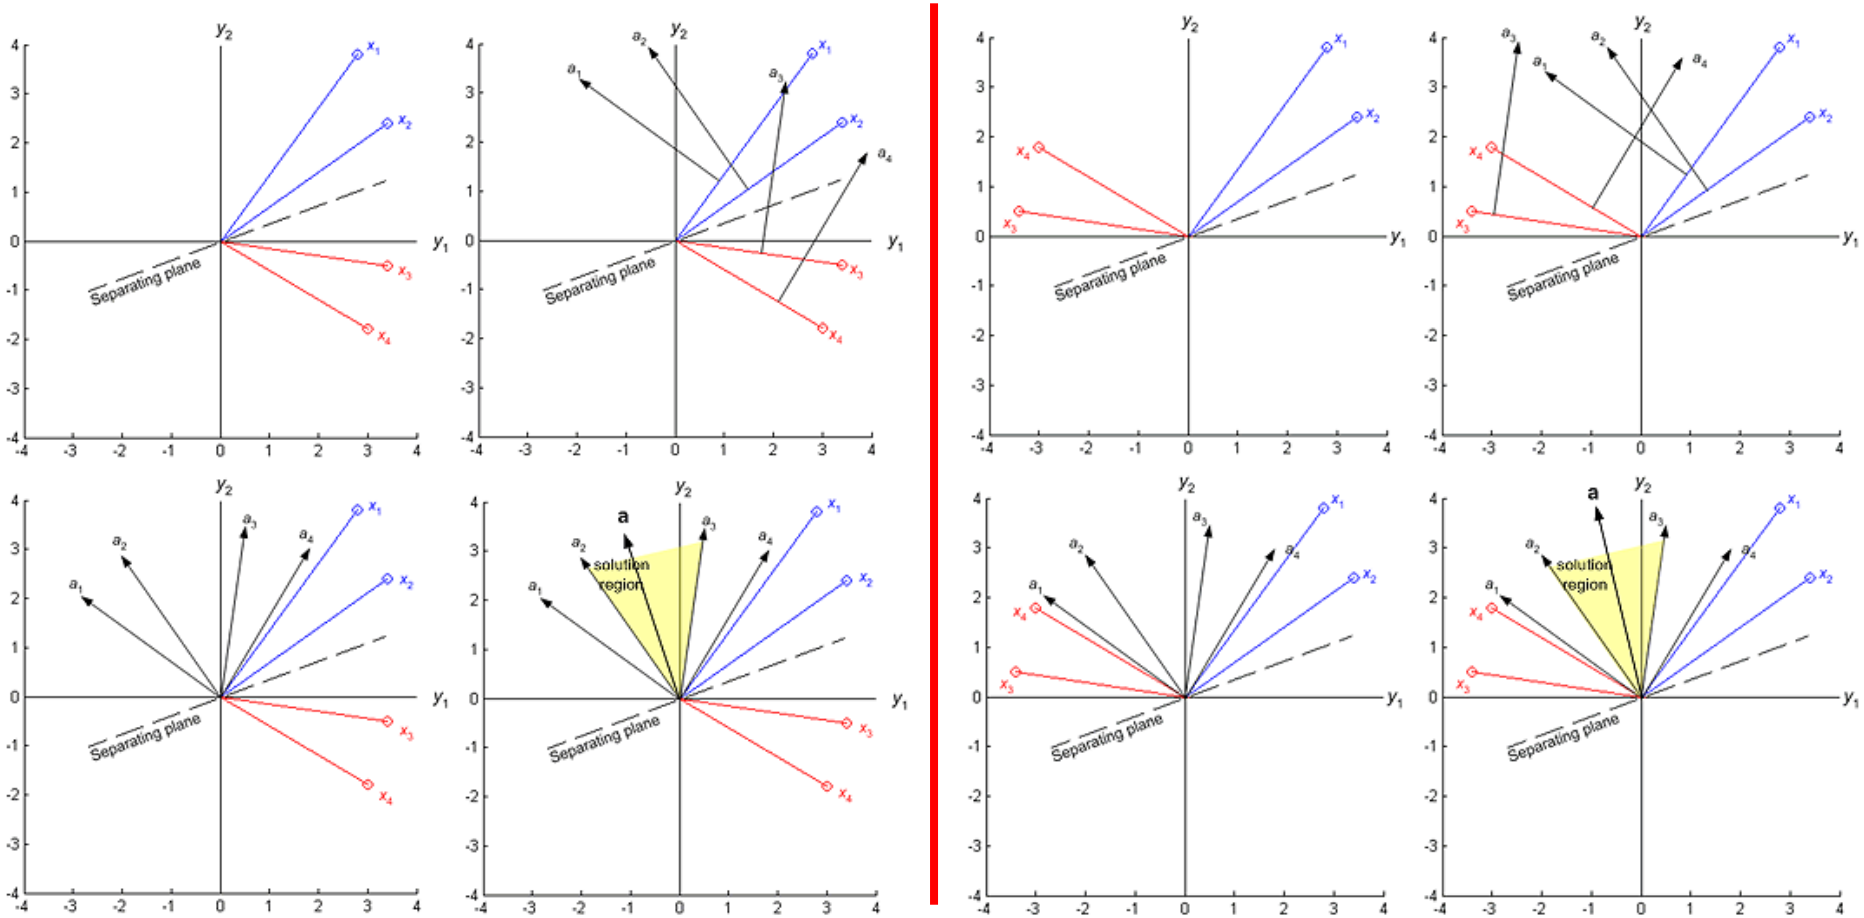

未规范化　　规范化

几个基本概念

- **对解区的限制**

使解向量更可靠 $a^T y_n \geq b > 0$**，避免解收敛到解区边界的某点上**

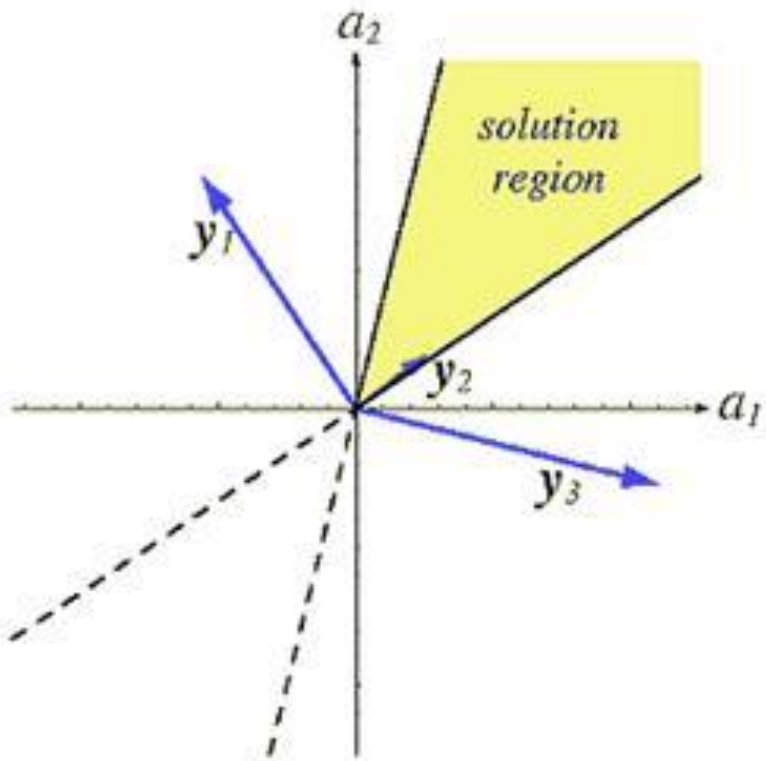

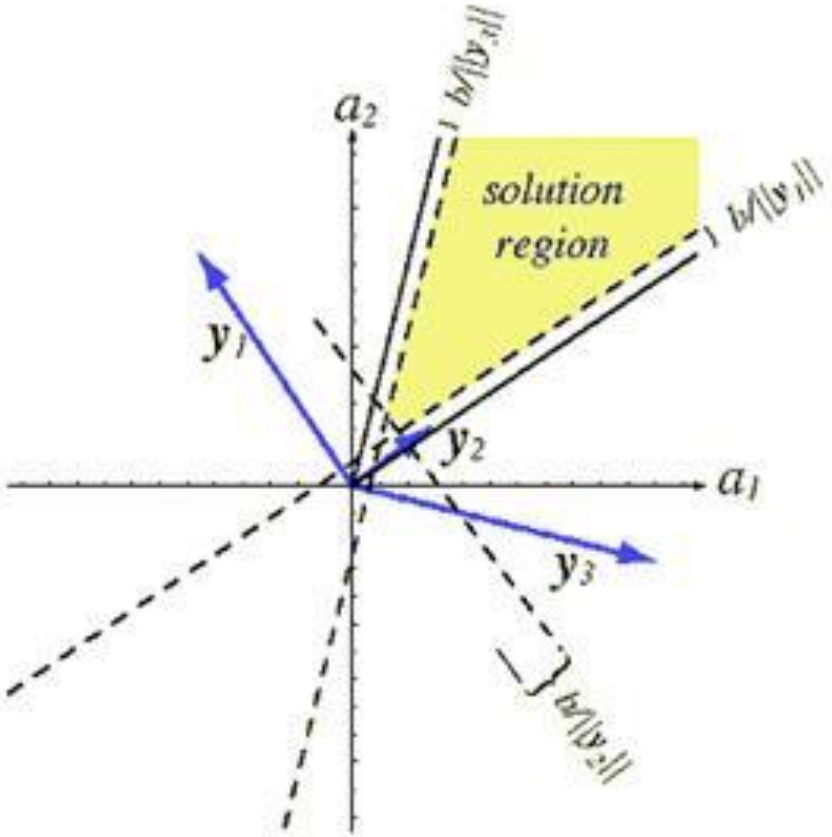

感知机准则

- **寻找解向量*a****

对于一组样本$y_1, y_2, \ldots y_N$, 其中y_n是规范化增广样本向量, 使得:

$$a^T y_n > 0, n = 1, 2, \ldots, N$$

对于线性可分问题，构造准则函数 $J_P(a) = \sum_{y \in \eta^k} (-a^T y)$

其中 η^k **是被权向量*a*错分的样本集合，即当*y*被错分时，就有** $a^T y_n \leq 0$

因此 $J_P(a) \geq 0$**，仅当*a*为解向量或在解区边界时**$J_P(a) = 0$

也就是说，当且仅当 η^k **为空集时** $J_P^*(a) = min J_P(a) = 0$

此时无错分样本，这时的*a*就是解向量*a** 。

感知机准则

- 求使 $J_P(a)$ 达到最小值的 a^*

采用梯度下降法求解 $J_P(a) = \sum_{y \in \eta^k} (-a^T y)$

$$\nabla J_P(a) = \frac{\partial J_P(a)}{\partial a} = \sum_{y \in \eta^k} (-y)$$

$$a(k+1) = a(k) - \rho_k \nabla J$$ 梯度下降法迭代公式

$$a(k+1) = a(k) + \rho_k \nabla \sum_{y \in \eta^k} y$$

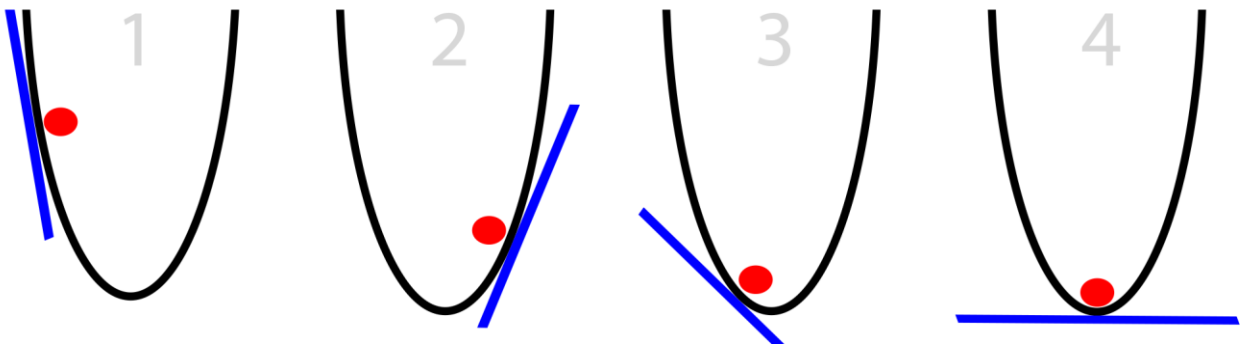

感知机准则-示例

- Sample set for two-class case
  - Class 1

$$\mathbf{x}_1 = \begin{pmatrix} -2 \\ 2 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} -2 \\ -2 \end{pmatrix} \qquad \mathbf{y}_1 = \begin{pmatrix} 1 \\ -2 \\ 2 \end{pmatrix}, \mathbf{y}_2 = \begin{pmatrix} 1 \\ -2 \\ -2 \end{pmatrix}$$

  - Class 2

$$\mathbf{x}_3 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \mathbf{x}_4 = \begin{pmatrix} 2 \\ -1 \end{pmatrix} \qquad \mathbf{y}_3 = \begin{pmatrix} -1 \\ -2 \\ -1 \end{pmatrix}, \mathbf{y}_4 = \begin{pmatrix} -1 \\ -2 \\ 1 \end{pmatrix}$$

  - Initial weight vector

$$\mathbf{a}(1) = \begin{pmatrix} 0 \\ 2 \\ 1 \end{pmatrix} \qquad \mathbf{a}(1)^t = \begin{pmatrix} 0 & 2 & 1 \end{pmatrix}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (1) $\mathbf{y}^{(1)t} = \begin{pmatrix} 1 & -2 & 2 \end{pmatrix}$

$$\mathbf{a}(1)^t \mathbf{y}^{(1)} = \begin{pmatrix} 0 & 2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \\ 2 \end{pmatrix} = -2 < 0$$

$$\mathbf{a}(2)^t = \begin{pmatrix} 0 & 2 & 1 \end{pmatrix} + \begin{pmatrix} 1 & -2 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 3 \end{pmatrix}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (2)

$$\mathbf{y}^{(2)t} = \begin{pmatrix} 1 & -2 & -2 \end{pmatrix}$$

$$\mathbf{a}(2)^t \mathbf{y}^{(2)} = \begin{pmatrix} 1 & 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \\ -2 \end{pmatrix} = -5 < 0$$

$$\mathbf{a}(3)^t = \begin{pmatrix} 1 & 0 & 3 \end{pmatrix} + \begin{pmatrix} 1 & -2 & -2 \end{pmatrix} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (3)

$$\mathbf{y}^{(3)t} = \begin{pmatrix} -1 & -2 & -1 \end{pmatrix}$$

$$\mathbf{a}(3)^t \mathbf{y}^{(3)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ -2 \\ -1 \end{pmatrix} = 1 > 0$$

$$\mathbf{a}(4)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \text{ (no change)}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (4) $\mathbf{y}^{(4)t} = \begin{pmatrix} -1 & -2 & 1 \end{pmatrix}$

$$\mathbf{a}(4)^t \mathbf{y}^{(3)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ -2 \\ 1 \end{pmatrix} = 3 > 0$$

$$\mathbf{a}(5)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \text{ (no change)}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (5)

$$\mathbf{y}^{(5)t} = \begin{pmatrix} 1 & -2 & 2 \end{pmatrix}$$

$$\mathbf{a}(5)^t \mathbf{y}^{(1)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \\ 2 \end{pmatrix} = 8 > 0$$

$$\mathbf{a}(6)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \qquad \text{(no change)}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (6)

$$\mathbf{y}^{(6)t} = \begin{pmatrix} 1 & -2 & -2 \end{pmatrix}$$

$$\mathbf{a}(6)^t \mathbf{y}^{(2)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \\ -2 \end{pmatrix} = 4 > 0$$

$$\mathbf{a}(7)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix}$$

感知机准则-示例

- Example (Cont.)
  - Iterative procedure
    - (7)

$$\mathbf{y}^{(7)t} = \begin{pmatrix} -1 & -2 & -1 \end{pmatrix}$$

$$\mathbf{a}(7)^t \mathbf{y}^{(7)} = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ -2 \\ -1 \end{pmatrix} = 1 > 0$$

$$\mathbf{a}(8)^t = \begin{pmatrix} 2 & -2 & 1 \end{pmatrix} \quad \text{(no change)}$$

感知机准则

- 结果不唯一且在线性不可分情况下不收敛

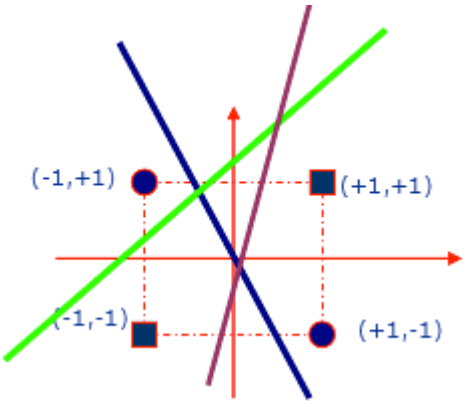

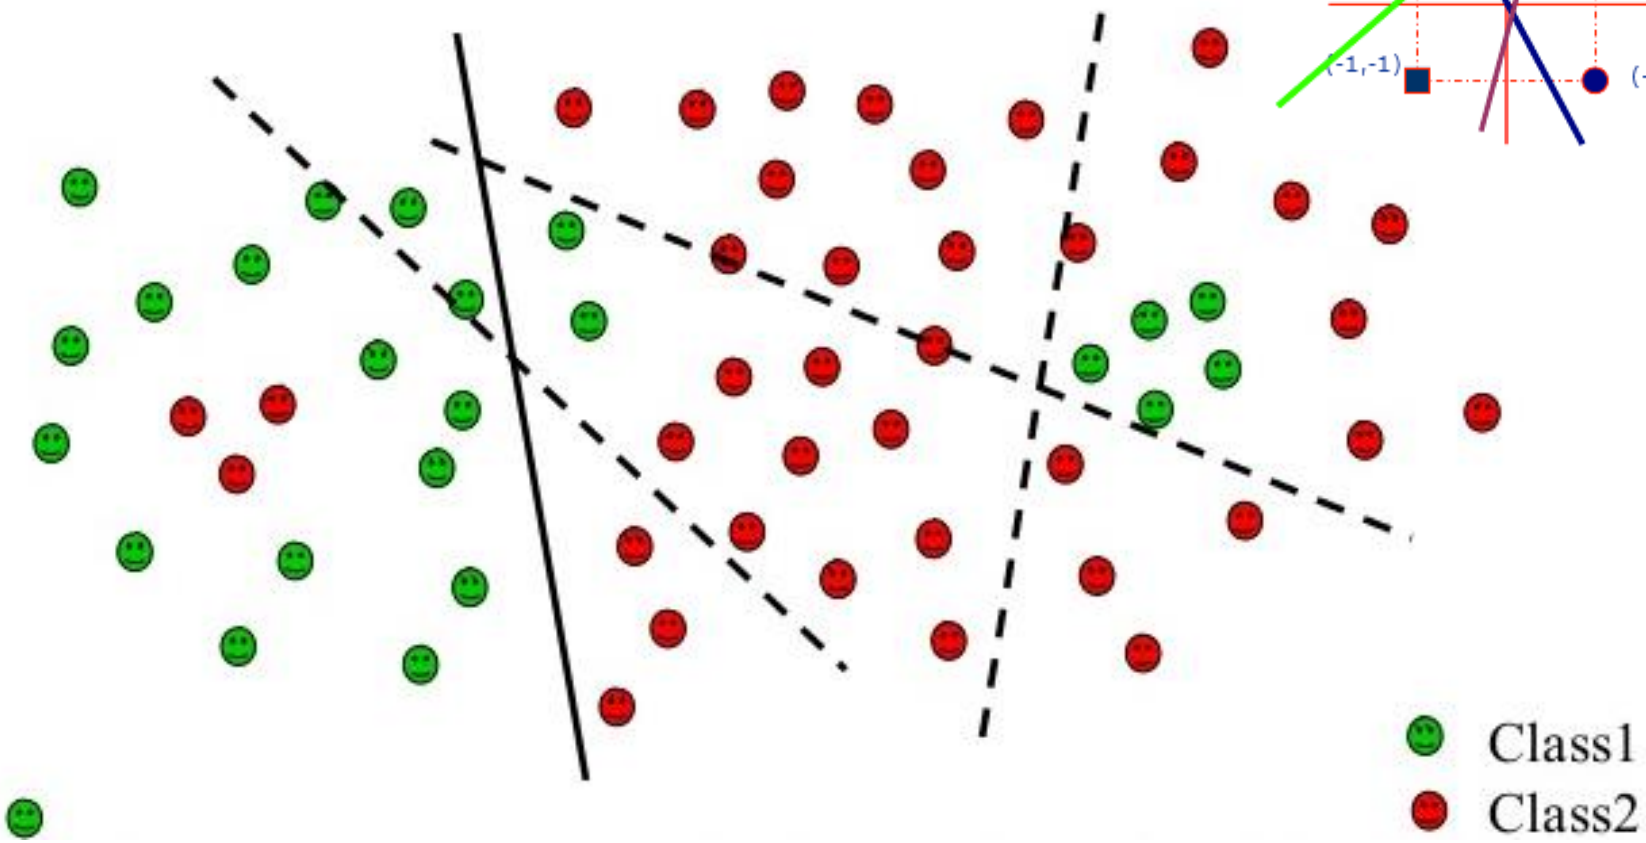

多分类问题
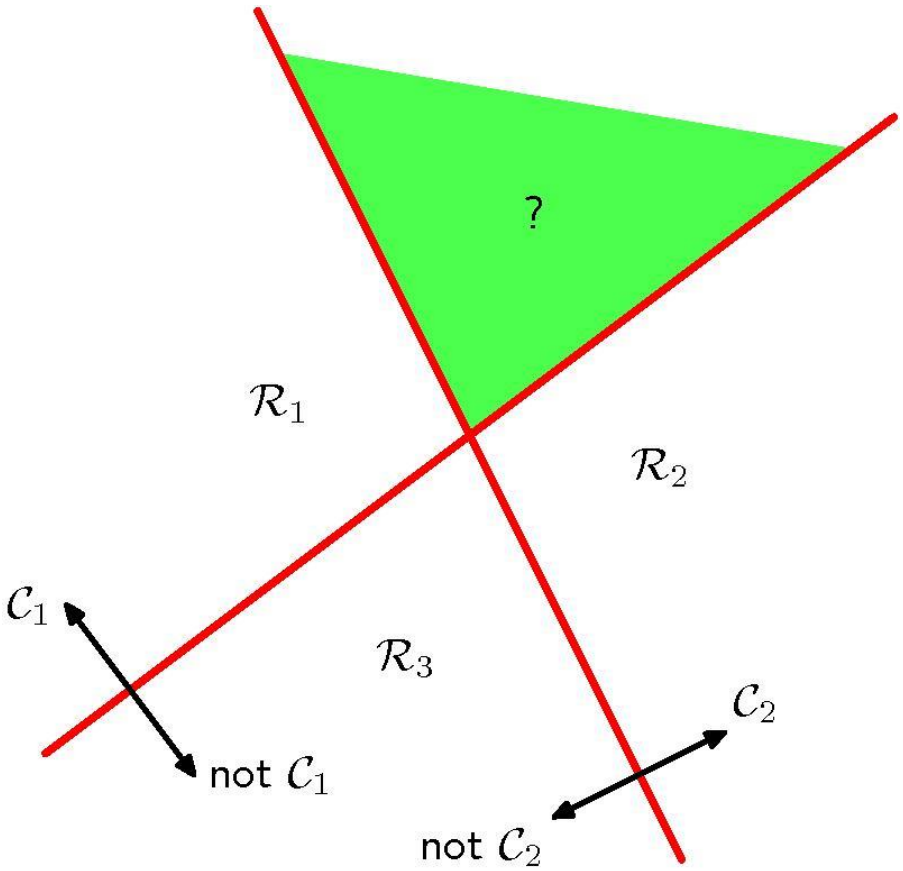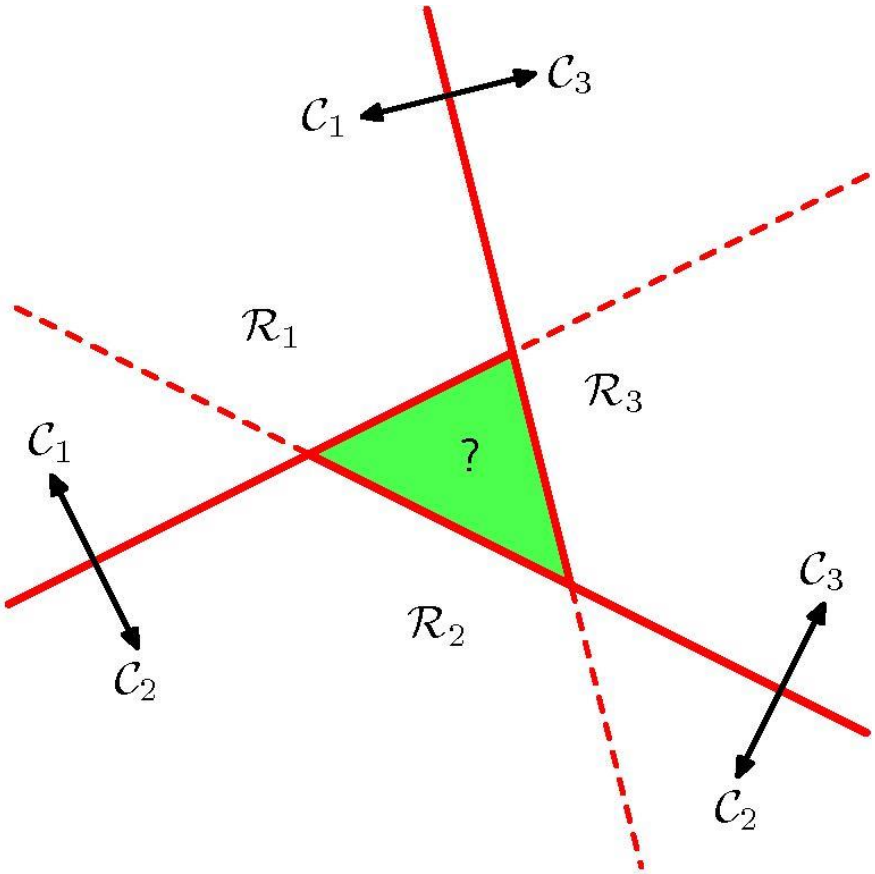
- **1 *vs.* (N-1) or 1 *vs.* 1**