机器学习
Machine Learning

北京航空航天大学计算机学院
School of Computer Science and Engineering, Beihang University
黄 迪 张永飞

2020年秋季学期
Fall 2020

部分内容来源于C. Bishop和A. NG等人的课程以及互联网资源

课前回顾

支持向量机

- SVM从线性可分情况下的最优分类面发展而来。

最优分类面就是要求分类线不但能将两类正确分开(训练错误率为0)，且使分类间隔最大。SVM考虑寻找一个满足分类要求的超平面，并且使训练集中的点距离分类面尽可能的远，也就是寻找一个分类面使它两侧的空白区域(Margin)最大。

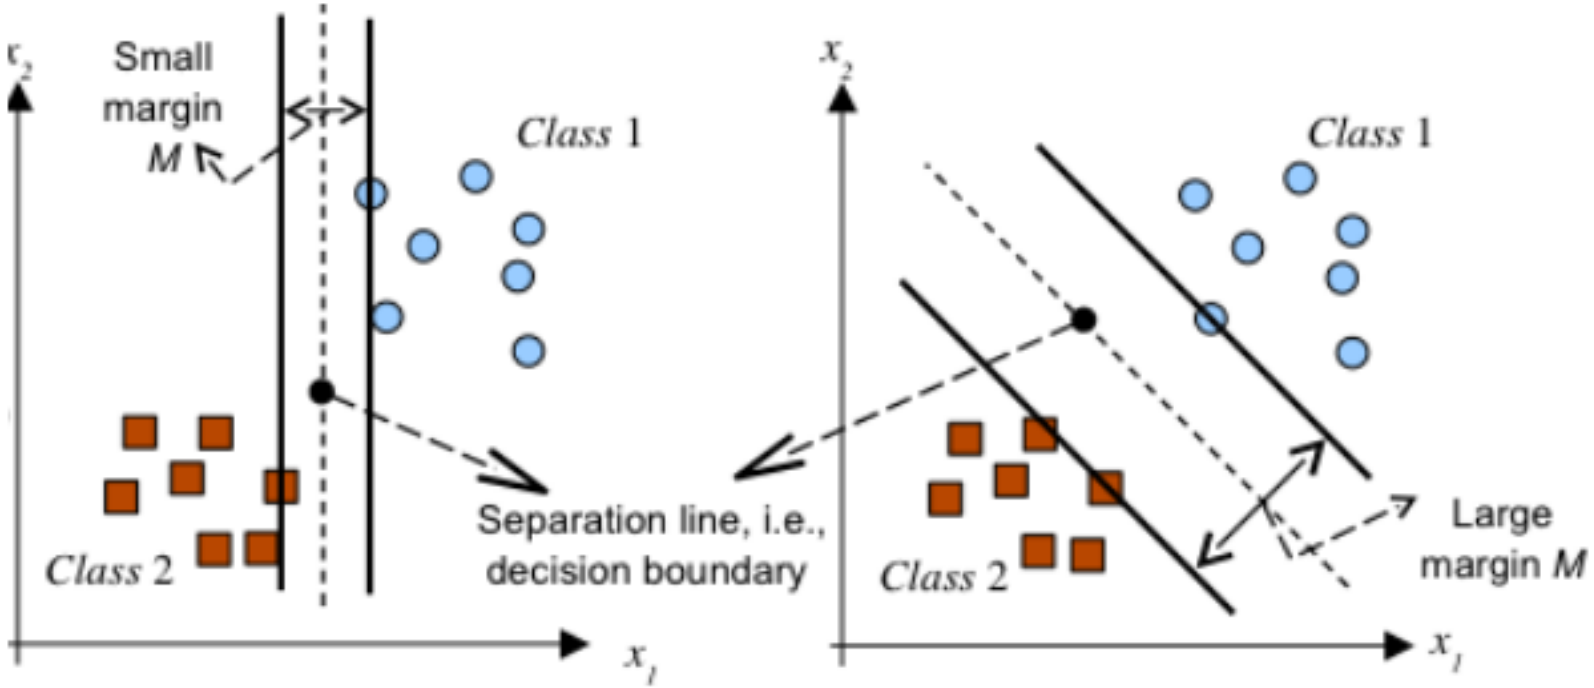

支持向量机

● 线性支持向量机

样本集 $\{x_n, t_n\}, n = 1, 2, ..., N,\ \ x_n \in \mathcal{R}^d; t_n \in \{-1, 1\}$

分类器 $y(x) = w^T x + b$

$$t_n = \begin{cases} 1, y(x_n) > 0 \text{ if } x_i \in w_1 \\ -1, y(x_n) < 0 \text{ if } x_i \in w_2 \end{cases} \quad \Rightarrow \quad t_n y(x_n) > 0$$

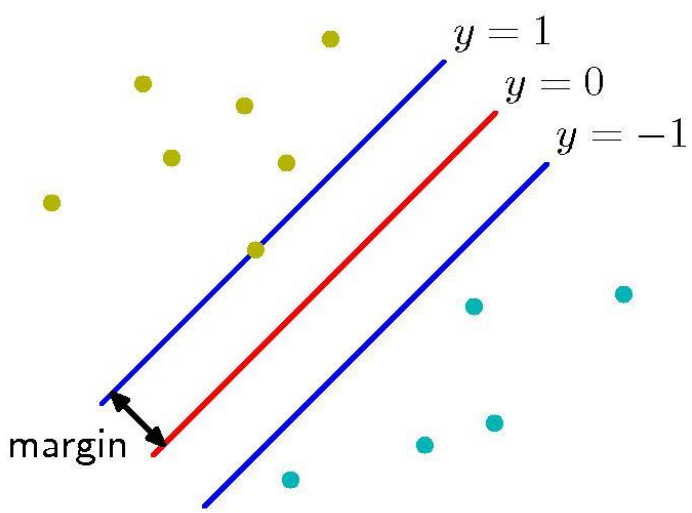

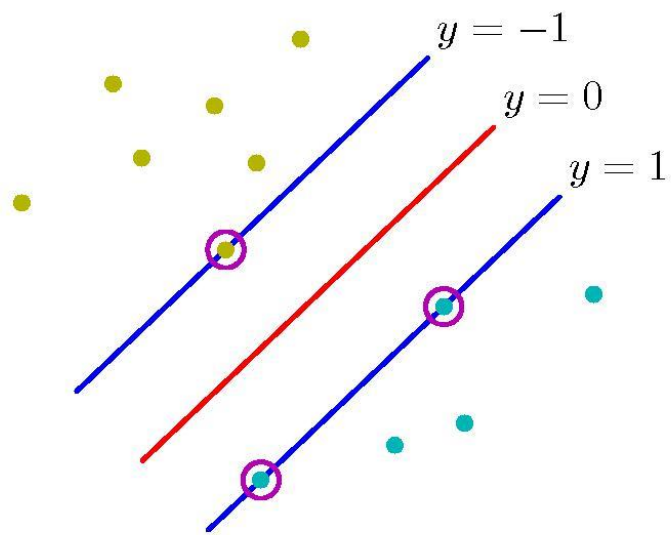

支持向量机

- **线性支持向量机**

样本集任意一点 x_n **到分类面(满足** $t_n y(x_n) > 0$**)的距离**

$$\frac{t_n y(x_n)}{\|w\|} = \frac{t_n(w^T x_n + b)}{\|w\|}$$

优化*w*和*b*使Margin最大

$$\arg\max_{w,b}\{\frac{1}{\|w\|}\min_n[t_n(w^T x_n + b)]\}$$

求解复杂

$$w \to kw, b \to kb$$

对于离超平面最近的点 $t_n(w^T x_n + b) = 1$

那么对于所有点满足 $t_n(w^T x_n + b) \geq 1$

对于决策超平面的标准表示
Canonical Representation

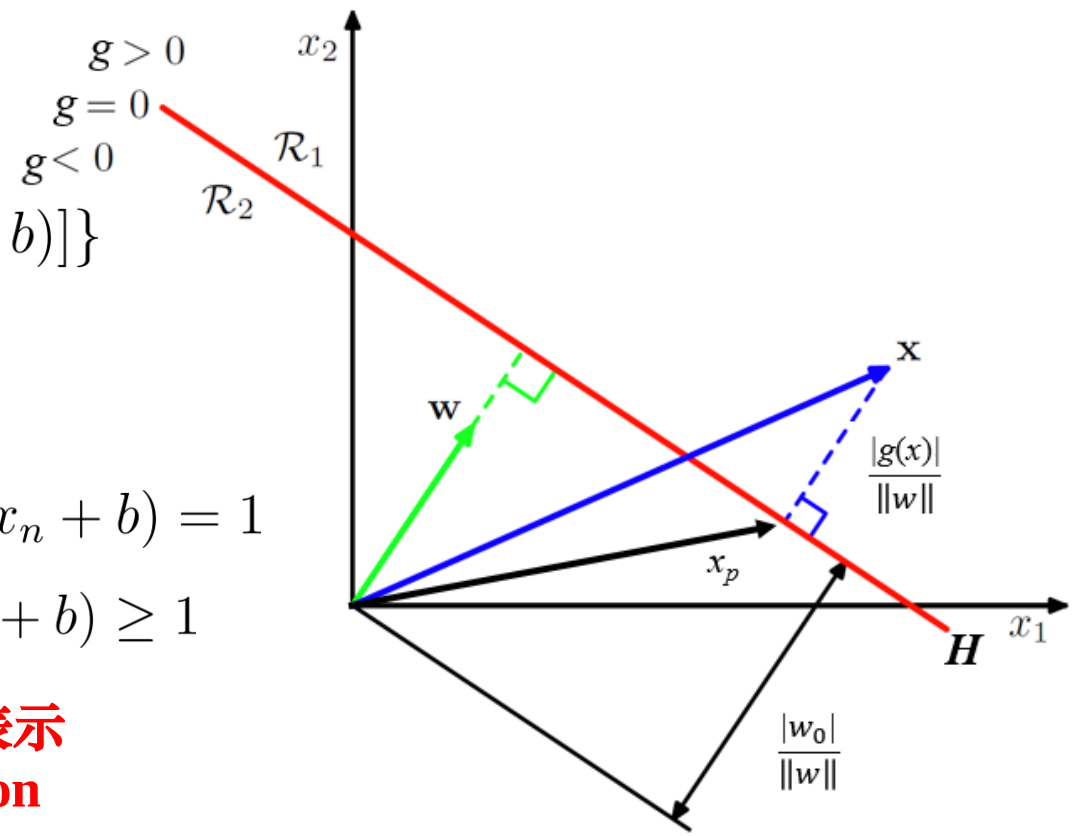

支持向量机

- **线性支持向量机**

KKT条件：

$$a_n \geq 0$$

$$t_n y(x_n) - 1 \geq 0$$

$$\boxed{a_n\{t_n y(x_n) - 1\} = 0}$$

支持向量：

$$t_n(w^T x + b) = 1, a_n > 0$$

非支持向量：

$$t_n(w^T x + b) > 1, a_n = 0$$

$$y(x) = \sum_{n=1}^{N} a_n t_n x_n^T x + b$$

$$b = \frac{1}{N_S} \sum_{n \in S} (t_n - \sum_{m \in S} a_m t_m x_n^T x_m)$$

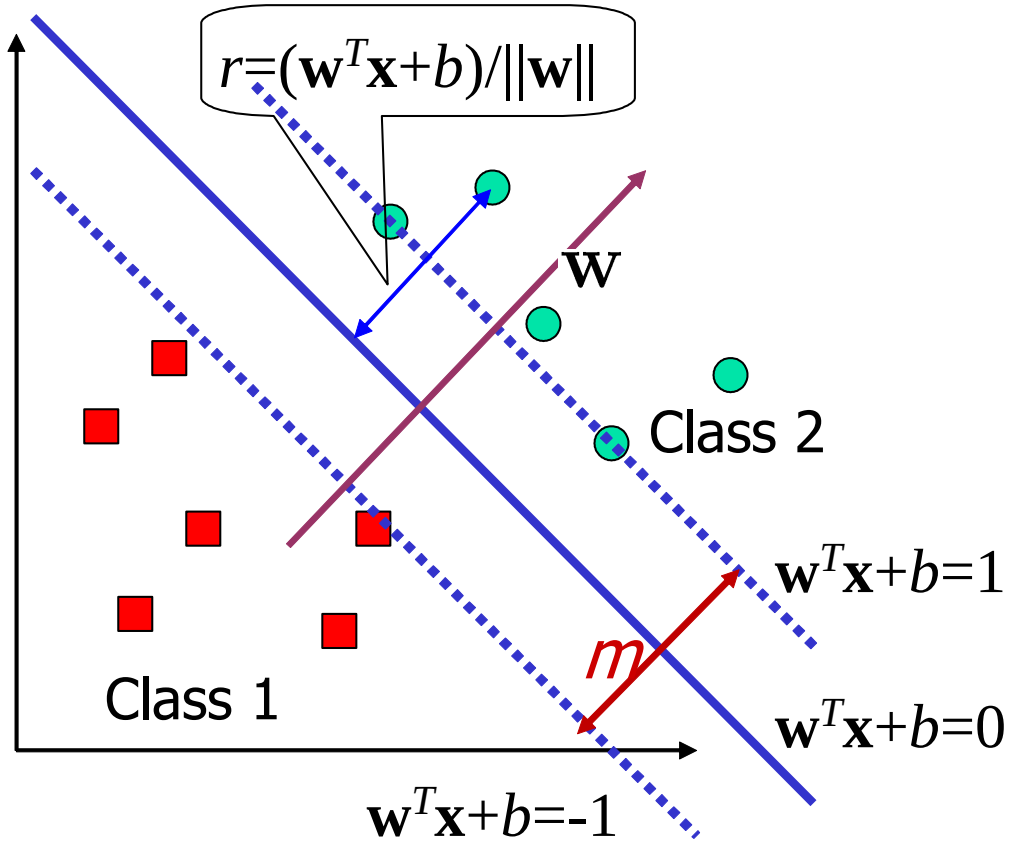

超平面法向量是支持向量的线性组合

支持向量机

- 处理噪声和离群点

求解最优分类面的时间代价大还可能导致泛化性能差。因此，对于分布有交集的数据需要有一定范围内的“错分”，又有较大分界区域的广义最优分类面。

准确性

泛化性

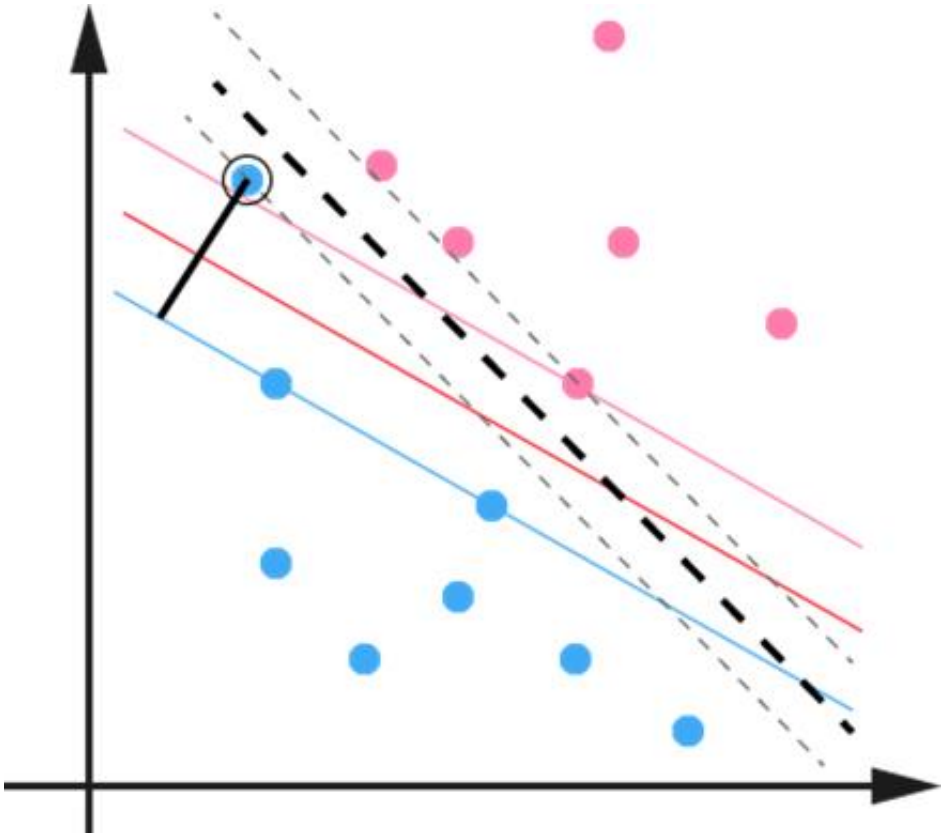

支持向量机

- **处理噪声和离群点**

引入松弛变量 $\xi_n \geq 0$

$$\boxed{\begin{aligned}\xi_n &= 0\\ \xi_n &= |t_n - y(x_n)|\end{aligned}}$$

$$\xi_n = 0$$
$$0 < \xi_n \leq 1$$
$$\xi_n > 1$$

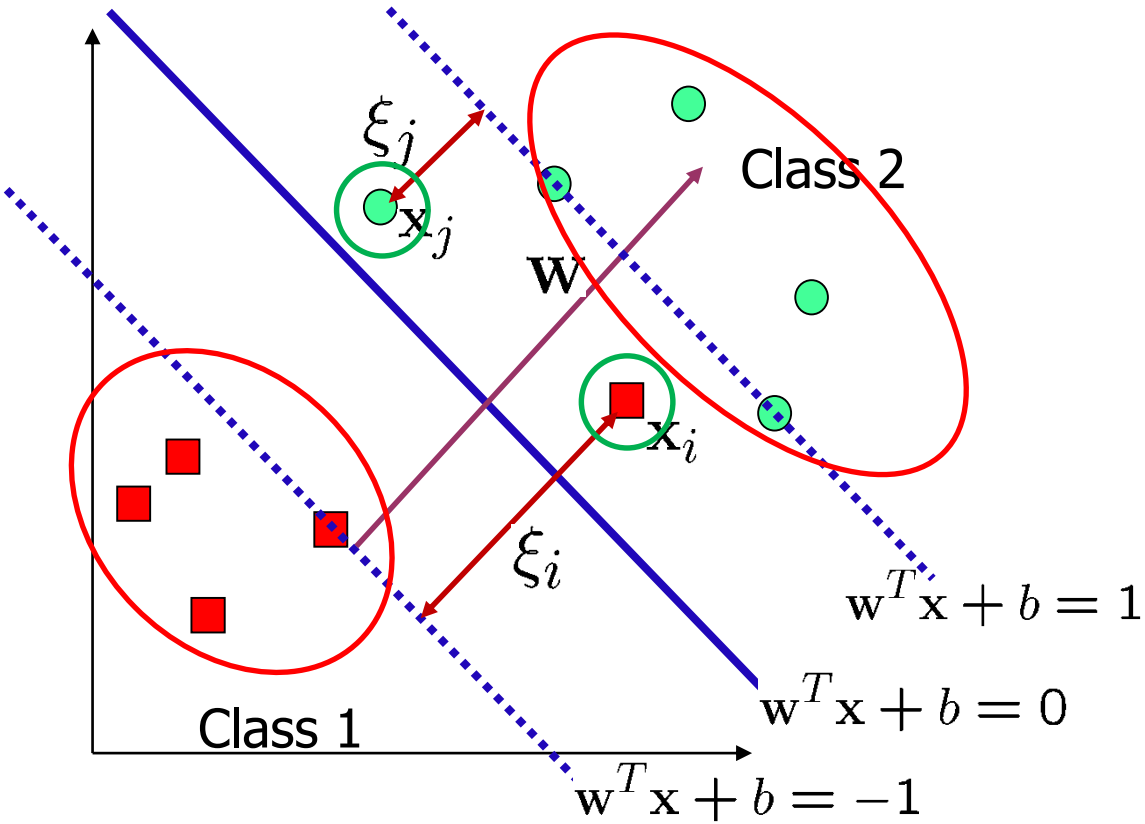

原有约束 $t_n y(x_n) \geq 1$ ➡ $t_n y(x_n) \geq 1 - \xi_n$

支持向量机

- **处理噪声和离群点**

这种处理方式也被视为是从硬间隔(Hard Margin)向软间隔(Soft Margin)的转变。

硬间隔

$$\min_{w,b} \frac{1}{2}\|w\|^2$$
$$s.t.\ t_n(w^T x_n + b) \geq 1,\ \ n = 1, ..., N$$

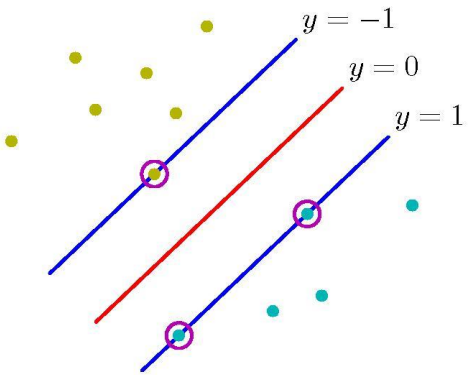

软间隔

$$\min_{w,b} \frac{1}{2}\|w\|^2 \boxed{+ C\sum_{n=1}^{N} \xi_n}$$
$$s.t.\ t_n(w^T x_n + b) \geq 1 - \xi_n,\ \ n = 1, ..., N$$
$$\xi_n \geq 0$$

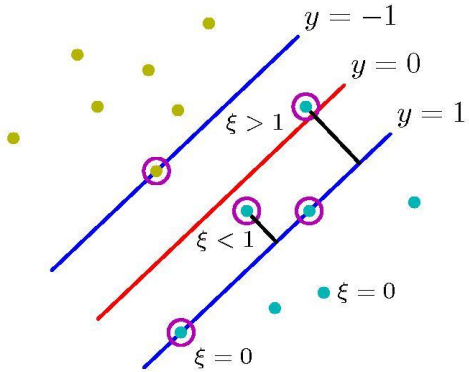

支持向量机

- **处理噪声和离群点**

得到其对偶形式：

$$\max_a \sum_{n=1}^{N} a_n - \frac{1}{2}\sum_{n=1}^{N}\sum_{m=1}^{N} a_n a_m t_n t_m x_n^T x_m$$

$$s.t.\ 0 \le a_n \le C, n = 1, 2, ..., N$$

$$\sum_{n=1}^{N} a_n t_n = 0$$ **二次规划问题**

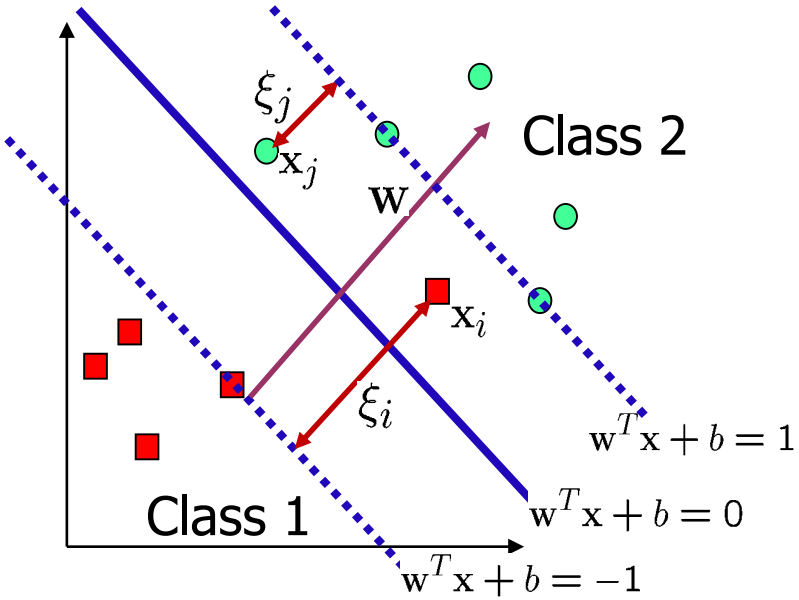

对于新样本预测的分类器：

$$y(x) = \sum_{n=1}^{N} a_n t_n x_n^T x + b$$

$$b = \frac{1}{N_{\mathcal{M}}} \sum_{n \in \mathcal{M}} (t_n - \sum_{m \in S} a_m t_m x_n^T x_m)$$

非支持向量： $a_n = 0$

支持向量： $t_n y(x_n) = 1 - \xi_n$

$$a_n < C \Rightarrow \mu > 0 \Rightarrow \xi_n = 0$$

$$a_n = C \Rightarrow \xi_n \le 1 \ or\ \xi_n > 1$$

支持向量机

非线性支持向量机

线性模型在解决复杂分类问题时适应性较差。而对于非线性可分的数据样本，可能通过适当的函数变换，将其在高维空间中转化为线性可分。

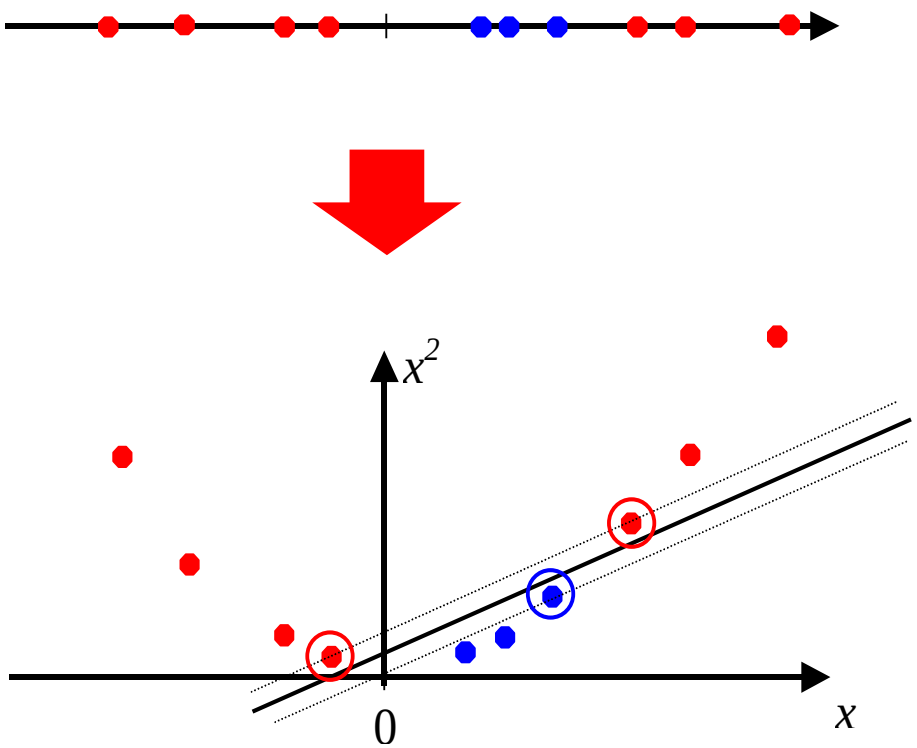

支持向量机

- **非线性支持向量机**

可以把样本*x*映射到某个高维特征空间$\phi(x)$，并在其中使用线性分类器。

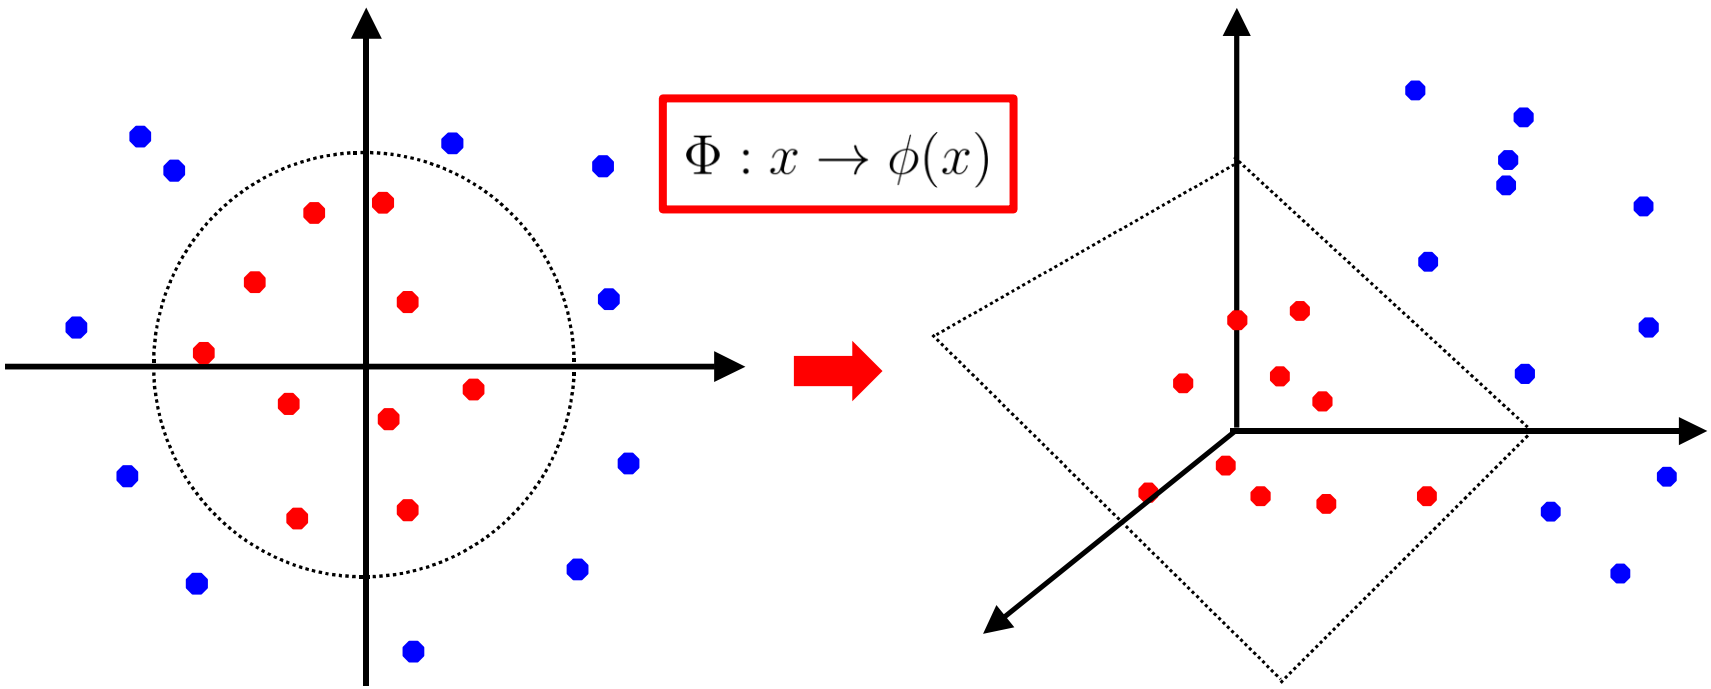

支持向量机

- **非线性支持向量机**

利用一个固定的非线性映射将数据映射到特征空间学习的线性分类器等价于基于原始数据学习的非线性分类器。

$$y(x) = w^T x + b \quad \Rightarrow \quad y(x) = w^T \phi(x) + b$$

决策时

$$y(x) = \sum_{n=1}^{N} a_n t_n x_n^T x + b \quad \Rightarrow \quad y(x) = \sum_{n=1}^{N} a_n t_n \boxed{k(x, x_n)} + b$$

$$k(x, x_n) = \phi(x_n)^T \phi(x)$$

核函数

核函数在特征空间中直接计算数据映射后的内积就像在原始输入数据的函数中计算一样，大大简化了计算过程。

支持向量机

- **非线性支持向量机**

利用一个固定的非线性映射将数据映射到特征空间学习的线性分类器等价于基于原始数据学习的非线性分类器。

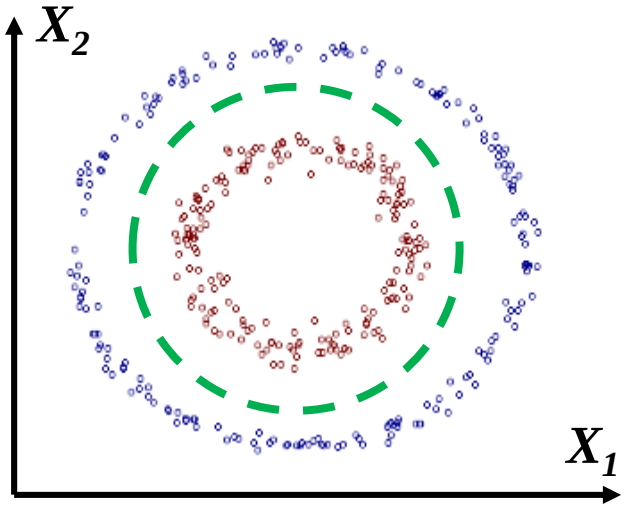

$$a_1X_1 + a_2X_1^2 + a_3X_2 + a_4X_2^2 + a_5X_1X_2 + a_6 = 0$$

$$Z_1 = X_1; Z_2 = X_1^2; Z_3 = X_2; Z_4 = X_2^2; Z_5 = X_1X_2$$

$$\Rightarrow \sum_{i=1}^{5} a_iZ_i + a_6 = 0 \qquad \phi : \mathbb{R}^2 \to \mathbb{R}^5$$

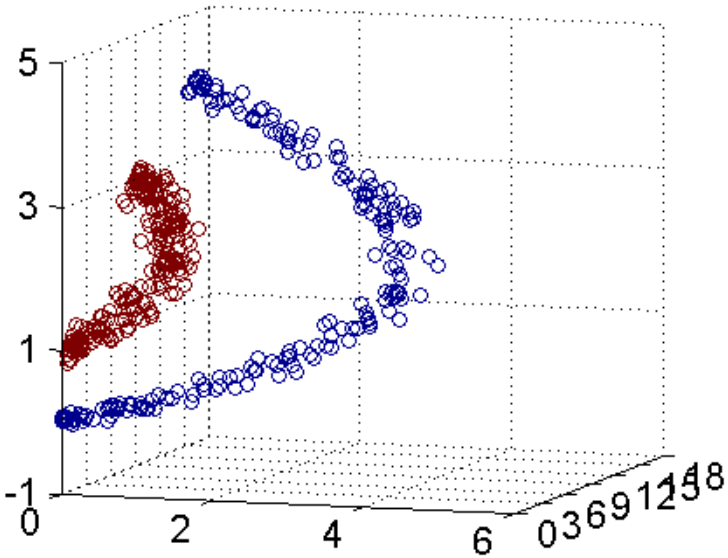

$$a_1X_1^2 + a_2(X_2 - c)^2 + a_3 = 0$$

$$Z_1 = X_1^2; Z_2 = X_2^2; Z_3 = X_2$$

$$\phi : \mathbb{R}^2 \to \mathbb{R}^3$$

支持向量机

- **非线性支持向量机**

利用一个固定的非线性映射将数据映射到特征空间学习的线性分类器等价于基于原始数据学习的非线性分类器。

$$a_1X_1 + a_2X_1^2 + a_3X_2 + a_4X_2^2 + a_5X_1X_2 + a_6 = 0 \quad \phi : \mathbb{R}^2 \to \mathbb{R}^5$$

原始样本增加到三维

$$a_1X_1^3 + a_2X_2^3 + a_3X_3^3 + a_4X_1^2X_2 + a_5X_1^2X_3 + a_6X_2^2X_1 + a_7X_2^2X_3 + a_8X_3^2X_1 + a_9X_3^2X_2 + a_{10}X_1X_2X_3 + a_{11}X_1^2 + a_{12}X_2^2 + a_{13}X_3^2 + a_{14}X_1X_2 + a_{15}X_2X_3 + a_{16}X_1X_3 + a_{17}X_1 + a_{18}X_2 + a_{19}X_3 + a_{20} = 0 \qquad \phi : \mathbb{R}^3 \to \mathbb{R}^{19}$$

维数大大增加
计算变得非常困难

$$k(x_1, x_2) = (< x_1, x_2 > +1)^2$$

利用核函数直接在原来的低维空间中进行计算不需要显式地写出映射后的结果，避免了先映射到高维空间中然后再根据内积的公式进行计算

支持向量机

● 非线性支持向量机

根据问题和数据的不同，选择带有不同的核函数。

一些常用的核函数:

线性核: $k(x_1, x_2) = x_1^T x_2$

多项式核: $k(x_1, x_2) = (< x_1, x_2 > + R)^d$

高斯核: $k(x_1, x_2) = \exp\{-\frac{\|x_1 - x_2\|^2}{2\sigma^2}\}$

Sigmoid核: $k(x_1, x_2) = \tanh(\beta_0 x_1^T x_2 + \beta_1)$

如何判断一个函数是否可以作为核函数?

Mercer定理:
$\mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R}$**上的映射*k*是一个有效核函数(也称Mercer核函数)当且仅当对于训练样本其相应的核函数矩阵是对称半正定的,即对于任何平方可积函数*g*(*x*)有** $\int\int k(x,y)g(x)g(y)dxdy \geq 0$ **。**

序列最小优化算法

- **J. C. Platt(1999年提出)**

支持向量机的学习问题可以形式化为求解具有全局最优解的凸二次规划问题。许多方法可以用于求解这一问题，但当训练样本容量很大时，这些算法往往效率较低，以致无法使用。

序列最小优化算法(Sequential Minimal Optimization, SMO)是一种启发式算法。基本思想是：如果所有变量都满足此优化问题的KKT条件，那么这个问题的解就得到了。

SMO算法的特点是不断地将原二次规划问题分解为只有两个变量的二次规划问题，并对子问题进行解析求解，直到所有变量都满足KKT条件为止。因为子问题解析解存在，所以每次计算子问题都很快，虽然子问题次数很多，但是总体上还是高效的。

第五章：决策树

Chapter 5: Decision Tree

引例

- 引例1：相亲

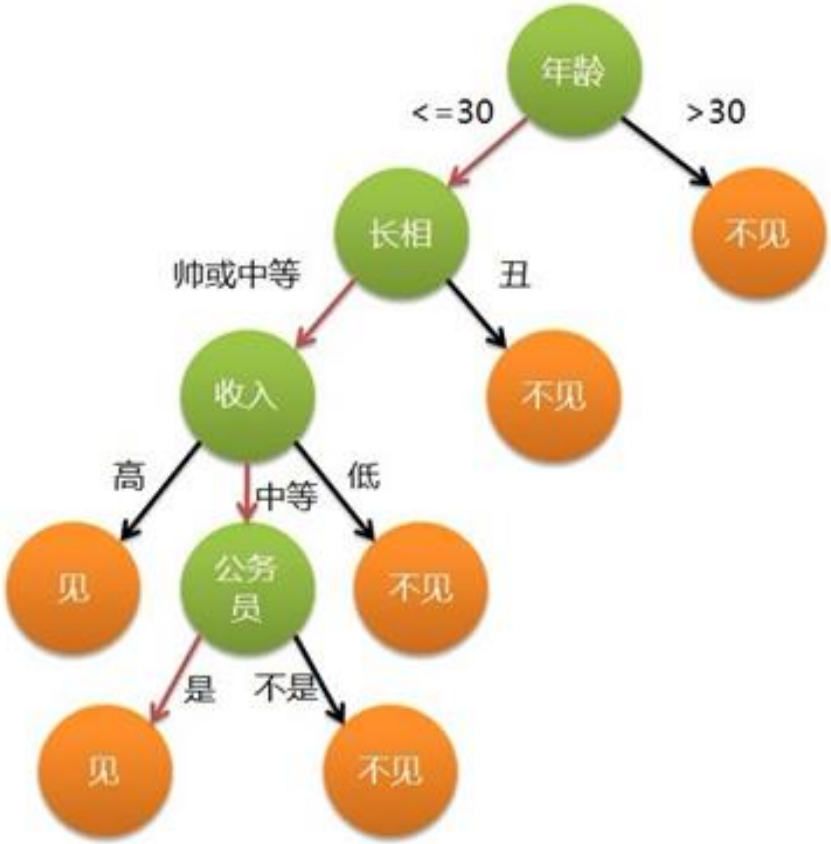

- 引例2：天气是否适合打网球

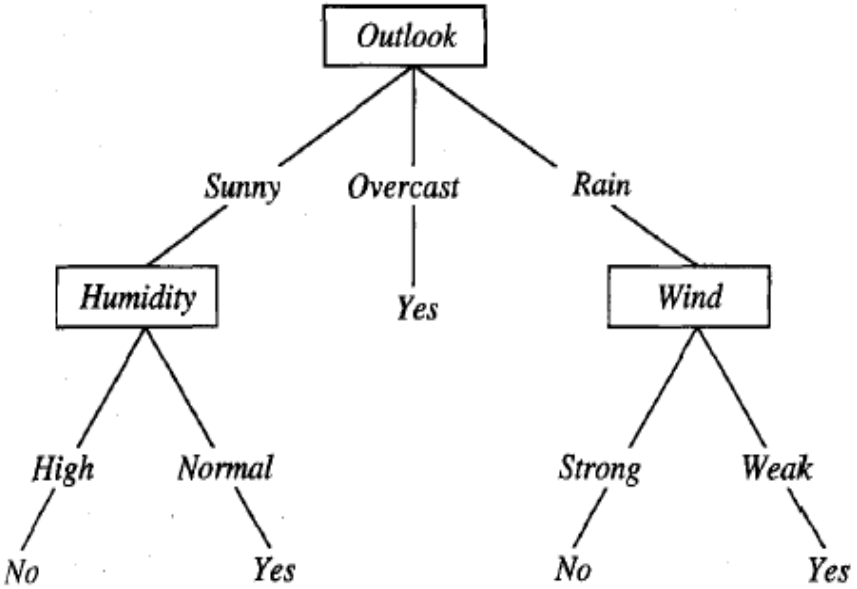

$$(Outlook = Sunny \wedge Humidity = Normal)$$
$$\vee \quad (Outlook = Overcast)$$
$$\vee \quad (Outlook = Rain \wedge Wind = Weak)$$

P38《机器学习》, T. M. Mitchell著，曾华军译

问题背景

- **问题举例**
  - 根据症状或检查结果分类患者
  - 根据起因或现象分类设备故障
  - 根据拖欠支付的可能性分类贷款申请
- **分类问题**
  - 把样例分类到各可能的离散值对应的类别
- **问题特征**
  - 实例由“属性-值”对表示，
    训练数据可以包含缺少属性值的实例
  - 属性可以是连续值或离散值
  - 具有离散的输出值

决策树定义

- 决策树(Decision Tree)
  - 决策树是一种**树型结构**，由结点和有向边组成
  - 结点
    - **内部结点**表示一个属性或特征
    - **叶结点**代表一种**类别**
  - 有向边/分支
    - **分支**代表一个测试**输出**

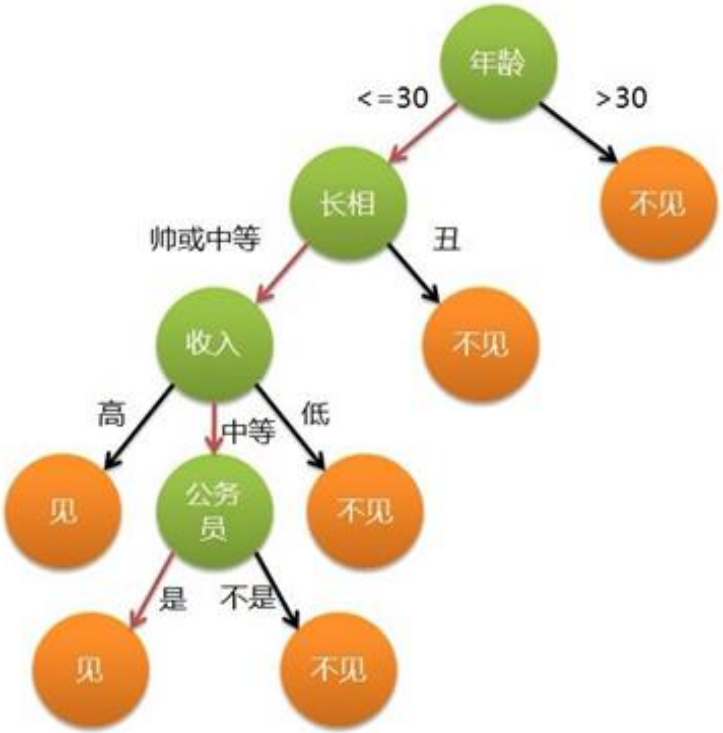

决策树算法

- **基本思想**
  - 采用自顶向下的**递归方法**，以信息熵为度量构造一棵熵值下降最快的树，到叶子结点处的熵值为零，此时每个叶结点中的实例都属于同一类
    - 决策树可以看成一个**if-then的规则集合**
    - 一个决策树将特征空间划分为不相交的单元(Cell)或区域(Region)

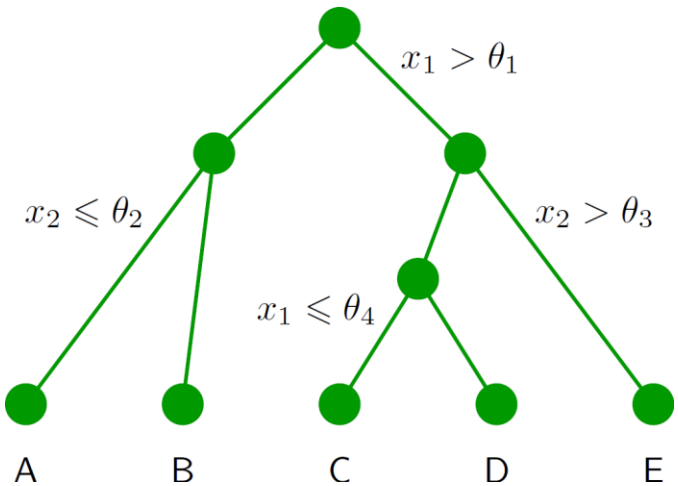

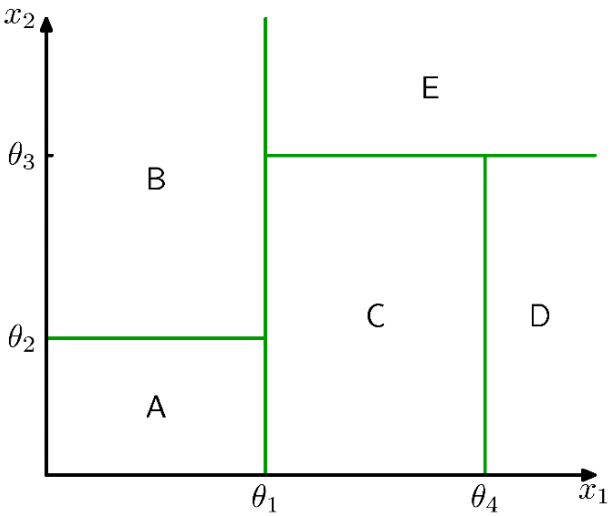

算法流程

- **基本流程分为两步**

  - **第1步：训练，从数据中获取知识进行学习**

  利用训练集建立(并精化)一棵决策树，构建决策树模型.

  - **第2步：测试，利用生成的模型对输入数据进行分类**

  对测试样本，从根结点依次测试记录的属性值，直至到达某个叶结点，找到该样本所在的类别.

算法流程

- 构建过程的基本流程
  - Step1：选取一个属性作为决策树的根结点，然后就这个属性所有的取值创建树的分支.
  - Step2：用这棵树来对训练数据集进行分类：
    - 如果一个叶结点的所有实例都属于同一类，则以该类为标记标识此叶结点.
    - 如果所有的叶结点都有类标记，则算法终止.
  - Step3：否则，选取一个从该结点到根路径中没有出现过的属性作为标记标识该结点，然后就这个属性的所有取值继续创建树的分支；重复算法步骤2.

主要算法

- 建立决策树的关键，即在当前状态下选择哪个属性作为分类依据

  示例：高？富？帅？　会C++？会图像处理？深度学习？

- **目标**：每个分支结点的样本尽可能属于同一类别，即结点的“纯度”(Purity)越来越高
- 根据不同的目标函数，建立决策树主要有以下三种算法
  - ID3：　信息增益
  - C4.5：　信息增益率
  - CART：基尼指数

ID3算法

- ID3 (Iterative Dichotomiser 3)迭代二分器算法
  - 由J. R. Quinlan于1979年提出
  - 一种最经典的决策树学习算法

基本思想：以信息熵为度量，用于决策树结点的属性选择，每次优先选取信息增益最大的属性，即能使熵值最小的属性，构造一棵熵值下降最快的决策树。到叶子结点的熵值为0，此时对应实例集中的实例属于同一类别。

ID3算法

- 信息熵(Entropy)
  - 信息论与概率统计中，熵表示随机变量不确定性的大小，是度量样本集合纯度最常用的一种指标.
  - 令离散随机变量*X*概率分布为 $p(X=x_i)=p_i$ ，则随机变量*X*的熵定义为：

$$H(X)=-\sum_{i=1}^{n} p_i \log_2 p_i$$

信息按二进制位编码，因此以2为底

  - 若*X*为连续随机变量，则概率分布变成概率密度函数、求和符号变成积分符号即可.

ID3算法

- 信息熵(Entropy)
  - 熵定义了一个函数(概率密度函数)到一个值(信息熵)的映射　　P(*x*)→H (函数→数值)
  - 熵是随机变量不确定性的度量：
    - 不确定性越大，熵值越大；
    - 若随机变量退化成定值，熵为0.

    示例：明天下雪？明天晴天？
  - 均匀分布是“最不确定”的分布

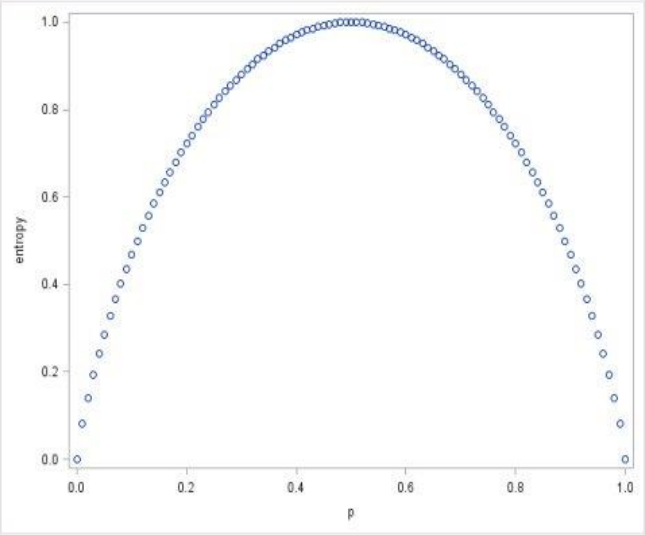

ID3算法

- 经验(信息)熵
  - 假设当前样本集合D中第c (c=1, 2, …, C)类样本所占比例为p_c，则D的经验信息熵(简称经验熵)定义为:

$$H(D) = -\sum_{c=1}^{C} p_c \log_2 p_c$$

$$= -\sum_{c=1}^{C} \frac{D_c}{D} \log_2 \frac{D_c}{D}$$

  - $H(D)$的值越小，则D的纯度越高.

ID3算法

- **条件熵(Conditional Entropy)**
  - 对随机变量(*X, Y*)，联合分布为 $p(X=x_i, Y=y_i)=p_{ij}$ 条件熵*H*(*Y*|*X*)表示在已知随机变量*X*的条件下，随机变量*Y*的不确定性，定义为在*X*给定条件下*Y*的条件概率分布的熵对*X*的数学期望：

$$H(Y \mid X) = -\sum_{i=1}^{n} p_i H(Y \mid X = x_i)$$

  - (*X, Y*)发生所包含的信息熵，减去*Y*单独发生包含的信息熵——在*Y*发生前提下，*X*发生“新”带来的信息熵.

ID3算法

- **条件熵(Conditional Entropy)**

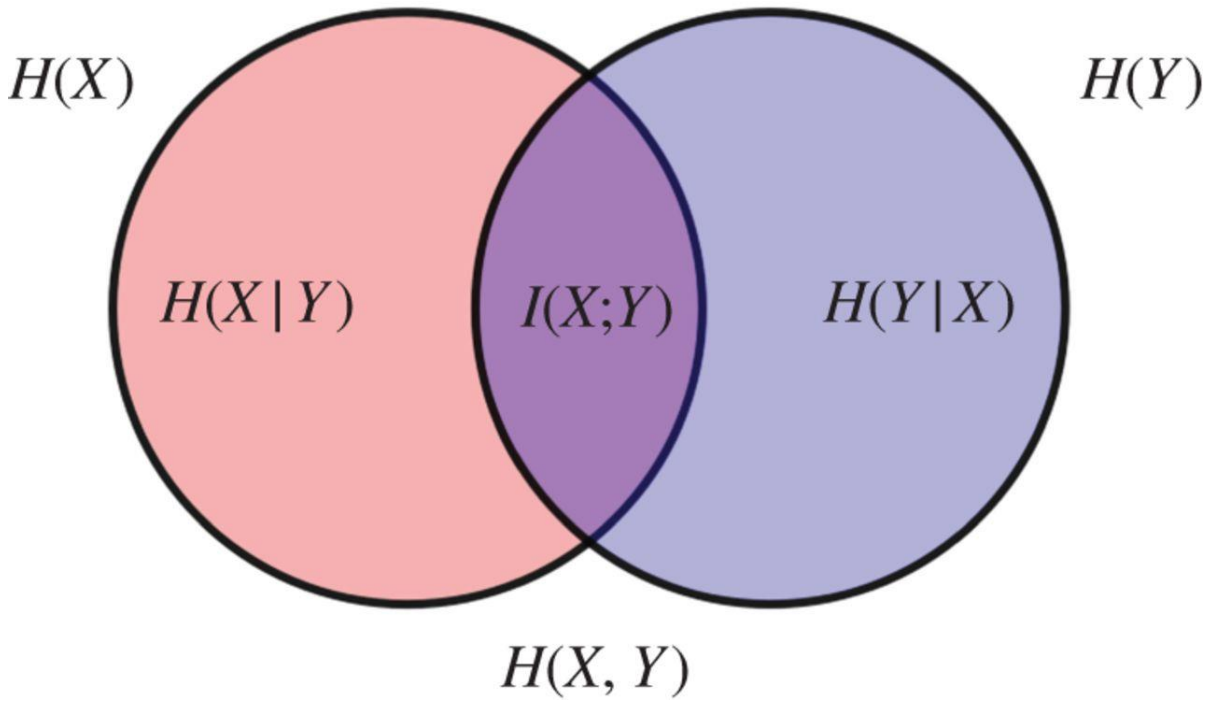

Venn图

ID3算法

- **条件熵-推导**

$$
\begin{aligned}
H(X|Y) &= H(X,Y) - H(Y) \\
&= -\sum_{x,y} p(x,y)\log_2 p(x,y) + \sum_{y} p(y)\log_2 p(y) \\
&= -\sum_{x,y} p(x,y)\log_2 p(x,y) + \sum_{y} (\sum_{x} p(x,y))\log_2 p(y) \\
&= -\sum_{x,y} p(x,y)\log_2 p(x,y) + \sum_{x,y} p(x,y)\log_2 p(y) \\
&= -\sum_{x,y} p(x,y)\log_2 \frac{p(x,y)}{p(y)} \\
&= -\sum_{x,y} p(x,y)\log_2 p(x|y)
\end{aligned}
$$

ID3算法

- 经验条件熵
  - 假设当前样本集合D共有C类，每一类有D_c个样本，属性a($a \in A$)有不同的取值$\{a_1, a_2, \ldots, a_N\}$，每一类中属性为$i$的样本数为$D_c^n$，则$D$的经验条件熵定义为

$$H(D|a) = -\sum_{n,c} p(D_c, a_n) \log_2 p(D_c | a_n)$$

$$= -\sum_{n=1}^{N} \frac{|D^n|}{|D|} \sum_{c=1}^{C} \frac{|D_c^n|}{|D^n|} \log_2 \frac{|D_c^n|}{|D^n|}$$

$$= \sum_{n=1}^{N} \frac{|D^n|}{|D|} H(D^n)$$

  - 特征a的信息对样本D的信息的不确定性减少的程度

ID3算法

- **信息增益(Information Gain)**
  - **特征*a*对训练数据集*D*的信息增益*G(D, a)*，定义为集合*D*的经验熵*H(D)*与特征*a*给定条件下*D*的经验条件熵*H(D|a)*之差，即：**

$$G(D,a) = H(D) - H(D \mid a)$$

$$= H(D) - \sum_{n=1}^{N} \frac{|D^n|}{|D|} H(D^n)$$

  - **ID3算法即是以此信息增益为准则，对每次递归的结点属性进行选择的.**

ID3算法

决策树的生成算法

输入： 训练数据集D, 特征集A, 阈值ε

输出： 决策树T

(1)若D中所有实例属于同一类C_k，则T为单结点树，并将类C_k作为该结点的类标记，返回T；

(2)若$A=\Phi$，则T为单结点树，并将D中实例数最大类C_k作为该结点类标记，返回T；

(3)否则，计算A中各特征对D的信息增益，选择信息增益最大的特征A_g；

(4)如果A_g的信息增益小于阈值ε，则置T为单结点树，并将D中样本数最大的类C_k作为该结点的类标记，返回T；

(5)否则，对A_g的每一个可能值a_i，分割D为若干非空子集D_i，将D_i中实例数最大的类作为标记，构建子结点，由结点及其子结点构成树T，返回T；

(6)对第i个子结点，以D_i为训练集，$A-\{A_g\}$为特征集，递归的调用第(1)~(5)步，得到子树T_i，返回T_i。

ID3算法-示例(1)

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

ID3算法-示例(1)

- **计算信息熵-以属性色泽为例**

$$H(D)=-\sum_{c=1}^{C}p_c\log_2 p_c=-\left(\frac{8}{17}\log_2\frac{8}{17}+\frac{9}{17}\log_2\frac{9}{17}\right)=0.998$$

$$H\left(D^{青绿}\right)=-\left(\frac{3}{6}\log_2\frac{3}{6}+\frac{3}{6}\log_2\frac{3}{6}\right)=1.000$$

$$H\left(D^{乌黑}\right)=-\left(\frac{4}{6}\log_2\frac{4}{6}+\frac{2}{6}\log_2\frac{2}{6}\right)=0.918$$

$$H\left(D^{浅白}\right)=-\left(\frac{1}{5}\log_2\frac{1}{5}+\frac{4}{5}\log_2\frac{4}{5}\right)=0.722$$

参照教材《机器学习》-周志华P75-77示例

ID3算法-示例(1)

- **计算信息增益-以属性色泽为例**

$$G\left(D,\text{色泽}\right)=H\left(D\right)-\sum_{n=1}^{3}\frac{\left|D^{n}\right|}{\left|D\right|}H(D^{n})$$

$$=0.998-\left(\frac{6}{17}\times 1.000+\frac{6}{17}\times 0.918+\frac{5}{17}\times 0.722\right)$$

$$=0.109$$

$G(D,$ 色泽$) = 0.109$

$G(D,$ 根蒂$) = 0.143$

$G(D,$ 敲声$) = 0.141$

$G(D,$ 纹理$) = 0.381$

$G(D,$ 脐部$) = 0.289$

$G(D,$ 触感$) = 0.006$

ID3算法-示例(1)

- 基于属性“纹理”对根节点进行划分

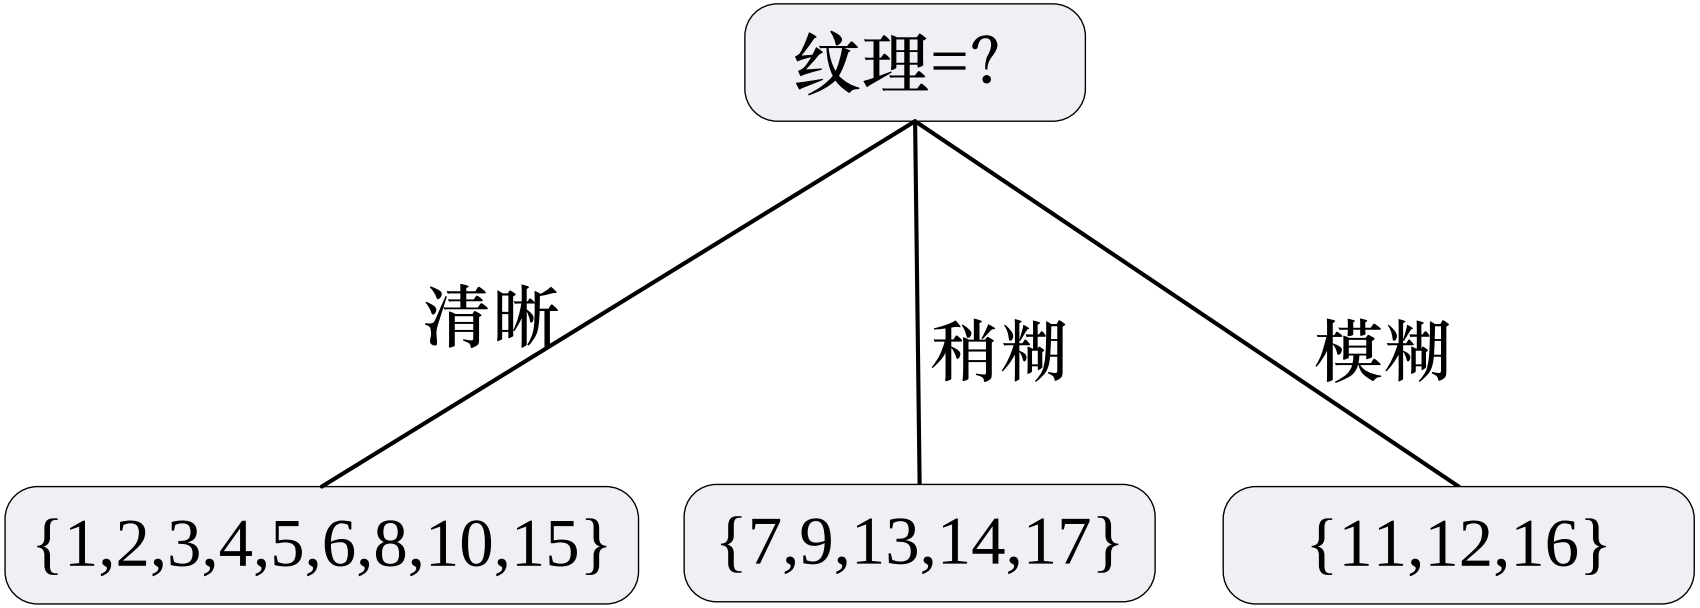

ID3算法-示例(1)

- 继续进行划分-以“纹理=清晰”分支为例
  - “纹理=清晰”分支：

    样本 {1, 2, 3, 4, 5, 6, 8, 10, 15}
  - 计算信息增益

$G(D^{清晰}, 色泽) = 0.043$

$G(D^{清晰}, 敲声) = 0.331$

$\boxed{G(D^{清晰}, 触感) = 0.458}$

$\boxed{\begin{array}{l} G(D^{清晰}, 根蒂) = 0.458 \\ G(D^{清晰}, 脐部) = 0.458 \end{array}}$

ID3算法-示例(1)

- 最终生成的决策树

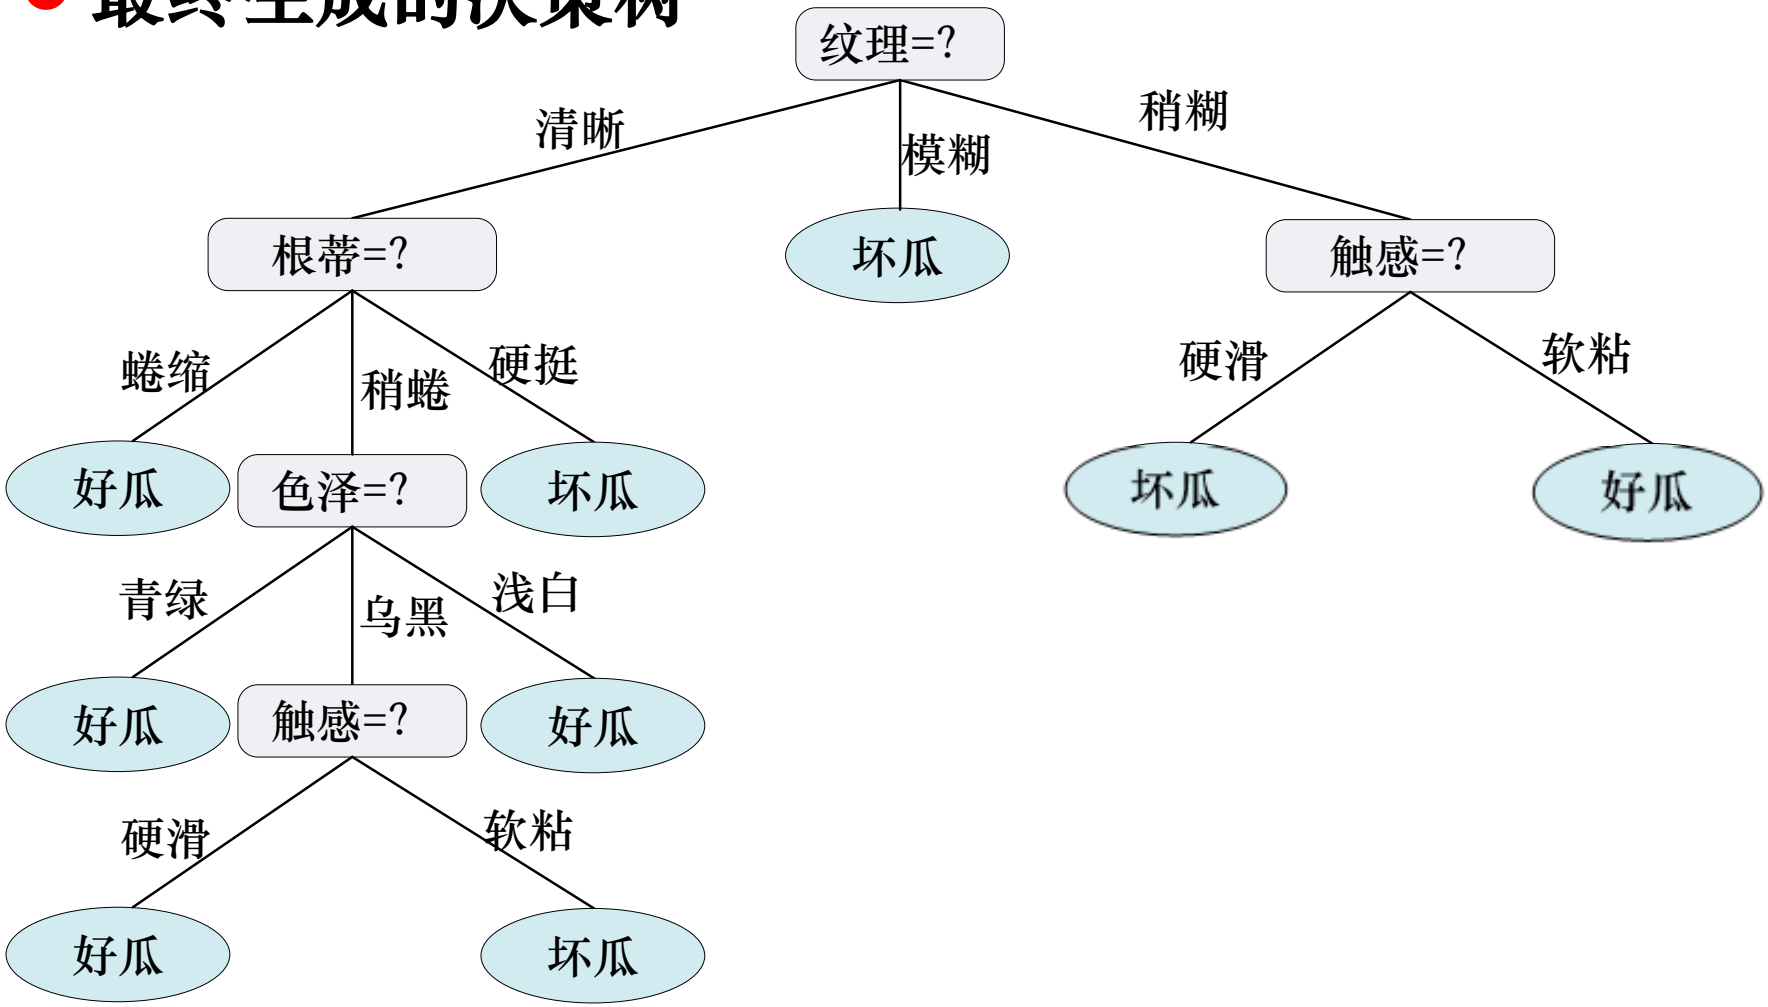

ID3算法-示例(2)

- 谁在买计算机?

问题:

假定公司收集了右表数据，那么对于任意给定的客人(测试样例)，预测这位客人是属于“买”计算机的一类，还是属于“不买”计算机的一类?

计数	年龄	收入	学生	信誉	买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第1步：计算数据集的经验熵

决策属性“买计算机？”

该属性分两类：买/不买

$|C_1|$(买)=641

$|C_2|$ (不买)= 383

$|D|=|C_1|+|C_2|=1024$

$P_1=641/1024=0.6260$

$P_2=383/1024=0.3740$

$$H(D) =-P_1\mathrm{Log}_2P_1-P_2\mathrm{Log}_2P_2$$
$$=-(P_1\mathrm{Log}_2P_1+P_2\mathrm{Log}_2P_2)$$
$$=0.9537$$

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2步:计算特征的信息增益

条件属性共有4个，分别是:
年龄、收入、学生、信誉
计算不同属性的信息增益

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2-1步:计算年龄的经验条件熵

年龄共分三个组:
青年、中年、老年
青年买与不买比例为128/256

$|D_{11}(买)|=128$
$|D_{12}(不买)|= 256$
$|D_1|=|D_{11}|+|D_{12}|=384$

$P_{11}=128/384$
$P_{12}=256/384$

H (青年|年龄)
$=-P_{11}\mathrm{Log}_2P_1-P_{12}\mathrm{Log}_2P_2$
$=-(P_{11}\mathrm{Log}_2P_{11}+P_{12}\mathrm{Log}_2P_{12})$
$=0.9183$

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2-2步:计算年龄的经验条件熵

年龄共分三个组:
青年、中年、老年
中年买与不买比例为256/0

$|D_{21}(买)|= 256$
$|D_{22}(不买)|= 0$
$|D_2|=|D_{21}|+|D_{22}|=256$

$P_{21}=256/256$
$P_{22}=0/256$

$H(中年|年龄)$
$=-P_{21}\mathrm{Log}_2P_{21}-P_{22}\mathrm{Log}_2P_{22}$
$=-(P_{21}\mathrm{Log}_2P_{21}+P_{22}\mathrm{Log}_2P_{22})$
$=0$

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2-3步:计算年龄的经验条件熵

年龄共分三个组:
青年、中年、老年
老年买与不买比例为125/127

$|D_{31}(买)|= 125$
$|D_{32}(不买)|= 127$
$|D_3|=|D_{31}|+|D_{32}|=252$

$P_{31}=125/252$
$P_{32}=127/252$

$H(老年|年龄)$
$=-P_{31}\mathrm{Log}_2P_{31}-P_{32}\mathrm{Log}_2P_{32}$
$=-(P_{31}\mathrm{Log}_2P_{31}+P_{32}\mathrm{Log}_2P_{32})$
$=0.9157$

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2-4步:计算年龄的信息增益

年龄共分三个组:
青年、中年、老年
所占比例
青年组 384/1025=0.375
中年组 256/1024=0.25
老年组 384/1024=0.375

计算年龄的平均信息期望
H(年龄)=0.375*0.9183+
0.25*0+
0.375*0.9157
=0.6877
G(年龄信息增益)
=0.9537-0.6877
=0.2660 (1)

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第3步:计算收入的信息增益

收入共分三个组:
高、中、低
H(收入)=0.9361
G(收入信息增益)=
0.9537- 0.9361=0.0176 (2)

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第4步:计算学生的信息增益

学生共分二个组:
学生、非学生
H(学生)=0.7811
G(学生信息增益)=
0.9537-0.7811=0.1726 (3)

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第5步:计算信誉的信息增益

信誉分二个组:
良好、优秀
H(信誉)= 0.9048
G(信誉信息增益)=
0.9537-0.9048=0.0453 (4)

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第6步:选择结点

年龄信息增益=
0.9537-0.6877=0.2660 (1)

收入信息增益=
0.9537-0.9361=0.0176 (2)

学生信息增益=
0.9537-0.7811=0.1726 (3)

信誉信息增益=
0.9537-0.9048=0.0453 (4)

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	青	中	否	良	不买
64	青	低	是	良	买
64	青	中	是	优	买

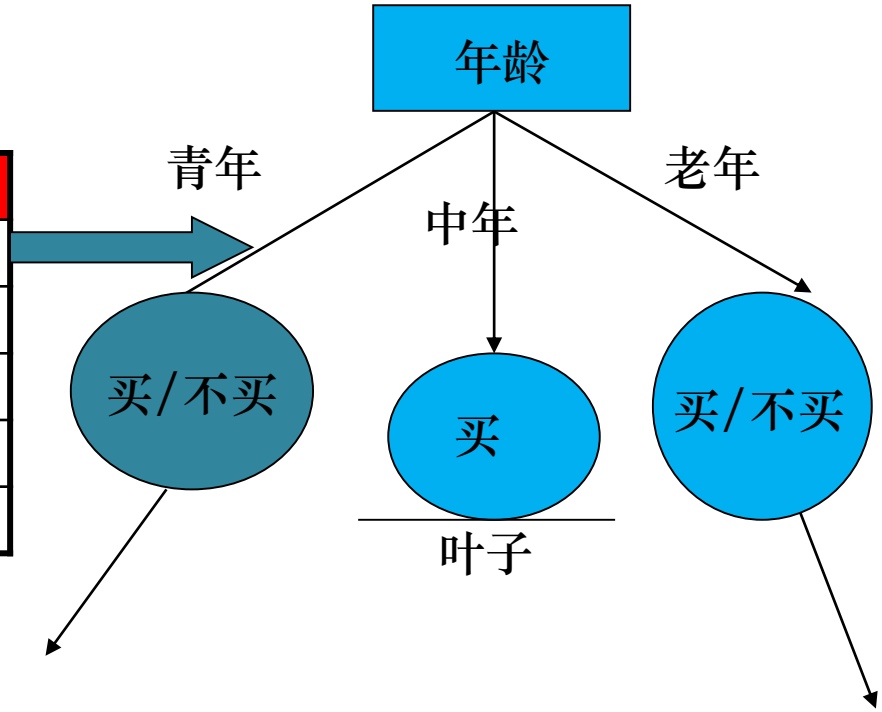

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	青	中	否	良	不买
64	青	低	是	良	买
64	青	中	是	优	买

青年买与不买比例为128/256

$|D_{11}(买)|=128$

$|D_{12}(不买)|= 256$

$|D_1|=|D_{11}|+|D_{12}|=384$

$P_{11}=128/384$

$P_{12}=256/384$

$H(青年|年龄)$

$=-P_{11}\mathrm{Log}_2P_1-P_{12}\mathrm{Log}_2P_2$

$=-(P_{11}\mathrm{Log}_2P_{11}+P_{12}\mathrm{Log}_2P_{12})$

$=0.9183$

ID3算法-示例(2)

- 如果选择收入作为结点，分高、中、低

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	青	中	否	良	不买
64	青	低	是	良	买
64	青	中	是	优	买

H(高)=0
比例: 28/384=0.3333

H(中)=0.9183
比例: 192/384=0.5

H(低)=0
比例: 64/384=0.1667

经验条件熵(加权总和):

H(收入) = 0.3333 * 0 + 0.5 * 0.9183 + 0.1667 * 0 = 0.4592

收入的信息增益

Gain(收入) = H(青年) - H(收入)=0.9183 – 0.4592 = 0.4591

ID3算法-示例(2)

计数	年龄	收入	学生	信誉	归类：买计算机?
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

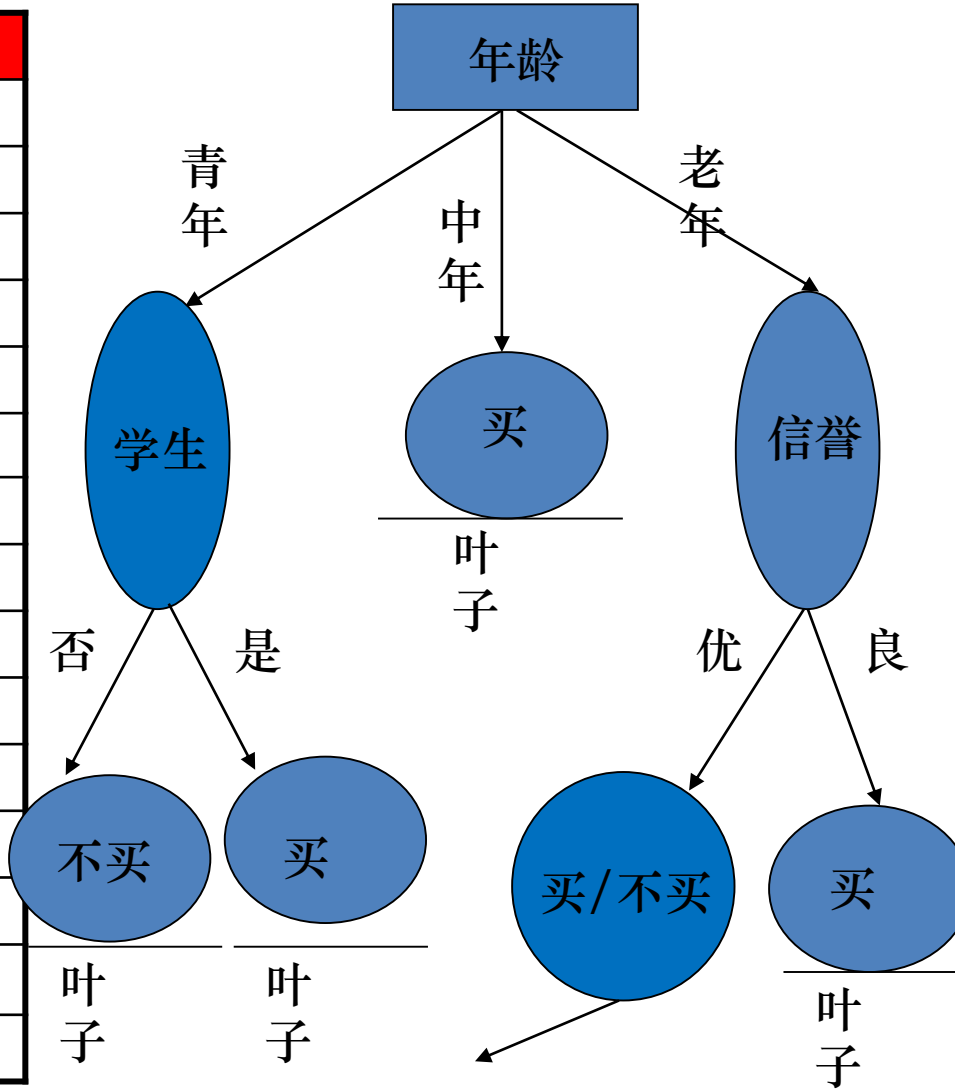

ID3算法

- 算法优点
  - 只需对训练实例进行较好地标注，就能进行学习，从一类无序、无规则事物(概念)中推理出分类规则.
  - 分类模型是树状结构，简单直观，可将决策树中到达每个叶结点的路径转换为IF—THEN形式的分类规则，比较符合人类的理解方式.

ID3算法

- ID3算法局限性
  - 信息增益偏好取值多的属性(极限趋近于均匀分布)
  - 可能会受噪声或小样本影响，易出现过拟合问题
  - 无法处理连续值的属性
  - 无法处理属性值不完整的训练数据
  - 无法处理不同代价的属性

属性筛选度量标准

- 信息增益的问题

$$G(D,a)=H(D)-\sum_{n=1}^{N}\frac{|D^n|}{|D|}H(D^n)$$

  - 信息增益准则对可取值数目*N*较多的属性有所偏好.
  - 取值更多的属性容易使得数据更“纯”，其信息增益更大。决策树会首先挑选这个属性作为树的顶/结点；结果训练出来的形状是一棵庞大且深度很浅的树，这样的划分极不合理.

属性筛选度量标准

- **信息增益率(Information Gain Ratio)**

$$G_{ratio}(D,a)=\frac{G(D,a)}{H(a)}$$

其中

$$H(a)=-\sum_{n=1}^{N}\frac{|D_n|}{|D|}\log_2\frac{|D_n|}{|D|}$$

称为属性*a*的固有值

***N*越大，*H*(*a*)通常也越大；因此采用信息增益率，可缓解信息增益准则对可取值数目较多的属性的偏好.**

C4.5算法就采用增益率替代了ID3算法的信息增益

属性筛选度量标准

- **基尼指数(Gini Index)**

$$Gini(D)=\sum_{c=1}^{C}\sum_{c'\neq c}p_c p_c'=1-\sum_{c=1}^{C}p_c^2=1-\sum_{c=1}^{C}\left(\frac{|D_c|}{|D|}\right)^2$$

直观反映了从数据集中随机抽取两个样本，其类别不一致的概率；基尼指数越小，数据集的纯度越高.

– **属性A的基尼指数** $$Gini(D,a)=\sum_{n=1}^{N}\frac{|D^n|}{|D|}Gini(D^n)$$

– **最优属性选择** $$a^*=\arg\min_{a\in A}Gini(D,a)$$

CART算法就采用基尼指数替代了ID3算法的信息增益

剪枝处理(Pruning)

- 问题：过拟合
  - 决策树对训练数据有很好的分类能力，但对未知的测试数据未必有好的分类能力，泛化能力弱，即可能发生过拟合现象.
- 可能原因
  - 训练数据有噪声，同时拟合了数据和噪音，影响分类效果.
  - 叶结点样本太少，易出现耦合的规律性，使一些属性恰巧可很好地分类，但却与实际目标函数无关.

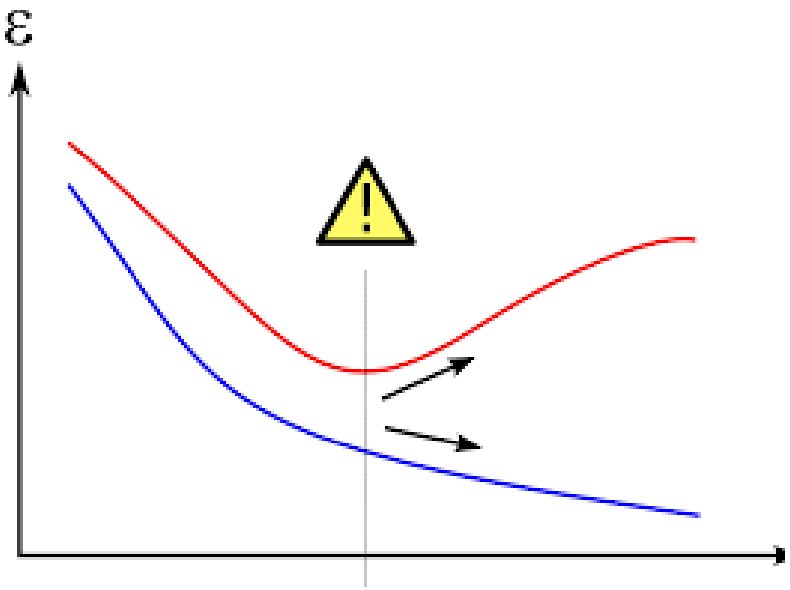

剪枝处理(Pruning)

- 针对过拟合问题
  - 剪枝是主要手段
- 基本策略
  - 预剪枝策略(Pre-pruning)：决策树生成过程中，对每个结点在划分前进行估计，若划分不能带来决策树泛化性能提升，则停止划分并将该节点设为叶结点.
  - 后剪枝策略(Post-pruning)：先利用训练集生成决策树，自底向上对非叶结点进行考察，若将该结点对应子树替换为叶结点能带来泛化性能提升，则将该子树替换为叶结点.

剪枝处理(Pruning)

训练样本

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

测试样本

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

预剪枝算法

- **ID3算法生成的决策树**

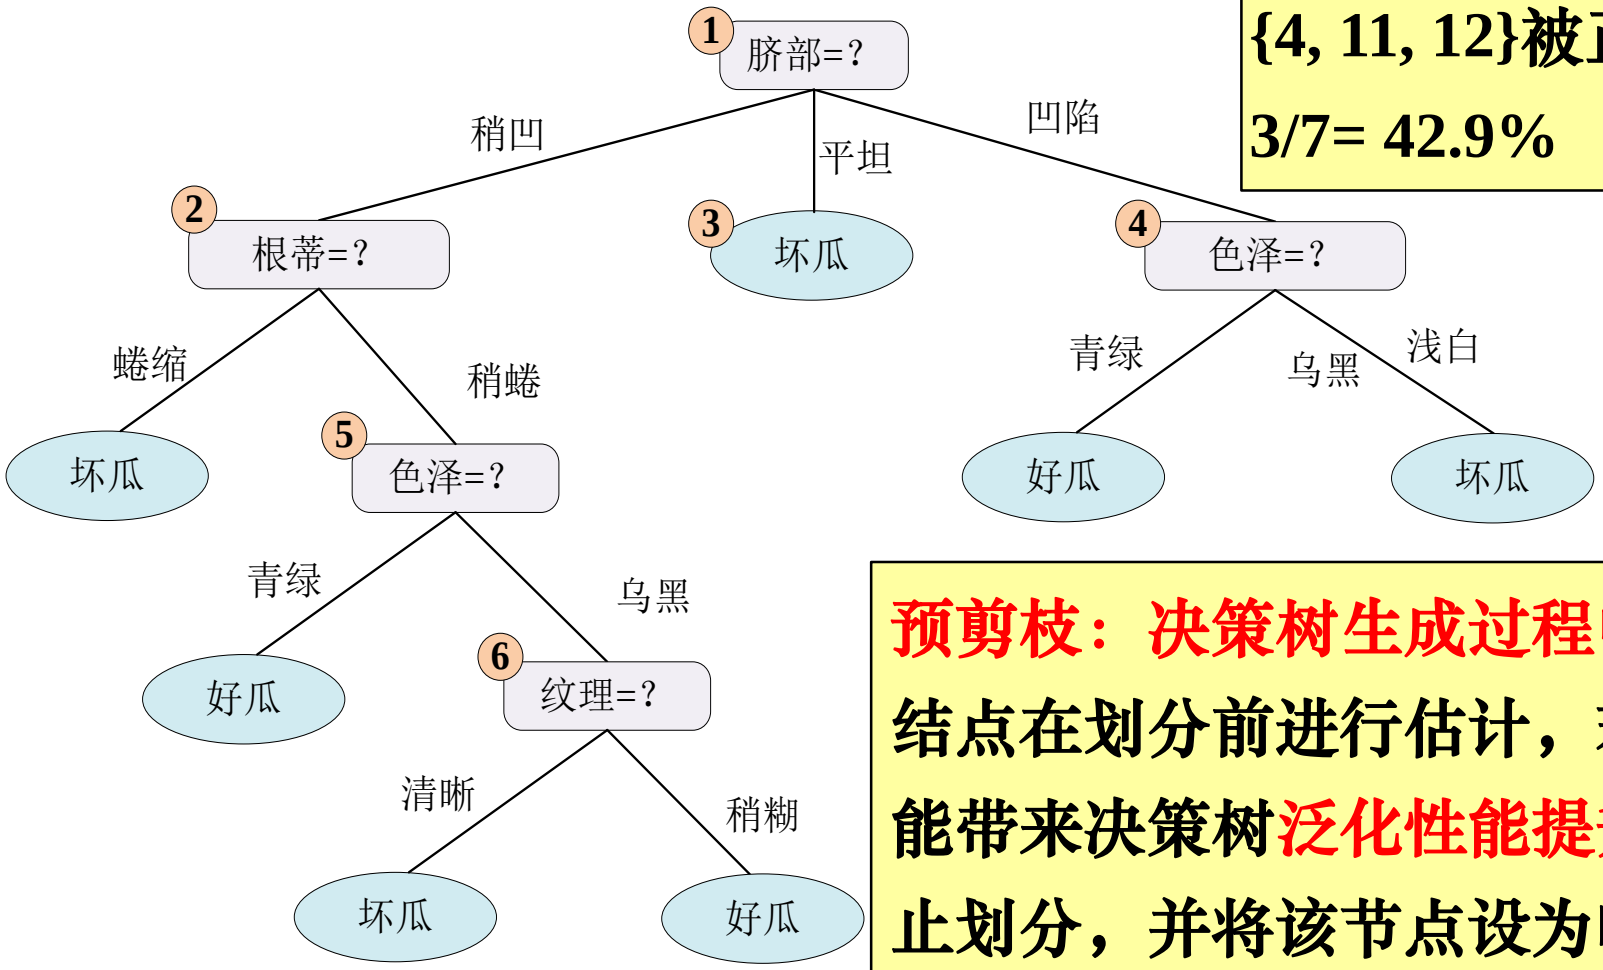

泛化性能：

{4, 11, 12}被正确划分

3/7= 42.9%

预剪枝：决策树生成过程中，对各结点在划分前进行估计，若划分不能带来决策树泛化性能提升，则停止划分，并将该节点设为叶结点.

预剪枝算法

- **第一步：评估结点1**
  - **属性选择：** 基于信息增益准则，选择属性“脐部”

    不划分：

    - 标记为训练样例数最多的类别，如“好瓜”
    - 泛化性能：{4, 5, 8}被正确分类 **3/7= 42.9%**

    划分：

    - 结点2：稍凹{6, 7, 15, 17}　　“好瓜”
    - 结点3：平坦{10, 16}　　“好瓜”
    - 结点4：凹陷{1, 2, 3, 14}　　“坏瓜”
    - 泛化性能：{4, 5, 8, 11, 12}被正确分类 **5/7= 71.4%**

评估结果/预剪枝决策：划分

预剪枝算法

- **第二步：评估结点2：训练样本{6, 7, 15, 17}**
  - **属性选择：**基于信息增益准则，选择属性“根蒂”

    不划分： {4, 5, 8, 11, 12}被正确分类 **5/7= 71.4%**

    划　分： {4, 5, 8, 11, 12}被正确分类 **5/7= 71.4%**

    评估结果/预剪枝决策：不划分
- **第三步：评估结点4：训练样本{1, 2, 3, 14}**
  - **属性选择：**基于信息增益准则，选择属性“色泽”

    不划分： {4, 5, 8, 11, 12}被正确分类 **5/7= 71.4%**

    划　分： {4, ~~5,~~ 8, 11, 12}被正确分类 **4/7= 57.1%**

    评估结果/预剪枝决策：不划分

预剪枝算法

- 最终生成的决策树

测试集精度
“脐部=？” 划分前：42.9%
划分后：71.4%
预剪枝决策：划分

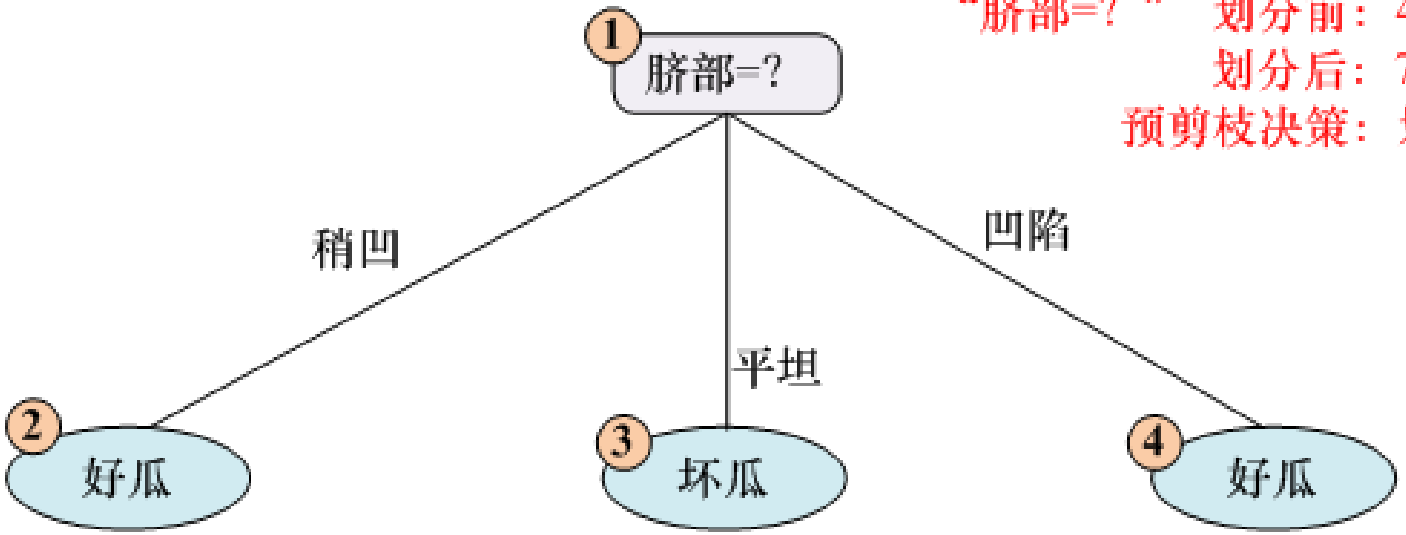

测试集精度
“脐部=？” 划分前：71.4%
划分后：57.1%
预剪枝决策：不划分

测试集精度
“色泽=？” 划分前：71.4%
划分后：71.4%
预剪枝决策：不划分

预剪枝算法

- **策略特点**
  - **优势**：“剪掉”很多没必要展开的分支，降低了过拟合风险，并且显著减少了决策树的训练时间开销和测试时间开销.
  - **劣势**：有些分支的当前划分有可能不能提高甚至降低泛化性能，但后续划分有可能提高泛化性能；预剪枝禁止这些后续分支的展开，可能会导致欠拟合.

后剪枝算法

- **ID3算法生成的决策树**

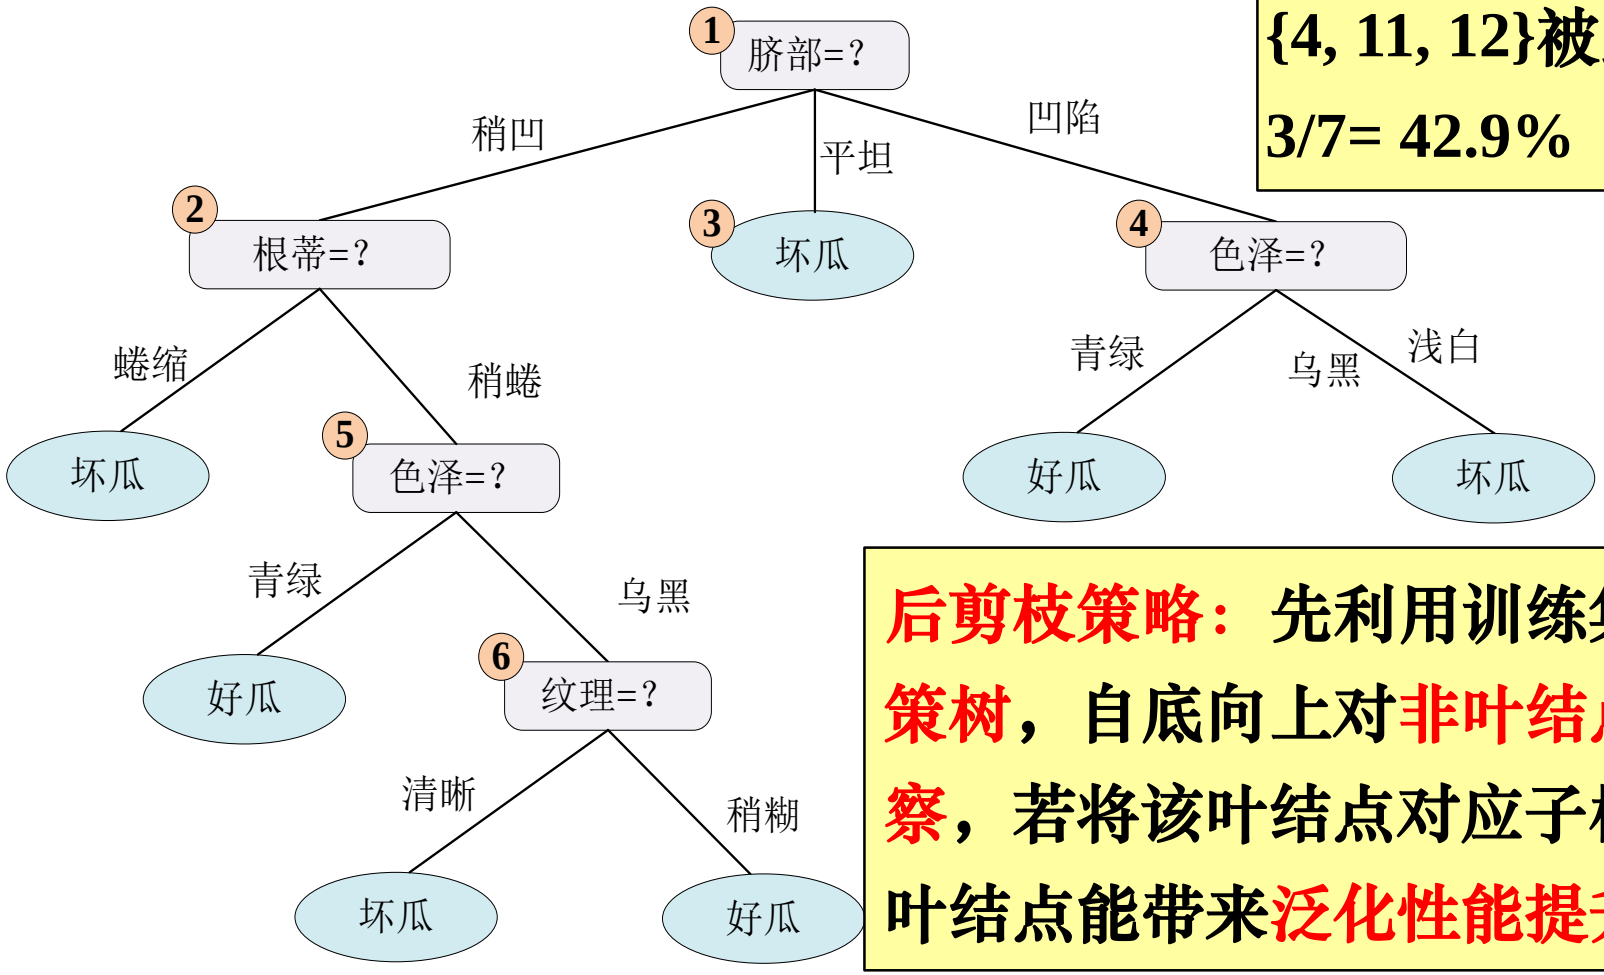

泛化性能：

{4, 11, 12}被正确划分

3/7= 42.9%

后剪枝策略：先利用训练集生成决策树，自底向上对非叶结点进行考察，若将该叶结点对应子树替换为叶结点能带来泛化性能提升，替换.

后剪枝算法

- **第一步：评估结点6**

剪枝前：

- 属性为“纹理”；样本为{7, 15}
- 泛化性能：{4, 11, 12}被正确分类 **3/7= 42.9%**

剪枝后：

- 把节点6替换为叶结点，“好/坏瓜”
- 泛化性能：{4, **8/9**, 11, 12}被正确分类 **4/7= 57.1%**

评估结果/后剪枝决策： 剪枝

后剪枝算法

- **第二步：评估结点5**

  剪枝前：

  - 属性为“色泽”，样本{6, 7, 15}
  - 泛化性能：同第一步 **4/7= 57.1%**

  剪枝后：

  - 把节点5替换为叶结点，“好瓜”
  - 泛化性能：{4, 8, 11, 12}被正确分类 **4/7= 57.1%**

评估结果/后剪枝决策： 不剪枝

后剪枝算法

- **第三步：评估结点4**

剪枝前：

- 属性为“色泽”，样本{1, 2, 3, 14}
- 泛化性能：同上一步 **4/7= 57.1%**

剪枝后：

- 把结点4替换为叶结点，“好瓜”
- 泛化性能：{4, **5**, 8, 11, 12}被正确分类 **5/7= 71.4%**

评估结果/后剪枝决策： 剪枝

后剪枝算法

- **第四步：评估结点2**

剪枝前：

- 属性为“根蒂”，样本{6, 7, 15, 17}
- 泛化性能：同上一步 **5/7= 71.4%**

剪枝后：

- 把结点2替换为叶结点，“好/坏瓜”
- 泛化性能：{4, 5, **8/9**, 11, 12}被正确分类 **5/7= 71.4%**

评估结果/后剪枝决策： 不剪枝

后剪枝算法

- **第五步：评估结点1**

  剪枝前：

  - 泛化性能：同上一步 **5/7= 71.4%**

  剪枝后：

  - 把结点1替换为叶结点
  - 泛化性能：{4, 5, 8, 11, 12}被正确分类 **5/7= 71.4%**

评估结果/后剪枝决策： 不剪枝

后剪枝算法

- 最终生成的决策树

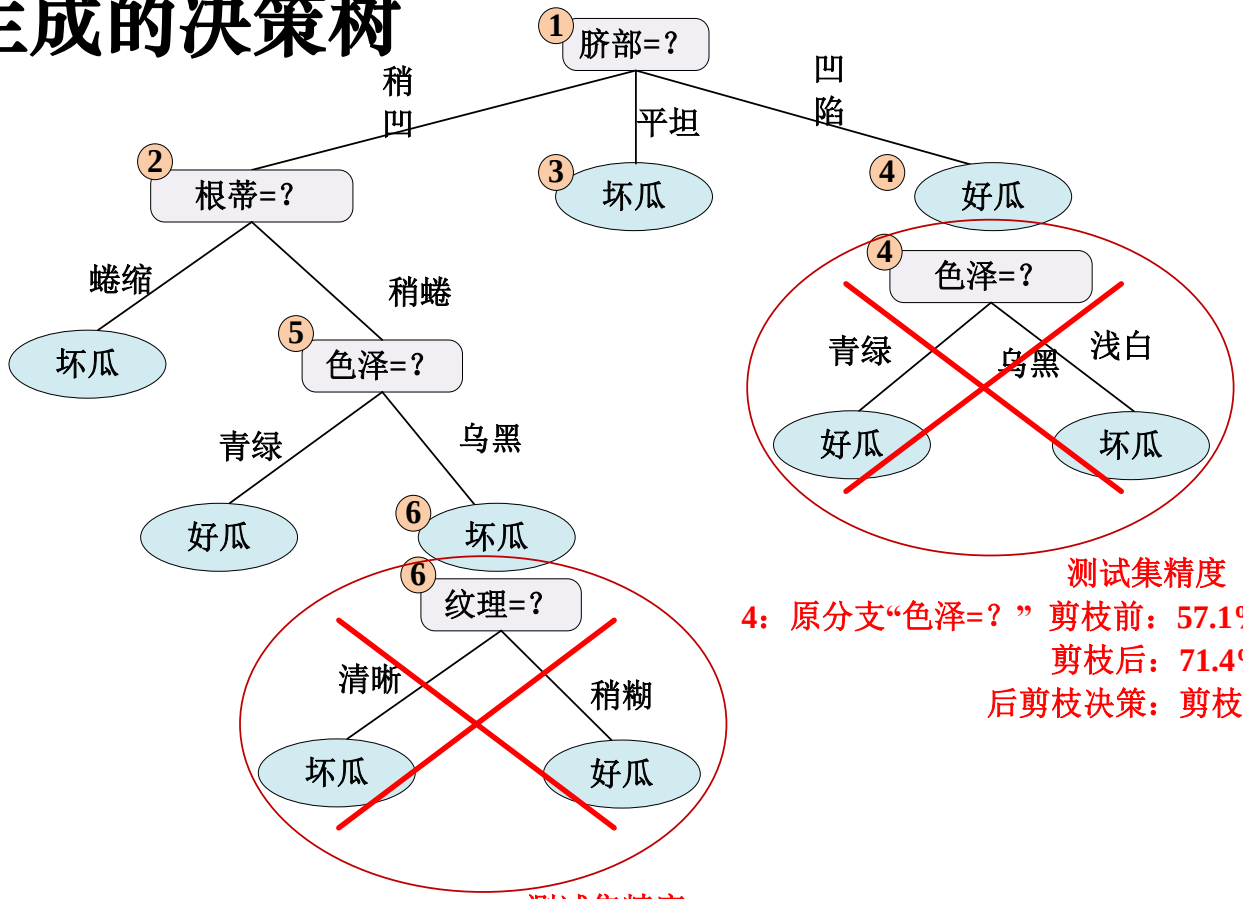

测试集精度

4：原分支“色泽=？”剪枝前：57.1%

剪枝后：71.4%

后剪枝决策：剪枝

测试集精度

6：原分支“纹理=？”剪枝前：42.9%

剪枝后：57.1%

后剪枝决策：剪枝

后剪枝算法

- **策略特点**
  - **优势**：测试了所有分支，比预剪枝决策树保留了更多分支，降低了欠拟合的风险，泛化性能一般优于预剪枝决策树.
  - **劣势**：后剪枝过程在生成完全决策树后再进行，且要自底向上对所有非叶节点逐一评估；因此，决策树的训练时间开销要高于未剪枝决策树和预剪枝决策树.

连续值处理

- 基本思想：采用二分法(Bi-Partition)进行离散化
  - 给定样本集D和连续属性a($a \in A$)，假定a在D上有N个不同取值，将这些值从大到小排序得到$\{a_1, a_2, \ldots, a_N\}$
  - 基于划分点t，可将D分为子集D_t^+和D_t^-，其中D_t^+ (D_t^-)包含了属性值A不小(大)于t的样本子集
  - t在$[a_n, a_{n+1})$上的任意取值的划分结果都相同

连续值处理

- **基本思想：采用二分法(Bi-Partition)进行离散化**
  - **候选划分点集合** $T_a = \left\{ \frac{a_n + a_{n+1}}{2} \middle| 1 \le n \le N-1 \right\}$
  - **信息增益** $G(D,a) = \max_{t \in T_a} G(D,a,t)$

$$= \max_{t \in T_a} \left(H(D) - \sum_{\lambda \in \{+,-\}} \frac{|D_t^\lambda|}{|D|} H(D_t^\lambda) \right)$$

其中，$G(D,A,t)$ 是样本集D基于划分点t二分后的信息增益．我们需选择使 $G(D,A,t)$ 最大的划分点t.

连续值处理-示例

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.46	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.36	0.37	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

连续值处理-示例

- **计算候选划分点集合**

$$T_a = \left\{ \frac{a_n + a_{n+1}}{2} \,\middle|\, 1 \le n \le N-1 \right\}$$

- $T_{密度}$= {0.244, 0.294, 0.351,…, 0.708, 0.746}

- $T_{含糖率}$= {0.049, 0.074, 0.095,…, 0.373, 0.126}

参照教材《机器学习》-周志华P84-85示例

连续值处理-示例

- **计算信息增益**

$$G(D,a)=\max_{t\in T_a}\left(H(D)-\sum_{\lambda\in\{+,-\}}\frac{|D_t^{\lambda}|}{|D|}H(D_t^{\lambda})\right)$$

- $G(D,$ 密度$) = 0.262$ $T^*_{密度}=0.381$
- $G(D,$ 含糖率$) =0.349$ $T^*_{含糖率}=0.126$

已知：

$G(D,$ 色泽$) = 0.109$ $G(D,$ 根蒂$) = 0.143$

$G(D,$ 敲声$) = 0.141$ $G(D,$ 纹理$) = 0.381$

$G(D,$ 脐部$) = 0.289$ $G(D,$ 触感$) = 0.006$

连续值处理-示例

- 最终生成的决策树

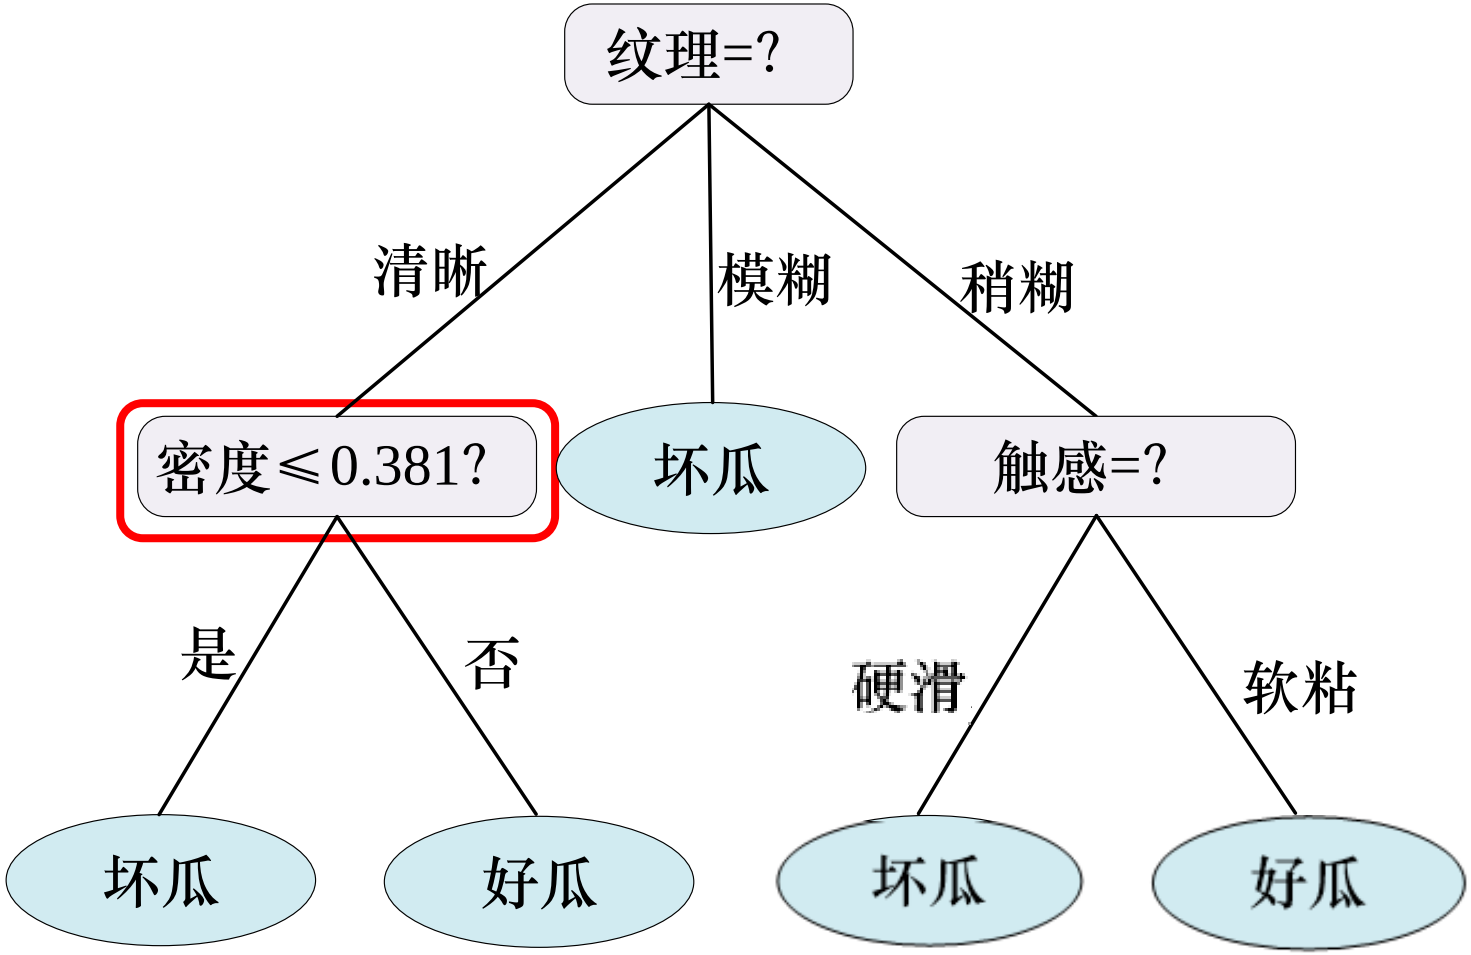

缺失值处理

- **问题描述**
  - 基本假设：所有样本的属性完整
  - 实际情况：存在不完整样本，即样本的某些属性缺失，特别是属性数目较多时
  - 如果简单放弃不完整样本，会导致数据信息浪费
  - 存在实际应用需要在属性缺失情况下进行决策

例如在医疗领域，由于诊测成本、隐私保护等问题，只有部分诊断结果…

缺失值处理

- **需要解决的两个问题**
  - 如何在属性值缺失的情况下进行划分属性选择(计算信息增益)?
  - 给定划分属性，若样本在该属性上的值缺失，如何对样本进行划分?

缺失值处理

- **定义**
  - $\tilde{D}$: ***D***中在属性***a***上没有缺失值的样本子集
  - 属性***a***$(a \in A)$ 有***N***个可取值$\{a_1, a_2, \ldots, a_N\}$
  - $\tilde{D}^n$: $\tilde{D}$中在属性***a***上取值为a_n的样本子集
  - $\tilde{D}_c$: $\tilde{D}$ 中属于第***c***$(c \in C)$类的样本子集
  - 无缺失值样本所占比例 $\rho = \dfrac{\sum_{x \in \tilde{D}} \omega_x}{\sum_{x \in D} \omega_x}$
  - 无缺失样本中第***c***类比例 $\tilde{p}_c = \dfrac{\sum_{x \in \tilde{D}_c} \omega_x}{\sum_{x \in \tilde{D}} \omega_x}, (1 \le c \le C), \sum_{c=1}^{C} \tilde{p}_c = 1$
  - 无缺失样本中属性***a***上取值为a_n的比例 $\tilde{r}_n = \dfrac{\sum_{x \in \tilde{D}^n} \omega_x}{\sum_{x \in \tilde{D}} \omega_x}, (1 \le n \le N), \sum_{n=1}^{N} \tilde{r}_n = 1$

缺失值处理

- **信息增益** $G(D,A)=\rho\times G(\tilde{D},A)$

$$=\rho\times\left(H(\tilde{D})-\sum_{n=1}^{N}\tilde{r}_n H(\tilde{D}_n)\right)$$

其中 $H(\tilde{D})=-\sum_{c=1}^{C}\tilde{p}_c\log_2\tilde{p}_c$

原则：让样本以不同概率划分到不同的子结点去

- 若样本x在属性a上的取值已知，则将x划入与其取值对应的子结点，且样本权值保持为ω_x
- 若样本x在属性a上的取值未知，则将x划入所有子结点，且样本权值在与属性值对应的子结点中调整为 $\tilde{r}_n\cdot\omega_x$

缺失值处理-示例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	—	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	—	是
3	乌黑	蜷缩	—	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	—	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	—	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	—	稍凹	硬滑	是
9	乌黑	—	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	—	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	—	否
12	浅白	蜷缩	—	模糊	平坦	软粘	否
13	—	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	—	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	—	沉闷	稍糊	稍凹	硬滑	否

缺失值处理-示例

- **计算信息熵-以属性色泽为例**

$$H\left(\tilde{D}\right)=-\sum_{c=1}^{C}\tilde{p}_c\log_2\tilde{p}_c=-\left(\frac{6}{14}\log_2\frac{6}{14}+\frac{8}{14}\log_2\frac{8}{14}\right)=0.985$$

$$H\left(\tilde{D}^{\text{青绿}}\right)=-\left(\frac{2}{4}\log_2\frac{2}{4}+\frac{2}{4}\log_2\frac{2}{4}\right)=1.000$$

$$H\left(\tilde{D}^{\text{乌黑}}\right)=-\left(\frac{4}{6}\log_2\frac{4}{6}+\frac{2}{6}\log_2\frac{2}{6}\right)=0.918$$

$$H\left(\tilde{D}^{\text{浅白}}\right)=-\left(\frac{0}{4}\log_2\frac{0}{4}+\frac{4}{4}\log_2\frac{4}{4}\right)=0.000$$

参照教材《机器学习》-周志华P86-88示例

缺失值处理-示例

- **计算信息增益-以属性色泽为例**

$$G\left(\tilde{D},\text{色泽}\right)=H\left(\tilde{D}\right)-\sum_{n=1}^{3}\tilde{r}_n H(\tilde{D}_n)$$

$$=0.985-\left(\frac{4}{14}\times 1.000+\frac{6}{14}\times 0.918+\frac{4}{14}\times 0.000\right)$$

$$=0.306$$

$$G\left(D,\text{色泽}\right)=\rho\times G\left(\tilde{D},\text{色泽}\right)=\frac{14}{17}\times 0.306=0.252$$

$G(D,$ 色泽$) = 0.252$

$G(D,$ 根蒂$) = 0.171$

$G(D,$ 敲声$) = 0.145$

$G(D,$ 纹理$) = 0.424$

$G(D,$ 脐部$) = 0.289$

$G(D,$ 触感$) = 0.006$

缺失值处理-示例

- **因此选择属性“纹理”用于对根结点划分**
  - 属性不缺失样本
    - “纹理=清晰”分支：样本 {1, 2, 3, 4, 5, 6, 15}
    - “纹理=稍糊”分支：样本 {7, 9, 13, 14, 17}
    - “纹理=模糊”分支：样本 {11, 12, 16}
    - 且样本在各结点中的权重ω保持为1
  - 属性缺失样本
    - 样本{8, 10}:同时进入三个分支，权重ω分别为$\frac{7}{15}, \frac{5}{15}, \frac{3}{15}$

缺失值处理-示例

- 最终生成的决策树

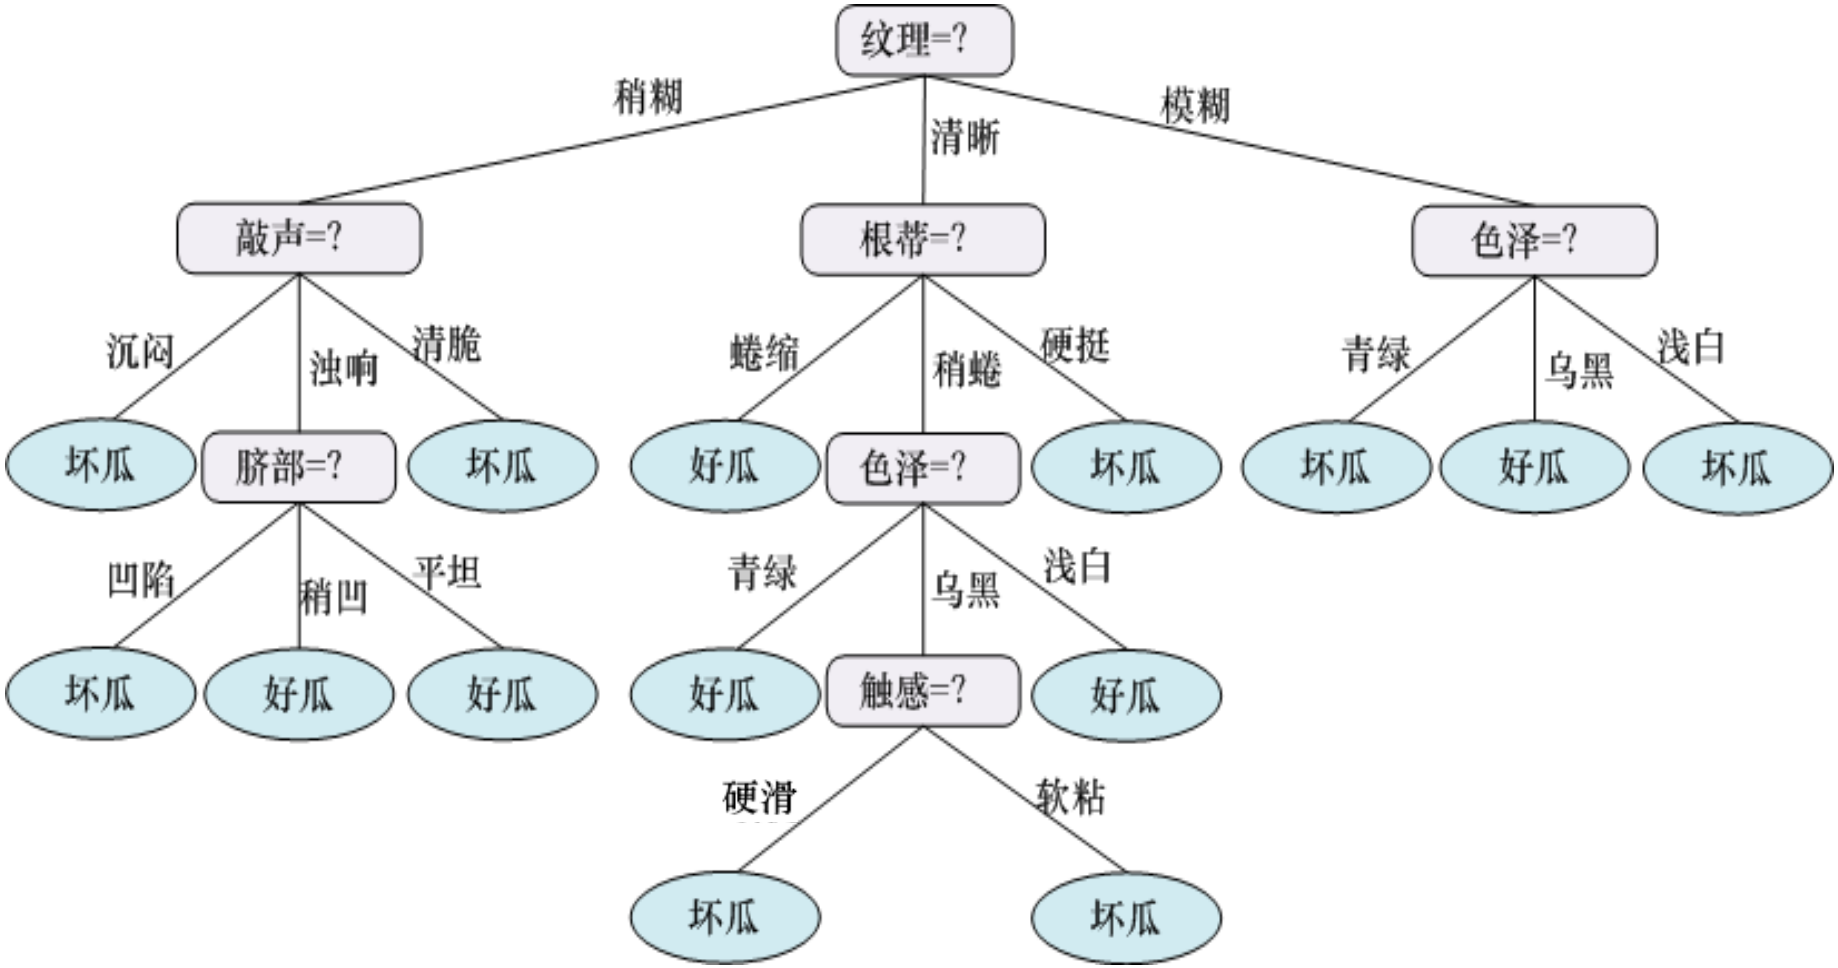

不同代价属性的处理

- **问题描述**
  - 不同的属性测量具有不同的代价
  - 医疗诊断为例：
    - 属性：体温、血压、血常规、活检
    - 代价不同：所需时间、费用、友好性等
- **基本思想**
  - 在属性筛选度量标准中考虑属性的不同代价
  - 优先选择低代价属性的决策树
  - 必要时才依赖高代价属性

不同代价属性的处理

- **属性筛选度量标准1** [*Tan et al.*, 1990, 1993]

$$G_{Cost}(D,a)=\frac{G(D,a)}{Cost(a)}$$

- **属性筛选度量标准2** [*Nunez et al.*, 1988, 1991]

$$G_{Cost}(D,a)=\frac{2^{G(D,a)}-1}{(Cost(a)+1)^{\omega}}$$

其中$Cost(\boldsymbol{a})$为属性$\boldsymbol{a}$的代价

$\omega\in[0,1]$为常数，决定代价对于信息增益的相对重要性

延伸阅读

- **概念学习系统(Concept Learning System, CLS)**
  - 1966年由Hunt等人提出，奠定决策树算法发展的基础
- **分类回归树(Classification And Regression Tree, CART)算法：**
  - 1984年由Breiman等人提出，是一种二分递归分割技术
- **J. R. Quinlan**
  - **1979年：ID3算法； 1993年：C4.5算法**
- **多变量决策树**
  - **OC1[Murthy et al., 1994]等**