机器学习
Machine Learning

北京航空航天大学计算机学院
School of Computer Science and Engineering, Beihang University
黄 迪

2020年秋季学期
Fall 2020

部分内容来源于C. Bishop和A. NG等人的课程以及互联网资源

第七章：聚类

Chapter 7: Clustering

机器学习算法

机器学习主要问题

	Supervised Learning	Unsupervised Learning
Discrete	Classification or Categorization	Clustering
Continuous	Regression	Dimensionality Reduction

什么是聚类?

- 无监督学习：训练样本的标记未知，通过学习揭示数据内在的性质及规律.

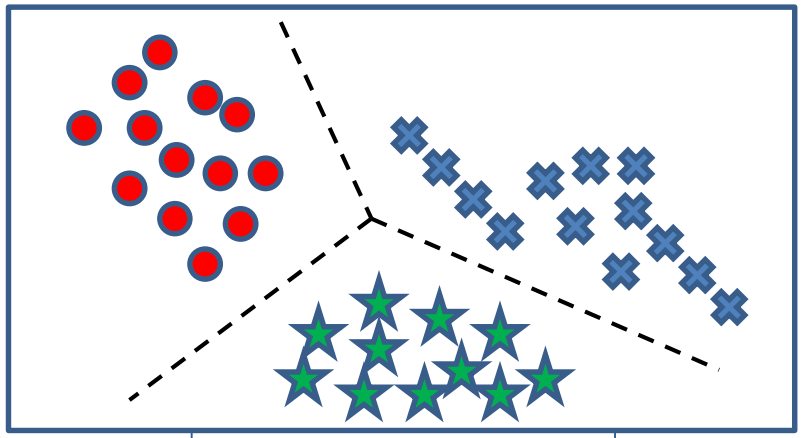

监督学习

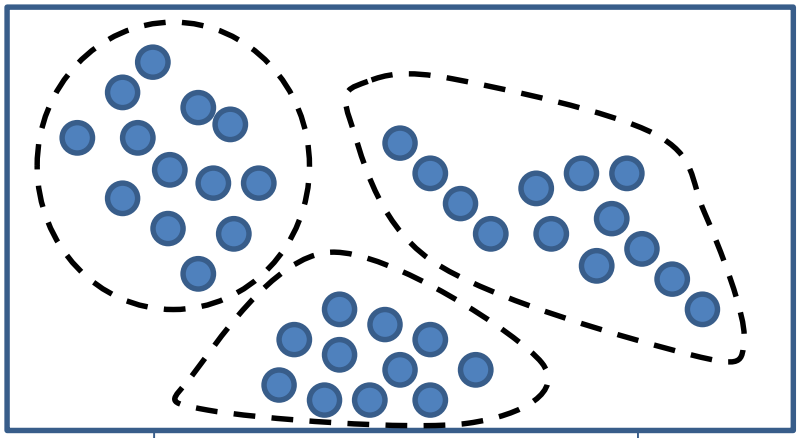

非监督学习

什么是聚类?

- 聚类目标：将数据集中的样本划分为若干个通常不相交的子集 (每个子集称为“簇”, Cluster).
- 聚类可以是一单独过程 (用于找寻数据内在的分布结构)，也可作为分类等其他学习任务的前驱过程.

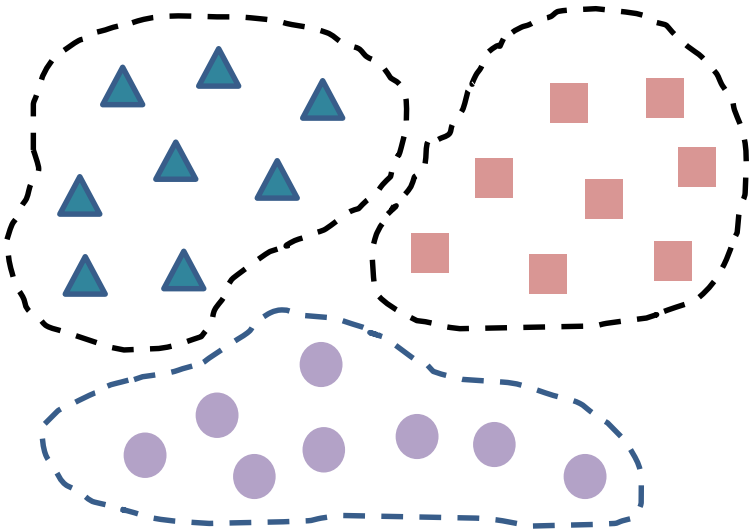

举例：瘢痕组织分割

- 脊髓损伤后会启动一系列与形成瘢痕组织相关的细胞及分子间的反应，最终在病变区域形成以星形胶质细胞为主的致密瘢痕组织，将损伤区与周围正常组织分隔开。瘢痕组织的出现，对脊髓损伤后再生的神经轴突起到了机械屏障和化学屏障的双重抑制作用，是阻碍脊髓损伤神经再生的主要障碍。

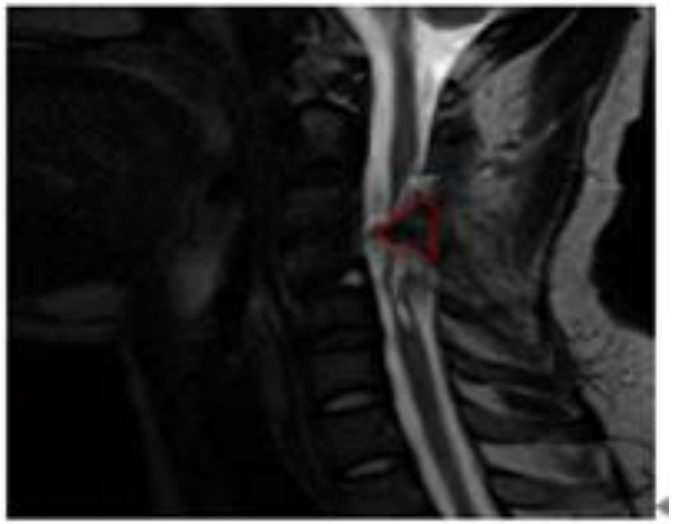

聚类的形式化描述

- 假定样本集 $D=\{x_1,x_2,\cdots,x_m\}$ 包含m个无标记样本,每个样本 $x_i=(x_{i1};x_{i2};\cdots;x_{in})$ 是一个 n 维的特征向量，聚类算法将样本集 D 划分成 k 个**不相交**的簇 $\{C_l|l=1,2,...,k\}$。其中 $C_{l'}\bigcap C_l=\phi,l'\neq l$，且 $D=\bigcup_{l=1}^{k}C_l$ 。
- 用 $\lambda_j\in\{1,2,\cdots,k\}$ 表示样本 x_j 的“簇标记”(Cluster Label)，即 $x_j\in C_{\lambda_j}$。于是，聚类的结果可用包含 m 个元素的簇标记向量 $\lambda=\{\lambda_1;\lambda_2;\cdots;\lambda_m\}$ 表示。

性能度量

- 聚类“有效性指标”(Validity Index)

  同一簇样本相似度高，不同簇样本差异度大。即“簇内相似度”(Intra-cluster Similarity)高,“簇间相似度”(Inter-cluster Similarity)低。

  - 外部指标 (External Index)

  将聚类结果与某个“参考模型”进行比较

  - 内部指标 (Internal Index)

  直接考察聚类结果而不用任何参考模型

性能度量

- **聚类“有效性指标”(Validity Index)**

对数据集 $D=\{x_1,x_2,\ldots,x_m\}$**，假定通过聚类得到的簇划分为** $C=\{C_1,C_2,\ldots,C_k\}$**，参考模型的簇划分为** $C^*=\{C_1^*,C_2^*,\ldots,C_s^*\}$**。相应地，令** λ**与** λ^***分别表示与** C **和** C^***对应的簇标记向量。**

定义

$$a=|SS|, SS=\{(x_i,x_j)|\lambda_i=\lambda_j,\lambda_i^*=\lambda_j^*,i<j\}$$

$$b=|SD|, SD=\{(x_i,x_j)|\lambda_i=\lambda_j,\lambda_i^*\neq\lambda_j^*,i<j\}$$

$$c=|DS|, DS=\{(x_i,x_j)|\lambda_i\neq\lambda_j,\lambda_i^*=\lambda_j^*,i<j\}$$

$$d=|DD|, DD=\{(x_i,x_j)|\lambda_i\neq\lambda_j,\lambda_i^*\neq\lambda_j^*,i<j\}$$

$$a+b+c+d=m(m-1)/2$$

性能度量

- **聚类“有效性指标”(Validity Index)**

外部指标:

- **Jaccard系数 (Jaccard Coefficient, JC)**

$$JC = \frac{a}{a+b+c}$$

- **FM指数 (Fowlkes and Mallows Index, FMI)**

$$FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$$

- **Rand指数 (Rand Index, RI)**

$$RI = \frac{2(a+b)}{m(m-1)}$$

[0,1]区间内
越大越好

性能度量

- **聚类“有效性指标”(Validity Index)**

  对簇划分 $C=\{C_1,C_2,\ldots,C_k\}$**，定义：**

  - **簇** C**内样本间的平均距离**

    $$avg(C)=\frac{2}{|C|(|C|-1)}\sum_{1\le i\le j\le |C|}dist(x_i,x_j)$$

  - **簇** C**内样本间的最远距离**

    $$diam(C)=max_{1\le i\le j\le |C|}dist(x_i,x_j)$$

  - **簇** C_i**与簇** C_j**最近样本间的距离**

    $$d_{min}(C)=min_{x_i\in C_i,x_j\in C_j}dist(x_i,x_j)$$

  - **簇** C_i**与簇** C_j**中心点间的距离**

    $$d_{cen}(C)=dist(\mu_i,\mu_j)\ \ \mu=\frac{1}{|C|}\sum_{1\le i\le |C|}x_i$$

性能度量

- **聚类“有效性指标”(Validity Index)**

内部指标:

- **DB指数 (Davies-Bouldin Index, DBI)**

$$DBI = \frac{1}{k}\sum_{i=1}^{k}\max_{j\neq i}\left(\frac{avg(C_i)+avg(C_j)}{d_{cen}(\mu_i,\mu_j)}\right)$$

越小越好

- **Dunn指数 (Dunn Index, DI)**

$$DI = \min_{1\leq i\leq k}\left\{\min_{j\neq i}\left(\frac{d_{min}(C_i,C_j)}{\max_{1\leq l\leq k} diam(C_l)}\right)\right\}$$

越大越好

聚类方法

- K均值(K-Means)
- K-means++
- Kernel K-means
- ISODATA
- AGNES

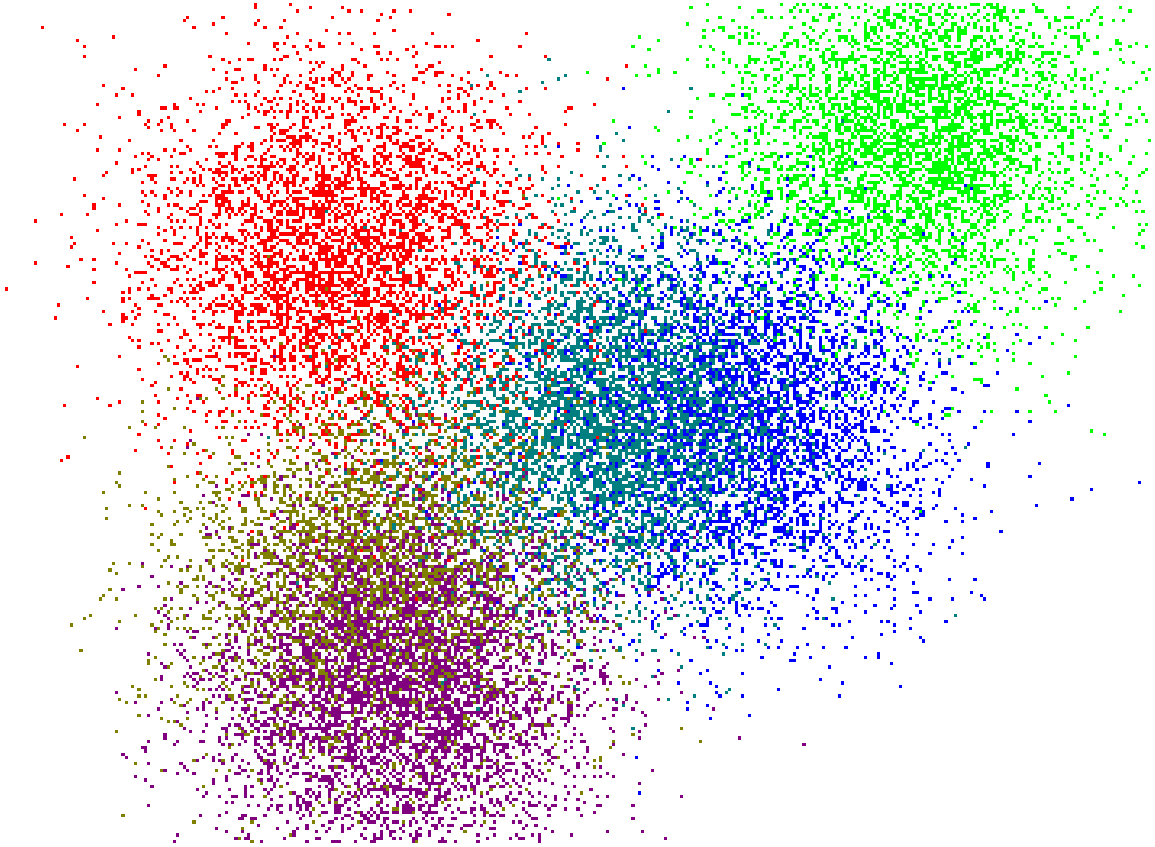

K均值算法

- 给定数据集$D=\{x_1,x_2,\cdots,x_m\}$，K均值算法针对聚类所得簇划分$C=\{C_1,C_2,\cdots,C_k\}$

- 最小化准则函数$E=\sum_{i=1}^{k}\sum_{x\in C_j}\|x-\mu_i\|_2^2$

其中，μ_i是簇C_i的均值向量

E在一定程度上刻画了簇内样本围绕簇均值向量的紧密程度，E值越小，簇内样本相似度越高。

K均值算法

- **K-means**

输入： 样本集$D = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_m\}$;
聚类簇数k.

过程：

从D中随机选择k个样本作为初始均值向量$\{\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \ldots, \boldsymbol{\mu}_k\}$
repeat
  令$C_i = \emptyset \ (1 \leq i \leq k)$
  for $j = 1, \ldots, m$ **do**
    计算样本$\boldsymbol{x}_j$与各均值向量$\boldsymbol{\mu}_i \ (1 \leq i \leq k)$的距离：$d_{ji} = ||\boldsymbol{x}_j - \boldsymbol{\mu}_i||_2$;
    根据距离最近的均值向量确定$\boldsymbol{x}_j$的簇标记：$\lambda_j = \arg\min_{i \in \{1,2,\ldots,k\}} d_{ji}$;
    将样本$\boldsymbol{x}_j$划入相应的簇：$C_{\lambda_j} = C_{\lambda_j} \bigcup \{\boldsymbol{x}_j\}$;
  end for
  for $i = 1, \ldots, k$ **do**
    计算新均值向量：$\boldsymbol{\mu}'_i = \frac{1}{|C_i|} \sum_{\boldsymbol{x} \in C_i} \boldsymbol{x}$;
    if $\boldsymbol{\mu}'_i \neq \boldsymbol{\mu}_i$ **then**
      将当前均值向量$\boldsymbol{\mu}_i$更新为$\boldsymbol{\mu}'_i$
    else
      保持当前均值向量不变
    end if
  end for
until 当前均值向量均未更新
return 簇划分结果

输出： 簇划分$\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$

K均值算法

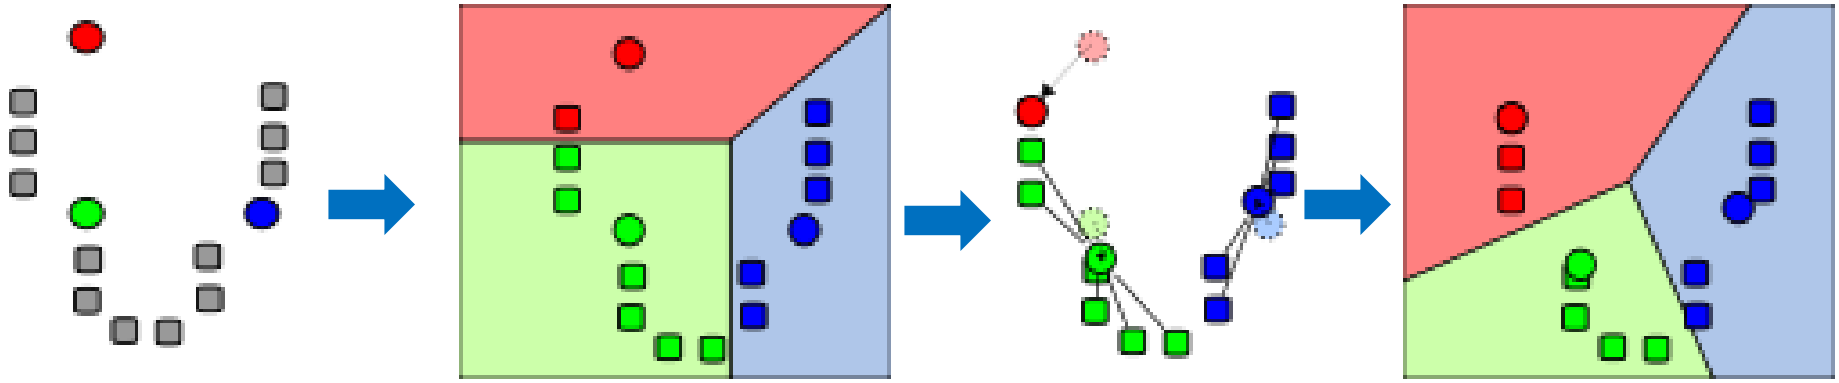

Initialize Cluster Centers **Assign Points to Clusters** **Re-compute Means** **Repeat (1) and (2)**

K均值过程示例

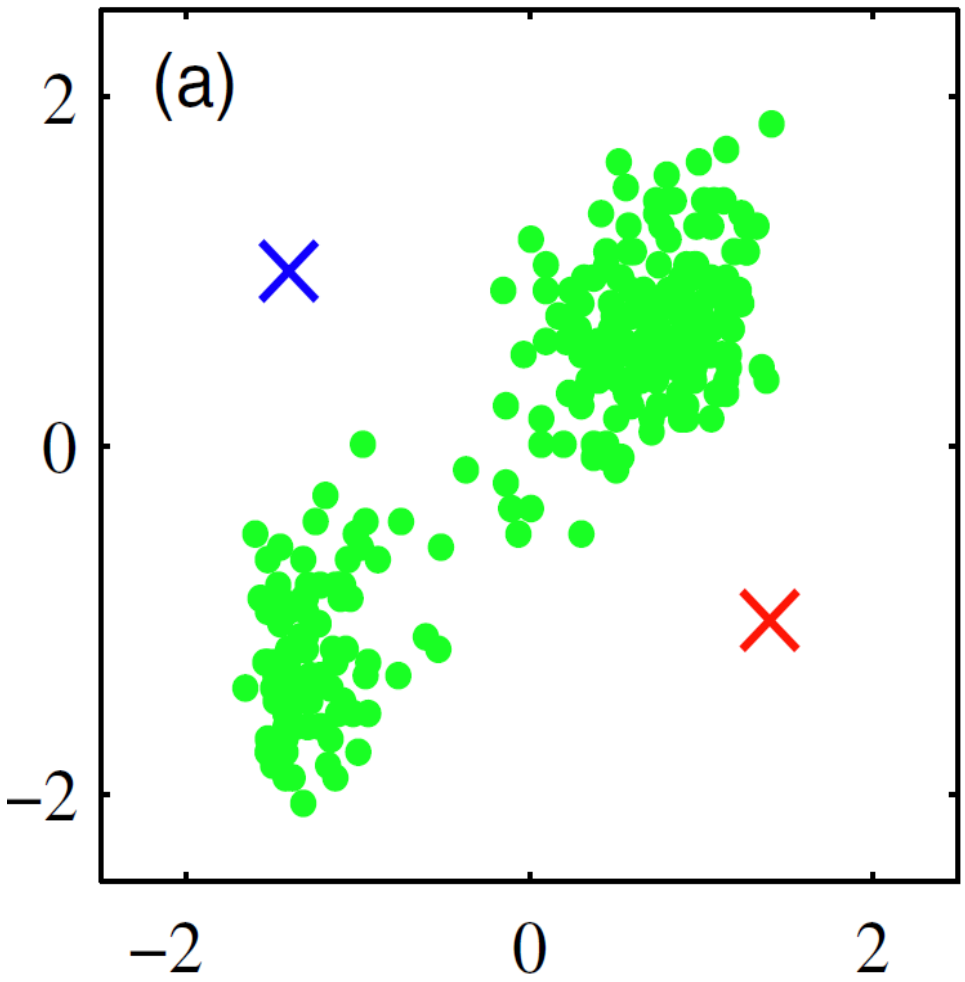

K均值过程示例

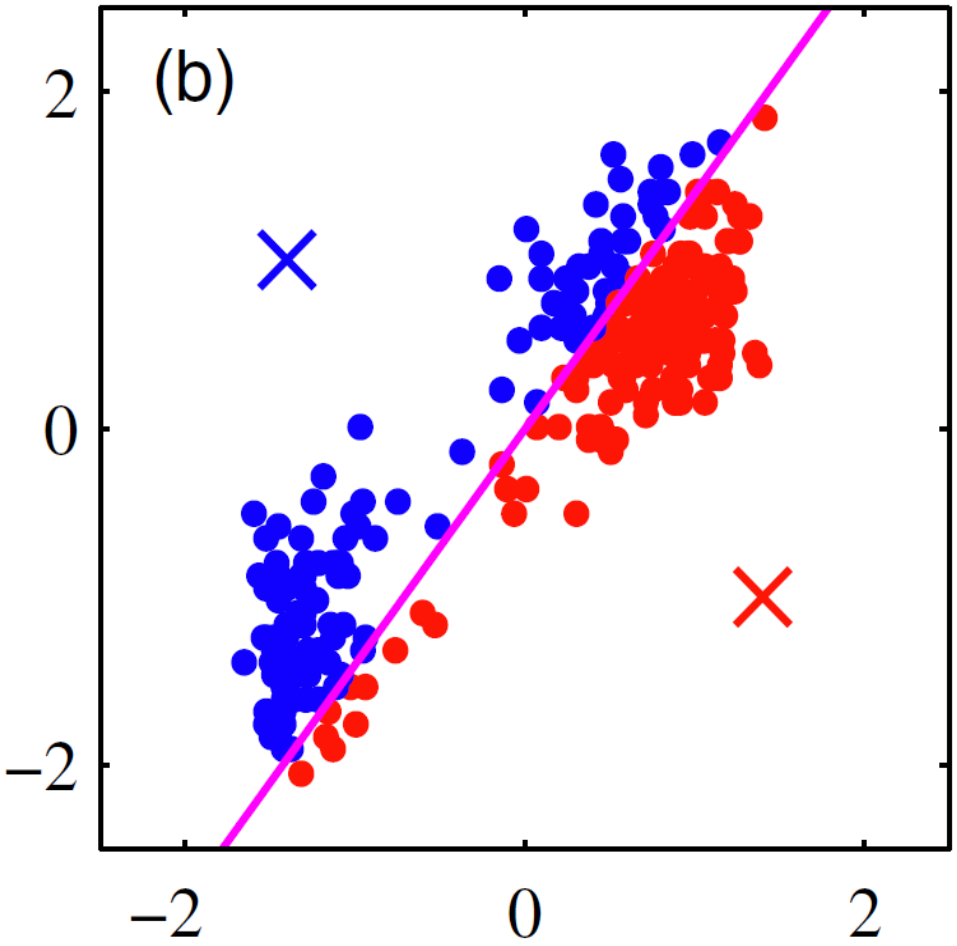

K均值过程示例

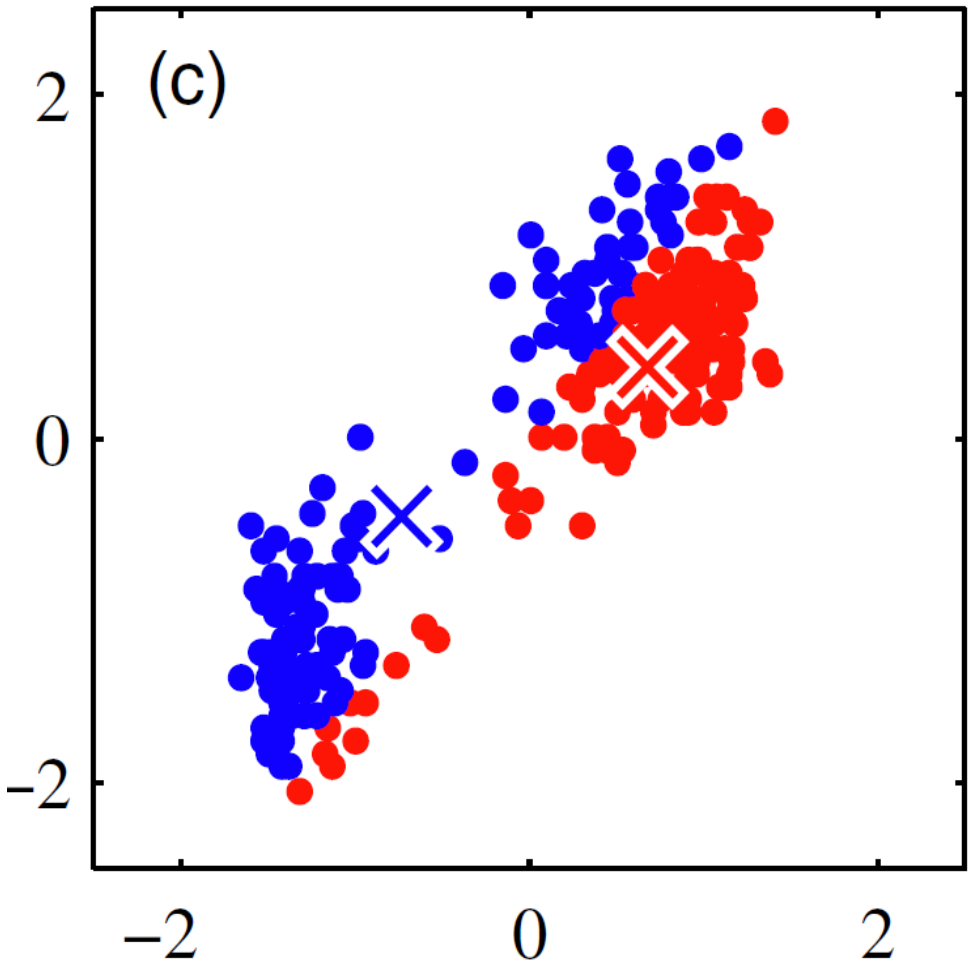

K均值过程示例

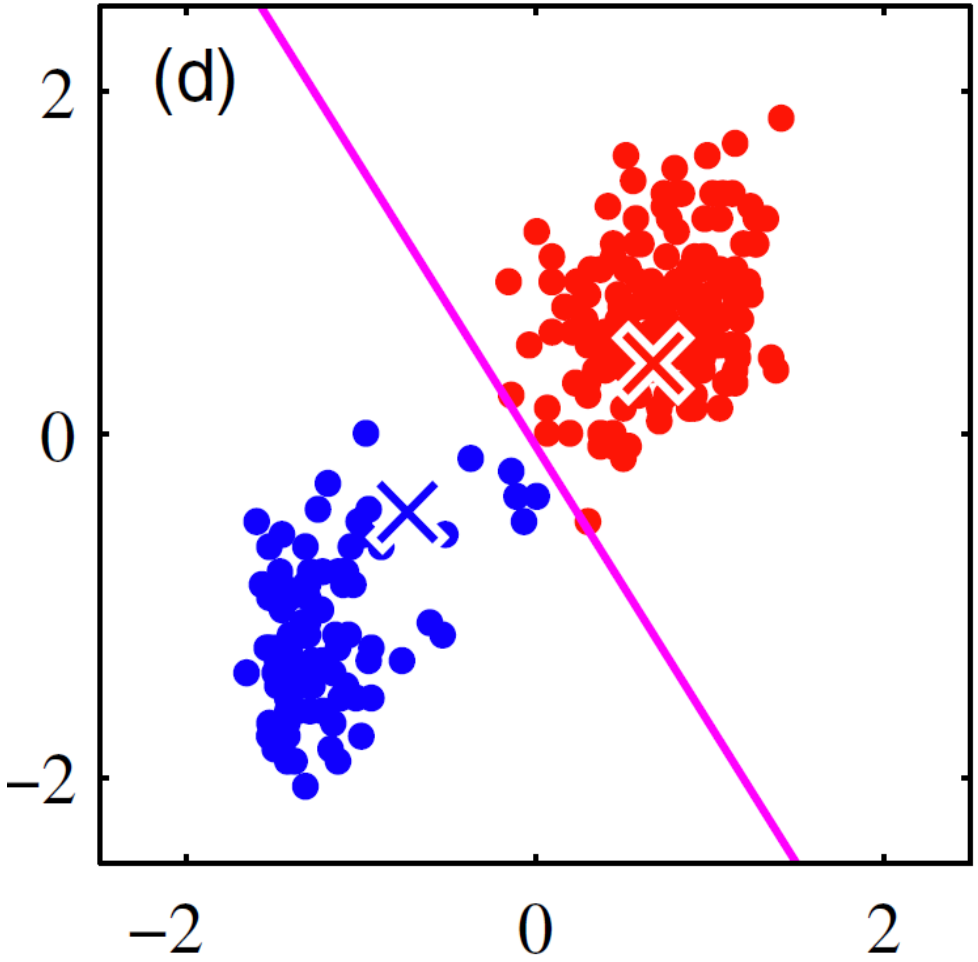

K均值过程示例

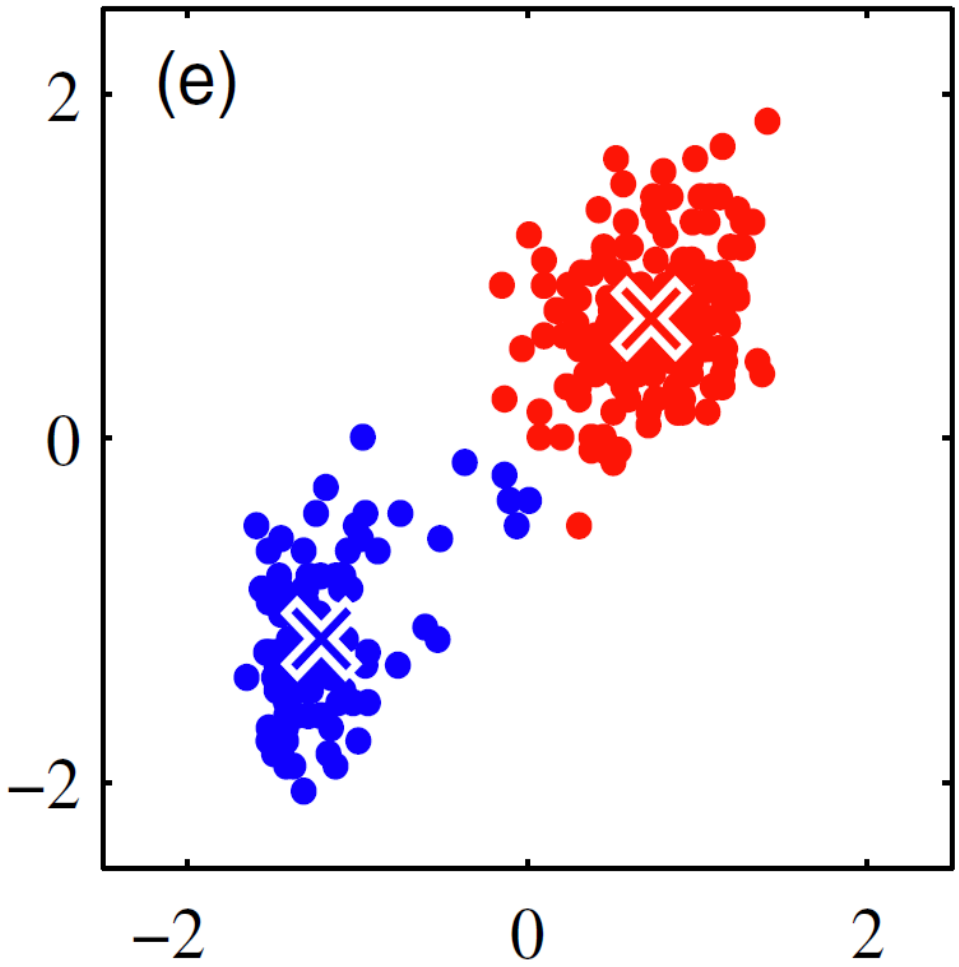

K均值过程示例

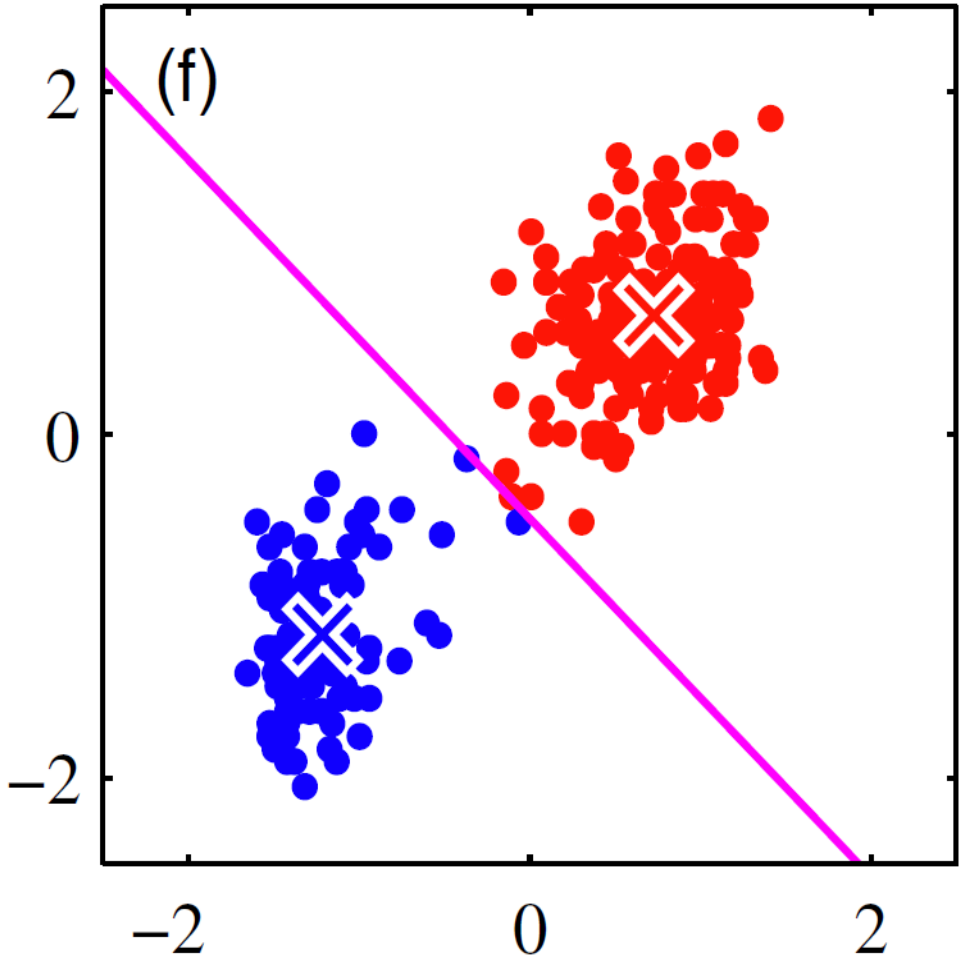

K均值过程示例

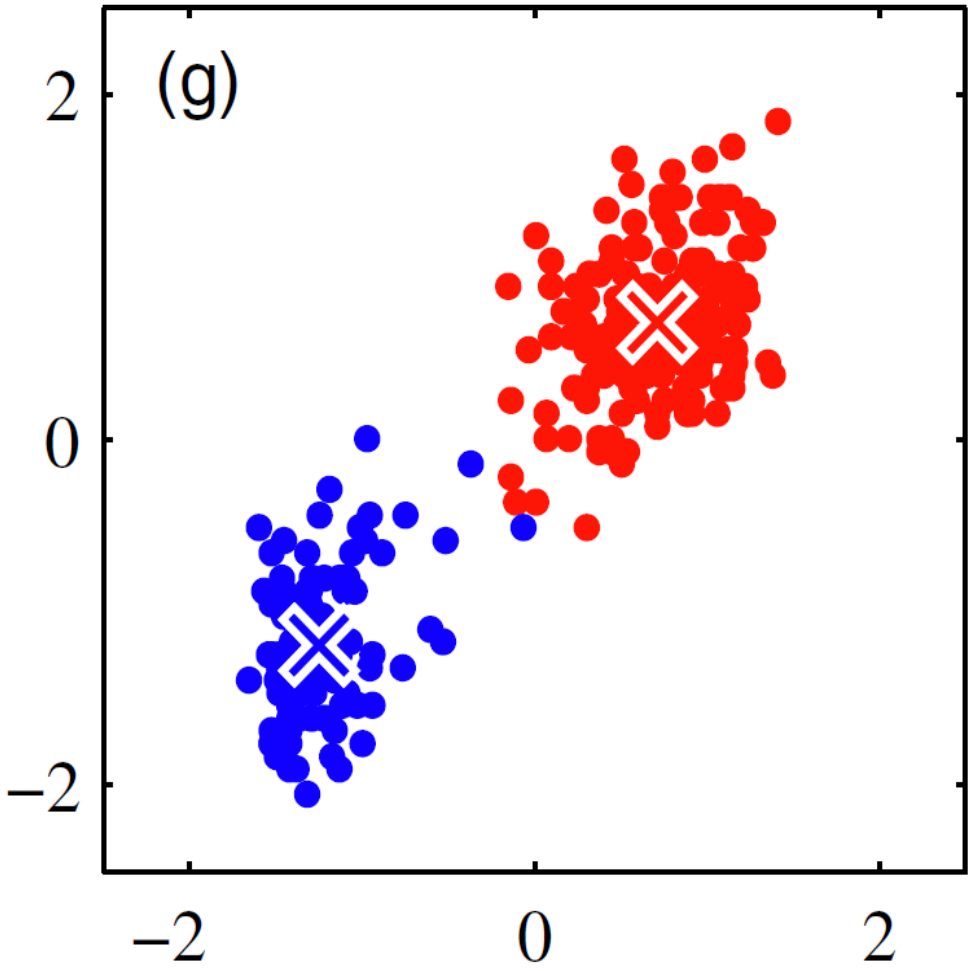

K均值过程示例

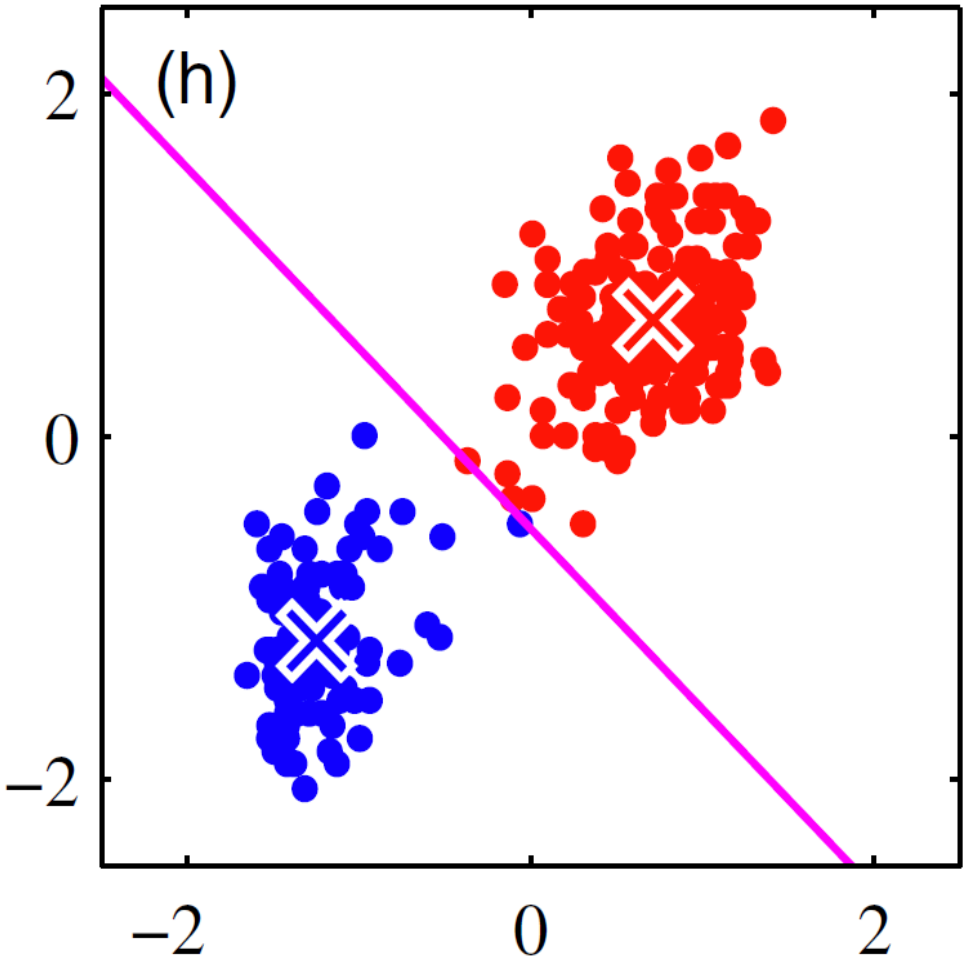

K均值过程示例

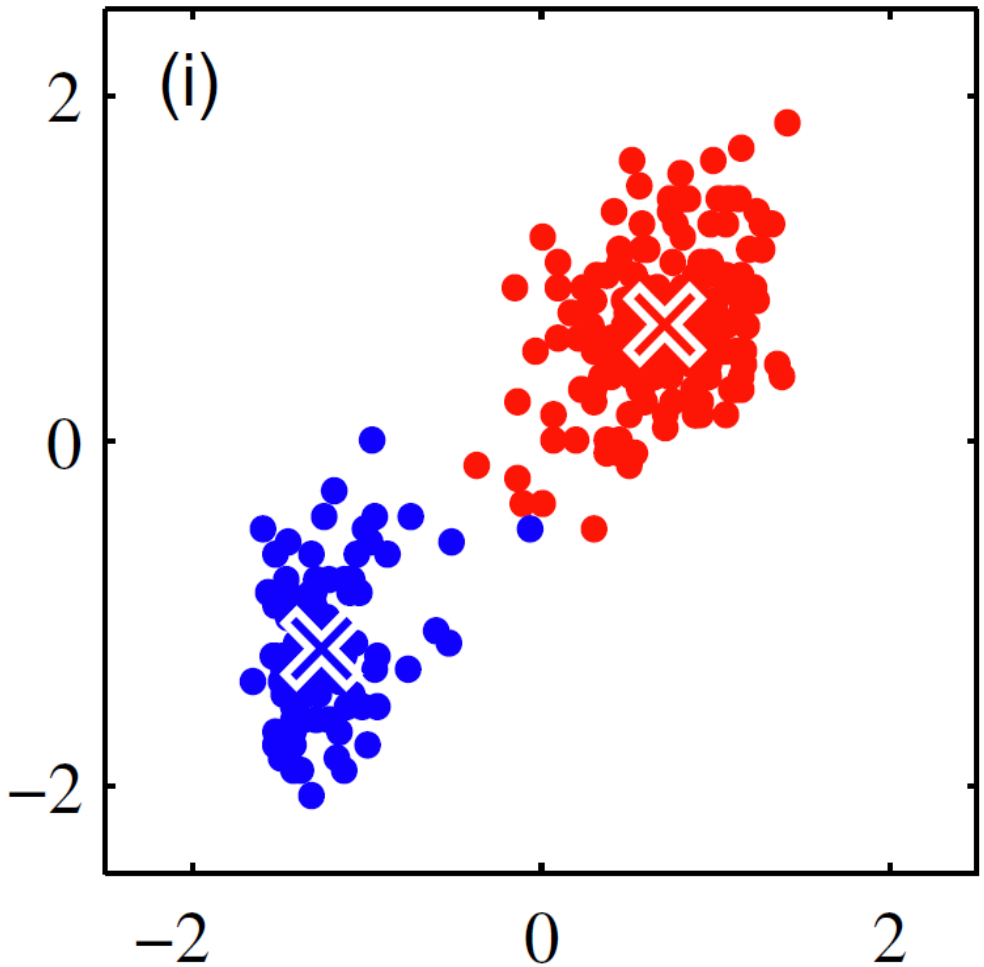

K均值过程示例

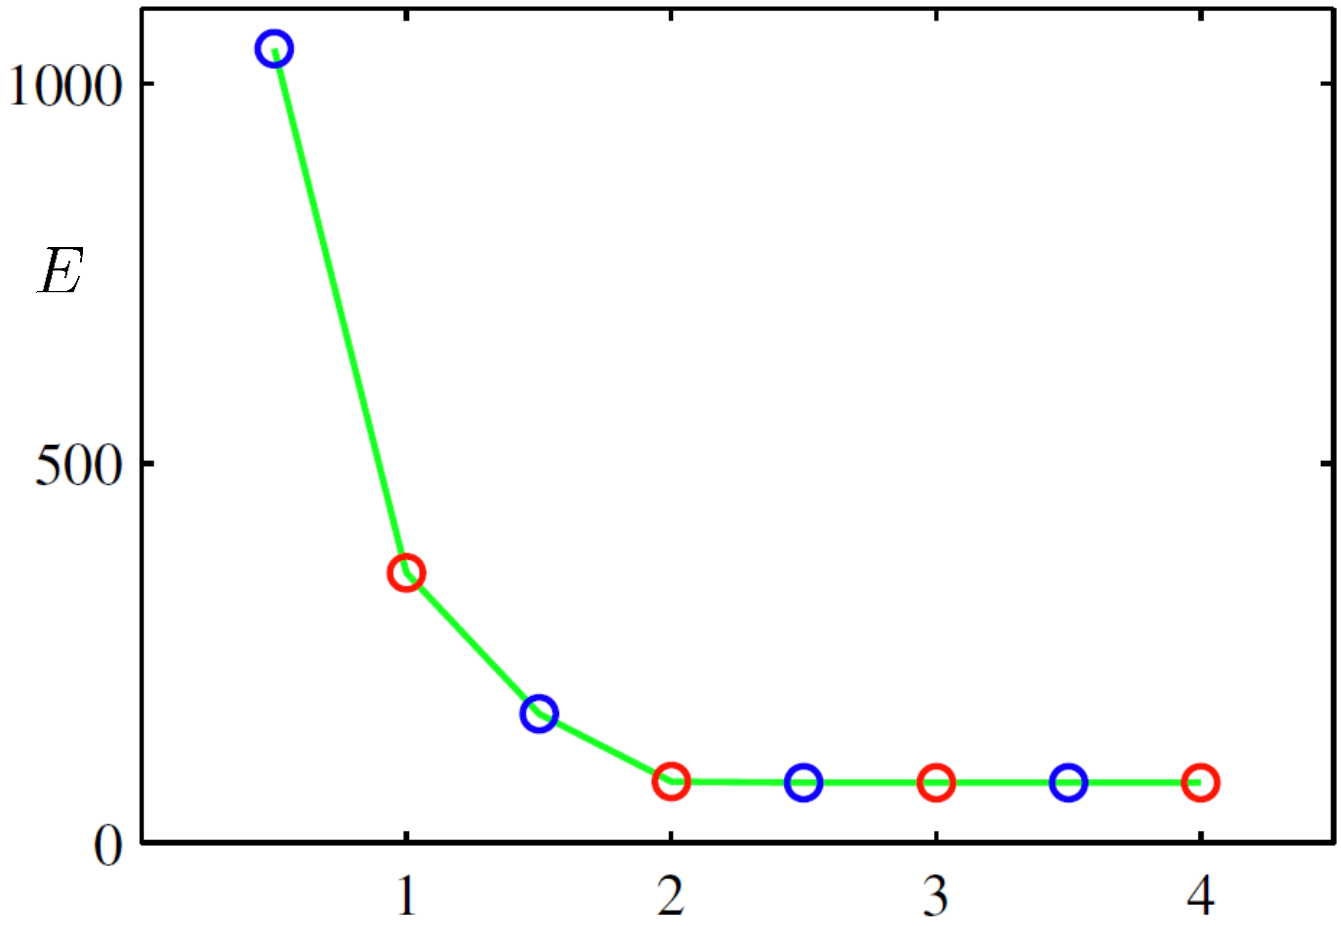

实例：基于K均值聚类的图像分割

实例：基于K均值聚类的图像分割

- K=2

实例：基于K均值聚类的图像分割

- K=3

实例：基于K均值聚类的图像分割

- K=10

K-means++

- **对于K-means的改进**

2007年由Arthur和Vassilvitskii提出的K-means++针对K均值算法的簇中心初始化做了改进。

****基本思想**：**

假设已选取了*n*个初始聚类中心(0<*n*<*k*)，在选取第*n*+1个中心时：距离当前*n*个聚类中心越远的点会有更高的概率被选为第*n*+1个聚类中心，即聚类中心离得越远越好。

$$\frac{D(x)^2}{\sum_{x\in\mathcal{X}} D(x)^2}$$

Kernel K-means

- **对于K-means的改进**

  传统K-means采用欧式距离进行样本间的相似度度量，显然并不是所有的数据集都适用于这种度量方式。

  ****基本思想**：**

  参照支持向量机中核函数的思想，将所有样本映射到另外一个特征空间(一般为高维)中再进行聚类。

ISODATA

- 迭代自组织数据分析算法

Iterative Self-Organizing Data Analysis Technique Algorithm

在K均值算法的基础上，增加对聚类结果的“合并”和“分裂”两个操作，并设定算法运行控制参数的一种聚类算法。

基本思想：

通过设定初始参数而引入人的决策，当某两类聚类中心距离小于某阈值时，将它们合并为一类，当某类标准差大于某一阈值或其样本数目超过某阈值时，将其分裂为两类。在某类样本数目少于某阈值时，需将其取消。

层次聚类算法

- **层次聚类**

  试图在不同层次对数据集进行划分，从而形成树形的聚类结构。数据集划分既可采用“自底向上”的聚合策略，也可采用“自顶向下”的分拆策略。

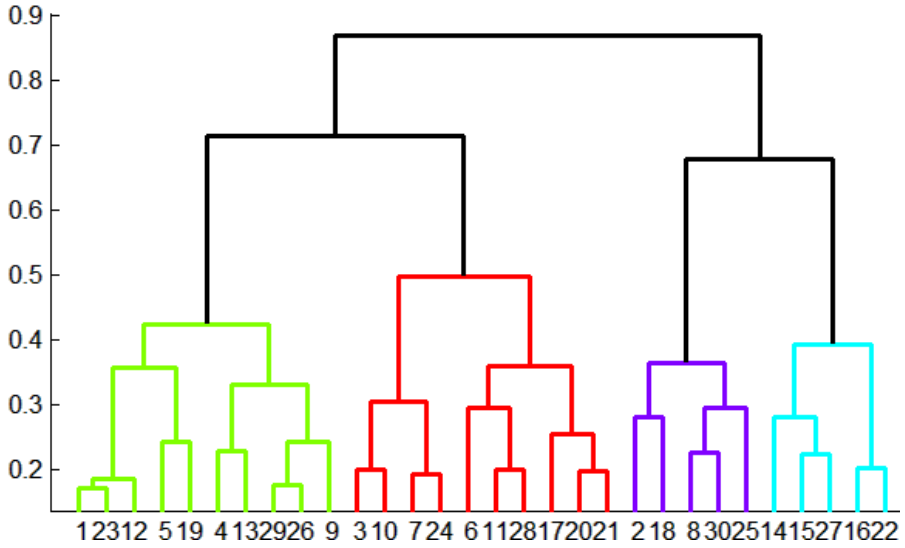

层次聚类算法

- **AGNES算法（Agglomerative Nesting）**

  自底向上的层次聚类算法。首先，将样本中的每个样本看做一个初始聚类簇，然后在算法运行的每一步中找出距离最近的两个聚类簇进行合并，该过程不断重复，直到达到预设的聚类簇的个数。

  两个聚类簇C_i和C_j的距离，常用的度量方式:

  最小距离: $$d_{min}(C_i, C_j) = \min_{x \in C_i, z \in C_j} dist(x, z)$$

  最大距离: $$d_{max}(C_i, C_j) = \max_{x \in C_i, z \in C_j} dist(x, z)$$

  平均距离: $$d_{avg}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{z \in C_j} dist(x, z)$$

层次聚类算法

- **AGNES算法（Agglomerative Nesting）**

1. Say "Every point is its own cluster"

层次聚类算法

- **AGNES算法（Agglomerative Nesting）**

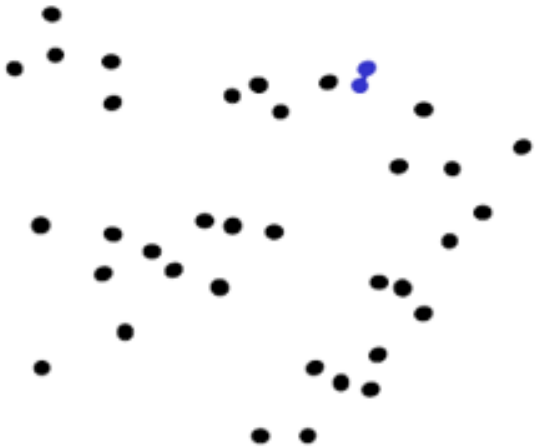

1. Say "Every point is its own cluster"
2. Find "most similar" pair of clusters

层次聚类算法

- **AGNES算法（Agglomerative Nesting）**

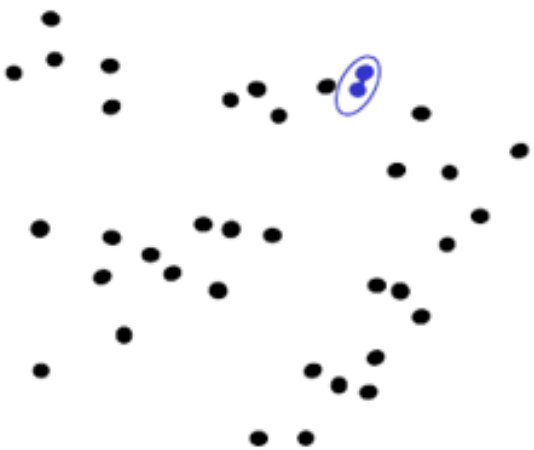

1. Say "Every point is its own cluster"
2. Find "most similar" pair of clusters
3. Merge it into a parent cluster

层次聚类算法

- **AGNES算法（Agglomerative Nesting）**

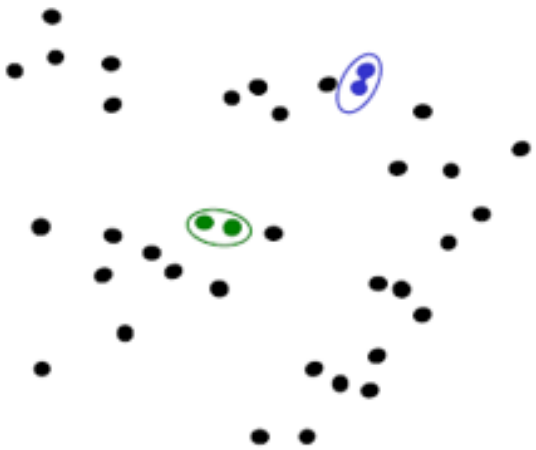

1. Say "Every point is its own cluster"
2. Find "most similar" pair of clusters
3. Merge it into a parent cluster
4. Repeat

层次聚类算法

- **AGNES算法（Agglomerative Nesting）**

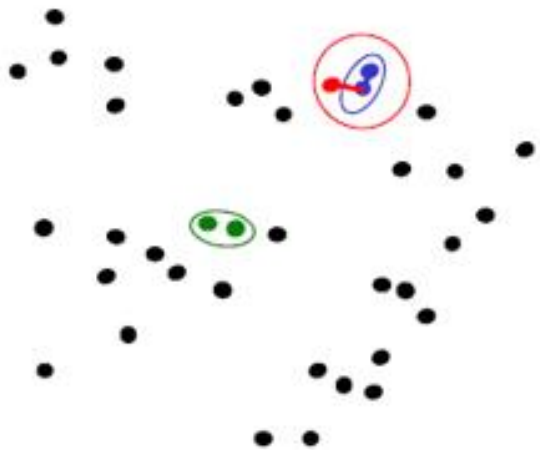

1. Say "Every point is its own cluster"
2. Find "most similar" pair of clusters
3. Merge it into a parent cluster
4. Repeat

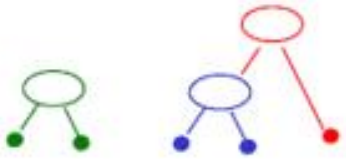

层次聚类方法

- **AGNES算法**

输入： 样本集$D = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_m\}$;
聚类簇距离度量函数$d \in \{d_{\min}, d_{\max}, d_{\text{avg}}\}$;
聚类簇数k.

过程：

```
for j = 1, ..., m do
    C_j = {x_j}
end for
for i = 1, ..., m do
    for j = i, ..., m do
        M(i, j) = d(C_i, C_j);
        M(j, i) = M(i, j)
    end for
end for
设置当前聚类簇个数：q = m
while q > k do
    找出距离最近的两个聚类簇(C_{i*}, C_{j*});
    合并(C_{i*}, C_{j*})：C_{i*} = C_{i*} ∪ C_{j*};
    for j = j* + 1, ..., q do
        将聚类簇C_j重编号为C_{j-1}
    end for
    删除距离矩阵M的第j*行与第j*列;
    for j = 1, ..., q - 1 do
        M(i*, j) = d(C_{i*}, C_j);
        M(j, i*) = M(i*, j)
    end for
    q = q - 1
end while
return 簇划分结果
```

输出： 簇划分$\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$

聚类方法
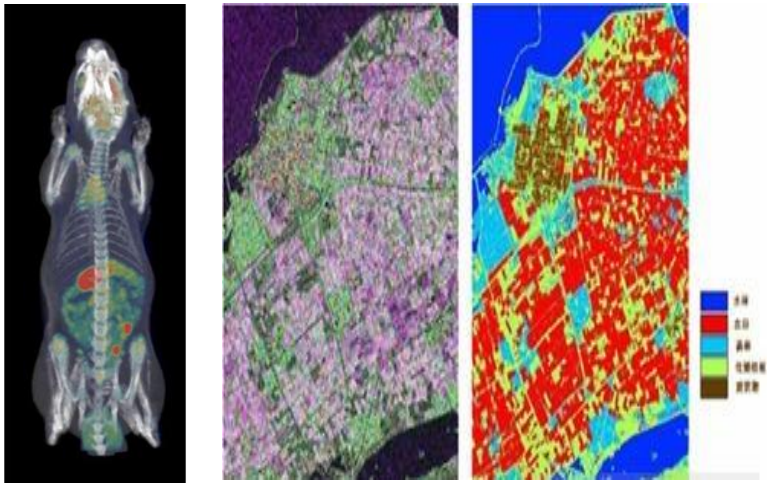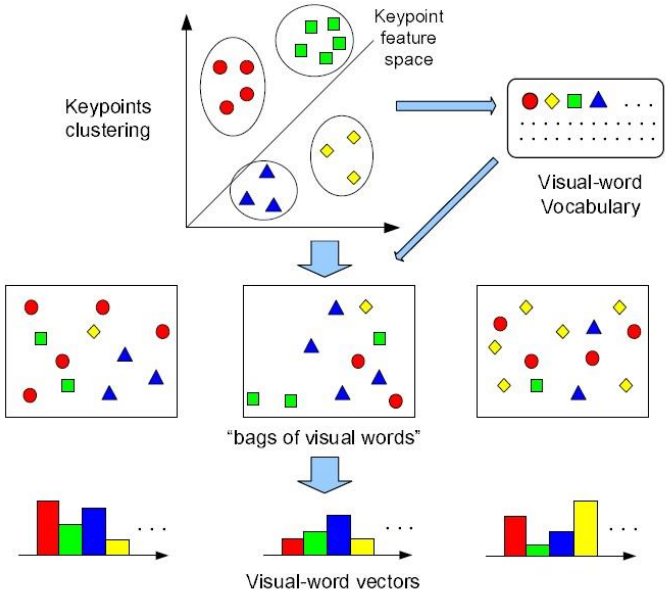
- 典型应用
  - 医学图像-组织分类
  - 遥感图像-地貌分类
  - BOW模型
  - 网络用户分类