统计学导论

（一）导论与数据搜集

北京航空航天大学人文社会科学学院高等教育研究所

黄文

目录

02 统计基本概念

04 小结及讨论

教师&课程介绍 01

03 数据的搜集

01 教师与课程介绍

黄文

- 9号教学楼527办公室
- Email: wenhuang@buaa.edu.cn

- 主要研究兴趣:
  - VR+AI在教育领域的应用
  - 学习分析
  - 生成式AI与高阶思维能力

教学计划

周数	主题	考核成绩	
1	统计与数据导论		黄文
2	数据的图表展示& 数据的概括性度量	课后作业 1（10 分）	黄文
3	概率和概率分布		黄文
4	统计量及其抽样分布		黄文
5	参数估计		黄文
6	假设检验	课后作业 2（10 分）	黄文
7	类别变量推断		于晓敏
8	方差分析		于晓敏
9	相关分析&一元线性回归		于晓敏
10	多元线性回归（一）		于晓敏
11	多元线性回归（二）	实验报告（20 分）	于晓敏
12	知识点串讲&统计方法前沿		黄文、于晓敏
		期末考试（60 分）	

教材及辅导书

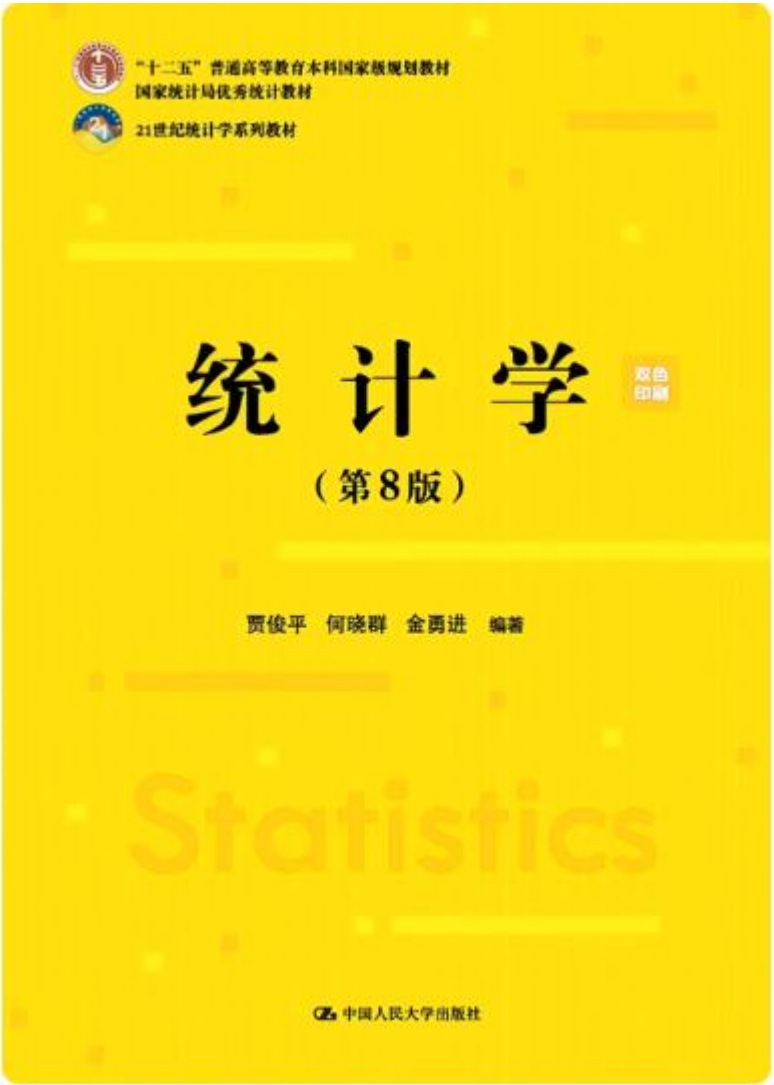
"十二五"普通高等教育本科国家级规划教材
国家统计局优秀统计教材
21世纪统计学系列教材
统计学
双色印刷
（第8版）
贾俊平 何晓群 金勇进 编著
Statistics
中国人民大学出版社

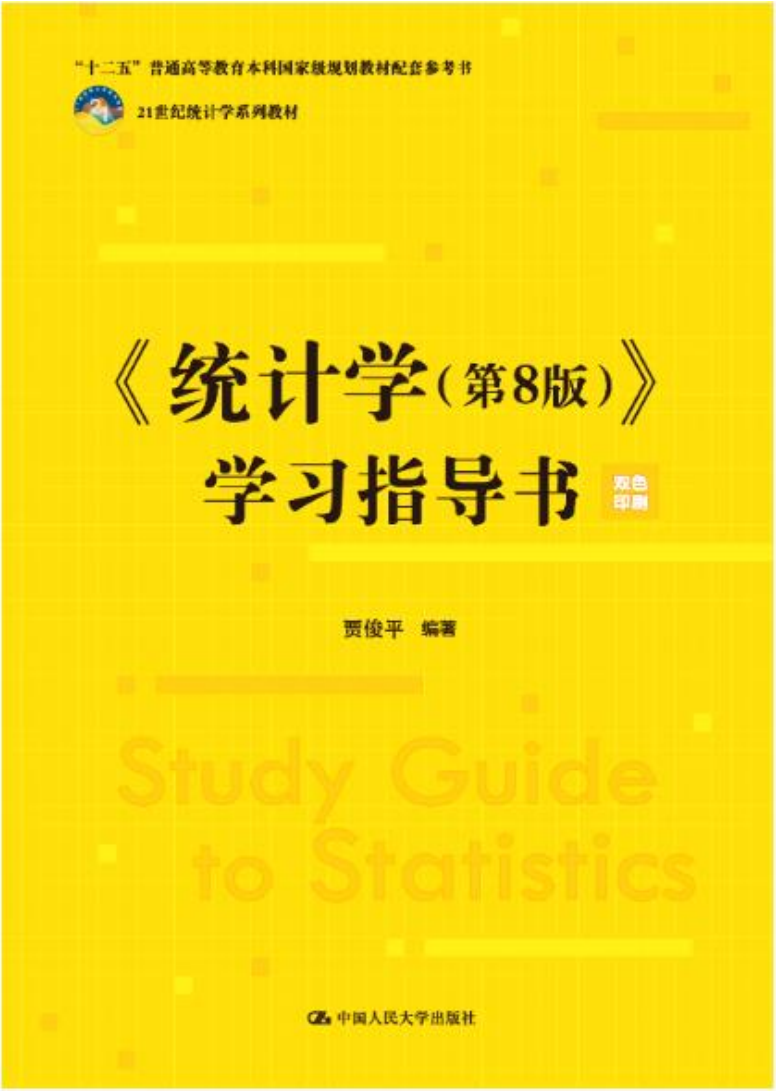
"十二五"普通高等教育本科国家级规划教材配套参考书
21世纪统计学系列教材
《统计学（第8版）》
学习指导书
双色印刷
贾俊平 编著
Study Guide to Statistics
中国人民大学出版社

操作软件

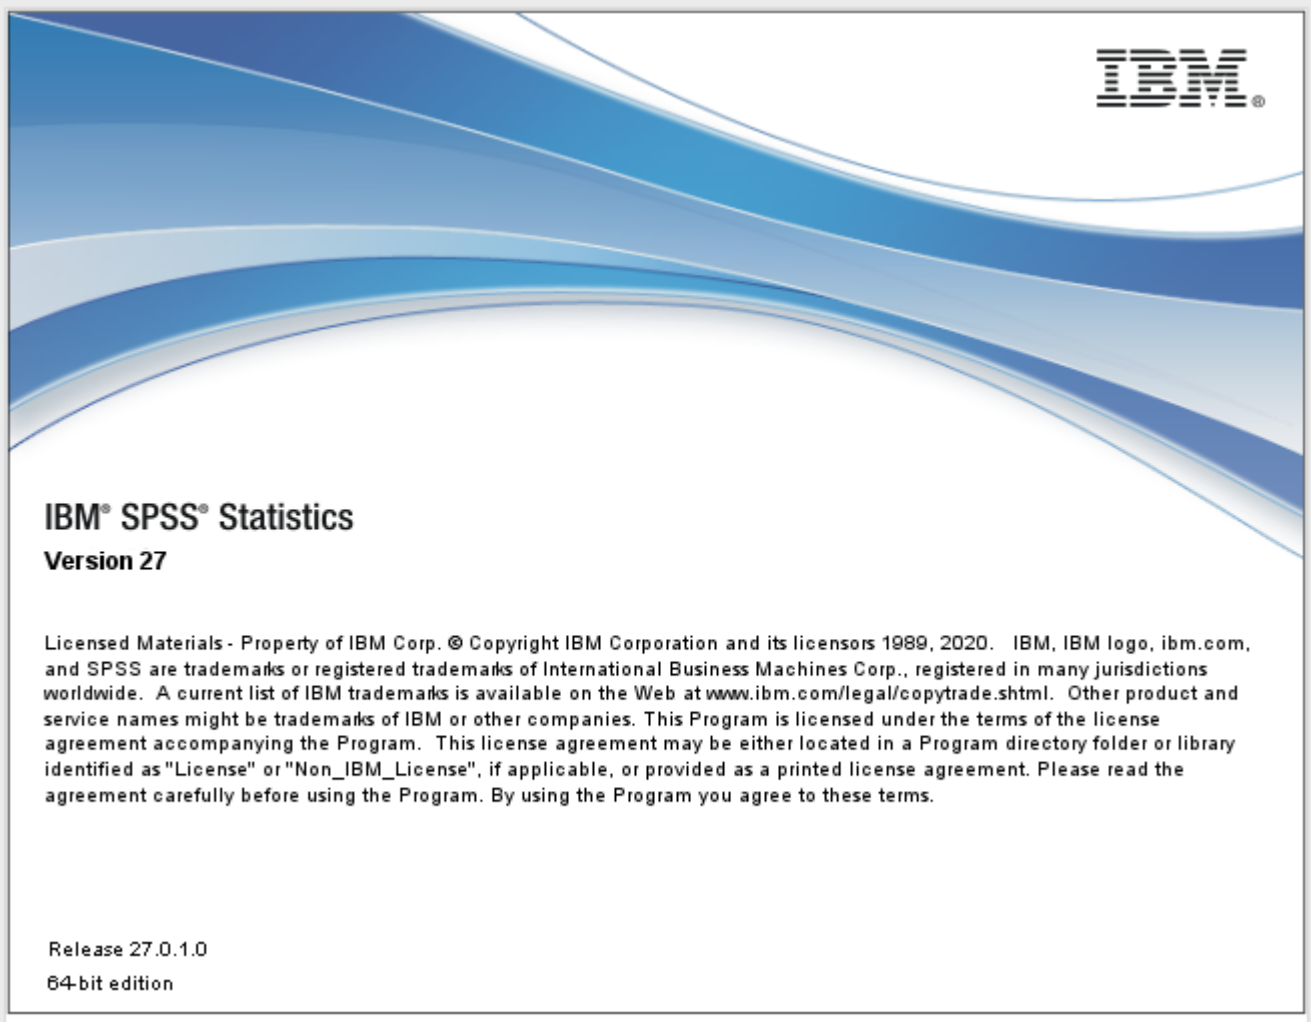

IBM SPSS新近版本均可

02 统计基本概念

数据无处不在

在法律领域，每起案件的卷宗信息、判决结果都是数据，支撑着司法公正的研判；
经济活动中，市场行情的波动、消费价格的涨跌，皆由海量数据勾勒出经济脉络；
管理场景里，员工绩效、运营效率等数据，成为优化决策的关键依据；
教育日常中，学生的成绩变化、课堂反馈，也化作数据助力教学改进
——数据，早已无声浸润于各领域。

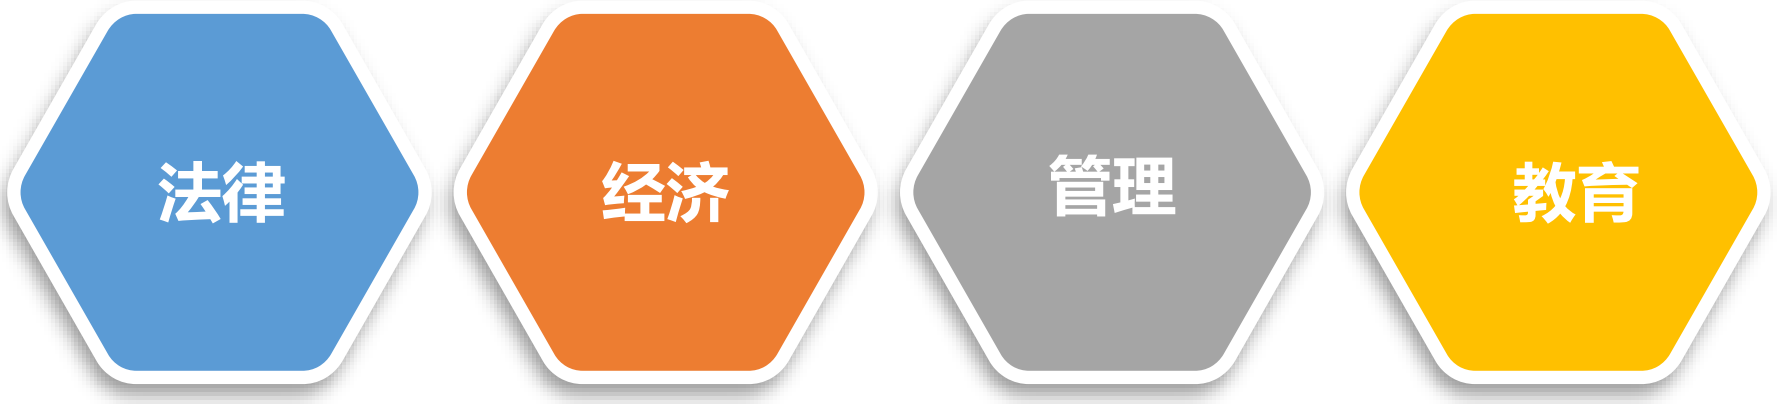

什么是统计?

什么是统计学

各种定义

1. 统计学是收集、分析、表述和解释数据的科学(不列颠百科全书)
2. 统计是一门收集、分析、解释和提供数据的科学(韦伯斯特国际辞典第3版)
3. 统计指的是一组方法，用来设计实验、获得数据，然后在这些数据的基础上组织、概括、演示、分析、解释和得出结论(Mario F.Triola,《初级统计学》)

收集、处理、分析、解释数据并从数据中得出结论的科学

收集数据：取得数据

处理数据：整理与图表展示

分析数据：利用统计方法分析数据

数据解释：结果的说明

得到结论：从数据分析中得出客观结论

包括描述方法、推断方法及其他方法

描述统计与推断统计

描述统计

- 研究数据收集、处理、汇总、图表描述、概括与分析等统计方法
- 描述数据特征找出数据的基本规律

  内容包括：搜集数据、整理数据、展示数据、描述性分析

VS

推断统计

- 研究如何利用样本数据来推断总体特征的统计方法
- 对总体特征作出推断

  内容包括：参数估计、假设检验

统计的应用领域

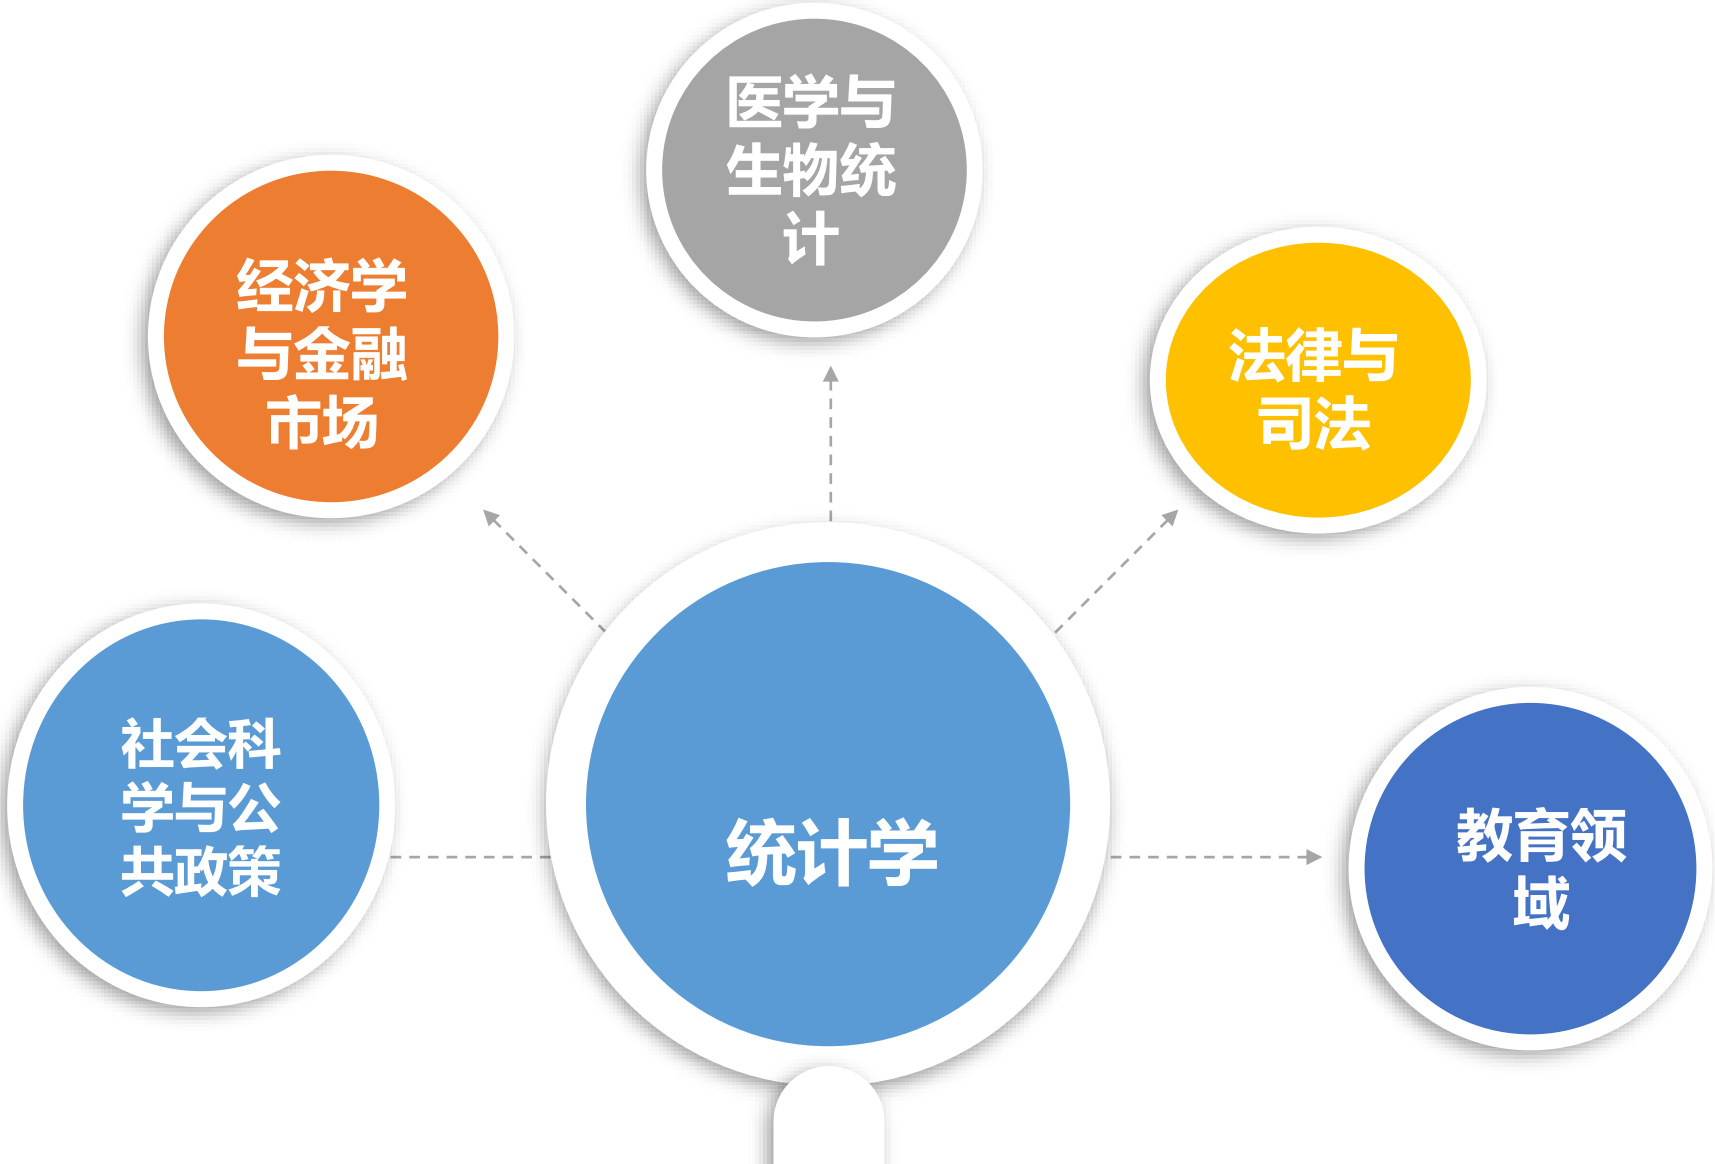

统计滥用

不好的样本或过小的样本

误导性图表

局部描述

故意曲解

数据的类型

按计量尺度

分类数据(categorical data)

- 只能归于某一类别的非数字型数据
- 有无序分类和有序分类

数值数据(metric data)

- 按数字尺度测量的观察值
- 有离散数据和连续数据

按收集方法

观测的数据(observational data)

- 通过调查或观测而收集到的数据
- 在没有对事物人为控制的条件下而得到的
- 有关社会经济现象的统计数据几乎都是观测数据

实验的数据(experimental data)

- 在实验中控制实验对象而收集到的数据
- 自然科学领域的数据大多数都为实验数据

按时间状况

截面数据(cross-sectional data)

- 在相同或近似相同的时间点上收集的数据
- 描述现象在某一时刻的变化情况

时间序列数据(time series data)

- 在不同时间上收集到的数据
- 描述现象随时间变化的情况

统计学中的基本概念（一）

总体(population)

- 所研究的全部个体(数据) 的集合，其中的每一个个体也称为元素
- 分为有限总体和无限总体
- 有限总体的范围能够明确确定，且元素的数目是有限的
- 无限总体所包括的元素是无限的，不可数的

样本 (sample)

- 从总体中抽取的一部分元素的集合
- 构成样本的元素的数目称为样本容量或样本量 (sample size)

参数(parameter)

- 描述总体特征的概括性数字度量，是研究者想要了解的总体的某种特征值
- 所关心的参数主要有总体均值、标准差、总体比例等
- 总体参数通常用希腊字母表示

统计量(statistic)

- 用来描述样本特征的概括性数字度量，它是根据样本数据计算出来的一些量，是样本的函数
- 所关心的样本统计量有*样本均值*、*样本标准差*、*样本比例*等
- 样本统计量通常用小写英文字母来表示

统计学中的基本概念（二）

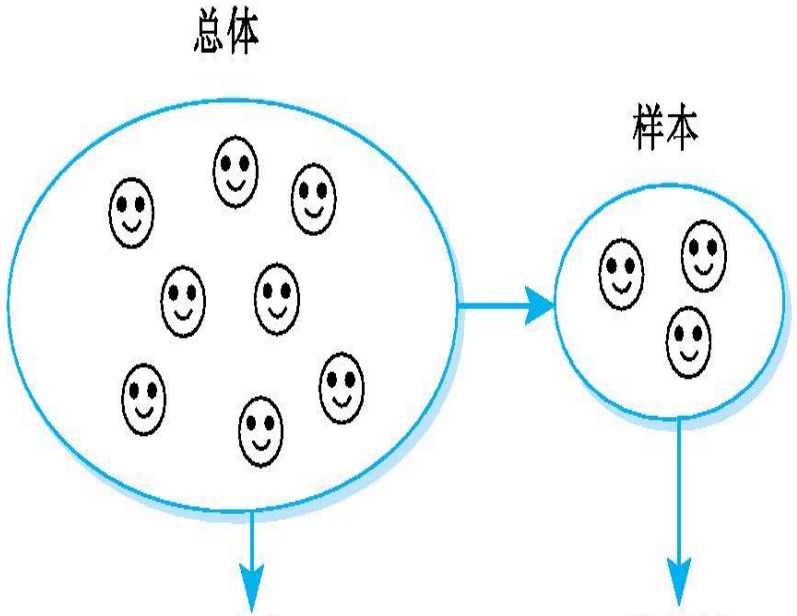

μ	平均数	$\bar{x}$
σ	标准差	s
π	比　例	p

变量(variable)

说明现象某种特征的概念

- 如商品销售额、受教育程度、产品的质量等级等
- 变量的具体表现称为变量值，即数据

变量可以分为

- 分类变量(categorical variable) ：说明事物类别的名称
- 数值变量(metric variable) ：说明事物数字特征的名称

  离散变量：取有限个值

  连续变量：可以取无穷多个值

03 数据的搜集

导读：美国民调机构2016年总统大选预测的失手

- 2016年轰动全球的重大事件之一是美国民调机构总统大选预测的失手。舆论普遍预测民主党的希拉里将在这次大选中获胜,但投票结果令人大跌眼镜,共和党的特朗普出人意料地成为第58届美国总统,舆论一片哗然。

- 调查中的缺失数据和失真数据是一个重要原因,数据分析表明,许多特朗普的支持者在调查中或者保持沉默,或者说了假话,对统计推断产生了误导。上述分析表明,**预测失败不是因为抽样技术和统计推断不科学,而是因为偏离了正确的抽样,调查数据存在虚假,推断中没有考虑关键的影响变量。**

数据的间接来源

二手数据的来源

- 统计部门和政府部门公布的有关资料，如各类统计年鉴
- 各类经济信息中心、信息咨询机构、专业调查机构等提供的数据
- 各类专业期刊、报纸、书籍所提供的资料
- 各种会议上交流的有关资料
- 从互联网或图书馆查阅到的资料
- 业务资料，如与业务经营活动有关的各种单据，记录
- 经营活动过程中的各种统计报表
- 各种财务，会计核算和分析资料等

二手数据的特点

- 搜集容易，采集成本低
- 作用广泛
  1. 分析所要研究的问题
  2. 提供研究问题的背景
  3. 帮助研究者更好地定义问题
  4. 检验和回答某些疑问和假设
  5. 寻找研究问题的思路和途径
- 搜集二手资料在研究中应优先考虑

二手数据的评估

- 数据是谁搜集的？
- 可信度评估
- 为什么目的而搜集的？
- 数据是怎样搜集的？
- 什么时候搜集的

数据的直接来源

调查数据

- 通过调查方法获得的数据
- 通常是对社会现象而言
- 通常取自有限总体

实验数据

- 通过实验方法得到的数据
- 通常是对自然现象而言
- 也被广泛运用到社会科学中
  - 如心理学、教育学、社会学、经济学、管理学等

调查方法：概率抽样（一）

概率抽样

- 也称随机抽样
- 特点
  1. 按一定的概率以随机原则抽取样本
  2. 抽取样本时使每个单位都有一定的机会被抽中
  3. 每个单位被抽中的概率是已知的，或是可以计算出来的
  4. 当用样本对总体目标量进行估计时，要考虑到每个样本单位被抽中的概率

简单随机抽样

- 从总体N个单位中随机地抽取n个单位作为样本，每个单位入抽样本的概率是相等的
- 最基本的抽样方法，是其它抽样方法的基础
- 特点
  1. 简单、直观，在抽样框完整时，可直接从抽取样本
  2. 用样本统计量对目标量进行估计比较方便
- 局限性
  1. 当N很大时，不易构造抽样框
  2. 抽出的单位很分散，给实施调查增加了困难
  3. 没有利用其它辅助信息以提高估计的效率

调查方法：概率抽样（二）

分层抽样

- 将抽样单位按某种特征或某种规则划分为不同的层，然后从不同的层中独立、随机地抽取样本
- 优点
  - 保证样本的结构与总体的结构比较相近，从而提高估计的精度
  - 组织实施调查方便
  - 既可以对总体参数进行估计，也可以对各层的目标量进行估计

整群抽样

- 将总体中若干个单位合并为组(群),抽样时直接抽取群，然后对中选群中的所有单位全部实施调查
- 特点
  - 抽样时只需群的抽样框，可简化工作量
  - 调查的地点相对集中，节省调查费用，方便调查的实施
  - 缺点是估计的精度较差

调查方法：概率抽样（三）

系统抽样

- 将总体中的所有单位(抽样单位)按一定顺序排列，在规定的范围内随机地抽取一个单位作为初始单位，然后按事先规定好的规则确定其它样本单位
  - 先从数字1到k之间随机抽取一个数字r作为初始单位，以后依次取r+k，r+2k...等单位
- 优点：操作简便，可提高估计的精度
- 缺点：对估计量方差的估计比较困难

多阶段抽样

- 先抽取群，但并不是调查群内的所有单位，而是再进行一步抽样，从选中的群中抽取出若干个单位进行调查
  - 二阶抽样中群是初级抽样单位，第二阶段抽取的是最终抽样单位。将该方法推广，使抽样的阶段数增多，就称为多阶段抽样
- 具有整群抽样的优点，保证样本相对集中，节约调查费用
- 需要包含所有低阶段抽样单位的抽样框；同时由于实行了再抽样，使调查单位在更广泛的范围内展开
- 在大规模的抽样调查中，是经常被采用的方法

调查方法：非概率抽样（一）

非概率抽样

- 相对于概率抽样而言
- 抽取样本时不是依据随机原则，而是根据研究目的对数据的要求，采用某种方式从总体中抽出部分单位对其实施调查
- 有方便抽样、判断抽样、自愿样本、滚雪球抽样、配额抽样等方式

方便抽样

- 具有整群抽样的优点，保证样本相对集中，节约调查费用
- 调查过程中由调查员依据方便的原则，自行确定入抽样本的单位
  - 调查员在街头、公园、商店等公共场所进行拦截调查
  - 厂家在出售产品柜台前对路过顾客进行的调查
- 优点：容易实施，调查的成本低
- 缺点：样本单位的确定带有随意性，样本无法代表有明确定义的总体，调查结果不宜推断总体

调查方法：非概率抽样（二）

自愿样本

- 被调查者自愿参加，成为样本中的一分子，向调查人员提供有关信息
  - 例如，参与报刊上和互联网上刊登的调查问卷活动，向某类节目拨打热线电话等，都属于自愿样本
- 自愿样本与抽样的随机性无关
  - 样本是有偏的
  - 不能依据样本的信息推断总体

滚雪球抽样

- 先选择一组调查单位，对其实施调查之后，再请他们提供另外一些属于研究总体的调查对象，调查人员根据所提供的线索，进行此后的调查。这个过程持续下去，就会形成滚雪球效应
- 适合于对稀少群体和特定群体研究
- 优点：容易找到那些属于特定群体的被调查者，调查的成本也比较低

调查方法：非概率抽样（三）

配额抽样

- 操作简单，可以保证总体中不同类别的单位都能包括在所抽的样本之中，使得样本的结构和总体的结构类似
- 抽取具体样本单位时，不是依据随机原则，属于非概率抽样

概率抽样和非概率抽样的比较

- 概率抽样
  - 依据随机原则抽选样本
  - 样本统计量的理论分布存在
  - 可根据调查的结果推断总体
- 非概率抽样
  - 不是依据随机原则抽选样本
  - 样本统计量的分布是不确定的
  - 无法使用样本的结果推断总体

搜集数据的基本方法（一）

自填式

- 没有调查员协助的情况下由被调查者自己完成调查问卷
  - 问卷递送方法有：调查员分发、邮寄、网络、媒体
- 要求调查问卷结构严谨，有清楚的说明
- 弱点
  - 问卷的返回率比较低
  - 不适合结构复杂的问卷
  - 调查周期比较长
  - 数据搜集过程中出现的问题难于及时采取调改措施

面访式

- 调查员与被调查者面对面提问、被调查者回答的一种调查方式
- 优点
  - 可提高调查的回答率
  - 可提高调查数据的质量
  - 能调节数据搜集所花费的时间
- 弱点
  - 调查的成本较高
  - 调查过程的质量控制有一定难度

搜集数据的基本方法（二）

电话式

- 通过电话向被调查者实施调查
- 特点
  - 速度快，能在短时间内完成调查
  - 适合于样本单位十分分散的情况
- 局限
  - 如果被调查者没有电话，调查将无法实施
  - 访问的时间不能太长
  - 使用的问卷需要简单
  - 被访者不愿意接受调查时，难以说服

观察式

- 就调查对象的行动和意识，调查人员边观察边记录以收集所需信息
- 调查人员不是强行介入
- 能够在被调查者不察觉的情况下获得资料
  - 如交通流量的调查

调查方法比较

项目	自填式	面访式	电话式
调查时间	慢	中等	快
调查费用	低	高	低
问卷难度	要求容易	可以复杂	要求容易
有形辅助物的使用	中等利用	充分利用	无法利用
调查过程控制	简单	复杂	容易
调查员作用的发挥	无法发挥	充分发挥	一般发挥
回答率	最低	较高	一般

实验方法（ 实验中的问题和统计 ）

实验组和对照组

- 将研究对象分为两组：实验组和对照组
- 实验组和对照组的产生应遵循随机原则，而且应该匹配
  - 匹配指对实验单位的背景材料进行分析比较，将情况类似的每对单位分别随机地分配到实验组和对照组

实验中的问题

- 人的意愿
  - 研究的对象是人的时候，在划分实验组和对照组时的随机原则将面临挑战
- 心理问题
  - 人们对被研究非常敏感，这使得他们更加注意自我，从而走到事物的另一个极端
- 道德问题
  - 当某种实验涉及道德问题时，人们会处于进退两难的尴尬境地

实验中的统计

- 实验设计本身就是一个统计问题
- 确定进行实验所需要的单位的个数，以保证实验可以达到统计显著的结果
- 将统计的思想融入到实验设计中，使实验设计符合统计分析的标准
- 对实验数据进行分析时，统计可以提供最恰当的分析方法

抽样误差和非抽样误差

抽样误差

- 由于抽样的随机性所带来的误差
- 所有样本可能的结果与总体真值之间的平均性差异
- 影响抽样误差的大小的因素
  - 样本量的大小
  - 总体的变异性

非抽样误差

- 除抽样误差之外的，由于其他原因造成的样本观察结果与总体真值之间的差异
- 存在于所有的调查之中
  - 概率抽样，非概率抽样，全面性调查
- 有抽样框误差、回答误差、无回答误差、调查员误差、测量误差

误差控制

- 抽样误差可计算和控制
- 非抽样误差的控制
  - 调查员的挑选
  - 调查员的培训
  - 督导员的调查专业水平
  - 调查过程控制
    - 调查结果进行检验、评估
    - 现场调查人员进行奖惩的制度

05 小结及讨论

统计的基本概念

- 数据无处不在
- 什么是统计学：概念，涉及步骤，描述/推断统计，
- 统计的应用领域
- 数据的类型：分类/数值，观测/实验，截面/序列
- 统计学基本概念：总体/样本

数据的搜集

- 间接来源：二手数据
- 直接来源：调查/实验数据
- 调查方法：概率/非概率抽样
- 数据搜集方法：自填/面访/电话
- 实验方法
- 抽样/非抽样误差