统计学导论

（二）图形表示与概括性度量

北京航空航天大学人文社会科学学院高等教育研究所

黄文

目录

数据的图形表示

02

04

小结及作业

回顾上周课程

01

03

数据的概括性

01 回顾上周课程

统计的基本概念

- 数据无处不在
- 什么是统计学：概念，涉及步骤，描述/推断统计，
- 统计的应用领域
- 数据的类型：分类/数值，观测/实验，截面/序列
- 统计学基本概念：总体/样本

数据的搜集

- 间接来源：二手数据
- 直接来源：调查/实验数据
- 调查方法：概率/非概率抽样
- 数据搜集方法：自填/面访/电话
- 实验方法
- 抽样/非抽样误差

02 数据的图形表示

数据的预处理：审核

二手数据–别人调查或实验的数据

- 统计部门和政府部门公布的有关资料，如各类统计年鉴
- 各类经济信息中心、信息咨询机构、专业调查机构等提供的数据
- 各类专业期刊、报纸、书籍所提供的资料
- 各种会议上交流的有关资料
- 从互联网或图书馆查阅到的资料
- 业务资料，如与业务经营活动有关的各种单据，记录
- 经营活动过程中的各种统计报表
- 各种财务，会计核算和分析资料等

二手数据的特点

- 搜集容易，采集成本低
- 作用广泛
  1. 分析所要研究的问题
  2. 提供研究问题的背景
  3. 帮助研究者更好地定义问题
  4. 检验和回答某些疑问和假设
  5. 寻找研究问题的思路和途径

二手数据的评估

- 数据是谁搜集的？
- 可信度评估
- 为什么目的而搜集的？
- 数据是怎样搜集的？
- 什么时候搜集的

数据的预处理：数据筛选

数据筛选（data filter）是根据需要找出符合特定条件的某类数据

【例3.1】表3-1是8名学生4门课程的考试成绩数据(单位:分)。试找出统计学成绩等于75分的学生,英语成绩最高的前三名学生,四门课程成绩都大于70分的学生

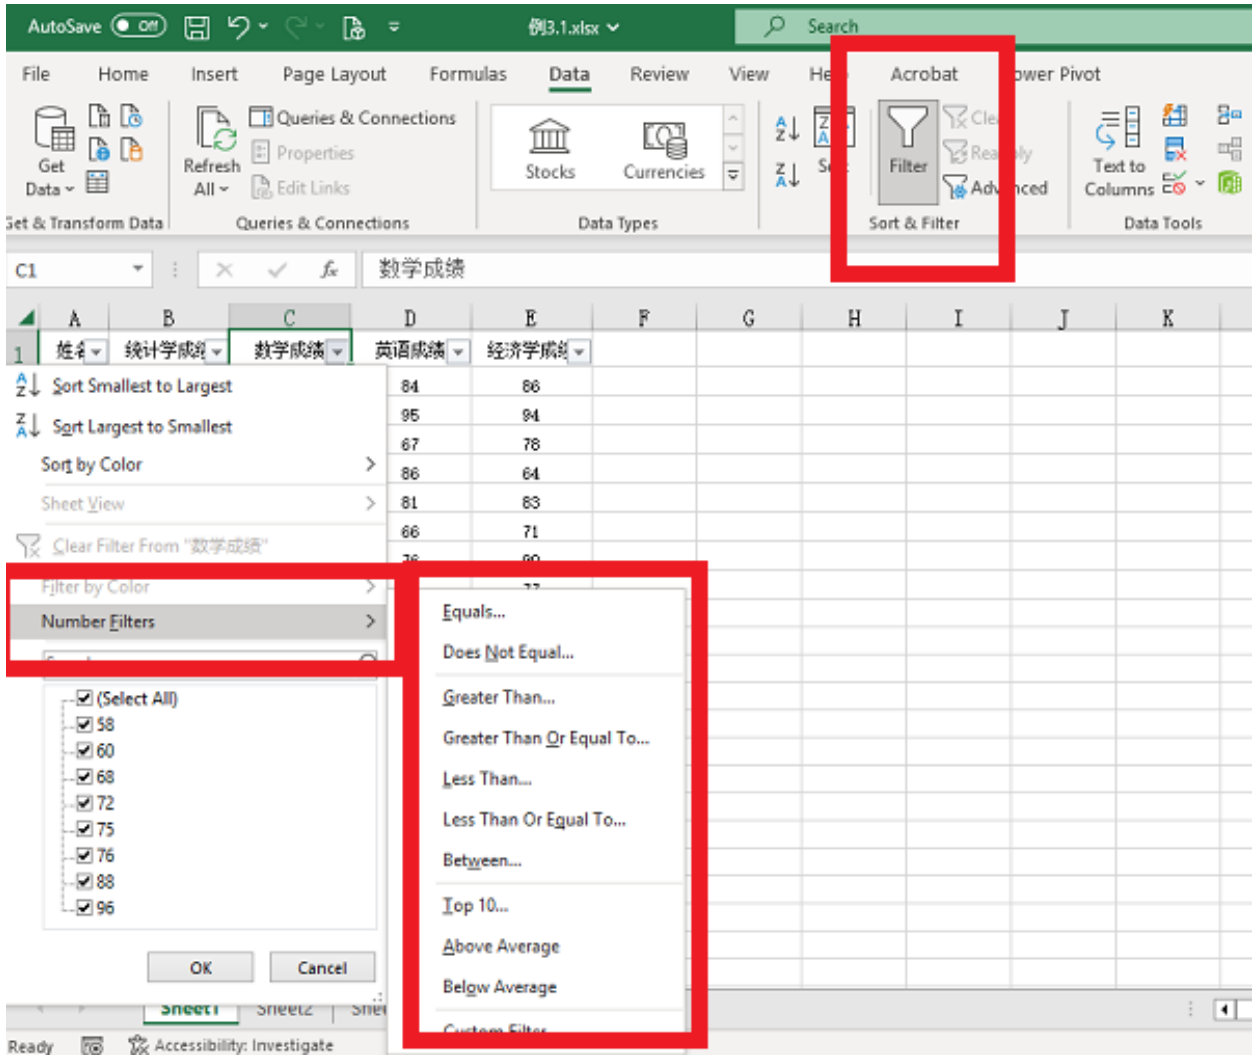

尝试用AI提示词再次完成数据筛选任务

【例3.1】表3-1是8名学生4门课程的考试成绩数据(单位:分)。试找出统计学成绩等于75分的学生,英语成绩最高的前三名学生,四门课程成绩都大于70分的学生。

提示词：上传文件是8名学生4门课程的考试成绩数据(单位:分)。试找出统计学成绩等于75分的学生,英语成绩最高的前三名学生,四门课程成绩都大于70分的学生。

大模型输出：

统计学成绩等于75分的学生：赵颖、袁方。

英语成绩最高的前三名学生：王翔（95分）、陈风（92分）、李华（86分）。

四门课程成绩都大于70分的学生：王翔（统计学91分、数学75分、英语95分、经济学94分）、赵颖（统计学75分、数学96分、英语81分、经济学83分）、陈风（统计学87分、数学76分、英语92分、经济学77分）。

数据的预处理：数据排序

- **数据排序**是按一定顺序将数据排列。通过排序不仅可以大概了解数据的特征，还有助于对数据检查纠错，以及为重新归类或分组等提供方便。在某些场合，排序本身就是分析的目的之一。
- 对于**类别数据**，如果是字母型数据，排序有升序降序之分，但习惯上更多使用升序，因为升序与字母的自然排列相同；如果是汉字型数据，排序方式很多，比如按汉字的首位拼音字母排列，这与字母型数据的排序完全一样，也可按笔画排序，其中也有笔画多少的升序和降序之分。交替运用不同方式排序，在汉字型数据的检查纠错过程中十分有用。
- 对于**数值数据**的排序有两种，即升序和降序。设一组数据为x_1，x_2，…，x_n，升序后可表示为：$x_{(1)} < x_{(2)} < \cdots < x_{(n)}$；降序可表示为：$x_{(1)} > x_{(2)} > \cdots > x_{(n)}$。

数据的预处理： 分类数据的整理——频数与频数分布

- **频数(frequency)**——落在某一特定类别(或组)中的数据个数
- **频数分布(frequency distribution)**——把各个类别及落在其中的相应频数全部列出,并用表格形式表现出来
  - 由于类别数据本身就是用文字表达的类别，因此，只要先把所有的类别都列出来，然后计算出每一类别的频数，即可生成一张频数分布表
  - 频数分布表中落在某一特定类别的数据个数就是频数
  - 根据观察变量的多少，可以生成简单频数表、二维列联表和多维列联表等

简单的频数表

- 也称为一维列联表
- 只涉及一个分类变量时，这个变量的各类别（取值）可以放在频数分布表中“行”的位置，也可以放在“列”的位置，将该变量的各类别及其相应的频数列出来

频数与频数分布例题分析

【例3.2】为研究不同类型软饮料的市场销售情况,一家市场调查公司对随机抽取的一家超市进行调查。表3-2是调查员随机观察的50名顾客购买的饮料类型及购买者性别的记录。生成频数分布表,观察饮料类型和顾客性别的分布状况,并进行描述性分析

简单频数表、二维列联表和多维列联表等

编号	顾客性别	饮料类型	编号	顾客性别	饮料类型	编号	顾客性别	饮料类型
1	女	碳酸饮料	18	女	碳酸饮料	35	女	其他
2	男	绿茶	19	男	绿茶	36	女	碳酸饮料
3	男	矿泉水	20	男	其他	37	女	其他
4	女	矿泉水	21	女	碳酸饮料	38	女	果汁
5	男	碳酸饮料	22	男	绿茶	39	男	绿茶
6	男	矿泉水	23	男	绿茶	40	女	果汁
7	女	碳酸饮料	24	女	碳酸饮料	41	女	碳酸饮料
8	女	绿茶	25	男	碳酸饮料	42	女	果汁
9	男	果汁	26	女	绿茶	43	男	矿泉水
10	男	碳酸饮料	27	男	矿泉水	44	女	碳酸饮料
11	女	矿泉水	28	女	绿茶	45	女	绿茶
12	女	其他	29	女	碳酸饮料	46	女	其他
13	男	碳酸饮料	30	女	矿泉水	47	女	果汁
14	男	绿茶	31	男	其他	48	男	绿茶
15	男	碳酸饮料	32	男	碳酸饮料	49	女	其他
16	女	其他	33	女	果汁	50	女	矿泉水
17	男	矿泉水	34	男	矿泉水			

频数与频数分布例题分析

饮料类型

		频率	百分比	有效百分比	累积百分比
有效	果汁	6	12.0	12.0	12.0
	矿泉水	10	20.0	20.0	32.0
	绿茶	11	22.0	22.0	54.0
	其他	8	16.0	16.0	70.0
	碳酸饮料	15	30.0	30.0	100.0
	总计	50	100.0	100.0	

顾客性别 * 饮料类型 交叉表

计数

		饮料类型					
		果汁	矿泉水	绿茶	其他	碳酸饮料	总计
顾客性别	男	1	6	7	2	6	22
	女	5	4	4	6	9	28
总计		6	10	11	8	15	50

顾客性别 * 饮料类型 交叉表

			饮料类型					
			果汁	矿泉水	绿茶	其他	碳酸饮料	总计
顾客性别	男	计数	1	6	7	2	6	22
		占 顾客性别 的百分比	4.5%	27.3%	31.8%	9.1%	27.3%	100.0%
		占 饮料类型 的百分比	16.7%	60.0%	63.6%	25.0%	40.0%	44.0%
		占总计的百分比	2.0%	12.0%	14.0%	4.0%	12.0%	44.0%
	女	计数	5	4	4	6	9	28
		占 顾客性别 的百分比	17.9%	14.3%	14.3%	21.4%	32.1%	100.0%
		占 饮料类型 的百分比	83.3%	40.0%	36.4%	75.0%	60.0%	56.0%
		占总计的百分比	10.0%	8.0%	8.0%	12.0%	18.0%	56.0%
总计		计数	6	10	11	8	15	50
		占 顾客性别 的百分比	12.0%	20.0%	22.0%	16.0%	30.0%	100.0%
		占 饮料类型 的百分比	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%
		占总计的百分比	12.0%	20.0%	22.0%	16.0%	30.0%	100.0%

条形图和帕累托图

条形图（bar chart）

- 用一定宽度的条形来表示各类别频数的图形，用于观察不同类别频数的多少或分布状况
- 绘制时，各类别可以放在横轴，也可以放在纵轴，将各类别放在横轴绘制的条形图也称为柱形图（column chart）
- 只有一个分类变量时，可以绘制简单条形图和帕累托图
- 有两个分类变量时，可以绘制簇状条形图或堆积条形图

- 简单条形图
  - 是根据一个分类变量绘制的，用于描述该变量的各类别的频数分布状况
  - 其中的各个类别可以放在横轴，也可以放在纵轴
- 帕累托图（pareto plot）
  - 以意大利经济学家V.Pareto的名字而命名的，它是按各类别的频数多少降序排列后绘制的条形图。帕累托图可以看做是简单条形图的一个变种
- 簇状条形图或堆积条形图
  - 可以将两个变量的条形图以簇状或堆积的方式绘制

条形图和帕累托图例题分析

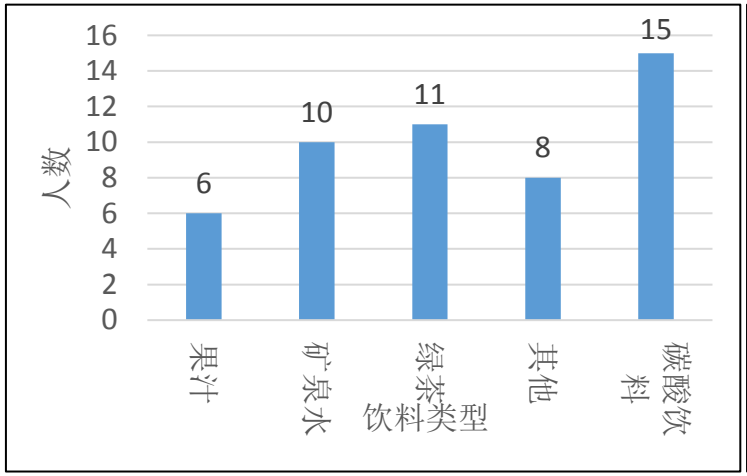

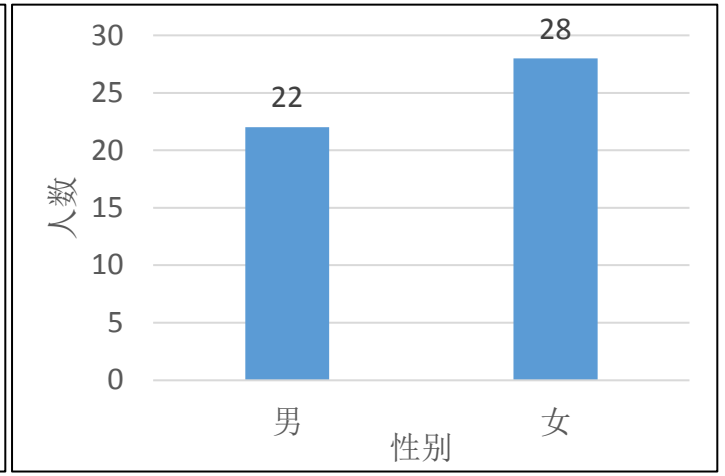

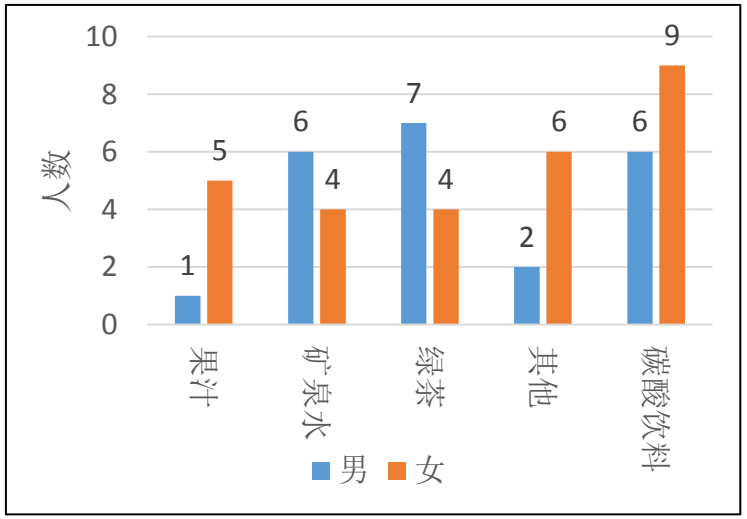

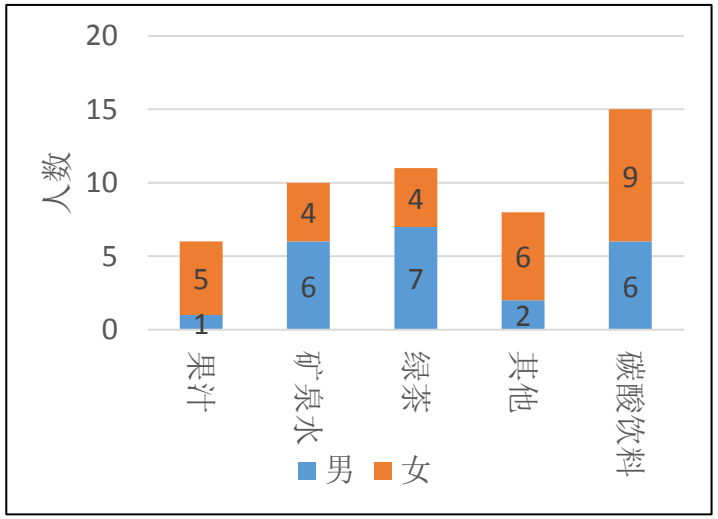

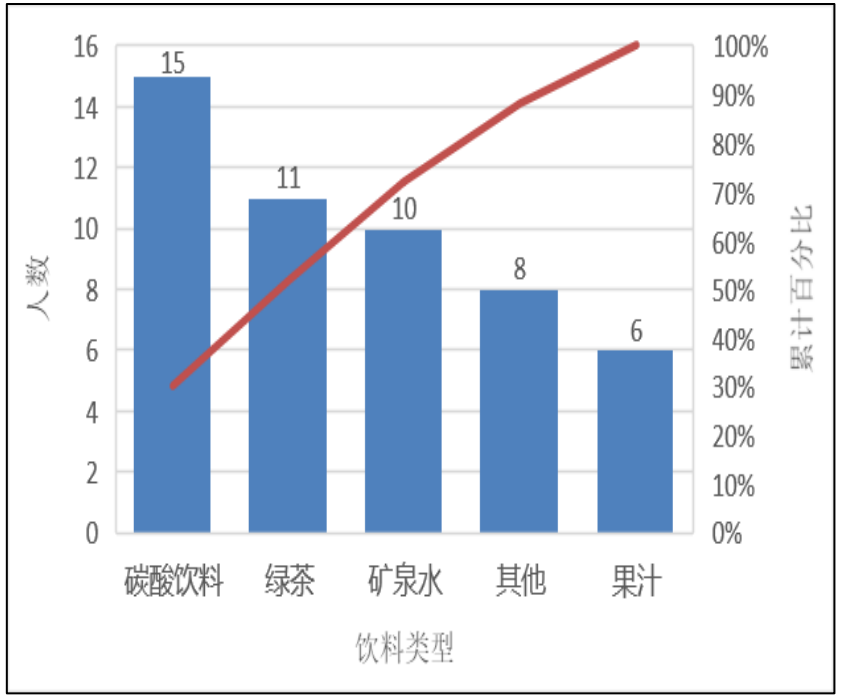

饼图和环形图

饼图（pie chart）

- 是用圆形及圆内扇形的角度来表示一个样本（或总体）中各类别的频数占总频数比例大小的图形
- 对于研究结构性问题十分有用

环形图（doughnut chart）

- 环形图与饼图类似，但又有区别。环形图中间有一个“空洞”，每个样本用一个环来表示，样本中每一类别的频数构成用环中的一段表示。因此，环形图可显示多个样本各类别频数占其相应总频数的比例，从而有利于构成的比较研究
- 绘制环形图时，先向圆心方向画一条垂线（圆的半径），然后顺时针方向依次画出各类别所占的百分比。其中样本的顺序依次从内环到外环

饼图和环形图例题分析

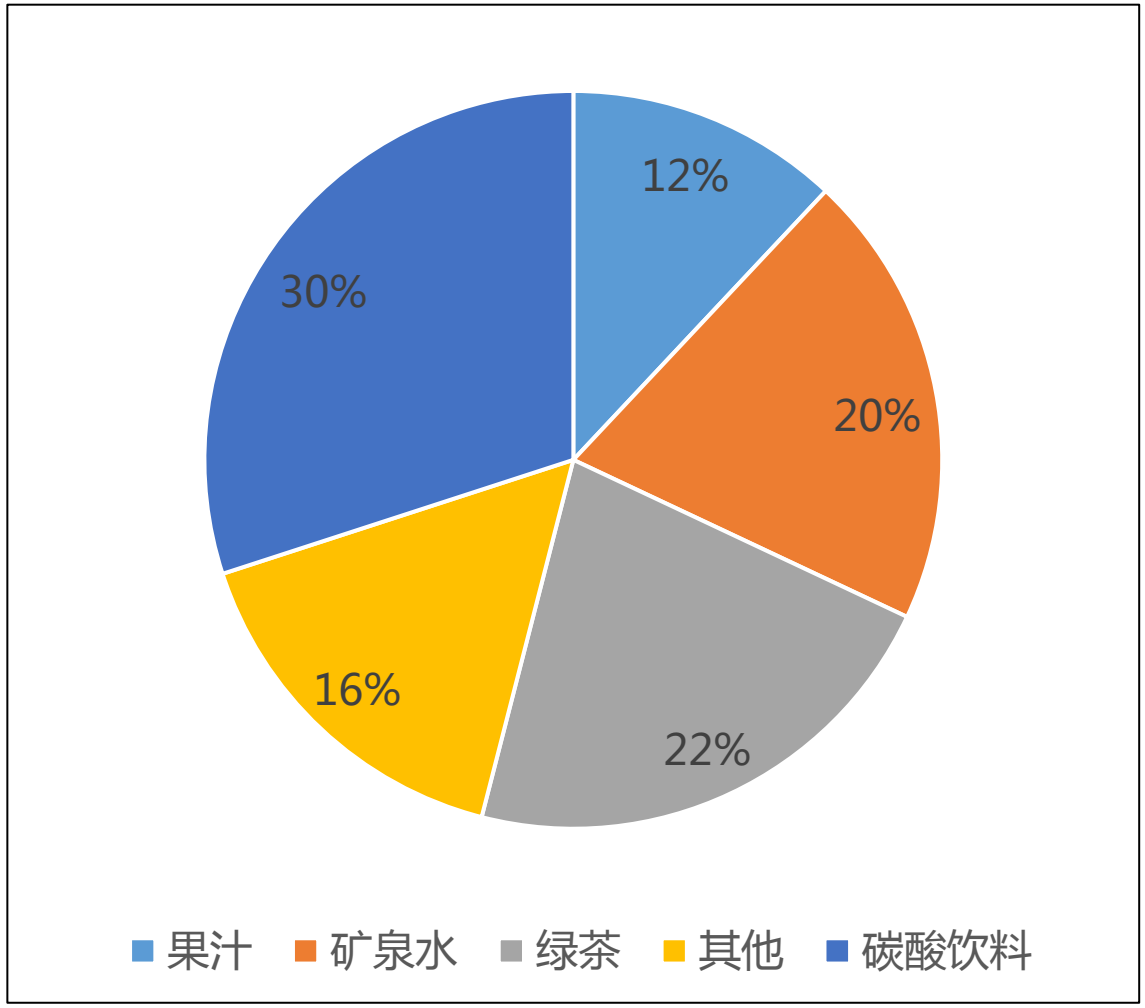
12%
20%
22%
16%
30%
果汁
矿泉水
绿茶
其他
碳酸饮料

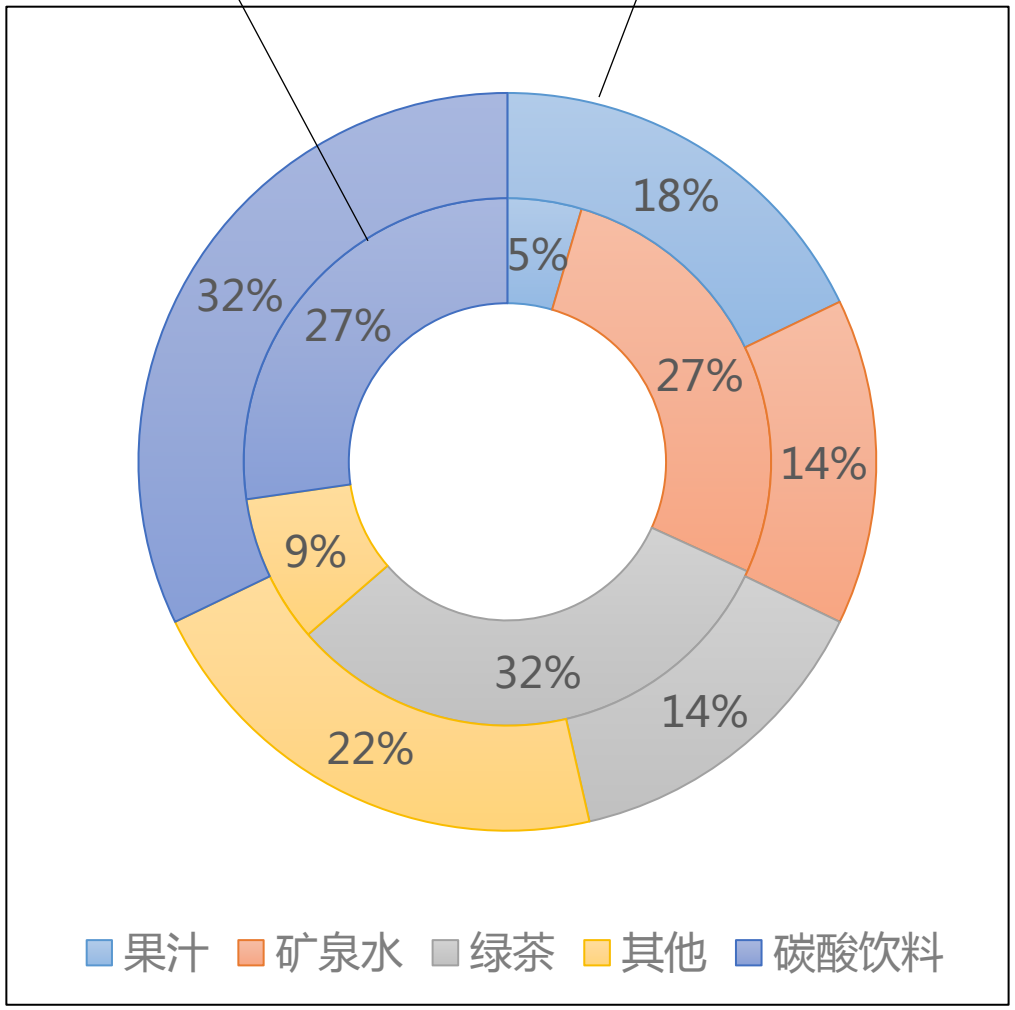
理科学科群学生
文科学科群学生
18%
5%
32%
27%
27%
14%
9%
32%
14%
22%
果汁
矿泉水
绿茶
其他
碳酸饮料

数据分组例题分析

- 数据分组是根据统计研究的需要,将原始数据按照某种标准分成不同的组别,分组后的数据称为**分组数据(grouped data)**
- 在组距分组中,一个组的最小值称为**下限值**，一个组的最大值称为**上限值**
- 数据分组的主要目的是观察数据的分布特征
- 数据经分组后再计算出各组中数据出现的频数,就形成了一张**频数分布表**

【例3.3】表3-8是某电脑公司连续4个月每天的销售量数据(单位:台)。试对数据进行分组

234	159	187	155	172	183	182	177	163	158
143	198	141	167	194	225	177	189	196	203
187	160	214	168	173	178	184	209	176	188
161	152	149	211	196	234	185	189	196	206
150	161	178	168	174	153	186	190	160	171
228	162	223	170	165	179	186	175	197	208
153	163	218	180	175	144	178	191	197	192
166	196	179	171	233	179	187	173	174	210
154	164	215	233	175	188	237	194	198	168
174	226	180	172	190	172	187	189	200	211
156	165	175	210	207	181	205	195	201	172
203	165	196	172	176	182	188	195	202	213

数据分组例题分析

解：分组和制作频数分布表的具体步骤如下:

第1步:确定组数。一组数据分多少组合适呢?一般与数据自身的特点及数据的多少有关。由于分组的目的之一是观察数据分布的特征,因此组数的多少应适中。组数太少,数据的分布就会过于集中,组数太多,数据的分布就会过于分散,这些都不便于观察数据分布的特征和规律。组数的确定应以能够显示数据的分布特征和规律为目的。**一般情况下,一组数据所分的组数不应少于5组且不多于15组,即5≤K≤15。**实际应用时,可根据数据的多少和特点及分析的要求来确定组数。本例中由于数据较多,可分为10组。

第2步:确定各组的组距。组距(class width)是一个组的上限与下限的差。组距可根据全部数据的最大值和最小值及所分的组数来确定,即**组距=(最大值-最小值)÷组数**。例如,对于本例数据,最大值为237,最小值为141,则组距=(237-141)÷10=9.6。为便于计算,组距宜取5或10的倍数,而且第一组的下限应低于最小变量值,最后一组的上限应高于最大变量值,因此组距可取10。

【例3.3】用【直方图】命令制作数值数据的频数分布表

用Excel【数据分析】工具中的【直方图】命令可生成数值数据的频数分布表。但需要注意的是，Excel在作频数分布表时，每一组的频数包括一个组的上限值，即$a < x \leq b$。**而实际分组时，通常规定“上组限不在内”,即当相邻两组的上下限重叠时,恰好等于某一组上限的变量值不算在本组内,而计算在下一组内，即x满足$a \leq x < b$。**因此，需要输入一列比上限值小的数作为【接收区域】。就【例3.3】而言，分别输入149，159，169，179，189，199，209，219，229，239作为【接收区域】，然后按下列骤操。

第1步：选择【数据】→【数据分析】→【直方图】，单击【确定】。

第2步：在【输入区域】方框内输入原始数据所在的区域；在【接收区域】方框内输入上限值所在的区域；在【输出区域】方框内输入结果输出的位置；选择【图表输出】。**单击【确定】。**

数据分组例题分析

	A	B	C
1	按销售量分组(台)	频数（天）	频率（%）
2	140~150	4	3.33
3	150~160	9	7.50
4	160~170	16	13.33
5	170~180	27	22.50
6	180~190	20	16.67
7	190~200	17	14.17
8	200~210	10	8.33
9	210~220	8	6.67
10	220~230	4	3.33
11	230~240	5	4.17
12	**合计**	**120**	**100**

	A	B	C
1	按销售量分组(台)	频数（天）	频率（%）
2	150以下	4	3.33
3	150~160	9	7.50
4	160~170	16	13.33
5	170~180	27	22.50
6	180~190	20	16.67
7	190~200	17	14.17
8	200~210	10	8.33
9	210~220	8	6.67
10	220~230	4	3.33
11	230及以上	5	4.17
12	**合计**	**120**	**100**

数据数据的图示：直方图

- **直方图(histogram)**是用于展示数值数据分布的一种图形,它是用矩形的宽度和高度(即面积)来表示频数分布的
- 绘制该图时,**在平面直角坐标中,用横轴表示数据分组,纵轴表示频数或频率,**这样,将一个组与相应的频数就形成了一个矩形,将多个矩形并列在一起就是直方图

【例3.3】Excel绘制的直方图——默认

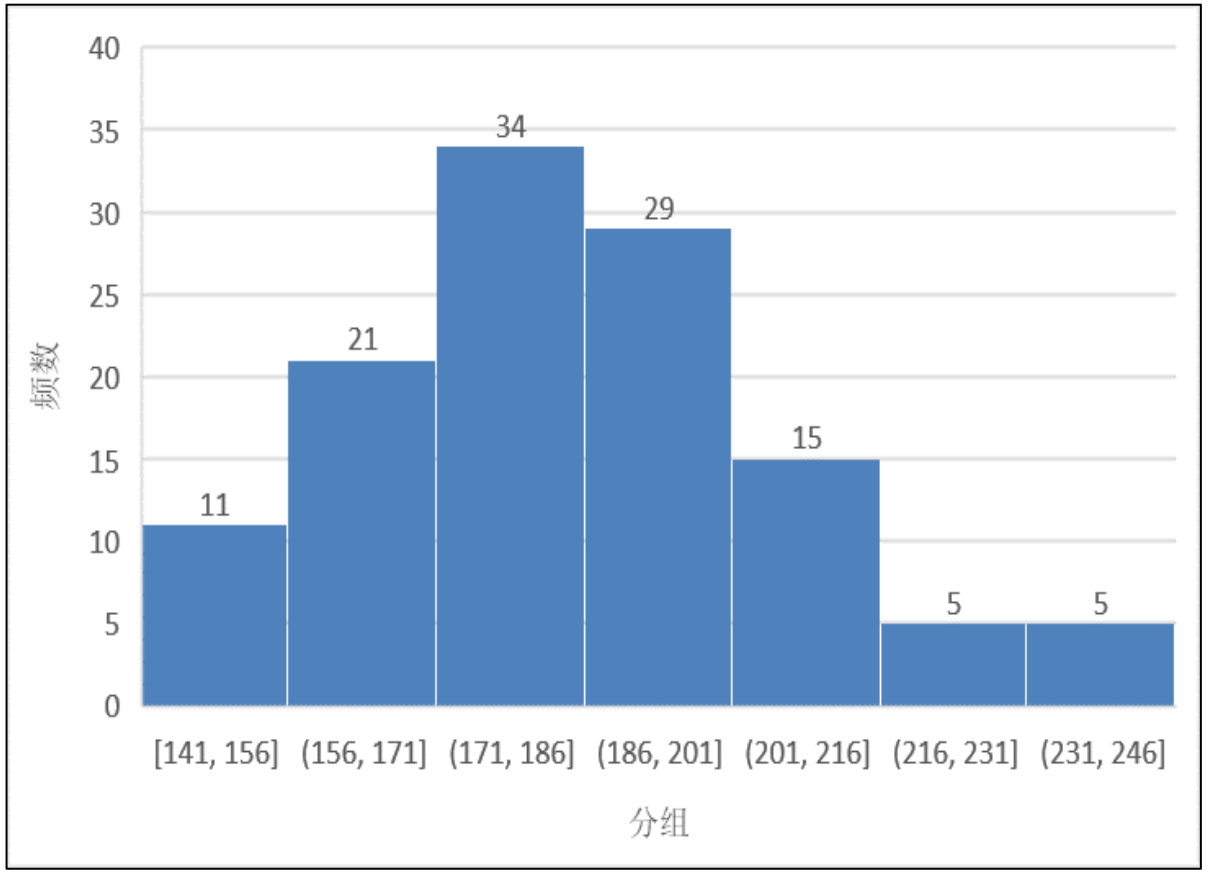

数据分组例题分析

【例3.3】Excel绘制的直方图——分成10组

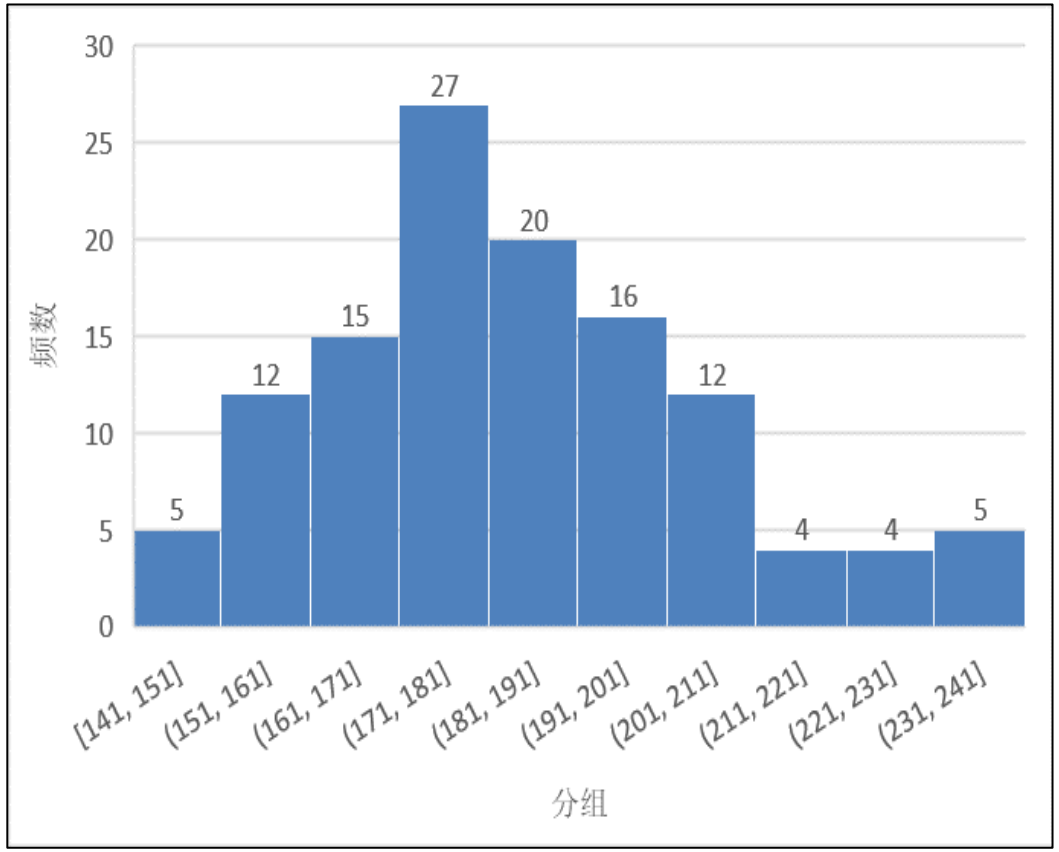

【例3.3】Excel绘制的直方图——组距为10，下溢箱为150，溢出箱为230

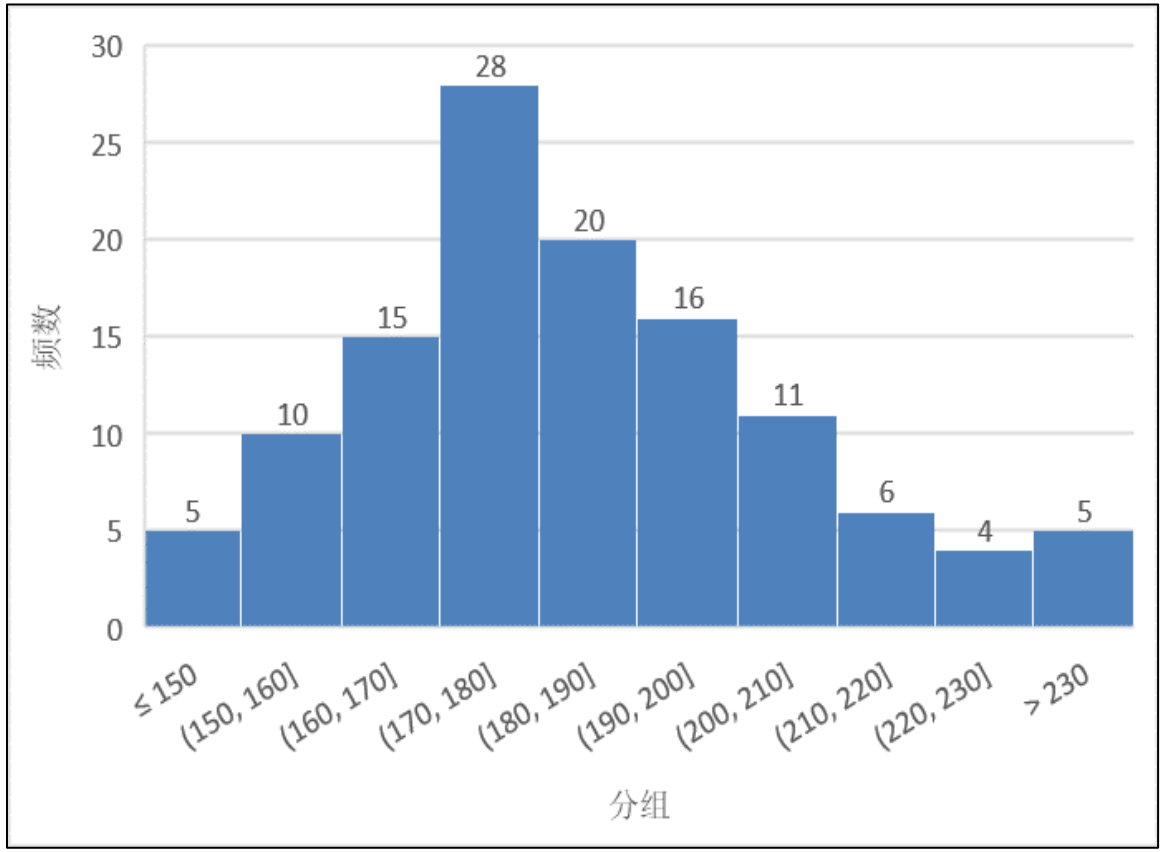

数据数据的图示：箱形图

绘制箱形图步骤

- **首先，找出一组数据的中位数（median）和两个四分位数（quartiles），并画出箱子**。中位数是一组数据排序后处在50%位置上的数值。四分位数是一组数据排序后处在25%位置和75%位置上的两个分位数值，分别用$Q_{25\%}$和$Q_{75\%}$表示。$Q_{75\%}-Q_{25\%}$称为四分位差或四分位距（quartile deviation），用IQR表示。用两个四分位数画出箱子（四分位差的范围），并画出中位数在箱子里面的位置。
- **其次，计算出内围栏和相邻值，并画出须线。**内围栏（inter fence）是与$Q_{25\%}$和$Q_{75\%}$的距离等于1.5倍四分位差的两个点，其中$Q_{25\%}-1.5\times\mathrm{IQR}$称为下内围栏，$Q_{75\%}+1.5\times\mathrm{IQR}$称为上内围栏。上下内围栏一般不在箱形图中显示，只是作为确定离群点的界限。然后找出上下内围栏之间的最大值和最小值（即非离群点的最大值和最小值），称为相邻值（adjacent value），其中$Q_{25\%}-1.5\times\mathrm{IQR}$范围内的最小值称为下相邻值，$Q_{75\%}+1.5\times\mathrm{IQ}$范围内的最大值称为上相邻值。用直线将上下相邻值分别与箱子连接，称为须线（whiskers）。
- **最后，找出离群点，并在图中单独标出**。离群点（outlier）是大于上内围栏或小于下内围栏的数值，也称外部点（outside value），在图中用“O”单独标出 这些统计量将在第4章详细介绍。
- **也可以设定3倍的四分位差作为围栏，称为外围栏（outer fence）**，其中$Q_{25\%}-3\times\mathrm{IQR}$称为下外围栏，$Q_{75\%}+3\times\mathrm{IQR}$称为上外围栏。外围栏也不在箱线图中显示。在外围栏之外的数据也称为极值（extreme）。Excel默认根据内围栏确定相邻值。

数据数据的图示：箱形图

示意图

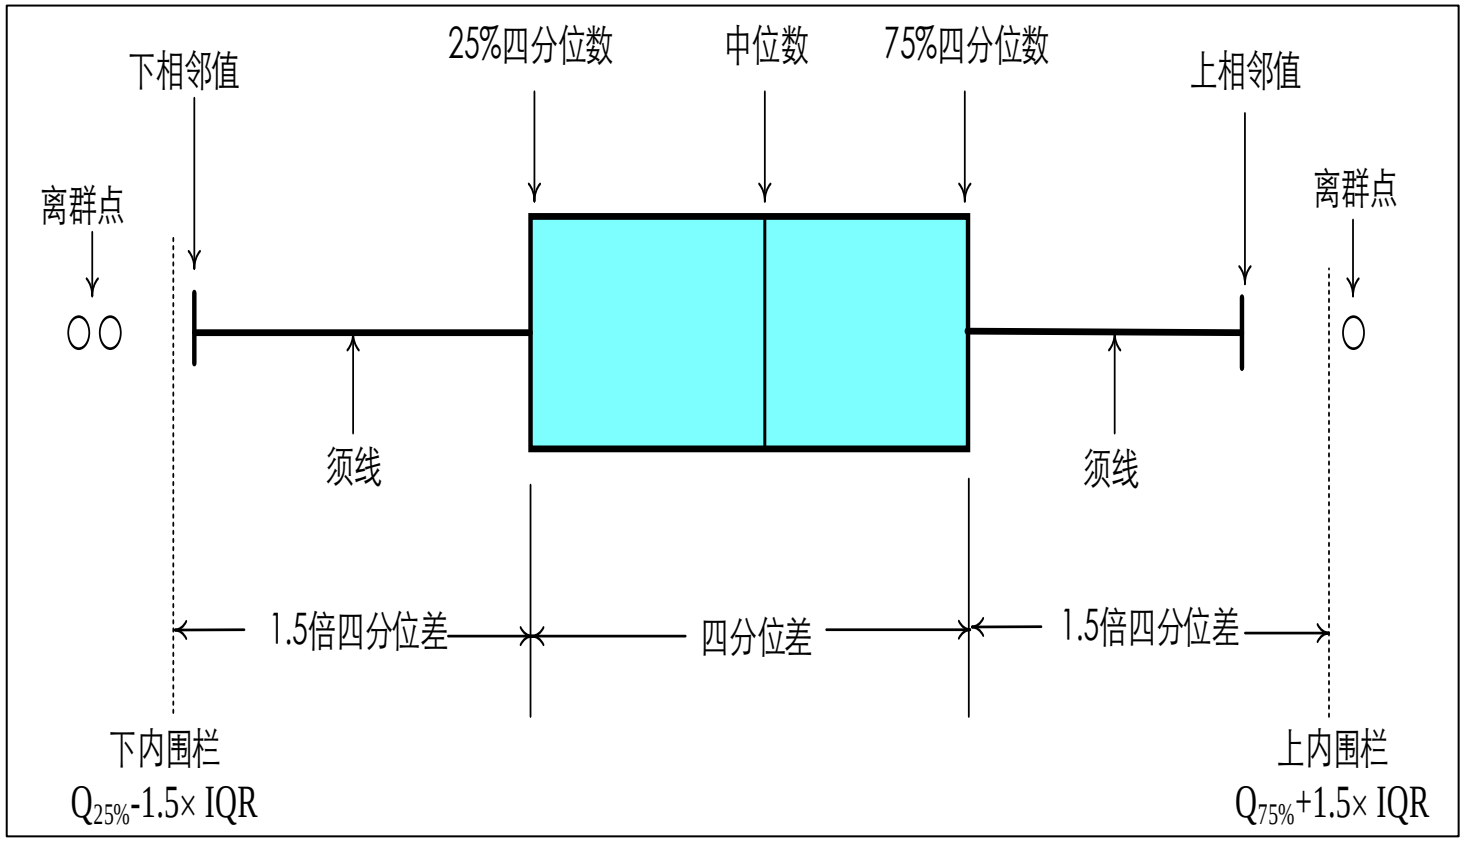

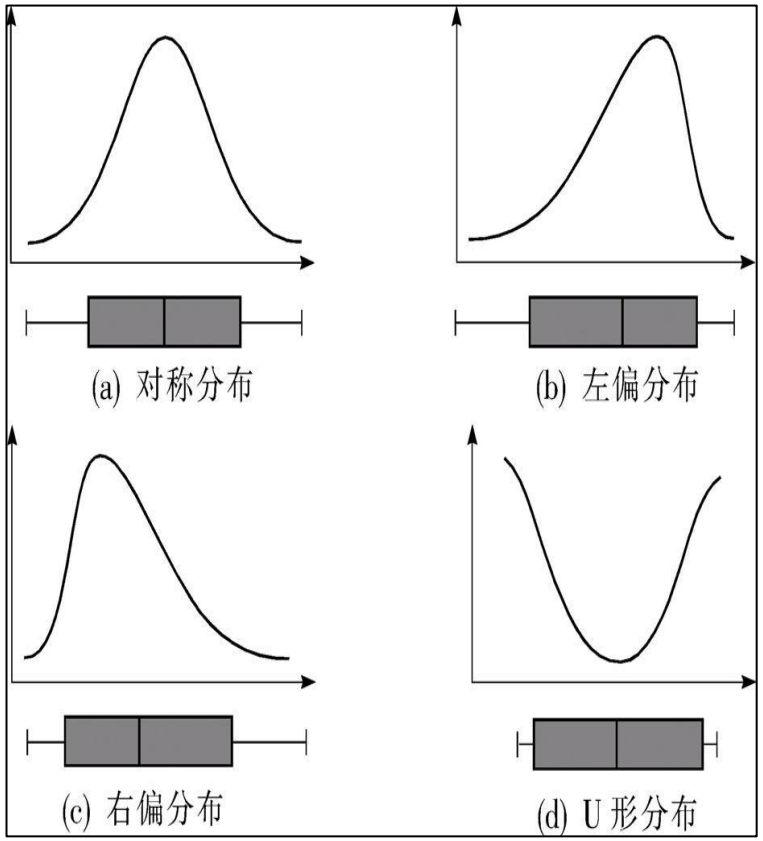

箱形图例题分析

【例3.4】从某大学的5个学院中各随机抽取30名学生，得到英语考试分数的数据如表3-11所示。绘制箱形图分析不同学院学生英语考试分数的分布特征

经济学院	法学院	商学院	理学院	统计学院
74	83	90	70	78
77	81	95	73	74
78	71	95	80	86
84	68	91	75	66
85	77	60	60	80
…	…	…	…	…
85	76	93	83	72
69	75	86	72	89
77	66	78	73	84
81	76	92	70	69
79	69	83	90	84

箱形图例题分析

【例3.4】从某大学的5个学院中各随机抽取30名学生，得到英语考试分数的数据如表3-11所示。绘制箱形图分析不同学院学生英语考试分数的分布特征

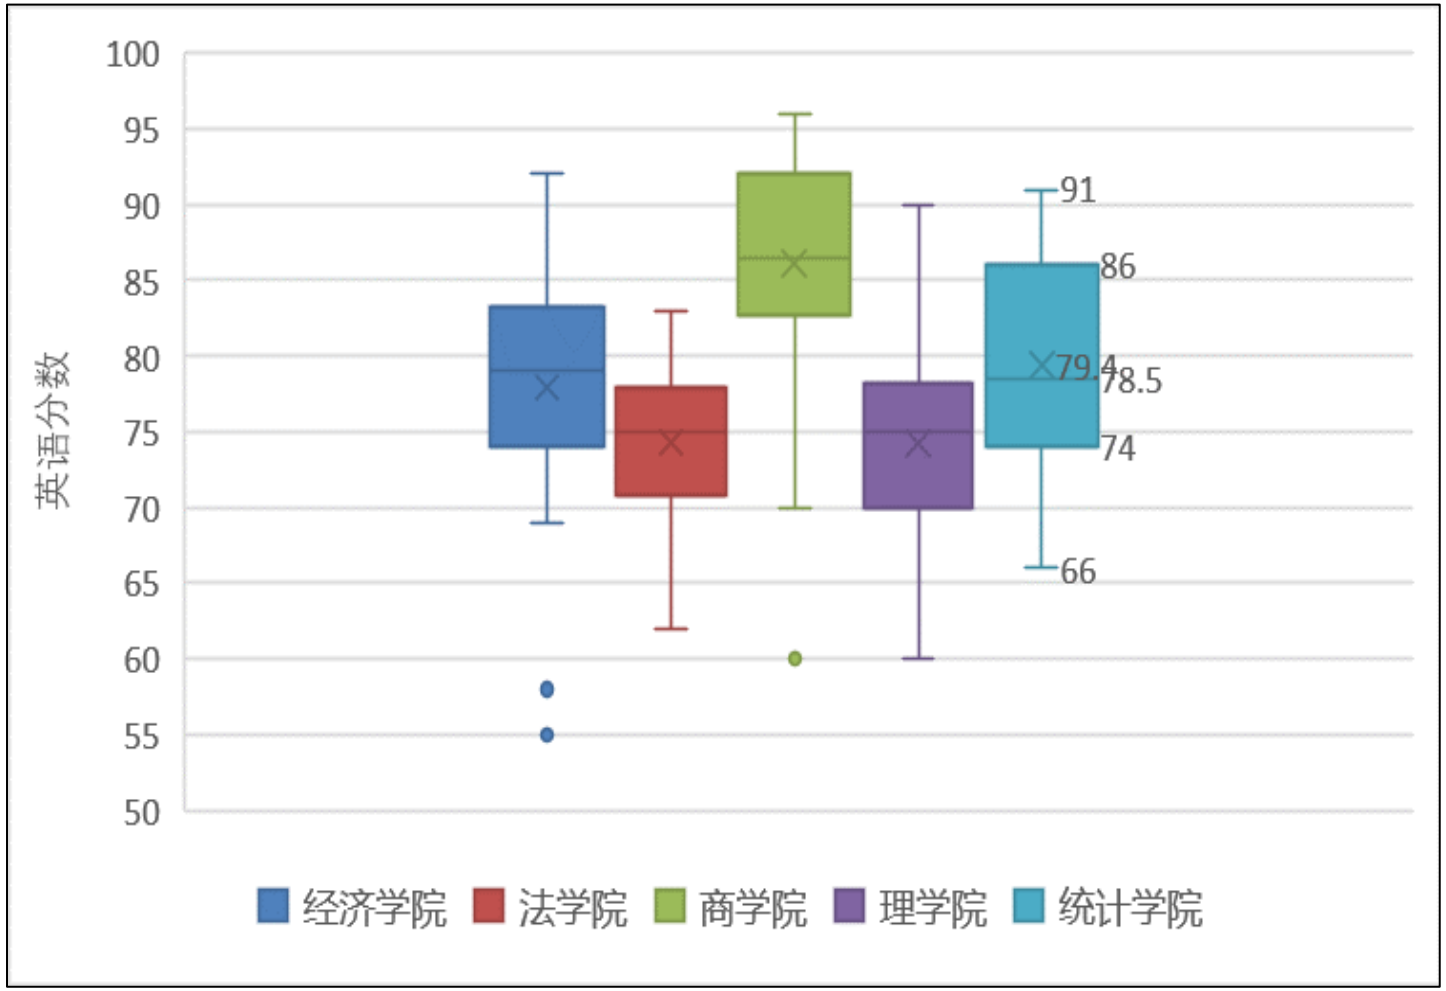

散点图例题分析

散 点 图 (scatter diagram)

- 展示两个数值变量之间关系的图形
- 横轴代表变量x,纵轴代表变量y，每组数据(x_i, y_i)在坐标系中用一个点表示，n组数据在坐标系中形成的n个点称为散点,由坐标及散点形成的二维数据图

【例3.5】随机抽取40个学生，得到身高和体重的胡如表3-12所示。制散点图分析身高和体重之间的关系

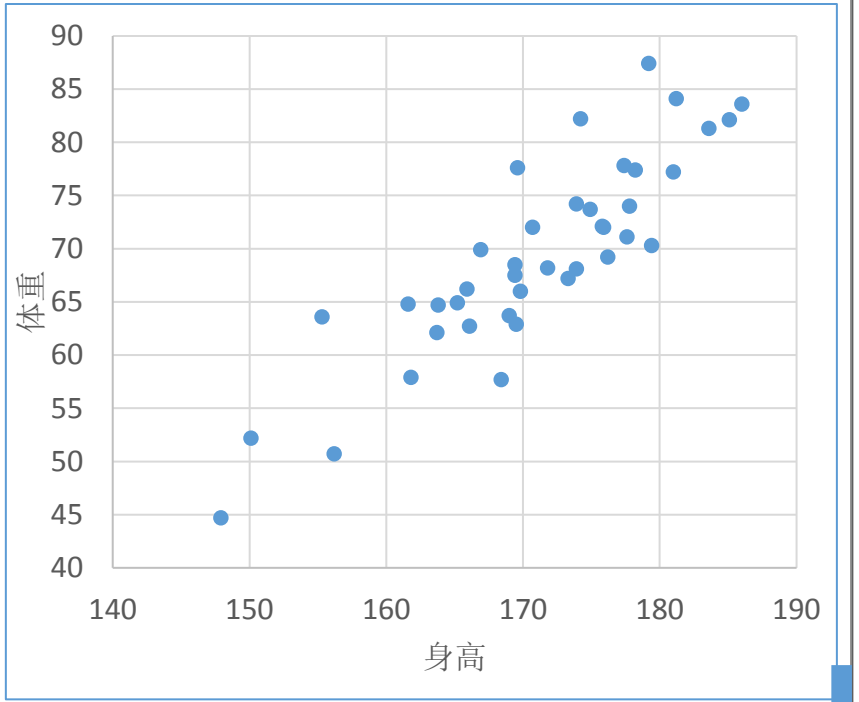

学号	身高（cm）	体重（kg）	学号	身高（cm）	体重（kg）
1	163.7	62.1	21	179.2	87.4
2	171.8	68.2	22	177.8	74
3	161.6	64.8	23	170.7	72
4	186	83.6	24	150.1	52.2
5	173.3	67.2	25	176.2	69.2
6	161.8	57.9	26	169.4	68.5
7	174.9	73.7	27	168.4	57.7
8	177.4	77.8	28	155.3	63.6
9	175.8	72.1	29	165.2	64.9
10	166.9	69.9	30	174.2	82.2
11	185.1	82.1	31	183.6	81.3
12	173.9	68.1	32	169	63.7
13	163.8	64.7	33	173.9	74.2
14	147.9	44.7	34	169.5	62.9
15	181.2	84.1	35	156.2	50.7
16	169.6	77.6	36	165.9	66.2
17	169.8	66	37	166.1	62.7
18	179.4	70.3	38	169.4	67.5
19	178.2	77.4	39	181	77.2
20	175.9	72	40	177.6	71.1

雷达图例题分析

雷达图(radar chart)

- 显示多个变量的常用图示方法，也称为蜘蛛图(spider chart)。设有n组样本$s_1, s_2, \dots, s_n$，每个样本测得p个变量$x_1, x_2, \dots x_p$。要绘制这p个变量的雷达图,具体做法是:先画一个圆,然后将圆p等分,得到p个点,令这p个点分别对应p个变量,再将这p个点与圆心连线,得到p个辐射状的半径,这p个半径分别作为p个变量的坐标轴 ,再将同一样本的值在p个坐标上的点连线。这样,n个样本形成的n个多边形就是雷达图
- 雷达图在显示或对比各变量的数值总和时十分有用。假定各变量的取值具有相同的正负号,则总的绝对值与图形所围成的区域成正比。此外,利用雷达图可以研究多个样本之间的相似程度。

【例3.6】表3-13是2018年北京、天津、上海和重庆人均各项消费支出数据。绘制雷达图比较4个地区人均消费支出的特点和相似性

地区	食品烟酒	衣着	居住	生活用品及服务	交通通信	教育文化娱乐	医疗保健	其他用品及服务
北京	8064.9	2175.5	14110.3	2371.9	4767.4	3999.4	3274.5	1078.6
天津	8647.5	1990.0	6406.3	1818.4	4280.9	3186.6	2676.9	896.3
上海	10728.2	2036.8	14208.5	2095.5	4881.2	5049.4	3070.2	1281.5
重庆	6220.8	1454.5	3498.8	1338.9	2545.0	2087.8	1660.0	442.8

雷达图例题分析

【例3.6】表3-13是2018年北京、天津、上海和重庆的人均各项消费支出数据。绘制雷达图比较4个地区人均消费支出的特点和相似性

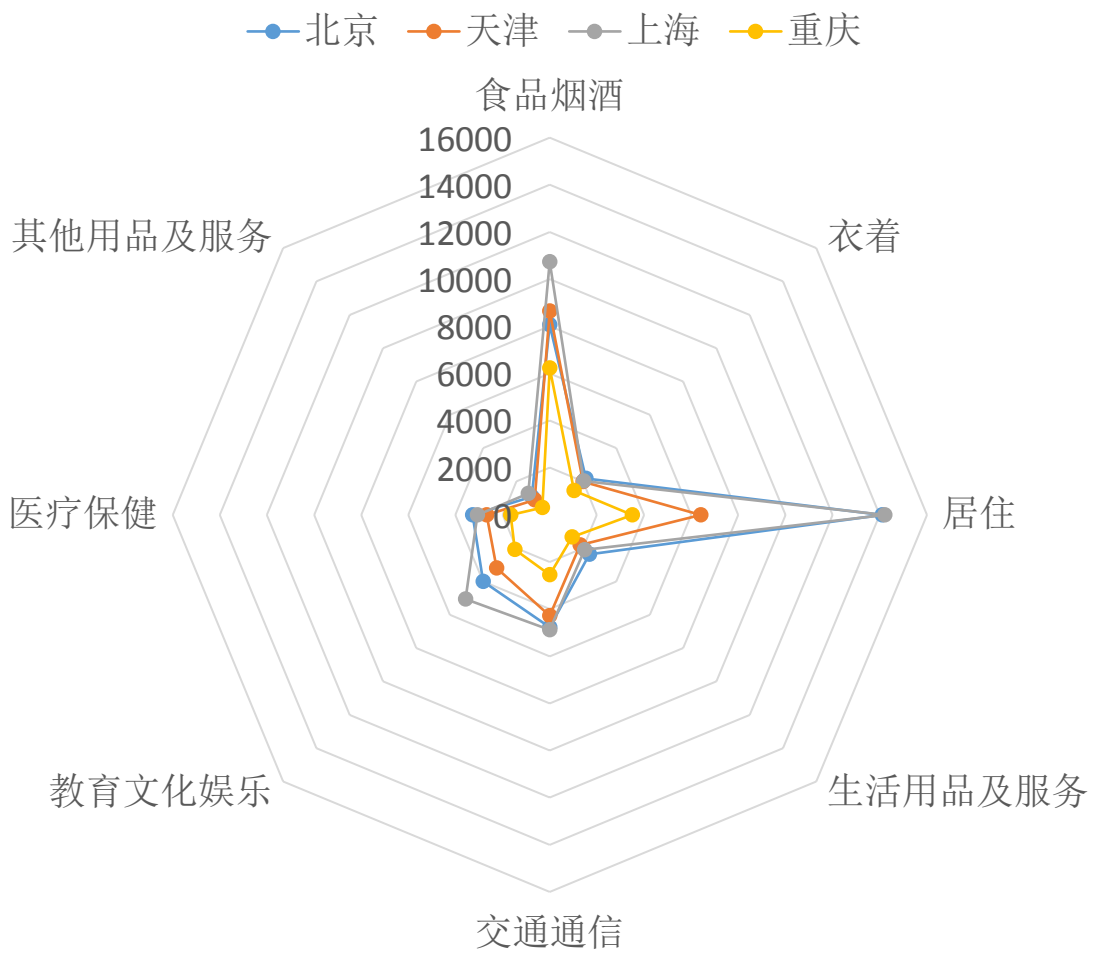

使用图表注意事项

- 精心设计的图表可以准确表达数据所要传递的信息
- 设计图表时，应尽可能简洁，以能够清晰地显示数据、合理地表达统计目的为依据
- 在绘制图形时，应避免一切不必要的修饰。过于花哨的修饰往往会使人注重图形本身，而掩盖了图形所要表达的信息。
- 图形大体上为4:3的一个矩形，过长或过高的图形都有可能歪曲数据，给人留下错误的印象
- 图表应有编号和标题。编号一般使用阿拉伯数字，如表1、表2等等。图表的标题应明示出表中数据所属的时间（when）、地点（where）和内容（what），即通常所说的3W准则。表的标题通常放在表的上方；图的标题可放在图的上方，也可放在图的下方

03 数据的概括性度量

集中趋势度量：平均数（简单平均数）

平均数（mean）

- 也称均值。一组数据相加后除以数据的个数得到的结果
- 平均数是度量数据集中趋势的常用统计量，在参数估计和假设检验中经常用到
- 设一组样本数据为x_1，x_2，…，x_n，样本量（样本数据的个数）为n，则样本平均数用$\bar{x}$（读作x-bar）表示，简平均数计算公式为

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{\sum_{i=1}^{n} x_i}{n}$$

注：如果有总体的全部数据x_1，x_2，…，x_N，总体均数用μ表示，其计算公式为

$$\mu = \frac{x_1 + x_2 + \cdots + x_N}{N} = \frac{\sum_{i=1}^{N} x_i}{N}$$

【例4.1】随机抽取30个消费者，得到他们每月网购金额的数据如表4-1所示。计算30个人的平均网购金额

429	671.2	622.4	678.7	393.2	331.3
477	450	536	450	478.2	583.8
655.9	373.5	540.1	303.6	397.4	515.3
507.1	431.3	511.1	570.1	427.1	386.2
512.9	455.1	465.4	452.7	437.5	625.4

$$\bar{x} = \frac{429.0 + 671.2 + \cdots + 437.5 + 625.4}{30} = \frac{14668.5}{30}$$

$$= 488.95$$

集中趋势度量：平均数（加权平均数）

加权平均数（weighted mean）

- 如果样本数据被分成k组，各组的组中值（一个组中的中间值，是组的下限值与上限值的平均数）分别用m_1，m_2，…，m_k表示，各组的频数分别用f_1，f_2，…，f_k表示，则样本平均数的计算公式为

$$\bar{x}=\frac{m_1f_1+m_2f_2+\cdots+m_kf_k}{f_1+f_2+\cdots+f_k}=\frac{\sum_{i=1}^{k}m_if_i}{n}$$

注：如果总体数据被分成k组，各组的组中值分别用M_1，M_2，…，M_k表示，各组数据出现的频数分别用f_1，f_2，…，f_k表示，则总体加权平均数的计算公式为

$$\mu=\frac{M_1f_1+M_2f_2+\cdots+M_kf_k}{f_1+f_2+\cdots+f_k}=\frac{\sum_{i=1}^{k}M_if_i}{N}$$

【例4.2】假定将表4-1的数据分成组距为50的组，分组结果如表4-2所示，计算网购金额的平均数

分组	人数
300~350	2
350~400	4
400~450	6
450~500	5
500~550	6
550~600	2
600~650	2
650~700	3

集中趋势度量：平均数（加权平均数）

【例4.2】假定将表4-1的数据分成组距为50的组，分组结果如表4-2所示，计算网购金额的平均数

分组	组中值（ m_i ）	人数（f_i）	$m_i \times f_i$
300~350	325	2	650
350~400	375	4	1500
400~450	425	6	2550
450~500	475	5	2375
500~550	525	6	3150
550~600	575	2	1150
600~650	625	2	1250
650~700	675	3	2025
合计	—	30	14650

加权平均数计算结果

$$\bar{x} = \frac{\sum_{i=1}^{n} m_i f_i}{n} = \frac{14650}{30}$$

$$= 488.33$$

集中趋势度量：中位数

中位数（median）

- 一组数据排序后处在中间位置上的数值，用Me表示
- 用一个点将全部数据等分成两部分，每部分包含50%的数据，一部分数据比中位数大，另一部分比中位数小，其特点是不受极端值的影响
- 计算中位数时，要先对n个数据从小到大进行排序，然后确定中位数的位置，最后确定中位数的具体数值。如果位置是整数值，中位数就是该位置所对应的数值；如果位置是整数加0.5的数值，中位数就是该位置两侧值的平均值。
- 设一组数据x_1，x_2，…，x_n按从小到大排序后为$x_{(1)}$，$x_{(2)}$，…，$x_{(n)}$，则中位数就是$(n+1)/2$位置上的值。计算公式为

$$M_e = \begin{cases} x_{\left(\frac{n+1}{2}\right)} & n\text{为奇数} \\ \frac{1}{2}\left\{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}\right\} & n\text{为偶数} \end{cases}$$

【例4.2】沿用例4.1。计算30个网购金额的中位数。

解：首先，将30人的网购金额数据排序，然后确定中位数的位置：$(30+1) \div 2 = 15.5$，中位数是排序后的第15.5位置上的数值，即中位数在第16个数值（465.4）和第16个数值（477.0）中间（0.5）的位置上。因此

$(465.4 + 477.0)/2 = 471.2$

集中趋势度量：四分位数

四分位数（quartile）

- 一组数据排序后处于25%和75%位置上的数值。它是用3个点将全部数据等分为4部分，其中每部分包含25%的数据。很显然，中间的四分位数就是中位数，因此通常所说的四分位数是指处在25%位置上和处在75%位置上的两个数值
- 计算四分位数时，首先对数据进行排序，然后确定四分位数所在的位置，该位置上的数值就是四分位数。与中位数不同的是，四分位数位置的确定方法有多种，每种方法得到的结果可能会有一定差异，但差异不会很大
- 设25%位置上的四分位数为$Q_{25\%}$，75%位置上的四分位数为$Q_{75\%}$，四分位数位置的公式为

$$Q_{25\%} = \frac{n+1}{4}，Q_{75\%} = \frac{3(n+1)}{4}$$

- 如果位置是整数，四分位数就是该位置对应的数值；如果是在整数加0.5的位置上，则取该位置两侧数值的平均数；如果是在整数加0.25或0.75的位置上，则四分位数等于该位置前面的数值加上按比例分摊的位置两侧数值的差值

注：Excel四分位数位置的计算公式为：$Q_{25\%}位置 = \frac{n+3}{4}$，$Q_{75\%}位置 = \frac{3n+1}{4}$

四分位数例题分析

【例4.4】沿用例4.1。计算30个网购金额的四分位数

解：先对n个数据从小到大进行排序，然后计算出四分位数的位置：

$Q_{25\%}$位置 $= \frac{30+1}{4} = 7.75$，$Q_{75\%}$位置 $= \frac{3\times(30+1)}{4} = 23.25$

$Q_{25\%}$在第7个数值（427.1）和第8个数值（429.0）之间0.75的位置上

$Q_{25\%} = 427.1 + 0.75 \times (429.0 - 427.1) = 428.525$。

$Q_{75\%}$在第23个数值（540.1）和第24个数值（570.1）之间0.25的位置上，因此，$Q_{25\%} = 540.1 + 0.25 \times (570.1 - 540.1) = 547.6$。

由于在$Q_{25\%}$和$Q_{75\%}$之间大约包含了50%的数据。就上面30人的网购金额而言，可以说大约有一半人的网购金额在428.525元和547.6元之间

数据数据的图示：箱形图

绘制箱形图步骤

- **首先，找出一组数据的中位数（median）和两个四分位数（quartiles），并画出箱子。**中位数是一组数据排序后处在50%位置上的数值。四分位数是一组数据排序后处在25%位置和75%位置上的两个分位数值，分别用$Q_{25\%}$和$Q_{75\%}$表示。$Q_{75\%}-Q_{25\%}$称为四分位差或四分位距（quartile deviation），用IQR表示。用两个四分位数画出箱子（四分位差的范围），并画出中位数在箱子里面的位置。
- **其次，计算出内围栏和相邻值，并画出须线。**内围栏（inter fence）是与$Q_{25\%}$和$Q_{75\%}$的距离等于1.5倍四分位差的两个点，其中$Q_{25\%}-1.5\times\mathrm{IQR}$称为下内围栏，$Q_{75\%}+1.5\times\mathrm{IQR}$称为上内围栏。上下内围栏一般不在箱形图中显示，只是作为确定离群点的界限。然后找出上下内围栏之间的最大值和最小值（即非离群点的最大值和最小值），称为相邻值（adjacent value），其中$Q_{25\%}-1.5\times\mathrm{IQR}$范围内的最小值称为下相邻值，$Q_{75\%}+1.5\times\mathrm{IQ}$范围内的最大值称为上相邻值。用直线将上下相邻值分别与箱子连接，称为须线（whiskers）。
- **最后，找出离群点，并在图中单独标出。**离群点（outlier）是大于上内围栏或小于下内围栏的数值，也称外部点（outside value），在图中用“O”单独标出 这些统计量将在第4章详细介绍。
- **也可以设定3倍的四分位差作为围栏，称为外围栏（outer fence）**，其中$Q_{25\%}-3\times\mathrm{IQR}$称为下外围栏，$Q_{75\%}+3\times\mathrm{IQR}$称为上外围栏。外围栏也不在箱线图中显示。在外围栏之外的数据也称为极值（extreme）。Excel默认根据内围栏确定相邻值。

数据数据的图示：箱形图

示意图

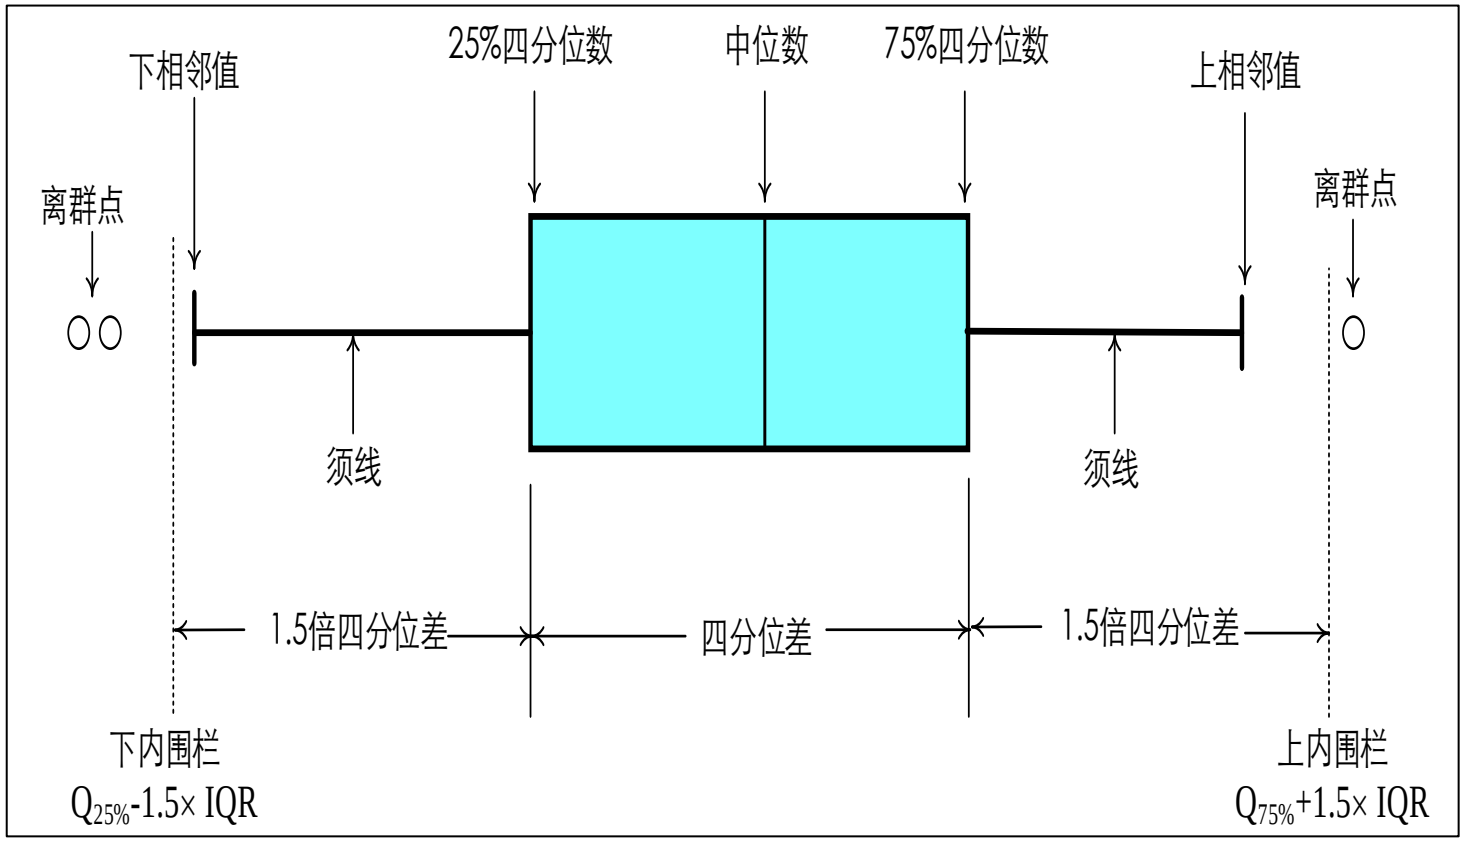

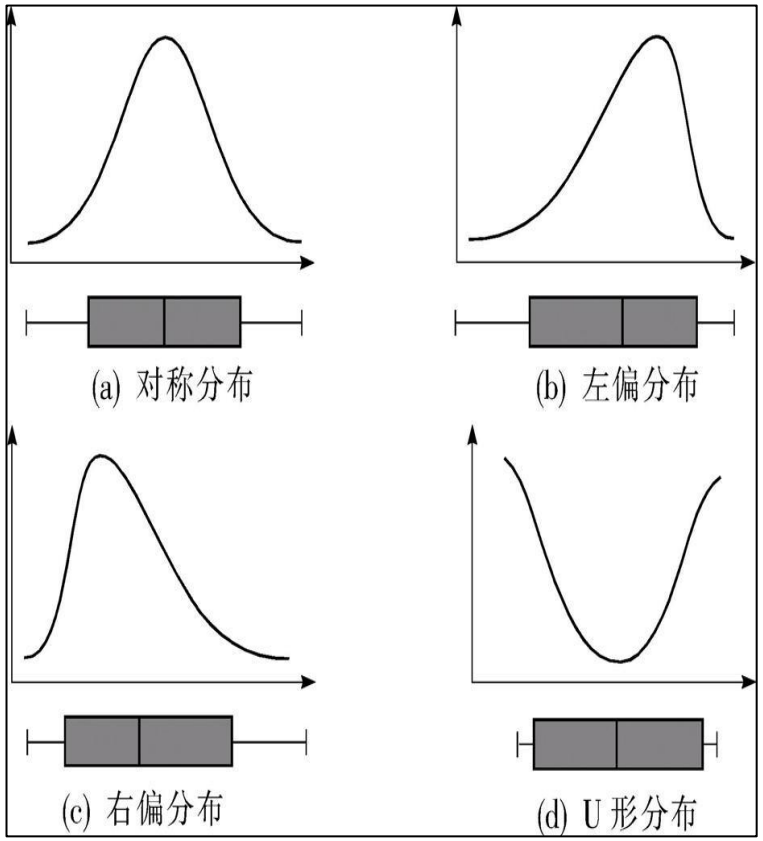

箱形图例题分析

【例3.4】从某大学的5个学院中各随机抽取30名学生，得到英语考试分数的数据如表3-11所示。绘制箱形图分析不同学院学生英语考试分数的分布特征

经济学院	法学院	商学院	理学院	统计学院
74	83	90	70	78
77	81	95	73	74
78	71	95	80	86
84	68	91	75	66
85	77	60	60	80
…	…	…	…	…
85	76	93	83	72
69	75	86	72	89
77	66	78	73	84
81	76	92	70	69
79	69	83	90	84

箱形图例题分析

【例3.4】从某大学的5个学院中各随机抽取30名学生，得到英语考试分数的数据如表3-11所示。绘制箱形图分析不同学院学生英语考试分数的分布特征

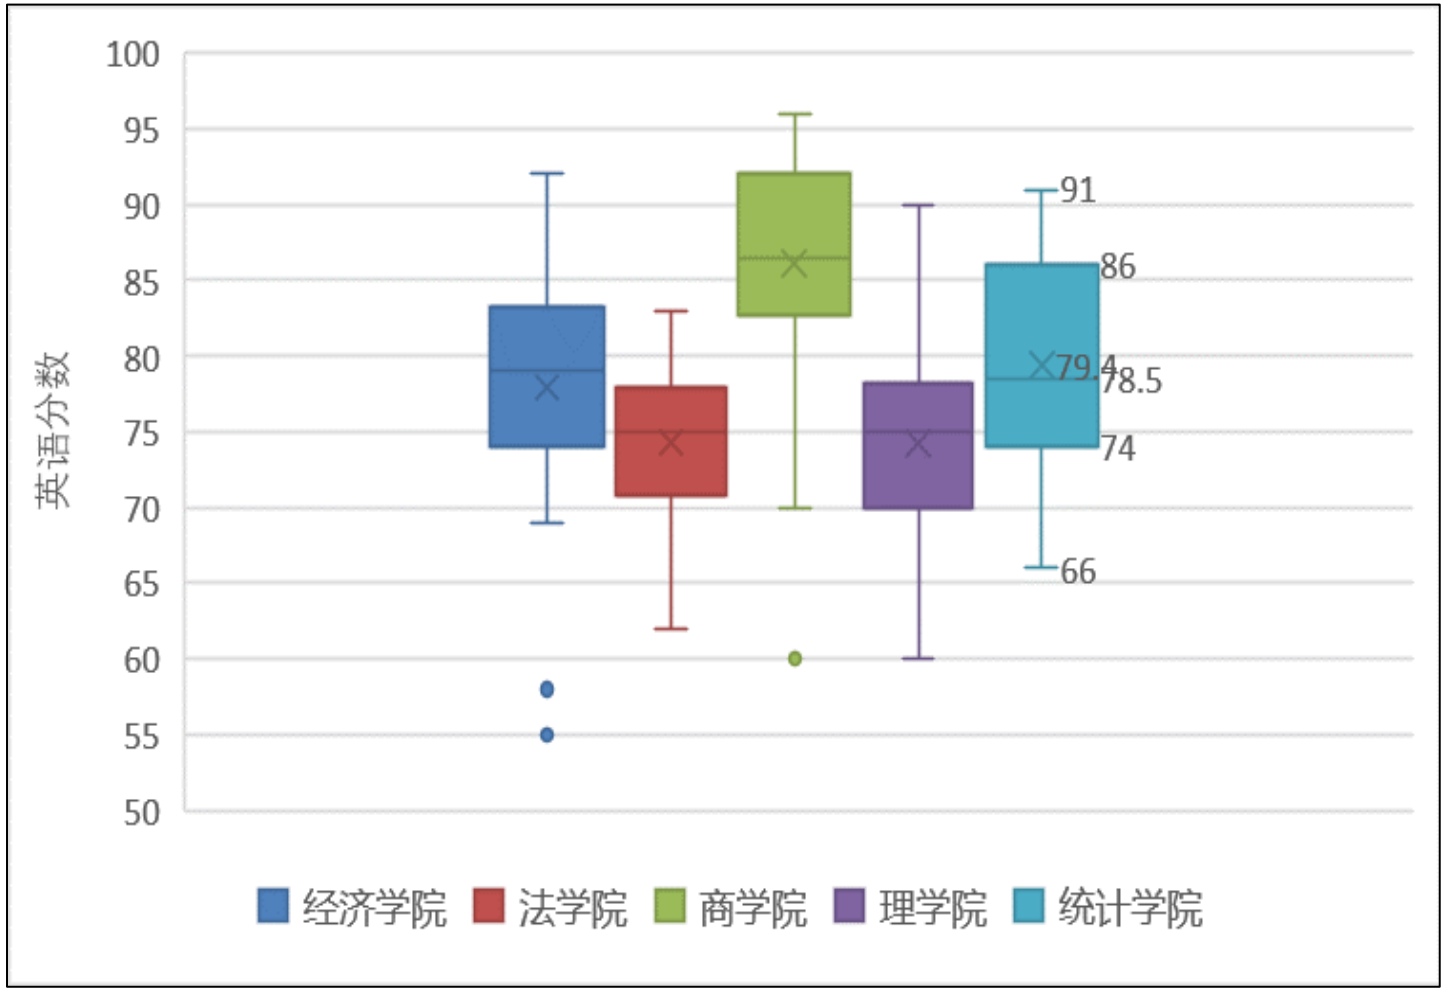

集中趋势度量：众数

众数（mode）

- 是一组数据中出现频数最多的数值，用M_o表示
- 一般情况下，只有在数据量较大时众数才有意义
- 从分布的角度看，众数是一组数据分布的峰值点所对应的数值
- 如果数据的分布没有明显的峰值，众数也可能不存在；如果有两个或多个峰值，也可以有两个或多个众数
- 例4.1——出现金额最多的是450，因此$M_o = 450$

集中趋势度量：几何平均数

几何平均数(geometric mean)

- n个变量值乘积的n次方根,用G表示。计算公式为

$$G=\sqrt[n]{x_1 \times x_2 \times \ldots \times x_n}=\sqrt[n]{\prod_{i=1}^{n} x_i}$$

式中,∏为连乘符号。

- 几何平均数是适用于特殊数据的一种平均数,它主要用于计算平均比率
- 当所掌握的变量值本身是比率形式时,采用几何平均法计算平均比率更为合理
- 在实际应用中,几何平均数主要用于计算现象的平均增长率 当数据中出现零值或负值时,不宜计算几何平均数

几何平均数例题分析

【例4.5】一位投资者持有一种股票,连续4年的收益率分别为4.5%,2.1%,25.5%,1.9%。计算该投资者在这4年内的平均收益率

解：设平均收益率为$\overline{G}$,有

$$\overline{G}=\sqrt[n]{\prod_{i=1}^{n} x_i}-1=\sqrt[4]{104.5\% \times 102.1\% \times 125.5\% \times 101.9\%}-1=8.078\ 7\%$$

即该投资者的投资年平均收益率为8.078 7%

众数、中位数和平均数的比较

- **平均数**
  - 易受极端值影响
  - 数学性质优良，实际中最常用
  - 数据对称分布或接近对称分布时代表性较好
- **中位数**
  - 不受极端值影响
  - 数据分布偏斜程度较大时代表性接好
- **众数**
  - 不受极端值影响
  - 具有不惟一性
  - 数据分布偏斜程度较大且有明显峰值时代表性较好

离散程度的度量：全距和四分位距

全距（range）

- 一组数据的最大值与最小值之差，也称极差，用R表示。计算公式为

$$R = \max(x) - \min(x)$$

例如，根据例4.1中的数据，计算30个人网购金额的全距为：$R = 678.7 - 303.6 = 375.1$

- 由于全距只是利用了一组数据两端的信息，容易受极端值的影响，不能全面反映数据的差异状况。虽然全距在实际中很少单独使用，但它总是作为分析数据离散程度的一个参考值。

四分位距（inter-quartile range）

- 是一组数据75%位置上的四分位数与25%位置上的四分位数之差，也称四分位差。用IQR表示四分位距，计算公式为：

$$IQR = Q_{75\%} - Q_{25\%}$$

- 四分位距反映了中间50%数据的离散程度。由于中位数处于数据的中间位置，因此，四分位距的大小说明了中位数对一组数据的代表程度

例如，根据例4.1计算的30个人网购金额的四分位数得，$IQR = 547.6 - 428.525元 = 119.075$。

离散程度的度量：方差和标准差

方差（variance）——原始数据

- 设样本方差为s^2，根据原始数据计算样本方差的公式为

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

- 样本标准差的计算公式为

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

方差（variance）——分组数据

- 如果原始数据被分成k组，各组的组中值分别为m_1，m_2，$\cdots$，m_k，各组的频数分别为f_1，f_2，$\cdots$，f_k，则加权样本方差的计算公式为：

$$s^2 = \frac{\sum_{i=1}^{k}(m_i - \bar{x})^2 f_i}{n-1}$$

- 加权样本标准差的计算公式为

$$s = \sqrt{\frac{\sum_{i=1}^{k}(m_i - \bar{x})^2 f_i}{n-1}}$$

方差和标准差例题分析

【例4.6】沿用例4.1。计算30个人网购金额的方差和标准差。

解：根据式（4.11）得：

$$s^2 = \frac{(429.0 - 488.95)^2 + \cdots + (625.4 - 488.95)^2}{30 - 1}$$

$$= 9529.6812$$

标准差为：$\sqrt{9529.6812} = 97.62$

【例4.7】沿用例4.2。根据表4-2的分组数据，计算网购金额的标准差

营业额分组	组中值（m_i）	人数（f_i）	$(m_i - \bar{x})^2$	$(m_i - \bar{x})^2 f$
300~350	325	2	26676.69	53353.38
350~400	375	4	12843.69	51374.76
400~450	425	6	4010.69	24064.13
450~500	475	5	177.69	888.44
500~550	525	6	1344.69	8068.13
550~600	575	2	7511.69	15023.38
600~650	625	2	18678.69	37357.38
650~700	675	3	34845.69	104537.07
合计	—	30.00	106089.51	294666.67

$$s = \sqrt{\frac{\sum_{i=1}^{k}(m_i - \bar{x})^2 f_i}{n-1}} = \sqrt{\frac{294666.67}{30-1}} = 100.80$$

离散程度的度量：离散系数

离散系数（coefficient of variation，CV）

- 也称变异系数，它是一组数据的标准差与其相应的平均数之比其计算公式为

$$CV = \frac{s}{\bar{x}}$$

- 离散系数消除了数据取值大小和计量单位对标准差的影响，因而可以反映一组数据的相对离散程度
- 离散系数大的说明数据的相对离散程度也就大，离散系数小的说明数据的相对离散程度也就大

离散系数例题分析

【例4.8】在奥运会女子10米气手枪比赛中,每个运动员首先进行每组10枪共4组的预赛,然后根据预赛总成绩确定进入决赛的8名运动员。决赛时8名运动员再进行10枪射击,将预赛成绩加上决赛成绩以确定最后的名次。在2008年8月10日举行的第29届北京奥运会女子10米气手枪决赛中,进入决赛的8名运动员的预赛成绩和最后10枪的决赛成绩如表4-5所示。评价哪名运动员的发挥更稳定

姓名	国家	预赛成绩	决赛10枪成绩（环）									
纳塔利娅·帕杰林娜	俄罗斯	391	10.0	8.5	10.0	10.2	10.6	10.5	9.8	9.7	9.5	9.3
郭文珺	中国	390	10.0	10.5	10.4	10.4	10.1	10.3	9.4	10.7	10.8	9.7
卓格巴德拉赫·蒙赫珠勒	蒙古	387	9.3	10.0	8.7	8.3	9.2	9.5	8.5	10.7	9.2	9.2
妮诺·萨卢克瓦泽	格鲁吉亚	386	9.8	10.3	10.0	9.5	10.2	10.7	10.4	10.6	9.1	10.8
维多利亚·柴卡	白俄罗斯	384	9.3	9.4	10.4	10.1	10.2	10.5	9.2	10.5	9.8	8.6
莱万多夫斯卡·萨贡	波兰	384	8.1	10.3	9.2	9.9	9.8	10.4	9.9	9.4	10.7	9.6
亚斯娜·舍卡里奇	塞尔维亚	384	10.2	9.6	9.9	9.9	9.3	9.1	9.7	10.0	9.3	9.9
米拉·内万苏	芬兰	384	8.7	9.3	9.2	10.3	9.8	10.0	9.7	9.9	9.9	9.7

离散系数例题分析

	A	B	C	D	E
1	运动员	国家	平均环数	标准差	离散系数
2	纳塔利娅·帕杰林娜	俄罗斯	9.81	0.6154	0.0627
3	郭文珺	中国	10.23	0.4373	0.0427
4	卓格巴德拉赫·蒙赫珠勒	蒙古国	9.26	0.7074	0.0764
5	妮诺·萨卢克瓦泽	格鲁吉亚	10.14	0.5461	0.0539
6	维多利亚·柴卡	白俄罗斯	9.8	0.6498	0.0663
7	莱万多夫斯卡·萨贡	波兰	9.73	0.7334	0.0754
8	亚斯娜·舍卡里奇	塞尔维亚	9.69	0.3573	0.0369
9	米拉·内万苏	芬兰	9.65	0.4625	0.0479

【例4.8】——结论

在最后10枪的决赛中,发挥比较稳定的运动员是塞尔维亚的亚斯娜·舍卡里奇和中国的郭文珺,发挥不稳定的运动员是蒙古国的卓格巴德拉赫·蒙赫珠勒和波兰的莱万多夫斯卡·萨贡

标准分数

标准分数（standard score）

- 某个数据与其平均数的离差除以标准差后的值
- 设样本数据的标准分数为z，则有

$$z_i = \frac{x_i - \bar{x}}{s}$$

- 标准分数可以测度每个数值在该组数据中相对位置，表示是某个数据与平均数相比相差多少个标准差

【例4.9】沿用例4.1。计算30个人网购金额的标准分数。

解：根据上面的计算结果，$\bar{x} = 488.95$，$s = 97.62$。以第1个人的标准分数为例，由式（4.16）得：

$$z = \frac{429.0 - 488.95}{97.62} = -0.6141$$

结果表示，第1个人的网购金额比平均网购金额低0.61412个标准差

标准分数例题分析

使用Excel【STANDARDIZE】函数可计算标准分数

第1步：将光标放在任意空白单元格。然后点击【公式】，点击插入函数【fx】。

第2步：在【选择类别】中选择【统计】，并在【选择函数】中点击【STANDARDIZE】，单击【确定】。

第3步：在【X】输入要计算标准分数的原始数据；在【Mean】框后输入该组数据的平均数；在【Standard_dev】框后输入该组数据的标准差。单击【确定】，即可得到该数据的标准分数（要得到多个数据的标准分数，向下复制该单元格即可）

网购金额	标准分数	网购金额	标准分数	网购金额	标准分数
429	-0.6141	622.4	1.367	393.2	-0.9808
477	-0.1224	536	0.482	478.2	-0.1101
655.9	1.7102	540.1	0.524	397.4	-0.9378
507.1	0.1859	511.1	0.2269	427.1	-0.6336
512.9	0.2453	465.4	-0.2412	437.5	-0.527
671.2	1.8669	678.7	1.9438	331.3	-1.6149
450	-0.399	450	-0.399	583.8	0.9716
373.5	-1.1826	303.6	-1.8987	515.3	0.2699
431.3	-0.5906	570.1	0.8313	386.2	-1.0526
455.1	-0.3468	452.7	-0.3713	625.4	1.3978

标准分数：经验法则与切比雪夫不等式

经验法则

- 当一组数据对称分布时
  - 约有68%的数据在平均数加减1个标准差的范围之内
  - 约有95%的数据在平均数加减2个标准差的范围之内
  - 约有99%的数据在平均数加减3个标准差的范围之内
- 在平均数加减3个标准差的范围内几乎包含了全部数据，而在3个标准差之外的数据在统计上也称为离群点

切比雪夫不等式(Chebyshev’s)

- 适用于数据不是对称时
- 切比雪夫不等式提供的是“下界”,也就是“所占比例至少是多少”,对于任意分布形态的数据,根据切比雪夫不等式,至少有(1-1/k2)的数据落在±k个标准差之内。其中k是大于1的任意值,但不一定是整数。对于k=2,3,4,该不等式的含义是
  - 至少有75%的数据在平均数±2个标准差的范围之内。
  - 至少有89%的数据在平均数±3个标准差的范围之内。
  - 至少有94%的数据在平均数±4个标准差的范围之内。

分布形状度量：偏度系数

偏度系数（coefficient of skewness）

- **偏度（skewness）是指数据分布的不对称性**
- 由统计学家K . Pearson于1895年首次提出
- 测度数据分布不对称性的统计量称为，记为SK
- 据原始数据计算偏度系数时，通常采用下面的公式：

$$SK = \frac{n}{(n-1)(n-2)} \sum \left(\frac{x - \bar{x}}{s} \right)^3$$

- **当数据对称分布时，偏度系数等于0。偏度系数越接近0，偏斜程度就越低，就越接近对称分布。如果偏度系数明显不同于0，表示分布是非对称的。若偏度系数大于1或小于-1，视为严重偏斜分布；若偏度系数在$0.5 \sim 1$或$-0.5 \sim -1$之间，视为是中等偏斜分布；偏度系数小于0.5或大于-0.5时，视为轻微偏斜。其中负值表示左偏分布（在分布的左侧有长尾），正值则表示右偏分布（在分布的右侧有长尾）**

分布形状度量：峰度系数

峰度系数（coefficient of kurtosis）

- **峰度（kurtosis）是指数据分布峰值的高低**
- 由统计学家K.Pearson于1905年首次提出
- 测度一组数据分布峰值高低的统计量称为，记作K
- 据原始数据计算峰度系数时，通常采用下面的公式

$$K = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum \left(\frac{x_i - \bar{x}}{s}\right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)}$$

- **峰度通常是与标准正态分布相比较而言**
- **由于标准正态分布的峰度系数为0，当K > 0时为尖峰分布，数据分布的峰值比标准正态分布高，数据相对集中；当K < 0时为扁平分布，数据分布的峰值比标准正态分布低，数据相对分散**

偏度与峰度系数例题分析

【例4.10】沿用例4.1。计算30个人网购金额的偏度系数和峰度系数。

解：根据式（4.17）得偏度系数为

$$SK = \frac{30}{(30-1)(30-2)}\sum\left(\frac{x_i - 488.95}{97.62}\right)^3 = \frac{30}{(30-1)(30-2)} \times 9.217966 = 0.3406$$

结果表示，网购金额为轻微的右偏

根据式（4.18）得峰度系数为

$$K = \frac{30(30+1)}{(30-1)(30-2)(30-3)}\sum\left(\frac{x_i - 488.95}{97.62}\right)^4 - \frac{3(30-1)^2}{(30-2)(30-3)} = -0.4075$$

04 小结及作业

数据的图表展示

- 数据的预处理
  - 数据审核、筛选、排序
- 分类数据的整理与展示
  - 频数
  - 条形图、帕累托图
  - 饼图、环形图
- 数值数据的整理与展示
  - 数据分组
  - 直方图、箱形图、散点图、雷达图

数据的概括性度量

- 集中趋势的度量
  - 简单平均数、加权平均数
  - 中位数、四分位数、众数、几何平均数
- 离散程度的度量
  - 全距、四分位距
  - 方差、标准差
  - 离散系数、标准分数
- 分布形状的度量
  - 偏度系数、峰度系数