统计学导论

（四）统计量及抽样分布

北京航空航天大学人文社会科学学院高等教育研究所

黄文

目录

01 回顾上周课程

02 连续型随机变量的概率分布

03 统计量及抽样分布

04 小结

01 回顾上周课程

随机事件及其概率

- 基本概念
  - 试验
  - 随机/必然/不可能事件
  - 基本事件/样本空间
- 事件的概率
  - 古典/统计定义
  - 主观概率定义
  - 概率计算例子

离散型随机变量及其分布

- 随机变量的概念
  - 离散型/连续型
- 离散型随机变量的概率分布
  - 0-1分布
  - 均匀分布
- 离散型随机变量的期望值和方差
- 几种常见的离散型概率分布
  - 二项分布
  - 泊松分布

泊松概率分布函数

$$\boxed{P\{X = x\} = \frac{\lambda^x e^{-\lambda}}{x!}} \qquad (x = 0,1,2,\cdots,n)$$

λ— 给定的时间间隔、长度、面积、体积内“成功”的平均数

e = 2.71828

x—给定的时间间隔、长度、面积、体积内“成功”的次数

- 当试验的次数 n 很大，成功的概率 p 很小时，可用泊松分布来近似地计算二项分布的概率 不用细究。

03 连续型随机变量的概率分布

连续型随机变量的概率分布

连续型随机变量的概率分布

1. 连续型随机变量可以取某一区间或整个实数轴上的任意一个值
2. 它取任何一个特定的值的概率都等于0
3. 不能列出每一个值及其相应的概率
4. 通常研究它取某一区间值的概率
5. 用数学函数的形式和分布函数的形式来描述

概率密度函数(probability density function)

1. 设X为一连续型随机变量，x 为任意实数，X的概率密度函数记为$f(x)$，它满足条件

$$(1) f(x) \geq 0$$

$$(2) \int_{-\infty}^{+\infty} f(x)\mathrm{d}x = 1$$

2. $f(x)$不是概率

分布函数 (distribution function)

1. 连续型随机变量的概率也可以用分布函数 $F(x)$来表示
2. 分布函数定义为

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\mathrm{d}t \qquad (-\infty < x < +\infty)$$

3. 根据分布函数，$P(a<X<b)$可以写为

$$P(a < X < b) = \int_{a}^{b} f(x)\mathrm{d}x = F(b) - F(a)$$

连续型随机变量的期望和方差

1. 连续型随机变量的数学期望为

$$E(X) = \int_{-\infty}^{+\infty} x f(x) \mathrm{d}x = \mu$$

2. 方差为

$$D(X) = \int_{-\infty}^{+\infty} [x - E(X)] f(x) \mathrm{d}x = \sigma^2$$

正态分布

正态分布(normal distribution)

1. 描述连续型随机变量的最重要的分布
2. 可用于近似离散型随机变量的分布
3. 经典统计推断的基础

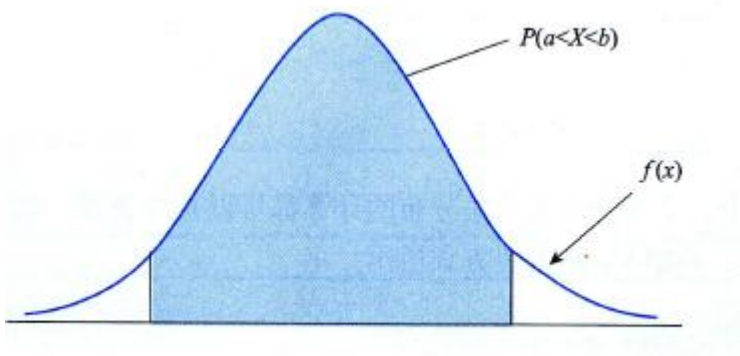

图 5－3　概率 $P(a<X<b)$

7. AI让我对学习更有好奇心。 [单选题]

选项	小计	比例
强烈不同意	0	0%
不同意	9	14.75%
中立	31	50.82%
同意	14	22.95%
强烈同意	7	11.48%
本题有效填写人次	**61**	

概率密度函数

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}}\, e^{-\frac{1}{2\sigma^2}(x-\mu)^2} \quad , \quad -\infty < x < +\infty$$

$f(x)$ = 随机变量 X 的频数

σ^2 = 总体方差

π =3.14159; e = 2.71828

x = 随机变量的取值 ($-\infty < x < +\infty$)

μ = 总体均值

正态分布函数的性质

1. 概率密度函数在x的上方，即$f(x)>0$
2. 正态曲线的最高点在均值μ，它也是分布的中位数和众数
3. 正态分布是一个分布族，每一特定正态分布通过均值μ和标准差σ来区分。 μ 决定了图形的中心位置，σ决定曲线的平缓程度，即宽度
4. 曲线$f(x)$相对于均值μ对称，尾端向两个方向无限延伸，且理论上永远不会与横轴相交
5. 正态曲线下的总面积等于1
6. 随机变量的概率由曲线下的面积给出

标准正态分布(standard normal distribution)

1. 一般的正态分布取决于均值μ和标准差 σ
2. 计算概率时 ，每一个正态分布都需要有自己的正态概率分布表，这种表格是无穷多的
3. 若能将一般的正态分布转化为标准正态分布，计算概率时只需要查一张表

标准正态分布函数

1. 任何一个一般的正态分布，可通过下面的线性变换转化为标准正态分布

$$Z = \frac{X-\mu}{\sigma} \sim N(0,1)$$

2. 标准正态分布的概率密度函数

$$\boxed{f(x) = \frac{1}{\sigma\sqrt{2\pi}}\, \mathrm{e}^{-\frac{1}{2\sigma^2}(x-\mu)^2}} \Rightarrow \phi(x) = \frac{1}{2\pi}\, \mathrm{e}^{-\frac{x^2}{2}} \quad , \quad -\infty < x < +\infty$$

3. 标准正态分布的分布函数

$$\Phi(x) = \int_{-\infty}^{x} \phi(t)\mathrm{d}t = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} \mathrm{e}^{-\frac{t^2}{2}} \mathrm{d}t$$

标准正态分布表

参考附录二，用Excel生成概率分布表

C2 =NORM.S.DIST($A2+$C1,TRUE)

	A	B	C	D	E	F	G	H	I	J	K
1		0	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
2	0	0.5	0.503989	0.507978	0.511966	0.515953	0.519939	0.523922	0.523922	0.531881	0.535856
3	0.1										
4	0.2										
5	0.3										
6	0.4										
7	0.5										
8	0.6										
9	0.7										
10	0.8										
11	0.9										
12	1										
13											

例题：考试成绩分析

某次考试成绩服从正态分布，平均分μ=80，标准差σ=12。求成绩在68分到95分之间的概率。

解：P(68<X<95)= $\mathbf{P}\left(\frac{68-80}{12} < \frac{X-80}{12} < \frac{95-80}{12}\right)$

$=\mathbf{P}\left(-1.0 < \frac{X-80}{12} < 1.25\right)$

$= \boldsymbol{\phi}(1.25) - \boldsymbol{\phi}(-1.0)$

$= \boldsymbol{\phi}(1.25) - [1 - \boldsymbol{\phi}(1.0)]$

$= \boldsymbol{\phi}(1.25) + \boldsymbol{\phi}(1.0) - 1$

$= 0.7357$ (73.57%)

	A	B	C	D	E	F	G	H
1	**x**	**0.00**	**0.01**	**0.02**	**0.03**	**0.04**	**0.05**	**0.06**
2	**0.0**	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239
3	**0.1**	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636
4	**0.2**	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026
5	**0.3**	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406
6	**0.4**	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772
7	**0.5**	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123
8	**0.6**	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454
9	**0.7**	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764
10	**0.8**	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051
11	**0.9**	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315
12	**1.0**	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554
13	**1.1**	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770
14	**1.2**	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962
15	**1.3**	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131
16	**1.4**	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279
17	**1.5**	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406

04 统计量及抽样分布

统计量

统计量

1. 设$X_1,X_2,\ldots,X_n$是从总体X中抽取的容量为n的一个样本，如果由此样本构造一个函数$T(X_1,X_2,\ldots,X_n)$，不依赖于任何未知参数，则称函数$T(X_1,X_2,\ldots,X_n)$是一个统计量
   - 样本均值、样本比例、样本方差等都是统计量
2. 统计量是样本的一个函数
3. 统计量是统计推断的基础

常用统计量：

$$\overline{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$$ 是样本均值

$$S^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\overline{X})^2$$ 是样本方差

$V=S/\overline{X}$ 是样本变异系数

$$\alpha_3=\sqrt{n-1}\sum_{i=1}^{n}(X_i-\overline{X})^3/\left(\sum_{i=1}^{n}(X_i-\overline{X})^2\right)^{3/2}$$，称 α_3 为样本偏度

$$\alpha_4=(n-1)\sum_{i=1}^{n}(X_i-\overline{X})^4/\left[\sum_{i=1}^{n}(X_i-\overline{X})^2\right]^2-3$$，称 α_4 为样本峰度

正态抽样分布

抽样分布 (sampling distribution)

1. 样本统计量的概率分布，是一种理论分布
   - 在重复选取容量为n的样本时，由该统计量的所有可能取值形成的相对频数分布
2. 随机变量是 **样本统计量**
   - 样本均值, 样本比例，样本方差等
3. 结果来自**容量相同**的**所有**可能样本
4. 提供了样本统计量长远而稳定的信息，是进行推断的理论基础，也是抽样推断科学性的重要依据

χ2分布

只能取正值，并且是右偏态的
形状取决于自由度（df）
随着自由度的增加，分布的范围扩大并向右偏移并逐渐趋于对称

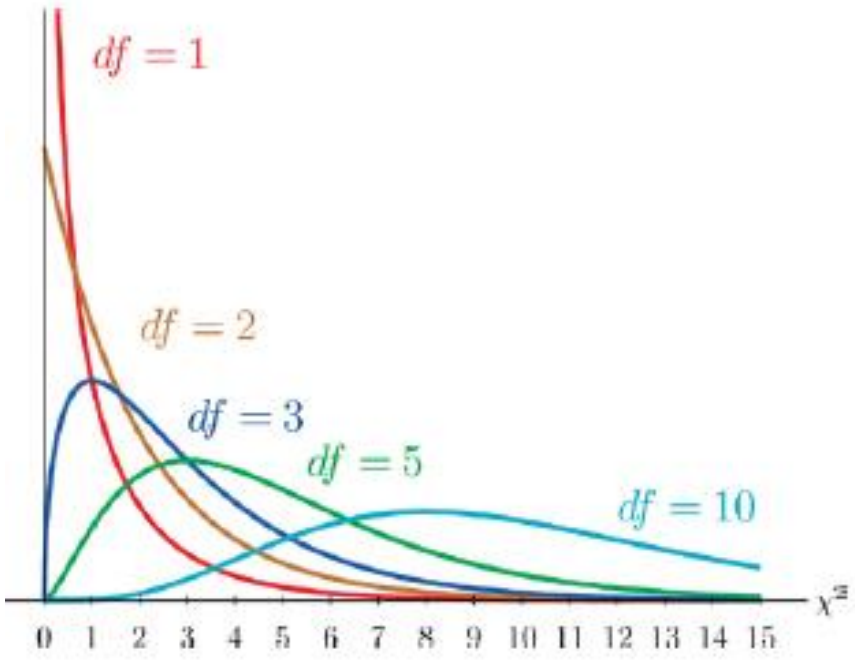

设 $X_1, X_2, \ldots, X_n$ 是来自标准正态总体 $N(0,1)$ 的独立同分布样本，则统计量： $Q = \sum_{i=1}^{n} X_i^2$

服从自由度为 n 的卡方分布，记作 $Q \sim \chi^2(n)$。

设 $X_1, X_2, \ldots, X_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的样本，样本均值为 $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$，则统计量：$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^{n} \left(\frac{X_i - \bar{X}}{\sigma}\right)^2 \sim \chi^2(n-1)$

其中 $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$ 为样本方差。

χ2分布

1. 期望为：$E(\chi^2)=n$，方差为：$D(\chi^2)=2n$(n为自由度)
2. 可加性：若U和V为两个独立的χ^2分布随机变量，$U\sim\chi^2(n_1)$，$V\sim\chi^2(n_2)$,则$U+V$这一随机变量服从自由度为n_1+n_2的χ^2分布
3. 用于评估变量与特定分布的拟合程度以及评估两个（分类）变量的独立性。

t分布

对称的，μ = 0，在总体标准差 σ 未知时替代正态分布

用于很多方面，包括确定两组的平均值在统计学上是否相同（即 t 检验）

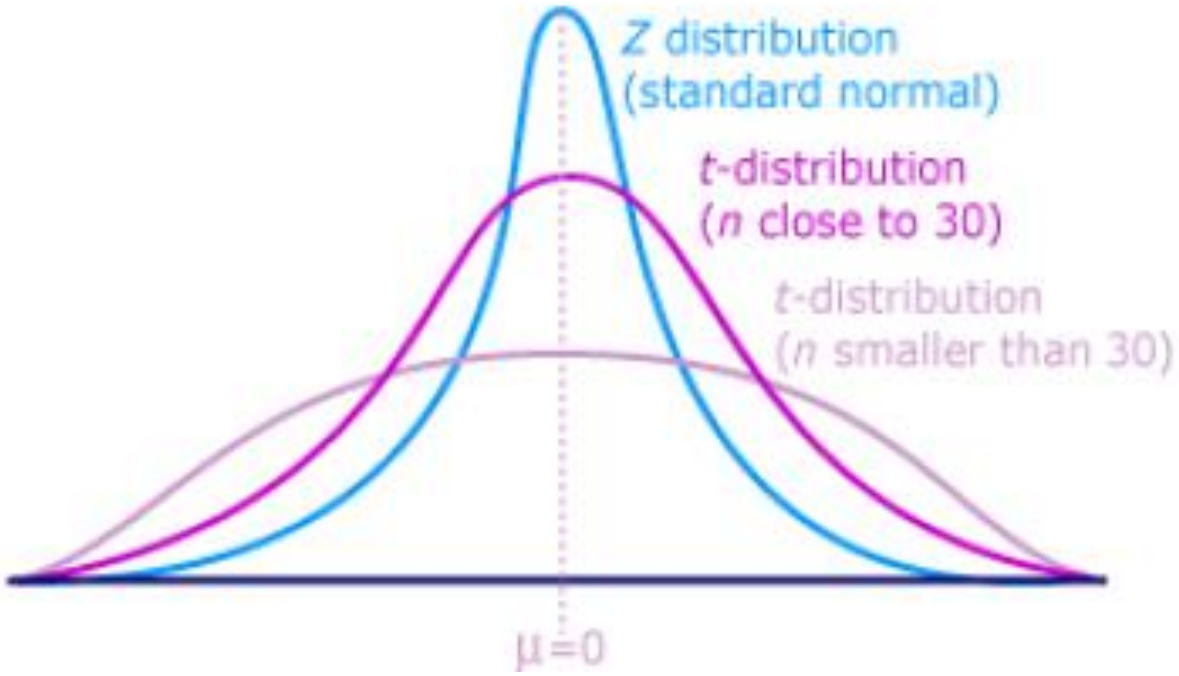

设样本均值为 $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ ，

样本标准差为 $S = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2}$ ，

则统计量 $T = \frac{\bar{X}-\mu}{S/\sqrt{n}}$ 服从自由度为 $n-1$ 的 t 分布，其中 μ 为总体均值。

t分布：自由度

1. 自由度反映了在满足一定约束条件下，数据点能够独立变化的“自由”程度。
2. 如果一组数据没有受到任何约束或限制，那么每个数据点都可以自由变化，此时自由度通常等于数据点数量n。但在实际统计分析中，数据往往受到各种约束，如总和固定、均值已知等。
3. 形状取决于自由度（df），而自由度是数据点数量 n 的函数。最常见的情况是 df = n - 1 。它通常要比正态分布平坦和分散。
4. 一个特定的分布依赖于称之为自由度的参数。随着自由度的增大，分布也逐渐趋于正态分布

F分布

设 $U \sim \chi^2(d_1)$ 和 $V \sim \chi^2(d_2)$ 是两个独立的卡方分布随机变量，自由度分别为 d_1 和 d_2。则统计量：

$$F = \frac{U/d_1}{V/d_2}$$

服从自由度为 (d_1, d_2) 的F分布，记作 $F \sim F(d_1, d_2)$。

核心作用：通过比较组间变异与组内变异，检验总体均值或方差的差异。

应用场景：方差分析、回归分析、方差齐性检验等。

样本均值的分布与中心极限定理

当总体分布为正态分布N(μ,σ^2) 时，X的抽样分布仍为正态分布，样本均值的数学期望为μ，方差为σ^2/n,则

$$\overline{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

中心极限定理：设从均值为μ、方差为σ^2 的任意一个总体中抽取样本量为n的样本，当n充分大时，样本均值的抽样分布近似服从均值为μ，方差为σ^2/n的正态分布。

例题

设从一个均值μ=10，标准差σ=0.6的总体中随机选取容量n=36的样本。假定该总体部署很偏，计算样本均值小于9.9的近似概率。

解：根据中心极限定理，不论总体的分布是什么形状，在假定总体分布不是很偏的情况下，当从总体中随机选取n=36的样本时，样本均值近似服从均值为$\mu_{\bar{X}}$=10，标准差$\sigma_{\bar{X}}=\frac{\sigma}{\sqrt{n}}$= 0.1的正态分布，即 $\bar{X}\sim N(10,\ 0.1^2)$

$$
\begin{aligned}
P(\bar{X}<9.9) &= P\left(\frac{\bar{X}-10}{0.1}<\frac{9.9-10}{0.1}\right) \\
&= P\left(Z<\frac{-0.1}{0.1}\right)=P(Z<-1) \\
&= 1-P(Z<1)=1-\Phi(1) \\
&=1-0.8413 \\
&=0.1587
\end{aligned}
$$

	A	B	C	D	E	F
1		0	0.01	0.02	0.03	0.04
2	0	0.5	0.503989	0.507978	0.511966	0.515953
3	0.1					
4	0.2					
5	0.3					
6	0.4					
7	0.5					
8	0.6					
9	0.7					
10	0.8					
11	0.9					
12	1	0.841345				
13						

04 小结

连续型随机变量的概率分布

- 概率密度与分布函数
- 正态分布
  - 正态分布定义及图形特点
  - 标准正态分布
  - 标准正态分布表

统计量及其抽样分布

- 统计量
  - （样本）统计量的概念
  - 常用统计量
- 由正态分布导出的几个重要分布
  - χ2分布
  - t分布
  - F分布
- 样本均值分布与中心极限定理